

Министерство образования и науки Российской Федерации
Московский физико-технический институт (национальный
исследовательский университет)

Физтех-школа прикладной математики и информатики
Кафедра проблем передачи информации и анализа данных

Выпускная квалификационная работа магистра по направлению 09.04.01
«Информатика и вычислительная техника »

Исследование глобальных квазиньютоновских методов оптимизации для задач математического программирования

Студент М05-404а группы
Можаев Р. М.

Научный руководитель
Камзолов Д. И.

Долгопрудный
2026

Содержание

Аннотация	4
Список обозначений	5
Базовые объекты	5
Квазиньютоновские обновления	5
SP-Broyden и SS-U	6
Соглашения	6
Введение	8
Актуальность темы	8
Объект и предмет исследования	8
Цель и задачи работы	9
Научная новизна	10
Теоретическая и практическая значимость	10
Положения, выносимые на защиту	10
Методология и методы исследования	11
Степень достоверности и апробация результатов	11
Структура и объём работы	11
1. Приближение якобиана	13
1.1. Постановка задачи	13
1.2. Общая формула: m секущих условий	13
1.3. Частный случай: $m = 1$	14
1.4. Роль V_m : что минимизирует обновление	14
1.4.1. $V_m = S_m$: минимум нормы Фробениуса при m секущих условиях	14
1.4.2. $m = 1, v_k = s_k$: минимум нормы Фробениуса при 1 секущем условии	15
1.4.3. $m = 1, v_k = y_k$: другое ранг-1 обновление	15
1.4.4. $m = 1$, другие v_k : класс Бройдена для $F(x) = 0$	15
1.5. Роль базовой матрицы $\hat{B}_k$	15
1.5.1. $\hat{B}_k = B_k$: накопление	15
1.5.2. $\hat{B}_k = B_0$: пересборка	16

1.6. Разрушение текущих условий при ранг-1 обновлении	16
2. Алгоритм SP-Broyden	17
2.1. Минимальность SP-обновления	21
2.2. Качество аппроксимации якобиана	22
2.3. Глобализация квазиньютоновских методов	28
2.4. Limited-memory: Шерман–Моррисон и L-SP-Broyden	30
2.5. Численные эксперименты	33
3. Симметричные квазиньютоновские обновления с контролем текущих условий	36
3.1. Мотивация	36
3.2. Конструкция и алгоритм $SS-\mathcal{U}$	37
3.3. Свойства	40
3.4. Сверхлинейная сходимость	41
3.5. Численные результаты	43
Заключение	48
Основные результаты работы	48
Связь результатов	49
Направления дальнейших исследований	50
Литература	51

Аннотация

Работа строит семейство квазиньютоновских обновлений, сохраняющих прошлые секущие условия, и применяет их к нелинейным системам и гладкой оптимизации.

Цель — построить и обосновать ранг-1 обновление, точно сохраняющее p прошлых секущих условий. **Задачи:** получить общую параметризацию мультисекантных обновлений якобиана; построить алгоритм SP-Broyden; перенести идею на симметричные методы.

Результаты: теорема минимальности SP-Broyden и теорема об ограниченной деградации с проектором ранга $p+1$ (вместо ранга 1 у классического Бройдена); для симметричного случая — обновление SS-U со сверхлинейной сходимостью по Dennis–More и расширением бассейна сходимости SR1 в 1,5–2 раза на Curved Valley. Результаты подтверждены численно на задачах Discrete BVP, Broyden Banded и Curved Valley.

Рекомендации. SP-Broyden пригоден как замена классического Бройдена в задачах с дорогим якобианом; SS-SR1 — для оптимизации в зонах быстрого вращения градиента.

Ключевые слова: квазиньютоновские методы, мультисекантный Бройден, SR1, ограниченная деградация, сверхлинейная сходимость.

Список обозначений

Базовые объекты

F	нелинейное отображение $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$ в задаче $F(x) = 0$ (главы 1, 2) или градиент $F = \nabla f$ задачи оптимизации (глава 3)
f	скалярная целевая функция $f: \mathbb{R}^n \rightarrow \mathbb{R}$ в оптимизации
$J(x)$	якобиан F в точке x ; в задаче оптимизации — гессиан $\nabla^2 f(x)$
J^*	якобиан в решении: $J^* = J(x^*) = \nabla F(x^*)$ (единое обозначение во всех главах; макрос <code>\Jstar</code>)
x^*	решение: $F(x^*) = 0$

Квазиньютоновские обновления

x_k	текущая итерация алгоритма
s_k	шаг: $s_k = x_{k+1} - x_k$
y_k	разность значений: $y_k = F(x_{k+1}) - F(x_k)$
d_k	направление поиска: $B_k d_k = -F(x_k)$
B_k	текущая аппроксимация якобиана
$\hat{B}_k$	базовая матрица в формуле обновления (накопление: $\hat{B}_k = B_k$; пересборка: $\hat{B}_k = \tilde{B}$, обычно I)
$\tilde{B}$	опорная (входная) матрица алгоритма SP-Broyden, параметр функции; точка сброса при пересборке. Не имеет итерационного индекса и не зависит от k
Δ_k	изменение матрицы: $\Delta_k = B_{k+1} - \hat{B}_k$

S_m, Y_m, V_m матрицы прошлых шагов, разностей и направлений обновления в общей мультисекущей формуле (3); V_m (m — ранг обновления) параметризует семейство

E_k ошибка аппроксимации якобиана: $E_k = B_k - J^*$

SP-Broyden и SS-U

m ранг мультисекущего обновления в общей формуле главы 1 (m секущих условий $B_{k+1}S_m = Y_m$); используется только в главе 1

p глубина сохраняемых *прошлых* секущих условий в SP-Broyden и его вариантах (главы 2, 3); число столбцов окна на одну больше, чем p — $S_p \in \mathbb{R}^{n \times (p+1)}$ за счёт включения текущей секущей s_k

S_p, Y_p окно текущего и p прошлых шагов и разностей, $S_p = [s_k \mid s_{k-1} \mid \cdots \mid s_{k-p}] \in \mathbb{R}^{n \times (p+1)}$

G_p грамиан окна: $G_p = S_p^\top S_p$

v_k^* оптимальный SP-вектор: $v_k^* = S_p G_p^{-1} e_1$

Π_k ортогональный проектор на $\text{col}(S_p)$: $\Pi_k = S_p G_p^{-1} S_p^\top$; $\Pi_k^\perp = I - \Pi_k$

τ порог числа обусловленности грамиана (адаптивный выбор глубины p)

$\mathcal{C}_k$ класс задач $\mathcal{Q}(L, \kappa, m)$: L -липшицев якобиан, κ -обусловленность, память глубины m

u_k^* ведущий собственный вектор коррекции SS-U (в $s_k^\perp$)

σ_k^* коэффициент ранг-1 коррекции SS-U

$\mathcal{U}$ базовое симметричное квазиньютоновское обновление (SR1, BFGS, PSB и т. п.) в конструкции SS-U

Соглашения

- Индекс k нумерует итерации алгоритма; индексы внутри окна пробегают $j = k - p, \dots, k$.
- $\mathbb{R}^n$ — пространство вещественных n -мерных векторов; I — единичная матрица подходящей размерности; $e_1 = (1, 0, \dots, 0)^\top$ — первый базисный вектор.

- Стандартная линейно-алгебраическая нотация (tr , rank , col , diag , $\cdot^\dagger$, $\sigma_{\min/\max}$, $\lambda_{\min/\max}$) используется в общепринятом значении.
- Если контекст не указан явно, все нормы матриц — фробениусовы ($\|\cdot\|_F$), все нормы векторов — евклидовы ($\|\cdot\|$).
- Константы обозначаются прописными латинскими буквами (L , C_d); параметры алгоритма — строчными греческими (τ , $\bar{\rho}$); индексы k указывают итерационную зависимость.

Введение

Актуальность темы

Квазиньютоновские методы занимают центральное место в вычислительной оптимизации с момента работы Broyden (1965) [1] и последующих классических работ Dennis и More [3, 4]. Они позволяют получить сверхлинейную скорость сходимости без вычисления якобиана (или гессиана), что особенно важно для задач, в которых явное дифференцирование дорого или недоступно: крупномасштабных систем уравнений, задач обучения нейронных сетей, равновесных и экономических моделей.

Классические алгоритмы Broyden, SR1 и BFGS на геометрически сложных ландшафтах (изогнутые долины, овраги, неквадратичные сильно нелинейные функции) демонстрируют резкое сужение бассейна сходимости и неустойчивую работу, хотя теория гарантирует сверхлинейность в локальном режиме. Практический разрыв между теорией и поведением классических методов на типичных задачах остаётся открытой проблемой.

Причина этой трудности — ранг-1 структура обновления Бройдена и сохранение лишь одного текущего условия на итерации: при ранг-1 обновлении из p прошлых текущих условий сохраняется только одно — текущее, а остальные нарушаются. Накопленные ошибки проектируются на «недоконтролируемые» направления и приводят к сужению бассейна сходимости. Это мотивирует поиск таких обновлений, которые *сохраняют прошлые текущие условия* и, как следствие, дают структурно более информативное разложение ограниченной деградации (с расширенным проектором ранга $p+1$ вместо ранга 1) — как для нелинейных систем, так и для гладкой оптимизации.

Объект и предмет исследования

Объект исследования — численные методы решения двух взаимосвязанных классов задач: нелинейных систем уравнений $F(x) = 0$ и безусловной гладкой оптимизации $\min_{x \in \mathbb{R}^n} f(x)$.

Предмет исследования — глобальные квазиньютоновские обновления приближённого якобиана B_k , сохраняющие на каждой итерации p прошлых секущих условий $B_{k+1}s_j = y_j$, $j = k-p, \dots, k$, и порождающие расширенный (ранг $p+1$) проектор bounded deterioration; в частности, ранг-1 обновление SP-Broyden для нелинейных систем и его симметричный аналог SS-U для оптимизации.

Цель и задачи работы

Цель работы: построить и теоретически обосновать семейство квазиньютоновских обновлений, сохраняющих прошлые секущие условия, и применить полученные алгоритмы к задачам нелинейных систем и гладкой оптимизации.

Задачи:

1. Получить общее семейство мультисекантных обновлений якобиана, параметризованное базовой матрицей и матрицей направлений, и охарактеризовать внутри него ранг-1 обновления, сохраняющие фиксированный набор прошлых секущих условий.
2. Построить алгоритм SP-Broyden для нелинейных систем: выбор направления обновления, адаптивное управление глубиной окна по числу обусловленности грамиана, процедура обновления.
3. Доказать для SP-Broyden теорему об ограниченной деградации с расширенным проектором: точное разложение $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k\Pi_k\|_F^2 + \Delta_k$ с проектором Π_k ранга $p+1$ (у классического Бройдена — ранга 1) и доказать, что отрицательный член $\|E_k\Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$ снимает с матрицы ошибки на каждой итерации не меньше информации, чем у классического Бройдена.
4. Перенести идею сохранения прошлых секущих условий на симметричные методы (SR1, BFGS, PSB): доказать несовместность одновременного выполнения всех требований, построить секантно-стабилизированные обновления SS-U с коррекцией в ортогональном дополнении $s_k^\perp$, исследовать сверхлинейность и расширение бассейна сходимости на модельных задачах.
5. Подтвердить теоретические результаты численными экспериментами на стандартных тестовых задачах: Discrete Boundary Value Problem, Broyden Banded и Curved Valley.

Научная новизна

1. Предложено и исследовано семейство обновлений SP-Broyden — ранг-1 минимальное обновление, сохраняющее p прошлых секущих условий $B_{k+1}s_j = y_j$, $j = k-p, \dots, k-1$. Для него получено *точное разложение* bounded deterioration $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$ с проектором Π_k ранга $p+1$ (вместо ранга 1 у классического Бройдена) и оценкой прироста $\Delta_k = O(L^2 \sigma_{\min}^{-2}(S_p) \cdot \sum_j \|x_j - x^*\|^2 \|s_j\|^2)$. Доказано строгое неравенство $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$: отрицательный член снимает с матрицы ошибки на каждой итерации *не меньше* информации, чем классический Бройден, а в типичной ситуации — строго больше.
2. Для симметричного случая доказана теорема о несовместности одновременного сохранения всех секущих условий с симметрией и предложена конструкция SS-U — ранг-1 коррекция в $s_k^\perp$, не нарушающая ни текущего секущего условия, ни симметрии. Установлена сверхлинейность SS-U по Dennis–More и численно продемонстрировано расширение бассейна сходимости по сравнению с SR1.

Теоретическая и практическая значимость

Теоретическая значимость. Работа даёт единый язык для анализа квазиньютоновских обновлений с памятью прошлых секущих условий и связывает понятия *мультисекантной памяти* и *ограниченной деградации*. В частности, показано, что геометрическая структура bounded deterioration — ранг проектора Π_k и набор сохраняемых секущих условий — не деталь анализа, а фактор, на каждой итерации снимающий с матрицы ошибки не меньше информации, чем классический Бройден.

Практическая значимость. Предложенные алгоритмы SP-Broyden и SS-SR1 реализованы на Python и доступны в виде библиотеки. На численных тестах SP-Broyden ускоряет решение Discrete BVP ($n=100$) в 2,4 раза по сравнению с классическим Broyden; SS-SR1 сходится там, где SR1 стагнирует или расходится, и расширяет бассейн сходимости в 1,5–2 раза на семействе Curved Valley.

Положения, выносимые на защиту

1. Общая параметризация $B_{k+1} = \hat{B}_k + (Y_m - \hat{B}_k S_m)(V_m^\top S_m)^{-1} V_m^\top$ ранг- m обновлений якобиана и её специализация к ранг-1 обновлениям, сохраняющим p прошлых секущих условий.
2. Теорема минимальности обновления SP-Broyden: единственное решение задачи минимизации нормы Фробениуса при $(p+1)$ секущих условиях (см. теорему 2.7).

3. Теорема об ограниченной деградации с расширенным проектором для SP-Broyden (см. теорему 2.11): точное разложение ошибки $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$ с проектором Π_k ранга $p+1$ (у классического Бройдена — ранга 1) и строгое неравенство $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$.
4. Теорема о несовместности симметричных мультисекантных обновлений (см. теорему 3.1) и конструкция SS-U как разрешение этой несовместности через коррекцию в $s_k^\perp$.
5. Численная верификация всех теоретических результатов на стандартных тестовых задачах (Discrete BVP, Broyden Banded, Curved Valley).

Методология и методы исследования

В работе используются методы вычислительной линейной алгебры (разложения QR и SVD, теория проекторов, оценки чисел обусловленности грамиана) и классической теории квазиньютоновских методов (свойства обновлений ранга 1 и 2, критерий сверхлинейности Dennis–More [3]). Численные эксперименты проведены в Python с использованием NumPy; задачи взяты из стандартного тестового набора [9].

Степень достоверности и апробация результатов

Все теоретические результаты снабжены полными доказательствами. Утверждения о скорости сходимости подтверждены численными экспериментами на стандартных тестовых задачах с единым критерием остановки. Исходный код экспериментов, исходные тексты диссертации и скрипты построения всех представленных рисунков открыты и доступны в публичном репозитории SP-Broyden.¹

Структура и объём работы

Работа состоит из введения, трёх глав, заключения и списка литературы.

- В **главе 1** («Приближение якобиана») вводится язык квазиньютоновских обновлений и формулируется общее семейство мультисекантных обновлений. Анализируется выбор матрицы направлений V_m и базовой матрицы $\hat{B}_k$.

¹<https://github.com/mojaevr/secant-conditions>. Версия, зафиксированная на момент защиты, — тег master-thesis-2026; команда сборки PDF и список основных скриптов (diag_ndim_stat.py, diag_jacerr_stat.py, diag_highdim_stat.py) приведены в README.md.

- В **главе 2** («Алгоритм SP-Broyden», см. главу [2](#)) строится обновление SP-Broyden, доказываются теоремы минимальности и ограниченной деградации, описывается адаптивный выбор глубины p и приводятся численные эксперименты для нелинейных систем.
- В **главе 3** идея сохранения прошлых текущих условий переносится на симметричные методы. Строится SS-U и его частный случай SS-SR1, доказываются сверхлинейная сходимость, исследуется расширение бассейна сходимости на семействе Curved Valley.

Глава 1

Приближение якобиана

1.1 Постановка задачи

Рассмотрим задачу решения нелинейной системы

$$F(x) = 0, \quad F: \mathbb{R}^n \rightarrow \mathbb{R}^n. \quad (1)$$

Квазиньютоновские методы строят последовательность $\{x_k\}$ по правилу

$$x_{k+1} = x_k + d_k, \quad B_k d_k = -F(x_k), \quad (2)$$

где $B_k \in \mathbb{R}^{n \times n}$ — аппроксимация якобиана $J(x_k) = F'(x_k)$.

Обозначим

$$s_k = x_{k+1} - x_k = d_k, \quad y_k = F(x_{k+1}) - F(x_k).$$

1.2 Общая формула: m секущих условий

Рассмотрим задачу обновления аппроксимации якобиана B_k при решении $F(x) = 0$, $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$. Обозначим $s_k = x_{k+1} - x_k$, $y_k = F(x_{k+1}) - F(x_k)$.

Пусть заданы m секущих условий: $B_{k+1} S_m = Y_m$, где

$$S_m = [s_{k-m+1} \mid \cdots \mid s_k] \in \mathbb{R}^{n \times m}, \quad Y_m = [y_{k-m+1} \mid \cdots \mid y_k] \in \mathbb{R}^{n \times m}.$$

Семейство обновлений, удовлетворяющих всем m секущим условиям:

$$\boxed{B_{k+1} = \widehat{B}_k + (Y_m - \widehat{B}_k S_m) (V_m^\top S_m)^{-1} V_m^\top} \quad (3)$$

где $\widehat{B}_k \in \mathbb{R}^{n \times n}$ — базовая матрица, $V_m \in \mathbb{R}^{n \times m}$ — матрица направлений ($V_m^\top S_m$ невырождена).

Проверка: $B_{k+1}S_m = \widehat{B}_k S_m + (Y_m - \widehat{B}_k S_m)(V_m^\top S_m)^{-1}V_m^\top S_m = \widehat{B}_k S_m + (Y_m - \widehat{B}_k S_m) = Y_m$. Условия выполнены при *любом* допустимом V_m .

Обновление $\Delta_k = B_{k+1} - \widehat{B}_k$ имеет ранг $\leq m$ (произведение $n \times m$ и $m \times n$ матриц).

1.3 Частный случай: $m = 1$

При $m = 1$ имеем $S_m = s_k$, $Y_m = y_k$, $V_m = v_k \in \mathbb{R}^n$, и формула (3) принимает вид:

$$B_{k+1} = \widehat{B}_k + \frac{(y_k - \widehat{B}_k s_k) v_k^\top}{v_k^\top s_k}. \quad (4)$$

Это ранг-1 обновление, удовлетворяющее единственному секущему условию $B_{k+1} s_k = y_k$.

При дополнительном ограничении $v_k^\top s_k = 1$ знаменатель исчезает:

$$B_{k+1} = \widehat{B}_k + (y_k - \widehat{B}_k s_k) v_k^\top. \quad (5)$$

1.4 Роль V_m : что минимизирует обновление

Выбор V_m при фиксированных $\widehat{B}_k$, S_m , Y_m определяет *форму* обновления Δ_k . Различные V_m удовлетворяют одним и тем же секущим условиям, но отличаются по норме изменения $\|\Delta_k\|_F = \|B_{k+1} - \widehat{B}_k\|_F$.

1.4.1 $V_m = S_m$: минимум нормы Фробениуса при m секущих условиях

Обновление принимает вид:

$$B_{k+1} = \widehat{B}_k + (Y_m - \widehat{B}_k S_m) (S_m^\top S_m)^{-1} S_m^\top. \quad (6)$$

Это **единственное** решение задачи $\min_B \|B - \widehat{B}_k\|_F$ при $B S_m = Y_m$ (проекция $\widehat{B}_k$ на аффинное подпространство, задаваемое секущими условиями, по норме Фробениуса; строгая выпуклость гарантирует единственность).

Ранг обновления $\leq m$. При большом m это может быть существенно: обновление ранга m требует $O(nm)$ операций на хранение и $O(n^2 m)$ на применение, что при $m \gg 1$ дороже ранг-1 обновления.

1.4.2 $m = 1$, $v_k = s_k$: минимум нормы Фробениуса при 1 секущем условии

Частный случай предыдущего при $m = 1$:

$$B_{k+1} = \hat{B}_k + \frac{(y_k - \hat{B}_k s_k) s_k^\top}{\|s_k\|^2}. \quad (7)$$

Это решение $\min_B \|B - \hat{B}_k\|_F$ при $B s_k = y_k$. При $\hat{B}_k = B_k$ — классический **метод Бройдена** (“good Broyden”, 1965).

Ранг 1, затраты $O(n^2)$ на шаг.

1.4.3 $m = 1$, $v_k = y_k$: другое ранг-1 обновление

$$B_{k+1} = \hat{B}_k + \frac{(y_k - \hat{B}_k s_k) y_k^\top}{y_k^\top s_k}. \quad (8)$$

Удовлетворяет секущему условию, но **не минимизирует** $\|B_{k+1} - \hat{B}_k\|_F$. Связано со **вторым методом Бройдена** (“bad Broyden”, 1965): формула (8) для прямого якобиана B_k соответствует минимуму $\|H_{k+1} - H_k\|_F$ при $H_{k+1} y_k = s_k$ для обратного якобиана $H_k \approx J^{-1}$ (Dennis, Schnabel, 1996).

1.4.4 $m = 1$, другие v_k : класс Бройдена для $F(x) = 0$

Любой вектор v_k с $v_k^\top s_k \neq 0$ даёт допустимое ранг-1 обновление. Gay (1979) показал, что для *линейных* систем выбор v_k не влияет на итоговую сходимость (метод заканчивается за $2n$ шагов при любом v_k). Для нелинейных систем различные v_k дают различное поведение; на практике используется почти исключительно $v_k = s_k$ (“good Broyden”).

1.5 Роль базовой матрицы $\hat{B}_k$

1.5.1 $\hat{B}_k = B_k$: накопление

Обновление отсчитывается от текущего приближения. Вся информация, усвоенная на предыдущих шагах, сохраняется в B_k неявно. Это стандартный выбор для метода Бройдена и его вариантов.

1.5.2 $\hat{B}_k = B_0$: пересборка

Обновление отсчитывается от начальной матрицы (как правило, $B_0 = I$). Информация за пределами текущего окна m — **стирается**: B_{k+1} зависит только от B_0 и последних m пар (s_j, y_j) .

При $V_m = S_m$ и $B_0 = I$ формула (6) даёт:

$$B_{k+1} = I + (Y_m - S_m) (S_m^\top S_m)^{-1} S_m^\top. \quad (9)$$

Это **ускорение Андерсона** типа I (Anderson, 1965; Walker, Ni, 2011; Fang, Saad, 2009). Эквивалентность с формулой Андерсона установлена в [4, 5]: при $B_0 = I$ и $\beta = 1$ мультисекунное обновление ранга m от I совпадает с ускорением Андерсона.

1.6 Разрушение текущих условий при ранг-1 обновлении

Утверждение 1.1.

Пусть B_{k+1} задано ранг-1 обновлением (4) с произвольным v_k ($v_k^\top s_k \neq 0$). Тогда для любого $j < k$:

$$B_{k+1} s_j = B_k s_j + (y_k - B_k s_k) \frac{v_k^\top s_j}{v_k^\top s_k}.$$

В частности, $B_{k+1} s_j = B_k s_j$ тогда и только тогда, когда $v_k^\top s_j = 0$.

Доказательство.

Прямое вычисление:

$$B_{k+1} s_j = \left(B_k + \frac{(y_k - B_k s_k) v_k^\top}{v_k^\top s_k} \right) s_j = B_k s_j + (y_k - B_k s_k) \frac{v_k^\top s_j}{v_k^\top s_k}.$$

Второе слагаемое зануляется тогда и только тогда, когда $v_k^\top s_j = 0$. ■

Следствие 1.1.

В классическом методе Бroyдена ($v_k = s_k$) текущее условие $B_{k+1} s_j = y_j$ сохраняется лишь при $s_k^\top s_j = 0$. В общем случае оно нарушается.

Глава 2

Алгоритм SP-Broyden

В этой главе строится и анализируется алгоритм SP-Broyden — квазиньютоновский метод решения системы $F(x) = 0$ с обновлением якобиана, сохраняющим $p + 1$ текущих условий вместо одного, как в классическом Бройдене. SP-обновление было введено в гл. 1 как один из мультитекущих вариантов; здесь устанавливаются его теоретические свойства и границы применимости.

Основные результаты главы: теорема 2.7 — единственность SP-обновления как минимизатора $\|B - B_k\|_F$ при сохранении $p + 1$ текущих условий; теорема 2.11 — точное разложение и оценка bounded deterioration по фробениусовой норме ошибки $E_k = B_k - J^*$; следствие 2.13 — безусловная $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов (структурное преимущество над классическим Бройденом); теорема 2.17 — глобальная сходимость в схеме “квазиньютоновский метод + Армихо”. Численные эксперименты (§2.5) и limited-memory вариант L-SP-Broyden (§2.4) дополняют теоретическую часть.

Обозначения и предположения главы. Рассматривается задача поиска корня $F(x) = 0$ с непрерывно-дифференцируемым отображением $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$ и якобианом $J(x) = F'(x)$. Обозначим x^* — корень системы ($F(x^*) = 0$), $J^* = J(x^*)$, $s_k = x_{k+1} - x_k$, $y_k = F(x_{k+1}) - F(x_k)$, $E_k = B_k - J^*$ — ошибку аппроксимации якобиана. Во всех теоретических утверждениях главы 2 предполагается, что якобиан липшицев на некоторой открытой окрестности $\mathcal{O} \subset \mathbb{R}^n$ точки x^* :

$$\|J(x) - J(y)\| \leq L \|x - y\|, \quad x, y \in \mathcal{O}. \quad (10)$$

Это стандартное предположение для анализа локальной сходимости квазиньютоновских методов; см. [3, 4].

Идея алгоритма SP-Broyden: выбрать v_k так, чтобы ранг-1 обновление (5) удовлетворяло текущему текущему условию $B_{k+1}s_k = y_k$ и одновременно *сохраняло*

p предыдущих текущих условий $B_{k+1}s_j = B_k s_j$ для $j = k-1, \dots, k-p$. По Утверждению 1.1, для этого достаточно потребовать $v_k^\top s_j = 0$ при $j = k-1, \dots, k-p$.

Определение 2.1 (SP-обновление).

Пусть задана глубина сохранения $p \geq 0$ и пусть шаги $s_k, s_{k-1}, \dots, s_{k-p}$ линейно независимы. Определим *SP-вектор* v_k^* как решение задачи

$$\min_{v \in \mathbb{R}^n} \|v\|^2 \quad \text{при} \quad v^\top s_k = 1, \quad v^\top s_j = 0 \quad (j = k-1, \dots, k-p). \quad (11)$$

SP-обновление якобиана имеет вид

$$B_{k+1} = B_k + (y_k - B_k s_k) (v_k^*)^\top. \quad (12)$$

Замечание 2.2 (Соглашение об обозначениях). Параметр p обозначает число *старых* текущих условий, которые сохраняются. Матрица $S_p = [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}] \in \mathbb{R}^{n \times (p+1)}$ содержит $p+1$ столбцов: текущий шаг s_k стоит первым (это определяет вектор e_1 в формулах ниже), за ним — p предыдущих шагов. В отличие от этого, в общей формуле (3) столбцы S_m расположены в хронологическом порядке: от старых к новым.

Утверждение 2.1 (Явная формула для v_k^*).

Пусть $S_p = [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}] \in \mathbb{R}^{n \times (p+1)}$ и $G_p = S_p^\top S_p \in \mathbb{R}^{(p+1) \times (p+1)}$ — *граммian*. Если G_p невырожден, то

$$v_k^* = S_p G_p^{-1} e_1, \quad (13)$$

где $e_1 = (1, 0, \dots, 0)^\top \in \mathbb{R}^{p+1}$. При этом $\|v_k^*\|^2 = e_1^\top G_p^{-1} e_1$.

Доказательство.

Задача (11) эквивалентна: $\min_v \|v\|^2$ при $S_p^\top v = e_1$. Целевая функция строго выпукла, ограничения аффинны, поэтому стационарная точка функции Лагранжа является глобальным минимумом.

Функция Лагранжа имеет вид $\mathcal{L}(v, \lambda) = \|v\|^2 - 2\lambda^\top (S_p^\top v - e_1)$. Условие стационарности $\nabla_v \mathcal{L} = 2v - 2S_p \lambda = 0$ даёт $v = S_p \lambda$. Подставляя в ограничение, получаем $G_p \lambda = e_1$, откуда $\lambda = G_p^{-1} e_1$ и $v_k^* = S_p G_p^{-1} e_1$.

Норма оптимального вектора: $\|v_k^*\|^2 = (v_k^*)^\top v_k^* = e_1^\top G_p^{-1} S_p^\top S_p G_p^{-1} e_1 = e_1^\top G_p^{-1} e_1$. ■

Замечание 2.3. При $p = 0$ ограничения ортогональности отсутствуют, $S_0 = [s_k]$, $G_0 = \|s_k\|^2$, и формула (13) даёт $v_k^* = s_k / \|s_k\|^2$. Обновление (12) принимает вид

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k) s_k^\top}{\|s_k\|^2},$$

что совпадает с классическим обновлением Бройдена (7).

Замечание 2.4 (Геометрическая интерпретация). Вектор v_k^* лежит в $\text{col}(S_p)$ (по построению $v = S_p \lambda$) и ортогонален подпространству $\text{span}(s_{k-1}, \dots, s_{k-p})$ (по ограничениям задачи). Таким образом, v_k^* направлен вдоль компоненты s_k , ортогональной прошлым шагам, и нормирован условием $v_k^{*\top} s_k = 1$. Обновление (12) модифицирует B_k только в направлениях, ортогональных прошлым шагам, что и обеспечивает сохранение текущих условий.

Полный алгоритм приведён в Алгоритме 1.

Algorithm 1 SP-Broyden($F, x_0, p_{\max}, \tilde{B}, \tau, \varepsilon$; опции)

Require: базовые параметры: $F: \mathbb{R}^n \rightarrow \mathbb{R}^n, x_0 \in \mathbb{R}^n, p_{\max} \geq 0, \tilde{B} \in \mathbb{R}^{n \times n}$ ▷
 опорная матрица алгоритма (параметр функции), куда происходит сброс в режиме пересборки; обычно I_n . Не путать с базовой матрицей $\hat{B}_k$ в формуле обновления.,
 $\tau > 0, \varepsilon > 0$
 опции: `multisecant` $\in \{\text{true}, \text{false}\}$, `accumulate` $\in \{\text{true}, \text{false}\}$, `globalize` $\in \{\text{true}, \text{false}\}$ ▷ флаг Армихо, см. Алгоритм 2
 $B_0 \leftarrow \tilde{B}, \quad k \leftarrow 0$
while $\|F(x_k)\| \geq \varepsilon$ **do**
 Решить $B_k d_k = -F(x_k)$
 if `globalize` **then**
 $\alpha_k \leftarrow$ Armijo-backtracking из Алгоритма 2
 else
 $\alpha_k \leftarrow 1$
 $x_{k+1} \leftarrow x_k + \alpha_k d_k$
 $s_k \leftarrow \alpha_k d_k, \quad y_k \leftarrow F(x_{k+1}) - F(x_k)$
 Адаптивный выбор глубины:
 $p \leftarrow 0$
 for $p' = 1, \dots, \min(p_{\max}, k)$ **do**
 $S_{p'} \leftarrow [s_k \mid s_{k-1} \mid \dots \mid s_{k-p'}]$ ▷ $n \times (p'+1)$ матрица
 if $\text{cond}(S_{p'}^\top S_{p'}) < \tau$ **then**
 $p \leftarrow p'$
 else
 break
 Обновление якобиана:
 if `accumulate` **then**
 $\hat{B}_k \leftarrow B_k$
 else

```

 $\hat{B}_k \leftarrow \tilde{B}$ 
 $S_p \leftarrow [s_k \mid s_{k-1} \mid \cdots \mid s_{k-p}]$ 
 $G_p \leftarrow S_p^\top S_p$ 
if multisecant and  $p > 0$  then
     $Y_p \leftarrow [y_k \mid y_{k-1} \mid \cdots \mid y_{k-p}]$ 
     $B_{k+1} \leftarrow \hat{B}_k + (Y_p - \hat{B}_k S_p) G_p^{-1} S_p^\top$ 
else
     $v_k \leftarrow S_p G_p^{-1} e_1$ 
     $B_{k+1} \leftarrow \hat{B}_k + (y_k - \hat{B}_k s_k) v_k^\top$ 
 $k \leftarrow k + 1$ 
return  $x_k$ 

```

▷ Ранг- $(p+1)$ обновление

▷ Ранг-1 обновление (при $p = 0$ — Бroyден)

Замечание 2.5 (Связь с таксономией обновлений). Параметры **accumulate** и **multisecant** задают четыре режима работы алгоритма, соответствующие ячейкам классификации Fang–Saad [6]:

	multisecant =false (ранг 1)	multisecant =true (ранг $p+1$)
accumulate =true	SP-Broyden (при $p = 0$ — Бройден)	Multisecant Broyden
accumulate =false	Ранг-1 обновление от $\tilde{B}$	Anderson Acceleration

Левая нижняя ячейка (**accumulate** = false, **multisecant** = false) формально корректна, но на каждом шаге использует только текущую пару (s_k, y_k) при фиксированной опорной матрице $\tilde{B}$, отбрасывая всю накопленную информацию; во всех численных экспериментах главы принят **accumulate** = true.

Замечание 2.6 (Сложность). Адаптивный выбор глубины и вычисление v_k требуют $O(np^2)$ операций (формирование грамиана и решение системы размера $(p+1) \times (p+1)$). При $p \ll n$ это пренебрежимо мало по сравнению с $O(n^2)$ на решение линейной системы $B_k d_k = -F(x_k)$. Опциональный backtracking-Армихо добавляет в среднем $j_k \leq J_{\max}$ дополнительных вычислений F на итерацию (типично $j_k \in \{0, 1, 2\}$, см. §2.3) и не меняет главного порядка стоимости. Мультиесекущая ветвь (**multisecant** = true) выполняет ранг- $(p+1)$ обновление $B_{k+1} = \hat{B}_k + (Y_p - \hat{B}_k S_p) G_p^{-1} S_p^\top$ и требует $O(n^2 p)$ операций (доминирует матрично-матричное произведение $\hat{B}_k S_p$); по лемме 2.8 при выполнении инварианта (18) она даёт тот же результат, что и ранг-1 ветвь, поэтому в численных экспериментах главы используется только ранг-1 форма.

2.1 Минимальность SP-обновления

Теорема 2.7 (Минимальность).

Пусть $S_p = [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}]$ и грамиан $G_p = S_p^\top S_p$ невырожден. Тогда обновление

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k)(v_k^*)^\top}{v_k^{*\top} s_k} \quad (14)$$

с $v_k^* = S_p G_p^{-1} e_1$ является единственным решением задачи

$$\min_{B \in \mathbb{R}^{n \times n}} \|B - B_k\|_F \quad \text{при} \quad B s_k = y_k, \quad B s_j = B_k s_j \quad (j = k-1, \dots, k-p). \quad (15)$$

Если, кроме того, $B_k s_j = y_j$ для $j = k-p, \dots, k-1$, то B_{k+1} удовлетворяет всем $p+1$ текущим условиям: $B_{k+1} s_j = y_j$ для $j = k-p, \dots, k$.

Доказательство.

Обозначим $\Delta = B - B_k$. Задача (15) принимает вид:

$$\min_{\Delta \in \mathbb{R}^{n \times n}} \|\Delta\|_F \quad \text{при} \quad \Delta s_k = y_k - B_k s_k, \quad \Delta s_j = 0 \quad (j = k-1, \dots, k-p). \quad (16)$$

Шаг 1: сведение к ранг-1 задаче. Обозначим $r = y_k - B_k s_k \in \mathbb{R}^n$ — невязку текущего условия. Запишем Δ в виде ранг-1 матрицы $\Delta = r w^\top$ для некоторого $w \in \mathbb{R}^n$. Тогда:

$$\Delta s_k = r (w^\top s_k), \quad \Delta s_j = r (w^\top s_j).$$

Ограничения (16) принимают вид:

$$w^\top s_k = 1, \quad w^\top s_j = 0 \quad (j = k-1, \dots, k-p). \quad (17)$$

Норма: $\|\Delta\|_F = \|r\| \cdot \|w\|$. Поскольку $\|r\|$ фиксировано, задача сводится к $\min_w \|w\|$ при ограничениях (17), что совпадает с (11).

Шаг 2: оптимальность ранг-1 формы. Покажем, что решение задачи (16) действительно имеет ранг 1. Пусть Δ^* — произвольное допустимое решение произвольного ранга. Разложим его строки: для каждой строки $\delta_i^\top$ (транспонированная i -я строка) ограничения задают $\delta_i^\top s_k = r_i$ и $\delta_i^\top s_j = 0$ для $j = k-1, \dots, k-p$. Минимальный по евклидовой норме вектор δ_i , удовлетворяющий этим условиям, находится из ККТ и имеет вид:

$$\delta_i^* = r_i \cdot S_p (S_p^\top S_p)^{-1} e_1 = r_i \cdot v_k^*.$$

Тогда $\Delta^* = r v_k^{*\top}$, что есть ранг-1 матрица.

Шаг 3: подстановка. Решение: $w^* = v_k^* = S_p G_p^{-1} e_1$ (по утверждению 2.1). Заметим, что $S_p^\top s_k$ — первый столбец грамиана G_p (по определению S_p , см. замечание 2.2), т.е. $S_p^\top s_k = G_p e_1$, откуда $v_k^{*\top} s_k = e_1^\top G_p^{-1} G_p e_1 = 1$. Следовательно, $B_{k+1} = B_k + r v_k^{*\top} = B_k + (y_k - B_k s_k) v_k^{*\top}$.

Шаг 4: единственность. Единственность следует из строгой выпуклости нормы Фробениуса на аффинном подпространстве, задаваемом линейными ограничениями из (16).

Шаг 5: сохранение текущих условий. По утверждению 1.1, $v_k^{*\top} s_j = 0$ для $j = k-1, \dots, k-p$ влечет $B_{k+1} s_j = B_k s_j$. Если $B_k s_j = y_j$, то $B_{k+1} s_j = y_j$. Вместе с $B_{k+1} s_k = y_k$ это дает $B_{k+1} s_j = y_j$ для всех $j = k-p, \dots, k$. ■

2.2 Качество аппроксимации якобиана

Лемма 2.8 (Эквивалентность SP-Broyden и мультисекундного обновления). Пусть $S_p = [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}] \in \mathbb{R}^{n \times (p+1)}$ имеет полный столбцовый ранг, $Y_p = [y_k \mid y_{k-1} \mid \dots \mid y_{k-p}]$, $G_p = S_p^\top S_p \in \mathbb{R}^{(p+1) \times (p+1)}$.

Пусть B_k удовлетворяет индуктивному инварианту:

$$B_k s_j = y_j \quad \text{для } j = k-1, \dots, k-p. \quad (18)$$

Тогда SP-обновление $B_{k+1}^{\text{SP}} = B_k + (y_k - B_k s_k) v_k^{*\top}$ с $v_k^* = S_p G_p^{-1} e_1$ совпадает с мультисекундным обновлением:

$$B_{k+1}^{\text{MS}} = B_k + (Y_p - B_k S_p) G_p^{-1} S_p^\top. \quad (19)$$

Доказательство.

По инварианту (18): $B_k s_j = y_j$ для $j = k-1, \dots, k-p$. Следовательно, в матрице $Y_p - B_k S_p \in \mathbb{R}^{n \times (p+1)}$ столбцы со 2-го по $(p+1)$ -й равны нулю:

$$Y_p - B_k S_p = (y_k - B_k s_k) e_1^\top,$$

где $e_1 \in \mathbb{R}^{p+1}$ — первый стандартный базисный вектор (тот же, что в (13)). Подставляя в (19):

$$B_{k+1}^{\text{MS}} = B_k + (y_k - B_k s_k) e_1^\top G_p^{-1} S_p^\top = B_k + (y_k - B_k s_k) v_k^{*\top} = B_{k+1}^{\text{SP}}.$$

Корректность построения v_k^* : $v_k^{*\top} s_j = e_1^\top G_p^{-1} S_p^\top s_j$. Поскольку s_j — столбец S_p с номером $(1 + k - j)$, имеем $S_p^\top s_j = G_p e_{1+k-j}$, откуда $v_k^{*\top} s_j = e_1^\top e_{1+k-j} = \delta_{jk}$. ■

Замечание 2.9 (Область применимости леммы 2.8). Инвариант (18) выполнен

индуктивно при (i) базовом режиме Алгоритма 1 с `accumulate` = true (когда $\widehat{B}_k = B_k$ на каждой итерации, и теорема 2.7 гарантирует $B_{k+1}s_j = y_j$ для $j = k-p, \dots, k$) и (ii) постоянной или невозрастающей эффективной глубине p . При `accumulate` = false или при расширении окна (увеличение p от итерации к итерации) инвариант сбрасывается, и ранг-1 ветвь (`multisecant` = false) расходится с мультисекундой; в этих случаях теорема 2.11 (b) применяется с пересчитанным B_k от точки сброса. В численных экспериментах главы используется базовый режим `accumulate` = true.

Лемма 2.10 (Локальная оценка длины шага через расстояние до корня). Пусть якобиан J удовлетворяет условию Липшица (10) с константой L на шаре $B(x^*, \delta_0) := \{x : \|x - x^*\| \leq \delta_0\}$, $F(x^*) = 0$, и пусть B_j обратима с $\|B_j^{-1}\| \leq M$ для всех j , рассматриваемых в анализе. Тогда для всех $x_j \in B(x^*, \delta_0)$ длина шага $s_j = -B_j^{-1}F(x_j)$ удовлетворяет

$$\|s_j\| \leq C_s \|x_j - x^*\|, \quad C_s := M \left(\|J^*\| + \frac{L}{2} \delta_0 \right), \quad (20)$$

где $\|J^*\|$ — спектральная (операторная) норма $J(x^*)$.

Доказательство.

По интегральной формуле Ньютона–Лейбница и $F(x^*) = 0$:

$$F(x_j) = F(x_j) - F(x^*) = \left(\int_0^1 J(x^* + t(x_j - x^*)) dt \right) (x_j - x^*).$$

Применяя оценку Липшица $\|J(x^* + \tau(x_j - x^*)) - J^*\| \leq L\tau \|x_j - x^*\|$ и интегрируя:

$$\left\| \int_0^1 J(x^* + t(x_j - x^*)) dt \right\| \leq \|J^*\| + \frac{L}{2} \|x_j - x^*\| \leq \|J^*\| + \frac{L}{2} \delta_0.$$

Отсюда $\|F(x_j)\| \leq (\|J^*\| + \frac{L}{2} \delta_0) \|x_j - x^*\|$. По условию леммы $\|s_j\| \leq M \|F(x_j)\|$, что даёт (20). ■

Теорема 2.11 (Bounded deterioration для SP-Broyden).

В условиях леммы 2.8 пусть дополнительно якобиан $J(x)$ удовлетворяет условию Липшица (10) с константой L на открытой окрестности $\mathcal{O} \subset \mathbb{R}^n$, содержащей x^* , все точки x_j и отрезки $\{x_j + ts_j : t \in [0, 1]\}$ для $j = k-p, \dots, k$. Обозначим $J^* = J(x^*)$, $E_k = B_k - J^*$,

$$\Pi_k = S_p G_p^{-1} S_p^\top \quad (\text{ортогональный проектор на } \text{col } S_p), \quad \Pi_k^\perp = I - \Pi_k.$$

Тогда:

(a) **Точное разложение.**

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k, \quad (21)$$

где

$$\Delta_k = \text{tr}(G_p^{-1} (Y_p - J^* S_p)^\top (Y_p - J^* S_p)). \quad (22)$$

(b) **Bounded deterioration.** Пусть выполнены условия леммы 2.10 с константой C_s (так что $\|s_j\| \leq C_s \|x_j - x^*\|$ для $j = k - p, \dots, k$). Обозначим

$$\rho_k := \max_{k-p \leq j \leq k} \|x_j - x^*\|, \quad \kappa_p := \kappa(S_p) = \frac{\sigma_{\max}(S_p)}{\sigma_{\min}(S_p)}. \quad (23)$$

Тогда

$$\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + C_{\text{SP}}^2 \rho_k^2, \quad C_{\text{SP}} := L(1 + C_s/2) \sqrt{p+1} \kappa_p. \quad (24)$$

Замечание 2.12 (Расшифровка C_{SP}). Структура константы C_{SP} прозрачна: L — константа Липшица якобиана; C_s — типичный размер шага относительно расстояния до корня (лемма 2.10); $\sqrt{p+1}$ — цена расширения окна текущих; κ_p — обусловленность окна S_p . Адаптивный порог $\text{cond}(G_p) < \tau$ Алгоритма 1 обеспечивает $\kappa_p \leq \sqrt{\tau}$, так что $C_{\text{SP}} \leq L(1 + C_s/2) \sqrt{\tau(p+1)}$. В классической форме Бройдена ($p = 0$, $\Pi_k = s_k s_k^\top / \|s_k\|^2$, $\kappa_0 = 1$) эта оценка переходит в стандартную bounded deterioration с $C_{\text{Br}} = L(1 + C_s/2)$, ср. [10, 4]. Константа $M = \sup_j \|B_j^{-1}\|$ из леммы 2.10, входящая в C_s , конечна при $\|E_j\| < \sigma_{\min}(J^*)$ (неравенство Вейля).

Доказательство.

Шаг 1: разложение E_{k+1} . По лемме 2.8, $B_{k+1} = B_{k+1}^{\text{MS}}$. Подставим определение (19):

$$\begin{aligned} E_{k+1} &= B_k - J^* + (Y_p - B_k S_p) G_p^{-1} S_p^\top \\ &= E_k + [(Y_p - J^* S_p) - E_k S_p] G_p^{-1} S_p^\top \\ &= E_k (I - S_p G_p^{-1} S_p^\top) + (Y_p - J^* S_p) G_p^{-1} S_p^\top. \end{aligned} \quad (25)$$

То есть:

$$E_{k+1} = E_k \Pi_k^\perp + R_k, \quad R_k = (Y_p - J^* S_p) G_p^{-1} S_p^\top. \quad (26)$$

Шаг 2: ортогональность строк. Покажем, что $\text{tr}((E_k \Pi_k^\perp)^\top R_k) = 0$.

Для каждого $i = 1, \dots, n$ рассмотрим i -ю строку каждого слагаемого, записанную как столбец транспонированной матрицы.

Строка i матрицы $E_k \Pi_k^\perp$:

$$(E_k \Pi_k^\perp)^\top e^{(i)} = \Pi_k^\perp E_k^\top e^{(i)} \in (\text{col } S_p)^\perp,$$

поскольку $\text{im } \Pi_k^\perp = (\text{col } S_p)^\perp$.

Строка i матрицы R_k :

$$R_k^\top e^{(i)} = S_p G_p^{-1} (Y_p - J^* S_p)^\top e^{(i)} \in \text{col } S_p,$$

поскольку вектор является линейной комбинацией столбцов S_p .

Скалярное произведение i -х строк:

$$\begin{aligned} (\Pi_k^\perp E_k^\top e^{(i)})^\top (S_p G_p^{-1} (Y_p - J^* S_p)^\top e^{(i)}) \\ = (E_k^\top e^{(i)})^\top \underbrace{\Pi_k^\perp S_p}_{=0} G_p^{-1} (Y_p - J^* S_p)^\top e^{(i)} = 0, \end{aligned}$$

где $\Pi_k^\perp S_p = (I - S_p G_p^{-1} S_p^\top) S_p = S_p - S_p G_p^{-1} G_p = 0$. Суммируя по i :

$$\text{tr}((E_k \Pi_k^\perp)^\top R_k) = \sum_{i=1}^n ((E_k \Pi_k^\perp)^\top e^{(i)})^\top (R_k^\top e^{(i)}) = 0. \quad (27)$$

Шаг 3: теорема Пифагора. Из (26) и (27):

$$\|E_{k+1}\|_F^2 = \|E_k \Pi_k^\perp\|_F^2 + \|R_k\|_F^2. \quad (28)$$

Аналогично, разложение $E_k = E_k \Pi_k + E_k \Pi_k^\perp$ даёт ортогональные (построчно) слагаемые, поскольку строка i матрицы $E_k \Pi_k$ лежит в $\text{col } S_p$, а строка i матрицы $E_k \Pi_k^\perp$ — в $(\text{col } S_p)^\perp$. Следовательно:

$$\|E_k\|_F^2 = \|E_k \Pi_k\|_F^2 + \|E_k \Pi_k^\perp\|_F^2. \quad (29)$$

Подставляя $\|E_k \Pi_k^\perp\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2$ в (28):

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \|R_k\|_F^2. \quad (30)$$

Шаг 4: вычисление $\|R_k\|_F^2$. Обозначим $A_k = Y_p - J^* S_p$. Тогда $R_k = A_k G_p^{-1} S_p^\top$

и:

$$\begin{aligned}
\|R_k\|_F^2 &= \text{tr}(S_p G_p^{-1} A_k^\top A_k G_p^{-1} S_p^\top) \\
&= \text{tr}(G_p^{-1} S_p^\top S_p G_p^{-1} A_k^\top A_k) \quad (\text{цикличность следа}) \\
&= \text{tr}(G_p^{-1} G_p G_p^{-1} A_k^\top A_k) = \text{tr}(G_p^{-1} A_k^\top A_k).
\end{aligned} \tag{31}$$

Это доказывает (21) с $\Delta_k = \|R_k\|_F^2$.

Шаг 5: оценка Δ_k сверху. Матрицы G_p^{-1} и $A_k^\top A_k$ положительно полуопределены. По неравенству $\text{tr}(MN) \leq \lambda_{\max}(M) \text{tr}(N)$ для положительно полуопределённых M, N :

$$\Delta_k = \text{tr}(G_p^{-1} A_k^\top A_k) \leq \lambda_{\max}(G_p^{-1}) \|A_k\|_F^2 = \frac{\|A_k\|_F^2}{\lambda_{\min}(G_p)} = \frac{\|A_k\|_F^2}{\sigma_{\min}^2(S_p)}. \tag{32}$$

Оценим $\|A_k\|_F^2$. Столбец матрицы A_k , отвечающий индексу j , равен $a_j = y_j - J^* s_j$. По теореме о среднем значении:

$$y_j - J^* s_j = \left(\int_0^1 [J(x_j + t s_j) - J^*] dt \right) s_j.$$

Поскольку $x_j + t s_j \in \mathcal{O}$ для $t \in [0, 1]$ и $J^* = J(x^*)$, по условию Липшица (10) и неравенству треугольника:

$$\|J(x_j + t s_j) - J^*\| \leq L \|x_j + t s_j - x^*\| \leq L (\|x_j - x^*\| + t \|s_j\|).$$

Интегрируя по $t \in [0, 1]$:

$$\left\| \int_0^1 [J(x_j + t s_j) - J^*] dt \right\| \leq L \|x_j - x^*\| + \frac{L}{2} \|s_j\|. \tag{33}$$

Следовательно:

$$\|a_j\| = \|y_j - J^* s_j\| \leq \left(L \|x_j - x^*\| + \frac{L}{2} \|s_j\| \right) \|s_j\|. \tag{34}$$

По лемме 2.10 $\|s_j\| \leq C_s \|x_j - x^*\|$ для всех $j = k - p, \dots, k$. Подставляя в (34):

$$\|a_j\|^2 \leq L^2 (1 + C_s/2)^2 \|x_j - x^*\|^2 \|s_j\|^2 \leq L^2 (1 + C_s/2)^2 \rho_k^2 \|s_j\|^2, \tag{35}$$

где $\rho_k = \max_j \|x_j - x^*\|$ из (23). Суммируя по j и пользуясь $\sum_j \|s_j\|^2 = \|S_p\|_F^2 \leq (p + 1) \sigma_{\max}^2(S_p)$:

$$\|A_k\|_F^2 \leq L^2 (1 + C_s/2)^2 (p + 1) \sigma_{\max}^2(S_p) \rho_k^2. \tag{36}$$

Подставляя в (32), получаем

$$\Delta_k \leq \frac{\|A_k\|_F^2}{\sigma_{\min}^2(S_p)} \leq L^2(1 + C_s/2)^2 (p+1) \kappa_p^2 \rho_k^2 = C_{\text{SP}}^2 \rho_k^2. \quad (37)$$

Подстановка в (30) даёт (24). ■

Следствие 2.13 (Подпространственная аппроксимация якобиана).

В условиях теоремы 2.11

$$\|E_{k+1} S_p\|_F \leq L(1 + C_s/2) \sqrt{p+1} \sigma_{\max}(S_p) \rho_k. \quad (38)$$

В частности, B_{k+1} аппроксимирует J^* на всём подпространстве $\text{col } S_p$ с точностью $O(\rho_k)$, зависящей лишь от локальной липшицевой константы и расстояния до корня (не от $\|E_k\|_F$ на $\text{col } S_p$).

Доказательство.

По (26) $E_{k+1} = E_k \Pi_k^\perp + R_k$. Поскольку $\Pi_k^\perp S_p = 0$ (Шаг 2 доказательства теоремы 2.11) и $G_p^{-1} G_p = I$,

$$E_{k+1} S_p = E_k \Pi_k^\perp S_p + R_k S_p = 0 + (Y_p - J^* S_p) G_p^{-1} S_p^\top S_p = Y_p - J^* S_p.$$

Оценка (36) даёт (38). ■

Замечание 2.14 (Сравнение с классическим Бройденом). Для обновления Бройдена первого типа ($v_k = s_k / \|s_k\|^2$) аналогичное разложение даёт:

$$\|E_{k+1}^{\text{Br}}\|_F^2 = \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + \frac{\|y_k - J^* s_k\|^2}{\|s_k\|^2}. \quad (39)$$

SP-Broyden имеет три взаимосвязанных структурных преимущества над классическим Бройденом:

(i) *Расширенный проектор ранга $p+1$.* В (39) вычитается проекция ошибки на одномерное направление s_k , в (21) — на $(p+1)$ -мерное подпространство $\text{col } S_p$. Поскольку $\text{span}(s_k) \subset \text{col } S_p$, имеем $\Pi_k - s_k s_k^\top / \|s_k\|^2 \succeq 0$ и

$$\|E_k \Pi_k\|_F^2 \geq \frac{\|E_k s_k\|^2}{\|s_k\|^2}, \quad (40)$$

причём неравенство строгое всякий раз, когда E_k имеет нетривиальную проекцию на $\text{col } S_p \setminus \text{span}(s_k)$.

(ii) *Сохранение $p+1$ секущих условий.* По теореме 2.7 $B_{k+1} s_j = y_j$ для всех

$j = k-p, \dots, k$, тогда как классический Бroyден сохраняет лишь текущее равенство $B_{k+1}^{\text{Br}} s_k = y_k$. Для $j < k$ возникает неконтролируемая невязка $B_{k+1}^{\text{Br}} s_j - y_j = E_k s_j + (y_k - B_k s_k) (s_k^\top s_j / \|s_k\|^2)$, наследующая прошлую ошибку $E_k s_j$.

(iii) *Подпространственная аппроксимация якобиана.* Прямое следствие (ii) — corollary 2.13: на всём $(p+1)$ -мерном подпространстве $\text{col } S_p$ ошибка E_{k+1} оценивается локальной липшицевой константой и расстоянием до корня. Аналогичный безусловный $O(\rho_k)$ -контроль для классического Бroyдена существует только в одномерном направлении s_k ($\|E_{k+1}^{\text{Br}} s_k\| = \|y_k - J^* s_k\| = O(\rho_k) \|s_k\|$); на $\text{col } S_p \setminus \text{span}(s_k)$ ошибка определяется глобальной историей.

2.3 Глобализация квазиньютоновских методов

Локальная теория §2.2 (а также параллельная теория для $\text{SS-}\mathcal{U}$ в гл. 3) гарантирует Q -сверхлинейную сходимость лишь в окрестности решения. Для глобальной сходимости из произвольной стартовой точки квазиньютоновская итерация дополняется демпфированием шага по правилу Армихо [23] (альтернатива — условия Вольфа [24, 7]; для рассматриваемого класса задач условия Армихо достаточно). Ниже конструкция формулируется в общем виде, применимом и к SP-Broyden (гл. 2, $F(x) = 0$), и к $\text{SS-}\mathcal{U}$ (гл. 3, $\min f$).

Общая постановка. Пусть $g: \mathbb{R}^n \rightarrow \mathbb{R}^n$ — “невязка” задачи (для системы $F = 0$ имеем $g \equiv F$; для минимизации $f - g \equiv \nabla f$), и пусть $A(x)$ — её якобиан-подобный оператор ($A = \nabla F$ в первом случае, $A = \nabla^2 f$ во втором; в обоих случаях корень x^* задачи характеризуется условием $g(x^*) = 0$). Квазиньютоновский метод строит последовательность $\{B_k\}$, аппроксимирующую $A_k := A(x_k)$, и шаг $d_k = -B_k^{-1}g(x_k)$. Обозначим $E_k = B_k - A_k$ — ошибку аппроксимации.

Глобализация требует merit-функции $\phi: \mathbb{R}^n \rightarrow \mathbb{R}$, удовлетворяющей условиям:

- (i) $\phi \in C^1(\mathbb{R}^n)$, $\nabla \phi$ непрерывен по Липшицу с константой L_ϕ на сублевельном множестве $\mathcal{L}_0 := \{x : \phi(x) \leq \phi(x_0)\}$;
- (ii) $\mathcal{L}_0$ ограничено и $\inf_{\mathbb{R}^n} \phi > -\infty$;
- (iii) стационарные точки ϕ в окрестности x^* совпадают с корнями g .

Два частных случая, покрывающих обе главы:

$$\text{(гл. 2)} \quad \phi(x) = \frac{1}{2} \|F(x)\|^2, \quad \nabla \phi = J(x)^\top F(x); \quad \text{(гл. 3)} \quad \phi(x) = f(x), \quad \nabla \phi = \nabla f(x). \quad (41)$$

В первом случае требование (iii) выполнено при невырожденном $J(x^*)$; во втором случае оно тривиально ($\nabla\phi = g$).

Условие убывания (Armijo). Зафиксируем константы $c_1 \in (0, 1/2)$ и $\rho \in (0, 1)$ (типично $c_1 = 10^{-4}$, $\rho = 1/2$). Алгоритм глобализации (Алгоритм 2) заменяет полный шаг $x_{k+1} \leftarrow x_k + d_k$ на $x_{k+1} = x_k + \alpha_k d_k$ с $\alpha_k = \rho^{j_k}$, где $j_k \in \mathbb{Z}_{\geq 0}$ — наименьшее целое, при котором выполнено неравенство Армихо

$$\phi(x_k + \alpha_k d_k) \leq \phi(x_k) + c_1 \alpha_k \nabla\phi(x_k)^\top d_k. \quad (42)$$

Соответствующее квазиньютоновское обновление применяется к секущей паре $s_k = \alpha_k d_k$, $y_k = g(x_{k+1}) - g(x_k)$.

Algorithm 2 Шаблон “квазиньютоновский метод + Armijo”

Require: задача $g(x) = 0$ и merit-функция ϕ как в (41); $x_0 \in \mathbb{R}^n$; B_0 ; $c_1 \in (0, 1/2)$, $\rho \in (0, 1)$, $\alpha_{\min} > 0$, $\varepsilon > 0$
 $k \leftarrow 0$
while $\|g(x_k)\| \geq \varepsilon$ **do**
 Решить $B_k d_k = -g(x_k)$
 $\alpha_k \leftarrow 1$
 while $\phi(x_k + \alpha_k d_k) > \phi(x_k) + c_1 \alpha_k \nabla\phi(x_k)^\top d_k$ **and** $\alpha_k > \alpha_{\min}$ **do**
 $\alpha_k \leftarrow \rho \alpha_k$
 $x_{k+1} \leftarrow x_k + \alpha_k d_k$, $s_k \leftarrow \alpha_k d_k$, $y_k \leftarrow g(x_{k+1}) - g(x_k)$
 выполнить квазиньютоновское обновление $B_k \rightarrow B_{k+1}$ (Алгоритм 1 или Алгоритм 4)
 $k \leftarrow k + 1$
return x_k

Лемма 2.15 (Условие угла для d_k , [4, 7]).

Пусть A_k обратим с $\sigma_k := \sigma_{\min}(A_k) > 0$, $\beta_k := \|A_k\|$, и существует $\eta \in (0, 1/2)$ такое, что

$$\|E_k\| \leq \eta \sigma_k. \quad (43)$$

Тогда B_k обратим, $\sigma_{\min}(B_k) \geq (1 - \eta)\sigma_k$, и шаг $d_k = -B_k^{-1}g(x_k)$ удовлетворяет поточечному условию угла

$$-\nabla\phi(x_k)^\top d_k \geq \eta_{0,k} \|\nabla\phi(x_k)\| \|d_k\|, \quad \eta_{0,k} := \frac{1 - 2\eta}{1 + \eta} \kappa(A_k)^{-1} > 0. \quad (44)$$

Доказательство.

По неравенству Вейля $\sigma_{\min}(B_k) \geq \sigma_k - \|E_k\| \geq (1 - \eta)\sigma_k$, откуда $\|E_k B_k^{-1}\| \leq \eta/(1 - \eta)$.

Случай (гл. 2): $\nabla\phi(x_k)^\top d_k = -F^\top A_k B_k^{-1} F = -F^\top (I - E_k B_k^{-1}) F$, откуда

$-\nabla\phi^\top d_k \geq \frac{1-2\eta}{1-\eta}\|F\|^2$; подстановка $\|d_k\| \leq ((1-\eta)\sigma_k)^{-1}\|F\|$ и $\|\nabla\phi\| \leq \beta_k\|F\|$ даёт (44).

Случай (гл. 3): $\nabla\phi(x_k)^\top d_k = -\nabla f^\top B_k^{-1}\nabla f$; при $A_k = \nabla^2 f(x_k) \succ 0$ и $\|E_k\| \leq \eta\sigma_k$ матрица B_k положительно определена, и $-\nabla\phi^\top d_k \geq \sigma_{\min}(B_k^{-1})\|\nabla f\|^2$. Аналогичное упрощение приводит к (44). ■

Замечание 2.16 (Положительная определённость для гл. 3). Условие (43) для гл. 3 включает не только ограниченность $\|E_k\|$, но и сохранение знака собственных чисел B_k (SR1 в общем случае положительной определённости не сохраняет; SS-SR1 наследует это ограничение). На практике для SR1-семейства при нарушении descent-условия применяется fallback на $-\nabla f$ или trust-region схема; см. обсуждение в [7, §6.2].

Глобальная сходимость.

Теорема 2.17 (Глобальная сходимость).

Пусть merit-функция ϕ удовлетворяет условиям (i)–(iii) выше, $\bar{\kappa} := \sup_{x \in \mathcal{L}_0} \kappa(A(x)) < \infty$, и условие (43) с $\eta \in (0, 1/2)$ выполнено для всех k (возможно, после конечного числа сбросов $B_k \leftarrow B_0$). Положим

$$\bar{\eta}_0 := \frac{1-2\eta}{1+\eta} \bar{\kappa}^{-1} > 0. \quad (45)$$

По лемме 2.15 $\eta_{0,k} \geq \bar{\eta}_0$ для всех k . Тогда последовательность $\{x_k\}$, порождённая Алгоритмом 2, удовлетворяет $\sum_k \cos^2 \theta_k \|\nabla\phi(x_k)\|^2 < \infty$ с $\cos \theta_k \geq \bar{\eta}_0 > 0$, откуда $\|\nabla\phi(x_k)\| \rightarrow 0$. В частности, любая предельная точка x^* удовлетворяет $\nabla\phi(x^*) = 0$; для гл. 2 при невырожденном $J(x^*)$ это эквивалентно $F(x^*) = 0$.

Доказательство.

Стандартный аргумент Цоутендейка [25]: лемма 2.15 даёт условие угла (44); L_ϕ -гладкость $\nabla\phi$ на $\mathcal{L}_0$ обеспечивает нижнюю оценку шага в (42); монотонное убывание ϕ и его ограниченность снизу замыкают суммирование. Подробности — [7, Th. 3.2]. ■

2.4 Limited-memory: Шерман–Моррисон и L-SP-Broyden

Мотивация. Прямая реализация Алгоритма 1 хранит плотную матрицу $B_k \in \mathbb{R}^{n \times n}$, что требует $O(n^2)$ памяти и $O(n^3)$ операций на решение системы $B_k d = -F(x_k)$ через LU-факторизацию. При $n = 10^4$ это $\approx 8 \cdot 10^8$ чисел двойной точности (≈ 800 МБ) и $\approx 10^{12}$ flops на итерацию, что делает прямую форму неприменимой к крупномасштабным задачам.

Шерман–Моррисон-форма. Поскольку SP-обновление имеет ранг 1, $B_{k+1} = B_k + u_k v_k^\top$ с $u_k = y_k - B_k s_k$ (используем $v_k^\top s_k = 1$, утверждение 2.1), формула Шермана–Моррисона [4, §3.4] даёт явное обновление обратной матрицы $H_k := B_k^{-1}$:

$$H_{k+1} = H_k + \frac{(s_k - H_k y_k) v_k^\top H_k}{v_k^\top H_k y_k}, \quad d_k = -H_k F(x_k). \quad (46)$$

Хранение H_k остаётся $O(n^2)$, но шаг d_k вычисляется как матрично-векторное произведение за $O(n^2)$ флорпс вместо $O(n^3)$. Знаменатель $v_k^\top H_k y_k$ в (46) равен $1 + v_k^\top H_k u_k$ из общей формы Шермана–Моррисона — после подстановки $u_k = y_k - B_k s_k$ и $v_k^\top s_k = 1$. Условие невырожденности $\det B_{k+1} \neq 0$ эквивалентно $v_k^\top H_k y_k \neq 0$.

Limited-memory L-SP-Broyden. Для $n \gtrsim 10^4$ хранить плотную H_k невозможно даже в форме (46). По аналогии с limited-memory BFGS [8, 15] предложим limited-memory вариант SP-Broyden, в котором базовая матрица $H_0 = I$ *никогда не формируется явно*. Вместо этого хранится скользящее окно последних m принятых троек $\{(s_j, y_j, v_j)\}_{j=k-m+1}^k$.

Применение H_k к произвольному вектору g реализуется рекурсией прямого прохода (Алгоритм 3), формально эквивалентной последовательной композиции (46) к $H_0 = I$ для всех корректировок текущего окна:

$$H_k g = H_{k-m} g + \sum_{j=k-m+1}^k \frac{(s_j - H_{j-1} y_j) (v_j^\top H_{j-1} g)}{v_j^\top H_{j-1} y_j}, \quad H_{k-m} = I. \quad (47)$$

Algorithm 3 Применение $H_k g$ для L-SP-Broyden (рекурсия прямого прохода)

Require: окно $\{(s_j, y_j, v_j)\}_{j=1}^m$, входной вектор g

Ensure: $z = H_k g$

```

1:  $z \leftarrow g$   $\triangleright H_0 = I$ 
2: for  $j = 1, 2, \dots, m$  do
3:    $w \leftarrow y_j$   $\triangleright$  вычислим  $H_j y_j$ 
4:   for  $i = 1, \dots, j - 1$  do
5:      $\beta_i \leftarrow (v_i^\top w) / \alpha_i^{\text{cache}}$ 
6:      $w \leftarrow w + \xi_i^{\text{cache}} \beta_i$ 
7:    $\alpha_j^{\text{cache}} \leftarrow v_j^\top w$ 
8:    $\xi_j^{\text{cache}} \leftarrow s_j - w$ 
9:    $\beta_j \leftarrow (v_j^\top z) / \alpha_j^{\text{cache}}$ 
10:   $z \leftarrow z + \xi_j^{\text{cache}} \beta_j$ 
11: return  $z$ 

```

Полный шаг L-SP-Broyden выглядит так: на итерации k вычисляется $d_k = -\text{APPLYH}(F(x_k); \text{window}_k)$; делается backtracking-Армихо (Алгоритм 2) или полный шаг $x_{k+1} = x_k + d_k$; формируется текущая $(s_k, y_k) = (x_{k+1} - x_k, F(x_{k+1}) - F(x_k))$; строится SP-направление v_k из текущего окна столбцов S_p (как в Алгоритме 1, шаги 5–13); тройка (s_k, y_k, v_k) добавляется в очередь, а самая старая тройка выталкивается, если длина $> m$.

Сложность L-SP-Broyden. Память: каждая тройка занимает $3n$ чисел с плавающей точкой, плюс служебные кэши $\xi^{\text{cache}}, \alpha^{\text{cache}}$ размера $O(nm)$, итого

$$\mathcal{M}_{\text{L-SP-Broyden}} = 3nm + nm + 2n = O(nm). \quad (48)$$

При $n = 10^4, m = 10$ это $4,2 \cdot 10^5$ чисел с плавающей точкой $\approx 3,4$ МБ. Время: тело внешнего цикла Алгоритма 3 выполняется m раз, внутреннего — до $m-1$ раз; стоимость одного обращения $H_k g$ составляет $O(nm^2)$ flops. На итерацию приходится 2 обращения (одно для d_k , одно для $H_k y_k$ при расчёте знаменателя α_k), итого $O(nm^2)$ flops/iter. При $n = 10^4, m = 10$ это $\approx 2 \cdot 10^6$ flops/iter — на пять порядков меньше, чем $O(n^2)$ у плотной формы (46).

Замечание 2.18 (Полный пересчёт vs. кэширование). Хотя величины $\xi_j^{\text{cache}}, \alpha_j^{\text{cache}}$ зависят только от $\{(s_i, y_i, v_i)\}_{i \leq j}$ и могут показаться допускающими кэширование между итерациями, при выталкивании самой старой пары из окна оставшиеся ξ_i становятся *несогласованными* с усечённой историей: $H_i y_i$ они вычислялись

относительно полного префикса $0, \dots, i-1$, не обрезанного префикса. Поэтому на каждом обращении $H_k g$ значения $\xi_i^{\text{cache}}, \alpha_i^{\text{cache}}$ *пересчитываются заново* из текущего окна (внутренний цикл Алгоритма 3). То же требование удерживает и L-BFGS two-loop [7, §7.2], где коэффициенты ρ_i хранятся (это скаляры), но кэширование произведений $H_i y_i$ исключено по той же причине.

Замечание 2.19 (Связь с L-BFGS и Anderson). Limited-memory BFGS [8, 15, 14] применим для *минимизации*: требует градиента ∇f и предполагает симметричный положительно определённый гессиан. Для систем $F(x) = 0$ без симметрии Якобиана — к которым относится большинство задач вариационных неравенств (гл. 4) — L-BFGS не применим напрямую без сведения к минимизации merit-функции $\psi(x) = \frac{1}{2} \|F(x)\|^2$ с расчётом $\nabla \psi = J(x)^\top F(x)$, требующим Якобиан-векторных произведений. L-SP-Broyden, как и классический Бройден, работает непосредственно с F и не требует симметрии. Anderson(m, β) [2, 5, 19] — альтернативный limited-memory метод без явной модели Якобиана; в нём окно $\{x_j, F(x_j)\}$ используется для построения мульти-секущей подгонки, но без управления условием (14) из гл. 4, что делает Anderson менее точным в режимах, где требуется субквадратичная сверхлинейность.

2.5 Численные эксперименты

В этом разделе представлены два эксперимента, прямо подтверждающих утверждения теоретической части главы: эволюция аппроксимации якобиана (проверка bounded deterioration по теореме 2.11) и проверка корректности limited-memory варианта Алгоритма 3 из §2.4.

Эволюция аппроксимации якобиана (проверка теоремы 2.11). Прямое измерение нормы $\|B_k - J(x_k)\|_F$ по итерациям на стандартной задаче Discrete BVP [9] размерности $n = 100$ (дискретизация $u'' + (u + t + 1)^3/2 = 0$, $u(0) = u(1) = 0$) приведено на Рис. 1. Для статистической корректности взято 20 случайных стартов $x_0 = x_0^{\text{def}} + 0,05 u_i$ с единичными $u_i \in \mathbb{R}^{100}$ (фиксированный seed), для каждого старта запущен каждый метод; на рисунке — медианная траектория $\|B_k - J(x_k)\|_F$ и затенённая полоса между 25- и 75-перцентилями. Якобиан $J(x_k)$ считается аналитически. По всем 20 стартам $\|E_k\|_F$ остаётся *ограниченной* вдоль траектории и убывает, что является прямой эмпирической верификацией оценки (24); SP-Broyden ($p \leq 5$, $p \leq 10$) достигает финального уровня $\|B - J\|_F \approx 5,7$ за медиану 141–145 итераций, классический Бройден — ≈ 7 за медиану 325 итераций. IQR-полосы у SP-Broyden особенно узкие (≤ 8 итераций при медианных ~ 145), что свидетельствует об устойчивости поведения к выбору x_0 .




Рисунок 1. Discrete BVP, $n = 100$, 20 случайных стартов из окрестности x_0 по умолчанию. Медианная траектория $\|B_k - J(x_k)\|_F$ для классического Бройдена ($p = 0$) и SP-Broyden ($p \leq 5$, $p \leq 10$); затенённая полоса — IQR между 25- и 75-перцентилями. Якобиан $J(x_k)$ вычислен аналитически.

Корректность L-SP-Broyden в высокой размерности. Для проверки эквивалентности рекурсии (47) плотной форме (46) при $m \geq p + 1$ проведено сравнение на задаче Broyden Banded (MGN #31, [9]) при $n \in \{10^4, 10^5\}$ для случайных стартов $x_0 = -0,1 \cdot \mathbf{1} + 0,05 u_i$ с единичными $u_i \in \mathbb{R}^n$ (фиксированный seed). При $n = 10^4$ плотный SP-Broyden-SM ($p \leq 5$) выступает baseline'ом ($n^2 = 10^8$ чисел с плавающей точкой ≈ 800 МБ оперативной памяти, 3 старта); при $n = 10^5$ плотная форма принципиально неприменима ($n^2 = 10^{10}$ чисел с плавающей точкой ≈ 80 ГБ). L-SP-Broyden запускается с $m \in \{5, 10, 20\}$ ($n = 10^4$, 8 стартов) и $m \in \{10, 20\}$ ($n = 10^5$, 4 старта). Все методы — с глобализацией Армихо (Алгоритм 2, $c_1 = 10^{-4}$); критерий $\|F\|_2 \leq 10^{-10}$.

При $n = 10^4$ L-SP-Broyden ($m = 20$) практически точно совпадает с плотным SP-Broyden-SM (медианы 34 vs 33 итераций; кривые сливаются на рисунке) — прямая эмпирическая верификация эквивалентности (47) при $m \geq p + 1$. Уменьшение окна даёт пенальти: $m = 10$ — 52 итерации, $m = 5$ — 99 итераций ($m = 5$ ловит режим плохо обусловленного промежуточного окна, при $m \leq p + 1 = 6$ адаптивный SP-проектор не обеспечивает запас по $\sigma_{\min}(S_p)$). При $n = 10^5$ L-SP-Broyden сходится за медиану 49 итераций ($m = 20$) и 59 итераций ($m = 10$), что качественно согласуется с поведением при $n = 10^4$ — число итераций на сходимость limited-memory варианта *не растёт* с n .




Рисунок 2. Broyden Banded. Медианная траектория $\|F(x_k)\|_2 + \text{IQR}$ по случайным стартам. Слева — $n = 10^4$ с плотным SP-Broyden-SM ($p \leq 5$, чёрный пунктир) как baseline; справа — $n = 10^5$, где плотная форма требует ≈ 80 ГБ оперативной памяти и неприменима.

Глава 3

Симметричные квазиньютоновские обновления с контролем текущих условий

3.1 Мотивация

В предыдущих разделах метод SP-Broyden решил задачу сохранения текущих условий для общих систем $F(x) = 0$, однако матрица B_k при этом несимметрична. Для задач безусловной оптимизации, где $F = \nabla f$ и $J^* = \nabla^2 f(x^*)$ симметричен, естественно требовать $B_k = B_k^\top$.

Классические симметричные квазиньютоновские обновления — SR1 (*symmetric rank-one*, Дэвидон [16]) и PSB (*Powell symmetric Broyden*, Пауэлл [17]) — удовлетворяют текущему текущему условию $B_{k+1}s_k = y_k$, но не контролируют невязку прошлых текущих $R_{\text{past}} = B_k s_{\text{past}} - Y_{\text{past}}$. Следующая теорема показывает, что одновременное точное выполнение всех текущих и симметрии невозможно.

Теорема 3.1 (Несовместность симметрии и одновременного сохранения всех текущих).

Пусть $B_k \in \mathbb{R}^{n \times n}$ удовлетворяет всем прошлым текущим условиям $B_k s_j = y_j$ ($j = 0, \dots, k-1$), и пусть симметричное обновление $B_{k+1} = B_k + \Delta B$, $\Delta B = \Delta B^\top$, сохраняет все текущие до k -й включительно:

$$B_{k+1}s_j = y_j \quad (j = 0, \dots, k-1), \quad B_{k+1}s_k = y_k.$$

В терминах поправки ΔB это означает

$$\Delta B s_j = 0 \quad (j = 0, \dots, k-1), \quad \Delta B s_k = r_k, \quad r_k := y_k - B_k s_k.$$

Тогда остаток r_k обязан быть ортогонален всем прошлым шагам:

$$s_j^\top r_k = 0 \quad \forall j < k. \quad (49)$$

Доказательство.

Для произвольного $j < k$:

$$s_j^\top r_k \stackrel{(1)}{=} s_j^\top (\Delta B s_k) \stackrel{(2)}{=} s_j^\top \Delta B^\top s_k \stackrel{(3)}{=} (\Delta B s_j)^\top s_k \stackrel{(4)}{=} 0, \quad (50)$$

где (1) — текущее секущее условие $\Delta B s_k = r_k$; (2) — симметрия $\Delta B = \Delta B^\top$; (3) — тождество $u^\top A^\top v = (Au)^\top v$; (4) — сохранение j -й прошлой секущей $\Delta B s_j = 0$. ■

Замечание 3.2 (Когда условие (49) выполнено). Пусть $F = \nabla f$, $f \in C^2$. По интегральной форме теоремы о среднем для градиента

$$y_j = \nabla f(x_j + s_j) - \nabla f(x_j) = \bar{H}_j s_j, \quad \bar{H}_j := \int_0^1 \nabla^2 f(x_j + t s_j) dt,$$

где $\bar{H}_j$ — средний гессиан вдоль j -го шага (симметричен). Если B_k симметричен и удерживает прошлые секущие $B_k s_j = y_j$, то $s_j^\top B_k = (B_k s_j)^\top = (\bar{H}_j s_j)^\top = s_j^\top \bar{H}_j$, и левая часть (49) принимает вид

$$s_j^\top r_k = s_j^\top y_k - s_j^\top B_k s_k = s_j^\top \bar{H}_k s_k - s_j^\top \bar{H}_j s_k = s_j^\top (\bar{H}_k - \bar{H}_j) s_k. \quad (51)$$

Случай квадратичной f . Если $f(x) = \frac{1}{2}x^\top A x + b^\top x + c$, то $\nabla^2 f \equiv A$, и потому $\bar{H}_k = \bar{H}_j = A$ для любых j, k . Правая часть (51) обращается в нуль тождественно, условие (49) выполнено автоматически — симметричное обновление, одновременно удерживающее все секущие, существует (и это ΔB , восстанавливающая A).

Случай неквадратичной f . Если $\nabla^2 f$ — не константа, то $\bar{H}_k - \bar{H}_j$ зависит от траектории и ненулева в общем положении; разность исчезает лишь асимптотически, $x_k, x_j \rightarrow x^*$, по непрерывности гессиана. Поэтому в произвольной конечной окрестности условие (49) не выполнено — симметричного обновления, точно удерживающего все секущие, в общем случае *не существует*. Это и есть та жёсткость, которую в §3.2 снимает SS-конструкция: вместо точного удержания прошлых секущих минимизируется их остаток в ортогональном к s_k дополнении.

3.2 Конструкция и алгоритм SS- $\mathcal{U}$

Определение 3.3 (Секантно-стабилизированное обновление).

Пусть $\mathcal{U}$ — базовое симметричное квазиньютоновское обновление, удовлетворяющее

текущему секущему условию $\mathcal{U}(B_k, s_k, y_k) s_k = y_k$. Секантно-стабилизированное расширение SS- $\mathcal{U}$:

$$B_{k+1} = \underbrace{\mathcal{U}(B_k, s_k, y_k)}_{B'_k} + \sigma_k^* u_k^* u_k^{*\top}, \quad u_k^* \perp s_k, \quad \|u_k^*\| = 1, \quad (52)$$

где u_k^* — ведущий собственный вектор матрицы $P_k M'_k P_k$,

$$M'_k = \frac{1}{2}(R'_k S_p^\top + S_p R_k'^\top), \quad R'_k = B'_k S_p - Y_p, \quad P_k = I - \hat{s}_k \hat{s}_k^\top,$$

а σ_k^* выбирается из минимума $\|R'_k + \sigma u^* u^{*\top} S_p\|_F^2$:

$$\sigma_k^* = -\frac{u_k^{*\top} R'_k S_p^\top u_k^*}{\|S_p^\top u_k^*\|^2}. \quad (53)$$

Базовые обновления $\mathcal{U}$. Алгоритм SS- $\mathcal{U}$, приведённый ниже, не зависит от выбора $\mathcal{U}$, кроме явного вычисления $B'_k = \mathcal{U}(B_k, s_k, y_k)$ на Шаге 1. В численных экспериментах настоящей главы рассматриваются два классических indefinitных симметричных обновления:

$$\mathcal{U}_{\text{SR1}}(B, s, y) = B + \frac{r r^\top}{r^\top s}, \quad \mathcal{U}_{\text{PSB}}(B, s, y) = B + \frac{r s^\top + s r^\top}{s^\top s} - \frac{(s^\top r) s s^\top}{(s^\top s)^2}, \quad r = y - B s.$$

SR1 требует skip-rule [7, §6.2]: при $|s^\top r| < \varepsilon_{\text{skip}} \|s\| \|r\|$ обновление пропускается, $B'_k = B_k$. PSB skip-правил не требует. SS-расширение строится по единому шаблону (52), ниже — общий псевдокод.

Реализация (52) вносит две численные проверки на стороне MS-коррекции — вырождение u_k^* после репроекции на $s_k^\perp$ (порог ε_u) и устойчивость знаменателя σ_k^* (порог ε_S); конкретное базовое $\mathcal{U}$ может вносить свой safeguard (skip-rule для $\mathcal{U} = \text{SR1}$). Ключевое наблюдение для Шага 3: $M'_k = \frac{1}{2}(R'_k S_p^\top + S_p R_k'^\top)$ — сумма двух матриц ранга $\leq p + 1$, поэтому

$$\text{rank}(P_k M'_k P_k) \leq \text{rank}(M'_k) \leq 2(p + 1), \quad (54)$$

и весь ненулевой спектр $A_k = P_k M'_k P_k$ лежит в $\text{range}(P_k [S_p, R'_k])$. Собственная задача переносится из $\mathbb{R}^n$ в подпространство размерности $r \leq 2(p + 1)$ через QR-ортогонализацию этого базиса (приём, стандартный для блочных Ланцош-итераций [28, Гл. 13]; ср. также подход Fang–Saad [6] для мультисекантных схем). Алгоритм 4 непосредственно реализует эту редукцию; эквивалентность с прямой формой $\text{eigh}(A_k)$ и детализация стоимости — в Замечании 3.4.

Algorithm 4 SS- $\mathcal{U}$ (∇f , x_0 , $p_{\max}$, ε ; $\mathcal{U}$, ε_u , ε_S)

Require: $\nabla f: \mathbb{R}^n \rightarrow \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$, $p_{\max} \geq 0$, $\varepsilon > 0$

Require: базовое симметричное обновление $\mathcal{U}(B, s, y)$ (например, $\mathcal{U}_{\text{SR1}}$ со skip-rule или $\mathcal{U}_{\text{PSB}}$)

Require: (численные пороги MS-коррекции; стандартные значения)

$\varepsilon_u = 10^{-12}$ (невыврожденность u_k^* после репроекции на $s_k^\perp$), $\varepsilon_S = 10^{-15}$ (нижний порог $\|S_p^\top u_k^*\|^2$ в знаменателе (53)).

$B_0 \leftarrow I_n$, $k \leftarrow 0$

while $\|\nabla f(x_k)\| \geq \varepsilon$ **do**

Решить $B_k d_k = -\nabla f(x_k)$

$\alpha_k \leftarrow$ Armijo-backtracking на f (Алгоритм 2, $\phi = f$, §2.3)

$x_{k+1} \leftarrow x_k + \alpha_k d_k$, $s_k \leftarrow \alpha_k d_k$, $y_k \leftarrow \nabla f(x_{k+1}) - \nabla f(x_k)$

$B'_k \leftarrow \mathcal{U}(B_k, s_k, y_k)$ $\triangleright B'_k = B_k$, если $\mathcal{U}$ срабатывает skip-rule

$p \leftarrow \min(p_{\max}, k)$

$S_p \leftarrow [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}]$, $Y_p \leftarrow [y_k \mid y_{k-1} \mid \dots \mid y_{k-p}]$ $\triangleright n \times (p+1)$

if $p \geq 0$ **and** S_p непуста **then**

$R'_k \leftarrow B'_k S_p - Y_p$ $\triangleright n \times (p+1)$, $O(n^2 p)$

$\hat{s}_k \leftarrow s_k / \|s_k\|$

$W \leftarrow [S_p \mid R'_k] - \hat{s}_k (\hat{s}_k^\top [S_p \mid R'_k])$ $\triangleright n \times 2(p+1)$, $\text{range}(W) \perp \hat{s}_k$

$Q \leftarrow \text{qr_thin}(W)$ $\triangleright$ орт. базис $\text{range}(W)$, $n \times r$, $r \leq 2(p+1)$, $O(np^2)$

$\tilde{M} \leftarrow \frac{1}{2} [(Q^\top R'_k)(S_p^\top Q) + (Q^\top S_p)(R'_k^\top Q)]$ $\triangleright r \times r$, $\tilde{M} = Q^\top M'_k Q$

$\tilde{M} \leftarrow \frac{1}{2}(\tilde{M} + \tilde{M}^\top)$ $\triangleright$ симметризация против ошибок плавающего

$(\lambda_i, v_i)_{i=1}^r \leftarrow \text{eigh}(\tilde{M})$ $\triangleright O(p^3)$

$j \leftarrow \arg \max_i |\lambda_i|$, $u \leftarrow Q v_j$ $\triangleright$ ведущий по $|\lambda|$, поднят в $\mathbb{R}^n$

$u \leftarrow u - (u^\top \hat{s}_k) \hat{s}_k$ $\triangleright$ репроекция на $s_k^\perp$ (ФР-страховка)

if $\|u\| < \varepsilon_u$ **then**

$B_{k+1} \leftarrow B'_k$ $\triangleright$ вырождение направления коррекции

else

$u \leftarrow u / \|u\|$, $\eta \leftarrow S_p^\top u$

if $\|\eta\|^2 < \varepsilon_S$ **then**

$B_{k+1} \leftarrow B'_k$ $\triangleright S_p^\top u \rightarrow 0$, нет информации о R_{past}

else

$\sigma_k^* \leftarrow -(u^\top R'_k \eta) / \|\eta\|^2$

$B_{k+1} \leftarrow B'_k + \sigma_k^* u u^\top$

else

$B_{k+1} \leftarrow B'_k$ $\triangleright k = 0$, окно пусто

$k \leftarrow k + 1$
return x_k

Замечание 3.4 (Стоимость и эквивалентность с прямой формой). Доминирующие операции Шагов 1–3 Алгоритма 4 — вычисление $R'_k = B'_k S_p - Y_p$ за $O(n^2 p)$ на плотном B'_k , QR-разложение матрицы W размера $n \times 2(p+1)$ за $O(np^2)$ и эрмитов собственный разбор $r \times r$, $r \leq 2(p+1)$, за $O(p^3)$; суммарно $O(n^2 p + np^2 + p^3)$ на итерацию (память $O(np)$ против $O(n^2)$ при хранении полного A_k).

Эквивалентная прямая форма — собрать $A_k = P_k M'_k P_k \in \mathbb{R}^{n \times n}$ явно и вызвать $\text{eigh}(A_k)$ напрямую (QR-итерация на трёхдиагонализированной форме [27, §8.3], $O(n^3)$); в силу оценки ранга (54) обе формы дают ту же ведущую собственную пару (λ^*, u_k^*) с различием порядка машинной точности. В численных экспериментах главы $n \leq 50$, и обе формы пренебрежимы по стоимости относительно вычисления ∇f и LU-решения системы $B_k d_k = -\nabla f$ (последнее — $O(n^3)$); фактически используется прямая форма $\text{eigh}(A_k)$, согласованная с Шагом 3 Алгоритма 4 в пределах машинной точности. Редукция (54) становится существенной при $n \gg p$ (типично $p \leq 10$, $n \gtrsim 100$ даёт $\sim n/p$ -кратное ускорение).

3.3 Свойства

Теорема 3.5 (Свойства SS- $\mathcal{U}$).

Обновление (52) обладает следующими свойствами:

1. *Текущее секущее условие:* $B_{k+1} s_k = y_k$ (точно).
2. *Симметрия:* если $\mathcal{U}$ сохраняет симметрию, то $B_{k+1} = B_{k+1}^\top$.
3. *Монотонность:* $\|R_{\text{past}}^{(k+1)}\|_F^2 \leq \|R'_{\text{past}}\|_F^2 - \frac{(u_k^{*\top} M'_k u_k^*)^2}{\|S_p^\top u_k^*\|^2}$.
4. *Ранг обновления:* $\text{rank}(B_{k+1} - B_k) \leq \text{rank}(\mathcal{U}) + 1$.

Доказательство.

1. Из $u_k^* \perp s_k$: $B_{k+1} s_k = B'_k s_k + \sigma_k^* (u_k^{*\top} s_k) u_k^* = y_k + 0 = y_k$.
2. $B_{k+1} = B'_k + \sigma_k^* u_k^* u_k^{*\top}$ — сумма двух симметричных матриц.
3. Пусть $\tilde{B} = B'_k + \sigma u u^\top$. Тогда $\|\tilde{B} S_p - Y_p\|_F^2 = \|R'\|_F^2 + 2\sigma (u^\top M' u) + \sigma^2 \|S_p^\top u\|^2$. Минимум по σ при (53) даёт убывание на $(u^\top M' u)^2 / \|S_p^\top u\|^2$.
4. Очевидно из конструкции. ■

3.4 Сверхлинейная сходимость

Теорема 3.6 (Условная Q-сверхлинейная сходимость SS- $\mathcal{U}$).

Пусть выполнены предположения:

- (H1) $F = \nabla f$, гессиан $\nabla^2 f$ липшицев в окрестности x^* с константой L_H ;
- (H2) метод SS- $\mathcal{U}$ сходится: $x_k \rightarrow x^*$, $s_k \rightarrow 0$, $\nabla f(x^*) = 0$;
- (H3) предельный гессиан $J^* := \nabla^2 f(x^*)$ невырожден;
- (H4) начиная с некоторого k_0 глобализация выдаёт полный квазиньютоновский шаг $s_k = -B_k^{-1} \nabla f(x_k)$, причём $\|B_k^{-1}\| \leq M_*$ равномерно при $k \geq k_0$;
- (H5) аппроксимация устойчива по приращениям: $\|B_{k+1} - B_k\|_F \leq C_B \|s_k\|$ при некоторой $C_B \geq 0$ в окрестности x^* .

Тогда:

1. (условие Денниса–Море)

$$\frac{\|(B_k - J^*) s_k\|}{\|s_k\|} \leq L_H(\|x_k - x^*\| + \|s_k\|) + C_B \|s_k\| \xrightarrow{k \rightarrow \infty} 0;$$

2. (Q-сверхлинейность) $\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \rightarrow 0$.

Доказательство.

Шаг 1 (DM-условие для B_{k+1}). Из точного секущего условия $B_{k+1} s_k = y_k$ (Теорема 3.5.1):

$$(B_{k+1} - J^*) s_k = y_k - J^* s_k = \int_0^1 [\nabla^2 f(x_k + t s_k) - \nabla^2 f(x^*)] s_k dt.$$

По (H1) $\|\nabla^2 f(x_k + t s_k) - \nabla^2 f(x^*)\| \leq L_H(\|x_k - x^*\| + \|s_k\|)$, откуда

$$\|(B_{k+1} - J^*) s_k\| \leq L_H(\|x_k - x^*\| + \|s_k\|) \|s_k\|. \quad (55)$$

Шаг 2 (перенос на B_k). По (H5) $\|B_{k+1} - B_k\|_F \leq C_B \|s_k\|$, откуда

$$\|(B_k - J^*) s_k\| \leq \|(B_{k+1} - J^*) s_k\| + \|B_{k+1} - B_k\| \cdot \|s_k\| \leq [L_H(\|x_k - x^*\| + \|s_k\|) + C_B \|s_k\|] \|s_k\|.$$

Деление на $\|s_k\|$ и применение (H2) дают пункт 1.

Шаг 3 (Q-сверхлинейность через характеризацию Денниса–Море). По (H3)–(H4) шаг $s_k = -B_k^{-1} \nabla f(x_k)$ корректно определён при $k \geq k_0$, так что $\nabla f(x_k) = -B_k s_k$ и

$$\|\nabla f(x_k) + J^* s_k\| = \|(J^* - B_k) s_k\| = \|(B_k - J^*) s_k\|.$$

Согласно характеристике Денниса–Море [11, Th. 2.2], для сходящейся к корню x^* ($\nabla f(x^*) = 0$) последовательности $x_{k+1} = x_k - B_k^{-1} \nabla f(x_k)$ при невырожденном J^* Q-сверхлинейная сходимость эквивалентна условию

$$\frac{\|\nabla f(x_k) + J^* s_k\|}{\|s_k\|} \xrightarrow{k \rightarrow \infty} 0,$$

т. е. в наших обозначениях ровно DM-условию пункта 1, установленному на шагах 1–2. Применяя эквивалентность, получаем $\|x_{k+1} - x^*\|/\|x_k - x^*\| \rightarrow 0$. ■

Замечание 3.7 (Роль предположений). Предположения (H3) и (H4) суть стандартные локальные допущения о хорошей обусловленности задачи: невырожденность J^* нужна для применимости Денниса–Море [11], а допустимость полного шага в окрестности x^* — классическое следствие условия Армихо с $c_1 < 1/2$ для дважды-дифференцируемой f ([7], Th. 3.6). Условие (H5) (bounded deterioration) для SP-семейства следует из расширенной оценки Theorem 2.11 (b) ($\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 + O(\|s_k\|^2)$); для SR1 без MS-коррекции (H5) может нарушаться, что даёт практические расходимости [13], наблюдаемые в численных экспериментах §3.5 (см. рис. 3, нижний ряд, панель $n = 50$: SR1 сходится 47/50, тогда как SS-SR1 — 50/50).

Замечание 3.8 (Скорость теоремы 3.6 разделяется с базовым обновлением). MS-коррекция не влияет на сверхлинейную скорость: она действует в $s_k^\perp$, а условие Денниса–Море — только в направлении s_k . Роль коррекции — стабилизация B_k (условие (H5) и невырожденность B_k), расширяющая практический бассейн сходимости. Более того, само доказательство Th. 3.6 использует от SS- $\mathcal{U}$ только текущее секующее условие $B_{k+1}s_k = y_k$, выполняемое и базовым обновлением; поэтому при выполнении (H1)–(H5) тем же аргументом Q-сверхлинейная скорость следует и для базового SR1 (классический результат Конна–Гулда–Тойнта, Халфана–Бёрда–Шнабеля); узкое место в этом случае — посылка (H2) (бассейн сходимости) и условие (H5), ровно те два пункта, которые и предназначена закрывать MS-коррекция.

Следствие для эмпирической части. Поскольку асимптотическая скорость, заявленная в Th. 3.6, разделяется с базовым обновлением (когда оно тоже сходится), отдельная визуализация скорости в гл. 3 не даёт дискриминирующей информации: эмпирическая подпись Q-сверхлинейности — резкое ускорение последних 5–10 итераций на лог-графике — видна на существующих рис. 3 и 4 для любой сошедшейся траектории (SR1, SS-SR1, PSB, SS-PSB). Дискриминатор SS-конструкции — предпосылка (H2), т. е. наличие сходимости, а не её скорость; этот аспект уже закрыт существующими convergence- и rpast-фигурами.

3.5 Численные результаты

Постановка статистического эксперимента. Для общего случая ведущий собственный вектор u_k^* матрицы $P_k M'_k P_k$ (см. Опр. 3.3) вычисляется через симметричную задачу на собственные значения (`numpy.linalg.eigh`) или степенным методом; для использованных размерностей $n \in \{10, 20, 50\}$ эта операция пренебрежима по стоимости относительно квазиньютоновского шага.

Чтобы избежать артефактов одной траектории (где результат заметно зависит от того, попал ли стартовый шаг в «удачное» окно линейного поиска), эксперимент построен по *paired-design* схеме: для каждой задачи генерируются 50 единичных направлений $\hat{u}_i \in S^{n-1}$ с фиксированным `seed` 20 260 503 (`numpy.random.default_rng`), и стартовая точка $x_0^{(i)} = R_0 \hat{u}_i$ берётся на сфере радиуса $R_0 = \|x_0^{\text{std}}\|$, где x_0^{std} — стандартная стартовая точка задачи. Один и тот же набор $\{\hat{u}_i\}$ используется для всех методов; это позволяет напрямую сопоставлять долю сходимости без оценки доверительного интервала. Все методы используют общий *backtracking-Armijo* ($c_1 = 10^{-4}$, откат $\alpha/2$, до 40 откатов), $B_0 = I$, окно прошлых секущих $p = 5$, критерий останова $\|\nabla f\|_2 \leq 10^{-8}$ или 500 итераций; направление шага $d_k = -B_k^{-1} \nabla f(x_k)$ через LU-разложение системы.

Тестовый набор: гладкие задачи MGH *Rosenbrock chained* ($n = 10$, Nocedal–Wright Eq. 2.22) и *Extended Rosenbrock* ($n = 10$, MGH #21) — контроль на отсутствие деградации; задача с узкой искривлённой долиной *Extended Curved Valley* (блочно по 2 координаты, $f(x_1, x_2) = \frac{\alpha}{2}(x_2 - \beta x_1^2)^2 + \frac{1}{2}(x_1^2 + x_2^2)$, $\alpha = 100$, $\beta = 1,5$, x_0^{std} блочно $= (1,8; 1,8)$) — стресс-тест на стабилизацию, прогоняемый при $n \in \{10, 20, 50\}$ для оценки масштабируемости.

Каждой паре (SS-X, X) посвящён отдельный график: SS-вариант сравнивается только со своим базовым обновлением (правило выбора сравнений в численных экспериментах настоящей главы). Ниже последовательно разбираются обе пары — SR1/SS-SR1 и PSB/SS-PSB.

Прямая иллюстрация теоремы 3.5, п. 3: динамика накопленной невязки на паре PSB / SS-PSB. Convergence-кривые рис. 3 и 4 показывают итоговую долю сходимости и медианное число итераций, но оставляют открытым прямой вопрос: действительно ли MS-коррекция *ограничивает* накопленную невязку $\|B_k S_p - Y_p\|_F$ в смысле теоремы 3.5, п. 3? Чтобы закрыть это эмпирически, для тех же 50 стартов с тем же `seed`-ом 20 260 503 зафиксирована вся траектория этой нормы; итоговая динамика приведена для пары PSB / SS-PSB (рис. 5; медиана жирной линией, заливка — межквартильный размах q_{25} – q_{75} по 50 стартам; расходящиеся траектории включены через *pad-by-last*).

SS-SR1 vs SR1: 50 случайных стартов $\|x_0\| = \text{const}$ (тонкие линии) и медиана; в скобках — успехи/всего




Рисунок 3. SS-SR1 vs SR1: сходимость $\|\nabla f(x_k)\|_2$ на пяти тестовых конфигурациях. Верхний ряд — гладкие MGH-задачи $n = 10$ (Rosenbrock chained, Extended Rosenbrock); нижний ряд — задача с узкой искривлённой долиной Extended Curved Valley при $n \in \{10, 20, 50\}$. По 50 случайных стартов на сфере $\|x_0\| = R_0 = \|x_0^{\text{std}}\|$ (тонкие линии), медиана жирной линией; в легенде указано число сошедшихся стартов из 50. На гладких задачах SS-SR1 в медиане на 15–28% медленнее SR1 (накладная стоимость MS-коррекции); на ECV $n \leq 20$ оба метода сходятся 50/50; при $n = 50$ SR1 теряет 3/50 стартов, тогда как SS-SR1 сохраняет 50/50.

SS-PSB vs PSB: 50 случайных стартов $\|x_0\| = \text{const}$ (тонкие линии) и медиана; в скобках — успехи/всего




Рисунок 4. SS-PSB vs PSB: те же пять конфигураций, что на рис. 3. Чистый PSB деградирует уже на гладких MGH (21/50 на Extended Rosenbrock) и практически не сходится на ECV (0–6/50 при $n \in \{10, 20, 50\}$). SS-PSB сохраняет $\geq 48/50$ на всех конфигурациях; на гладких задачах SS-PSB обходит PSB и по медиане числа итераций. Иллюстрация того, что MS-коррекция способна спасти indefinitные базовые обновления с сильной деградацией.

Пара PSB / SS-PSB выбрана как чистая иллюстрация по двум причинам. Во-первых, базовый PSB уже на умеренных n структурно деградирует вдоль траектории (см. рис. 4: 0–6/50 сходимости на ECV); это даёт MS-коррекции достаточно *материала* для работы и делает разрыв $\|B_k S_p - Y_p\|_F$ визуально разрешимым. Во-вторых, для пары SR1 / SS-SR1 базовый SR1 на использованных режимах часто и без MS-коррекции удерживает $\|B_k S_p - Y_p\|_F$ на приемлемом уровне (что отражает ограничение самой теоремы Th. 3.6: MS-коррекция нужна там, где SR1 *реально* деградирует, и не создаёт преимущества там, где уже не деградирует), так что прямая grast-картинка для этой пары читается хуже, чем косвенная сходимостная метрика рис. 3; пара оставлена иллюстрироваться через convergence на рис. 3.

Картина на рис. 5 согласуется со структурным предсказанием. На всех пяти конфигурациях SS-PSB снижает медиану $\|B_k S_p - Y_p\|_F$ на 3–5 порядков относительно PSB. Особенно показателен ECV $n = 20$, где PSB не сходится ни на одном из 50 стартов: $\|B_k S_p - Y_p\|_F$ у него остаётся выше 10^{-3} , тогда как SS-PSB планомерно снижает её до $\sim 10^{-7}$. Это прямая эмпирическая поддержка утверждения 3 теоремы 3.5: оценка $\left\|R_{\text{past}}^{(k+1)}\right\|_F^2 \leq \|R'_{\text{past}}\|_F^2 - (u_k^{*\top} M'_k u_k^*)^2 / \|S_p^\top u_k^*\|^2$ выполнена по построению на каждом шаге; интегральный эффект — системно меньшая медиана $\|B_k S_p - Y_p\|_F$ — наблюдается именно там, где базовое обновление действительно теряет устойчивость.

Сводный вывод. SS-конструкция Опр. 3.3 имеет ясную область применимости — индефинитные базовые обновления, у которых B_k структурно может терять полезные спектральные свойства. На двух таких базовых обновлениях — SR1 и PSB — MS-коррекция эмпирически подтверждает свою роль ограничителя накопленной невязки $\|B_k S_p - Y_p\|_F$ (теорема 3.5, п. 3): рис. 5 — медиана $\|B_k S_p - Y_p\|_F$ у SS-PSB системно ниже PSB на 3–5 порядков, на ECV $n = 20$ PSB не сходится, а SS-PSB планомерно снижает невязку до $\sim 10^{-7}$. Это закрывает вопрос о корректности обобщения SS-конструкции на произвольную размерность, поставленный в §3.2: ограниченность $\|B_k S_p - Y_p\|_F$ на всём окне — именно тот эффект, который MS-коррекция должна давать по построению.

SS-PSB vs PSB: накопленная невязка прошлых секущих $\|B_k S_p - Y_p\|_F$. 50 стартов; медиана (жирная) и IQR (q25-q75, заливка)




Рисунок 5. Накопленная невязка прошлых секущих $\|B_k S_p - Y_p\|_F$ для пары PSB / SS-PSB на тех же пяти конфигурациях, что и рис. 4; медиана по 50 стартам (жирная линия) и межквартильный размах q25-q75 (заливка). Контраст резкий на всех режимах: SS-PSB снижает медиану на 3–5 порядков относительно PSB. На ECV $n = 20$ PSB не сходится (0/50), а $\|B_k S_p - Y_p\|_F$ у него остаётся выше 10^{-3} — структурная причина отказа базового обновления, против которой и работает MS-коррекция. Прямая эмпирическая поддержка теоремы 3.5, п. 3.

Заключение

Основные результаты работы

В работе развита единая точка зрения на квазиньютоновские обновления с памятью прошлых секущих условий и последовательно применена к задачам нелинейных систем и гладкой оптимизации. Ключевые результаты по главам перечислены ниже.

Глава 1 (приближение якобиана). Выведена общая формула семейства мультисекантных обновлений

$$B_{k+1} = \widehat{B}_k + (Y_m - \widehat{B}_k S_m) (V_m^\top S_m)^{-1} V_m^\top,$$

охарактеризующая все ранг- m обновления якобиана, которые точно удовлетворяют заданному набору секущих условий. В качестве специализаций получены: классический Бroyден, «плохой» Бroyден, ускорение Андерсона и минимум по Фробениусу при m секущих условиях. Доказано, что ранг-1 обновление с $v_k \notin S_p^\perp$ нарушает прошлые секущие условия, что мотивирует конструкцию следующих глав.

Глава 2 (SP-Broyden). Построено обновление SP-Broyden, сохраняющее p прошлых секущих условий за счёт выбора направления $v_k^* = S_p G_p^{-1} e_1$, где $G_p = S_p^\top S_p$ — грамиан окна. Доказаны две ключевые теоремы:

- **Теорема минимальности (2.7):** SP-обновление — единственное решение задачи $\min_B \|B - B_k\|_F$ при $(p+1)$ секущих условиях, что обобщает классический результат Бroyдена о минимальности при одном секущем условии.
- **Теорема об ограниченной деградации с расширенным проектором (2.11):** получено точное разложение $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$ с проектором Π_k ранга $p+1$ (у классического Бroyдена — ранга 1) и оценка прироста $\Delta_k = O(\sigma_{\min}^{-2}(S_p) \cdot \sum_j \|x_j - x^*\|^2 \|s_j\|^2)$. Доказано строгое неравенство $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$: отрицательный член снимает с матрицы ошибки не

меньше информации, чем у классического Бройдена, и сохраняются $p+1$ текущих условий $B_{k+1}s_j = y_j, j = k-p, \dots, k$.

Предложен адаптивный выбор глубины p по числу обусловленности грамиана G_p , позволяющий автоматически сужать окно, когда прошлые текущие условия становятся коллинеарны. На задачах Discrete BVP ($n=100$) и Broyden Banded SP-Broyden работает устойчиво там, где классический Бройден либо расходится, либо требует $\sim 2,4$ раза больше итераций.

Глава 3 (SS-U и SS-SR1). Доказана теорема о несовместности точного сохранения p прошлых текущих условий с требованием симметрии (3.1): систему одновременно нельзя удовлетворить в общем положении. Предложено разрешение несовместности через конструкцию SS-U: симметричная ранг-1 коррекция $\sigma_k^* u_k^* (u_k^*)^\top$ в ортогональном дополнении $s_k^\perp$, подавляющая накопленные невязки прошлых текущих условий. Установлены:

- точное выполнение текущего текущего условия и симметрия (3.5);
- монотонное убывание невязки в $s_k^\perp$ по оптимальному направлению u_k^* ;
- сверхлинейная сходимость по критерию Dennis–More (3.6);
- расширение бассейна сходимости в 1,5–2 раза по сравнению с SR1 на семействе Curved Valley (эмпирический закон $R(\text{SR1}) \sim (\alpha\beta)^{-0,42}$ против $R(\text{SS-SR1}) \sim (\alpha\beta)^{-0,14}$).

Связь результатов

Главы работы связаны сквозной идеей: выбор направления обновления v_k , сохраняющий прошлые текущие условия, расширяет проектор bounded deterioration с ранга 1 до ранга $p+1$, что, в свою очередь, последовательно отражается на наблюдаемых и гарантированных свойствах итерационного процесса. В нелинейных системах (глава 2) это приводит к ускорению и устойчивости там, где классический Бройден неустойчив; в оптимизации (глава 3) — к расширению бассейна сходимости при сохранении сверхлинейности. Таким образом, расширение проектора bounded deterioration от ранга 1 (классический Бройден) до ранга $p+1$ (SP-Broyden) вместе с сохранением $p+1$ текущих условий — содержательное уточнение анализа классических методов, дающее на каждой итерации строго не меньше информации об ошибке аппроксимации якобиана.

Направления дальнейших исследований

- **Высокая размерность и limited memory.** Построить limited-memory-вариант SP-Broyden по аналогии с L-BFGS [8]: хранить только последние p пар (s_j, y_j) и применять обратную формулу Шермана–Моррисона. Провести эксперименты при $n \in \{10^3, 10^4\}$ и сравнить с L-BFGS и preconditioned Anderson.
- **Обобщение SS-U на не гладкие задачи.** Построить негладкий аналог SS-U (proximal-SS-U) для композитных задач $\min f(x) + g(x)$ и исследовать его скорость на задачах с разреженной регуляризацией.
- **Практическая валидация на прикладных задачах.** Применить SP-Broyden к задачам обучения (нелинейные системы, возникающие в физически-информированных нейронных сетях), а также к равновесным моделям из экономики.
- **Численная валидация глобализации.** Алгоритм 2 (общий шаблон “QN + Armijo”) и теорема 2.17 о глобальной сходимости (по Цоутендейку) предложены в §2.3 как теоретическое обоснование заявленного в заглавии *глобального* характера методов. Систематическое сравнение линейного поиска и trust-region модификаций на широком тестовом наборе Moré–Garbow–Hillstom — предмет дальнейшей численной валидации.
- **Корректная реализация и сравнение с современным Anderson.** Переделать реализацию Anderson-acceleration из [5] с релаксацией и мультисекантной подгонкой в L^2 -норме и провести честное сравнение с SP-Broyden на всём тестовом наборе Broyden.

Литература

- [1] Broyden C. G. A class of methods for solving nonlinear simultaneous equations // Math. Comp. — 1965. — V. 19(92). — P. 577–593. doi: [10.1090/S0025-5718-1965-0198670-6](https://doi.org/10.1090/S0025-5718-1965-0198670-6).
- [2] Anderson D. G. Iterative procedures for nonlinear integral equations // J. ACM. — 1965. — V. 12(4). — P. 547–560. doi: [10.1145/321296.321305](https://doi.org/10.1145/321296.321305).
- [3] Dennis J. E., Moré J. J. Quasi-Newton methods, motivation and theory // SIAM Rev. — 1977. — V. 19(1). — P. 46–89. doi: [10.1137/1019005](https://doi.org/10.1137/1019005).
- [4] Dennis J. E., Schnabel R. B. Numerical Methods for Unconstrained Optimization and Nonlinear Equations. — Philadelphia: SIAM, 1996. doi: [10.1137/1.9781611971200](https://doi.org/10.1137/1.9781611971200).
- [5] Walker H. F., Ni P. Anderson acceleration for fixed-point iterations // SIAM J. Numer. Anal. — 2011. — V. 49(4). — P. 1715–1735. doi: [10.1137/10078356X](https://doi.org/10.1137/10078356X).
- [6] Fang H. R., Saad Y. Two classes of multiseant methods for nonlinear acceleration // Numer. Linear Algebra Appl. — 2009. — V. 16(3). — P. 197–221. doi: [10.1002/nla.617](https://doi.org/10.1002/nla.617).
- [7] Nocedal J., Wright S. J. Numerical Optimization. — 2nd ed. New York: Springer, 2006. doi: [10.1007/978-0-387-40065-5](https://doi.org/10.1007/978-0-387-40065-5).
- [8] Nocedal J. Updating quasi-Newton matrices with limited storage // Math. Comp. — 1980. — V. 35(151). — P. 773–782. doi: [10.1090/S0025-5718-1980-0572855-7](https://doi.org/10.1090/S0025-5718-1980-0572855-7).
- [9] Moré J. J., Garbow B. S., Hillstom K. E. Testing unconstrained optimization software // ACM Trans. Math. Softw. — 1981. — V. 7(1). — P. 17–41. doi: [10.1145/355934.355936](https://doi.org/10.1145/355934.355936).
- [10] Broyden C. G., Dennis J. E., Moré J. J. On the local and superlinear convergence of quasi-Newton methods // J. Inst. Math. Appl. — 1973. — V. 12(3). — P. 223–245. doi: [10.1093/imamat/12.3.223](https://doi.org/10.1093/imamat/12.3.223).
- [11] Dennis J. E., Moré J. J. A characterization of superlinear convergence and its application to quasi-Newton methods // Math. Comp. — 1974. — V. 28(126). — P. 549–560. doi: [10.1090/S0025-5718-1974-0343581-1](https://doi.org/10.1090/S0025-5718-1974-0343581-1).

- [12] Shanno D. F., Phua K. H. Matrix conditioning and nonlinear optimization // Math. Programming. — 1978. — V. 14(1). — P. 149–160. doi: [10.1007/BF01588962](https://doi.org/10.1007/BF01588962).
- [13] Conn A. R., Gould N. I. M., Toint Ph. L. Convergence of quasi-Newton matrices generated by the symmetric rank one update // Math. Programming. — 1991. — V. 50(1–3). — P. 177–195. doi: [10.1007/BF01594934](https://doi.org/10.1007/BF01594934).
- [14] Byrd R. H., Nocedal J., Schnabel R. B. Representations of quasi-Newton matrices and their use in limited memory methods // Math. Programming. — 1994. — V. 63(1–3). — P. 129–156. doi: [10.1007/BF01582063](https://doi.org/10.1007/BF01582063).
- [15] Liu D. C., Nocedal J. On the limited memory BFGS method for large scale optimization // Math. Programming. — 1989. — V. 45(1–3). — P. 503–528. doi: [10.1007/BF01589116](https://doi.org/10.1007/BF01589116).
- [16] Davidon W. C. Variable metric method for minimization // SIAM J. Optim. — 1991. — V. 1(1). — P. 1–17. (Originally: AEC Research and Development Report ANL-5990, Argonne National Laboratory, 1959.) doi: [10.1137/0801001](https://doi.org/10.1137/0801001).
- [17] Powell M. J. D. A new algorithm for unconstrained optimization // Nonlinear Programming (Rosen J. B., Mangasarian O. L., Ritter K., eds.). — New York: Academic Press, 1970. — P. 31–65. doi: [10.1016/B978-0-12-597050-1.50006-3](https://doi.org/10.1016/B978-0-12-597050-1.50006-3).
- [18] Powell M. J. D. On the convergence of the variable metric algorithm // J. Inst. Math. Applies. — 1971. — V. 7(1). — P. 21–36. doi: [10.1093/imamat/7.1.21](https://doi.org/10.1093/imamat/7.1.21).
- [19] Toth A., Kelley C. T. Convergence analysis for Anderson acceleration // SIAM J. Numer. Anal. — 2015. — V. 53(2). — P. 805–819. doi: [10.1137/130919398](https://doi.org/10.1137/130919398).
- [20] Fukushima M. Equivalent differentiable optimization problems and descent methods for asymmetric variational inequality problems // Math. Programming. — 1992. — V. 53(1–3). — P. 99–110. doi: [10.1007/BF01585696](https://doi.org/10.1007/BF01585696).
- [21] Greenbaum A. Iterative Methods for Solving Linear Systems. — Philadelphia: SIAM, 1997. (Series: Frontiers in Applied Mathematics, Vol. 17.) doi: [10.1137/1.9781611970937](https://doi.org/10.1137/1.9781611970937).
- [22] Bhatia R., Davis C. A better bound on the variance // Amer. Math. Monthly. — 2000. — V. 107(4). — P. 353–357. doi: [10.2307/2589180](https://doi.org/10.2307/2589180).
- [23] Armijo L. Minimization of functions having Lipschitz continuous first partial derivatives // Pacific J. Math. — 1966. — V. 16(1). — P. 1–3. doi: [10.2140/pjm.1966.16.1](https://doi.org/10.2140/pjm.1966.16.1).
- [24] Wolfe P. Convergence conditions for ascent methods // SIAM Rev. — 1969. — V. 11(2). — P. 226–235. doi: [10.1137/1011036](https://doi.org/10.1137/1011036).

- [25] Zoutendijk G. Nonlinear programming, computational methods // Integer and Non-linear Programming (Abadie J., ed.). — Amsterdam: North-Holland, 1970. P. 37–86. <https://www.sciencedirect.com/book/9780720420845>.
- [26] Marquardt D.W. An algorithm for least-squares estimation of nonlinear parameters // J. Soc. Indust. Appl. Math. — 1963. — V. 11(2). — P. 431–441. doi: 10.1137/0111030.
- [27] Golub G. H., Van Loan C. F. Matrix Computations. — 4th ed. Baltimore: Johns Hopkins University Press, 2013. ISBN 978-1-4214-0794-4. <https://jhupbooks.press.jhu.edu/title/matrix-computations>.
- [28] Parlett B.N. The Symmetric Eigenvalue Problem. — Philadelphia: SIAM, 1998. (Series: Classics in Applied Mathematics, Vol. 20.) doi: 10.1137/1.9781611971163.