

Федеральное государственное автономное
образовательное учреждение высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»

Физтех-школа прикладной математики и информатики
Кафедра проблем передачи информации и анализа данных

Направление подготовки: 09.04.01 Информатика и вычислительная техника

ИССЛЕДОВАНИЕ ГЛОБАЛЬНЫХ КВАЗИНЬЮТОНОВСКИХ МЕТОДОВ ОПТИМИЗАЦИИ ДЛЯ ЗАДАЧ МАТЕМАТИЧЕСКОГО ПРОГРАММИРОВАНИЯ

(магистерская диссертация)

Студент:

Можаев Р. М.
группа М05-404а

(подпись студента)

Научный руководитель: Камзолов Д. И.

(подпись научного руководителя)

Долгопрудный
2026

Аннотация

Цель — развить количественный локальный анализ мультисекущего обновления Бройдена [30] для нелинейных систем и построить его секантно-стабилизированный симметричный аналог для гладкой оптимизации.

Задачи: получить точное разложение и явную константу для оценки bounded deterioration мультисекущего обновления через обусловленность окна шагов; вывести $O(\rho_k)$ -аппроксимацию якобиана на подпространстве прошлых шагов; построить симметричный аналог SS-U с условной Q-сверхлинейной сходимостью; провести численную верификацию.

Результаты. Оценка bounded deterioration для мультисекущего обновления, у Гэя–Шнабеля [18] данная в форме неравенства сверху для ранг-1 специализации, усилена до точного равенства с проектором ранга $p+1$ и явной константой $C_{\text{PB}} = L(1+C_s/2)\sqrt{p+1}\kappa_p$, не зависящей от размерности n ; установлена $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов. Для симметричного случая построена конструкция SS-U — ранг-1 коррекция в $s_k^\perp$, сохраняющая текущее секущее условие и симметрию, с условной Q-сверхлинейной сходимостью по Dennis–More; bounded deterioration композитного обновления установлено отдельной леммой.

Рекомендации. Мультисекущий Бройден и его limited-memory вариант L-PB рекомендованы вместо классического в задачах, где последний неустойчив или сходится медленно, включая крупномасштабные; SS-U — для гладкой оптимизации в задачах, на которых SR1 теряет устойчивость.

Содержание

Аннотация	2
Обозначения и сокращения	5
Базовые объекты	5
Квазиньютоновские обновления	5
Мультисекущий Бройден и SS-U	6
Соглашения	6
Введение	7
Актуальность темы	7
Объект и предмет исследования	8
Цель и задачи работы	8
Научная новизна	9
Теоретическая и практическая значимость	10
Положения, выносимые на защиту	11
Методология и методы исследования	11
Степень достоверности и апробация результатов	11
Структура и объём работы	12
1. Квазиньютоновские методы и мультисекущие обновления	13
1.1. Постановка задачи	13
1.2. Классические квазиньютоновские обновления	14
1.3. Локальная теория сверхлинейной сходимости	15
1.4. Мультисекущие обновления: общая формула и таксономия	16
1.5. Базовая матрица и связь с ускорением Андерсона	18
1.6. Глобализация и limited-memory варианты	18
1.6.1. Глобализация для нелинейных систем и оптимизации	19
1.6.2. Limited-memory реализации	19
1.7. Симметричные multi-secant подходы	20
1.8. Место настоящей работы	21

2. Мультисекунций Бройден	22
2.1. Качество аппроксимации якобиана	25
2.2. Limited-memory: ранг-1 специализация и L-PB	30
2.3. Численные эксперименты	36
3. Симметричные квазиньютоновские обновления с контролем текущих условий	40
3.1. Мотивация	40
3.2. Конструкция и алгоритм $SS-\mathcal{U}$	42
3.3. Свойства	46
3.4. Связь с известными подходами	46
3.5. Сверхлинейная сходимость	47
3.6. Численные результаты	56
Заключение	63
Основные результаты работы	63
Связь результатов	64
Направления дальнейших исследований	65
Список использованных источников	67

Обозначения и сокращения

Базовые объекты

F	отображение $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$ в задаче $F(x) = 0$ (главы 1, 2) или градиент $F = \nabla f$ задачи оптимизации (глава 3)
f	скалярная целевая функция $f: \mathbb{R}^n \rightarrow \mathbb{R}$ в оптимизации
$J(x)$	якобиан F в точке x ; в задаче оптимизации — гессиан $\nabla^2 f(x)$
J^*	якобиан в решении: $J^* = J(x^*) = \nabla F(x^*)$
x^*	решение: $F(x^*) = 0$

Квазиньютоновские обновления

x_k	приближение к решению на k -й итерации
s_k	шаг: $s_k = x_{k+1} - x_k$
y_k	разность значений: $y_k = F(x_{k+1}) - F(x_k)$
d_k	направление поиска: $B_k d_k = -F(x_k)$
B_k	текущая аппроксимация якобиана
$\hat{B}_k$	базовая матрица в формуле обновления (накопление: $\hat{B}_k = B_k$; пересборка: $\hat{B}_k = \tilde{B}$, обычно I)
$\tilde{B}$	опорная матрица — параметр алгоритма мультисекундного Бройдена, не зависящий от k ; к ней производится сброс при пересборке
Δ_k	изменение матрицы: $\Delta_k = B_{k+1} - \hat{B}_k$
S_m, Y_m, V_m	матрицы прошлых шагов, разностей и направлений обновления в общей мультисекундной формуле (5); V_m (m — ранг обновления) параметризует семейство

E_k ошибка аппроксимации якобиана: $E_k = B_k - J^*$

Мультисекующий Бройден и SS-U

m	ранг мультисекующего обновления в общей формуле главы 1 (m секующих условий $B_{k+1}S_m = Y_m$); используется только в главе 1
p	глубина сохраняемых <i>прошлых</i> секующих условий в мультисекующем Бройдене и его вариантах (главы 2, 3); число столбцов окна на одну больше, чем $p - S_p \in \mathbb{R}^{n \times (p+1)}$ за счёт включения текущей секующей s_k
S_p, Y_p	окно текущего и p прошлых шагов и разностей, $S_p = [s_k \mid s_{k-1} \mid \cdots \mid s_{k-p}] \in \mathbb{R}^{n \times (p+1)}$
G_p	грамиан окна: $G_p = S_p^\top S_p$
Π_k	ортогональный проектор на $\text{col}(S_p)$: $\Pi_k = S_p G_p^{-1} S_p^\top$; $\Pi_k^\perp = I - \Pi_k$
u_k^*	ведущий собственный вектор коррекции SS-U (в $s_k^\perp$)
σ_k^*	коэффициент ранг-1 коррекции SS-U
$\mathcal{U}$	базовое симметричное квазиньютоновское обновление (SR1, PSB) в конструкции SS-U

Соглашения

- Индекс k нумерует итерации алгоритма; индексы внутри окна пробегают $j = k - p, \dots, k$.
- I — единичная матрица подходящей размерности; $e_1 = (1, 0, \dots, 0)^\top$ — первый базисный вектор.
- Если контекст не указан явно, все нормы матриц — фробениусовы ($\|\cdot\|_F$), все нормы векторов — евклидовы ($\|\cdot\|$).
- Константы обозначаются прописными латинскими буквами (L, C_d); параметры алгоритма — строчными греческими ($\bar{\rho}$); индексы k указывают итерационную зависимость.

Введение

Актуальность темы

Квазиньютоновские методы занимают центральное место в вычислительной оптимизации с момента работы Broyden (1965) [6] и последующих классических работ Dennis и More [13, 14]. Они дают сверхлинейную скорость сходимости без вычисления якобиана (или гессиана), что особенно важно для задач, в которых явное дифференцирование дорого или недоступно: крупномасштабных систем уравнений, задач обучения нейронных сетей, равновесных и экономических моделей. На геометрически сложных ландшафтах (изогнутые долины, овраги, неквадратичные сильно нелинейные функции) поведение классических алгоритмов Broyden, SR1 и BFGS, однако, оказывается чувствительным к выбору начального приближения [24, 14, 10, 32], хотя теория гарантирует сверхлинейность в локальном режиме [7, 12].

Стандартный инструмент анализа сходимости квазиньютоновских методов — оценка ограниченной деградации (bounded deterioration [7, 14]), описывающая рост нормы матрицы ошибки $E_k = B_k - J(x^*)$ через проектор вдоль текущего шага. У классических обновлений ранга 1 (Бройден, SR1) и ранга 2 (BFGS) этот проектор имеет ранг 1: из p прошлых секущих условий $B_{k+1}s_j = y_j$, $j = k-p, \dots, k-1$, на следующую итерацию переходит лишь текущее. Естественный путь усиления оценки — сохранение прошлых секущих условий, расширяющее проектор ограниченной деградации с ранга 1 до ранга $p+1$, как для нелинейных систем, так и для гладкой оптимизации. Точность аппроксимации якобиана не является чисто теоретической характеристикой: в современных второпорядковых методах для вариационных неравенств [15] скорость глобальной сходимости явно зависит от нормы ошибки $\|B_k - J(x_k)\|$, и любое количественное усиление оценки этой ошибки непосредственно переносится в оценку метода более высокого уровня. В настоящей диссертации количественный анализ ограниченной деградации развивается для мультисекущего обновления Бройдена [30] на классе нелинейных систем $F(x) = 0$ (ранг-1 специализация Projected Broyden Гэя–Шнабеля [18] включена как имплементационная форма для limited-memory варианта); для гладкой минимизации построено секантно-стабилизированное

обновление $\text{SS-}\mathcal{U}$ как симметричный аналог. Получаемая константа ограниченной деградации $C_{\text{PB}} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$ зависит от обусловленности окна $\kappa_p = \kappa(S_p)$, а не от размерности n — что открывает дорогу к limited-memory варианту L-PB на крупномасштабных задачах.

Объект и предмет исследования

Объект исследования — численные методы решения двух взаимосвязанных классов задач: нелинейных систем уравнений $F(x) = 0$ и безусловной гладкой оптимизации $\min_{x \in \mathbb{R}^n} f(x)$.

Предмет исследования — глобальные квазиньютоновские обновления приближённого якобиана B_k , сохраняющие на каждой итерации p прошлых секущих условий $B_{k+1}s_j = y_j$, $j = k-p, \dots, k$, и порождающие расширенный (ранг $p+1$) проектор bounded deterioration; в частности, мультисекущее обновление Бройдена для нелинейных систем и его симметричный аналог SS-U для оптимизации.

Цель и задачи работы

Цель работы: развить теоретический анализ мультисекущего обновления Бройдена [30] для нелинейных систем и построить его секантно-стабилизированный симметричный аналог для гладкой оптимизации.

Задачи:

1. Сформулировать мультисекущее обновление Бройдена [30] как обновление ранга $p+1$; согласовать режимы `accumulate` $\in \{\text{true}, \text{false}\}$ с таксономией Fang–Saad [16]; зафиксировать ранг-1 специализацию [18] как имплементационную форму для limited-memory варианта.
2. Получить точное разложение и оценку bounded deterioration для мультисекущего обновления: $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$ с проектором Π_k ранга $p+1$ (у классического Бройдена — ранга 1) и явной геометрической константой $C_{\text{PB}} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$, где $\kappa_p = \kappa(S_p)$ — обусловленность окна шагов; вывести неравенство $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$ и количественную $O(\rho_k)$ -аппроксимацию якобиана на подпространстве прошлых шагов; усилить тем самым оценку Гэя–Шнабеля (Th. 4.2 из [18]).
3. Перенести идею сохранения прошлых секущих условий на симметричные методы (SR1, PSB): отталкиваясь от классической несовместности симметрии и сохранения

нескольких секущих условий [30], построить секантно-стабилизированные обновления SS-U с коррекцией в ортогональном дополнении $s_k^\perp$, исследовать сверхлинейность и устойчивую сходимость на модельных задачах.

4. Подтвердить теоретические результаты численными экспериментами на стандартных тестовых задачах.

Научная новизна

1. Для мультисекущего обновления Бройдена [30] $B_{k+1} = B_k + (Y_p - B_k S_p) G_p^{-1} S_p^\top$ получено *точное разложение* bounded deterioration

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$$

с проектором $\Pi_k = S_p G_p^{-1} S_p^\top$ ранга $p+1$ на $\text{col}(S_p)$ (у классического Бройдена — ранга 1, на $\text{span}(s_k)$) и локальной оценкой $\Delta_k = O(\rho_k^2)$, $\rho_k = \max_{k-p \leq j \leq k} \|x_j - x^*\|$, причём константа в $O(\cdot)$ выписана явно через геометрию окна: $C_{\text{РВ}} = L(1 + C_s/2)\sqrt{p+1} \kappa_p$, где $\kappa_p = \kappa(S_p)$ — обусловленность окна шагов. В литературе количественная форма оценки ограниченной деградации для общей мультисекущей формы [30] ранее не приводилась; для ранг-1 специализации Projected Broyden Гэя–Шнабеля [18] установлены минимум-Фробениус характеристика (Th. 2.1), оценка bounded deterioration в виде неравенства сверху (Th. 4.2) и Q-суперлинейная сходимость (Th. 4.5); приведённые ниже результаты усиливают этот анализ *количественно* и переносят на мультисекущую (общую несимметричную) форму:

- (а) *равенство* (а не оценка сверху) для $\|E_{k+1}\|_F^2$ через явный отрицательный член $\|E_k \Pi_k\|_F^2$;
 - (б) неравенство $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$, показывающее, что отрицательный член проекции мультисекущего обновления строго не меньше соответствующего одномерного члена в анализе классического Бройдена;
 - (с) покомпонентное разложение ошибки E_k по подпространствам $\text{col}(S_p)$ и $\text{col}(S_p)^\perp$ с количественной $O(\rho_k)$ -оценкой аппроксимации якобиана на $\text{col}(S_p)$ (см. следствие 2.12).
2. Для симметричного случая, отталкиваясь от классической несовместности симметрии и одновременного сохранения нескольких секущих условий [30], предложена конструкция SS-U — ранг-1 коррекция в $s_k^\perp$, не нарушающая ни текущего секущего условия, ни симметрии и стабилизирующая невязку прошлых секущих в смысле минимизации в $s_k^\perp$. В отличие от ранее известных симметричных

multi-secant подходов — весовой Frobenius-формы Gratton–Malmedy–Toint [21], SupPSB [4], gPSB [5] и grouped/ordered PSB [3] семейства, регуляризованной LS-формы Scieur и др. [19] — SS-U сохраняет точное выполнение текущей секущей и симметрии, а коррекция имеет ранг 1 (см. §3.4). Установлены композитное bounded deterioration в Lipschitz-форме под входной Q-линейной сходимостью (Лемма 3.12) и условная Q-сверхлинейность SS-U по Денниса–Море; численно продемонстрирована устойчивая сходимость на модельных задачах.

Теоретическая и практическая значимость

Теоретическая значимость. Получено точное разложение $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$ для мультисекущего обновления Бройдена — равенство в форме, в которой у Гэя–Шнабеля [18] получено лишь неравенство сверху (Th. 4.2) для ранг-1 специализации. Расширение проектора Π_k с одномерного $s_k s_k^\top / \|s_k\|^2$ (классический Бройден) до ранга $p+1$ на $\text{col}(S_p)$ для мультисекущего обновления позволяет дополнительно установить количественную $O(\rho_k)$ -аппроксимацию якобиана на $\text{col}(S_p)$ — структурное преимущество над классическим Бройденом. Отрицательный член точного разложения для мультисекущего обновления не меньше соответствующего члена классического Бройдена. В симметричной квазиньютоновской теории, отталкиваясь от классической несовместности симметрии и одновременного сохранения нескольких секущих условий [30], предложена конструкция SS-U как ранг-1 коррекция в $s_k^\perp$, разрешающая это препятствие; для неё установлена Q-сверхлинейность по критерию Денниса–Море.

Практическая значимость. Limited-memory вариант L-PB хранит $O(nm)$ векторов вместо плотной матрицы $O(n^2)$ и применим к нелинейным системам высокой размерности, где плотные квазиньютоновские формы исчерпывают память; формальное основание применимости даёт явный вид константы C_{PB} , которая зависит от обусловленности окна κ_p , а не от размерности n — ограниченная деградация теоретически не ухудшается с ростом n . По числу итераций до сходимости L-PB сходится за количество итераций, не зависящее от размерности n на стандартных тестовых задачах вплоть до $n = 10^5$; зазор с плотной ранг-1 PB-формой умеренный и монотонно сокращается с ростом m . По сравнению с классическим Бройденом расширенное окно секущих сокращает медианное число итераций до сходимости и сужает разброс по случайным стартам. В оптимизационной части семейство SS-U восстанавливает устойчивую сходимость симметричных обновлений PSB и SR1 на задачах, где базовое обновление структурно деградирует, не ухудшая сходимость на задачах, где деградации нет.

Положения, выносимые на защиту

1. Формулировка мультисекущего обновления Бройдена [30] как ранг- $(p+1)$ обновления в Алгоритме 1 и согласованное с таксономией Fang–Saad [16] описание режимов накопления; ранг-1 специализация $B_{k+1} = B_k + (y_k - B_k s_k) (S_p G_p^{-1} e_1)^\top$ под индуктивным инвариантом $B_k s_j = y_j$ ($j < k$) как имплементационная форма для limited-memory варианта L-PB (§2.2).
2. Теорема об ограниченной деградации с расширенным проектором для мультисекущего обновления (см. теорему 2.10): точное равенство $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$ с проектором Π_k ранга $p+1$ (у классического Бройдена — ранга 1) и явной локальной оценкой Δ_k через геометрию окна ($C_{PB} = L(1 + C_s/2)\sqrt{p+1} \kappa_p$, $\kappa_p = \kappa(S_p)$); неравенство $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$.
3. Количественная $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов $\text{col}(S_p)$ для мультисекущего обновления (следствие 2.12).
4. Конструкция секантно-стабилизированного обновления SS-U для симметричного случая: ранг-1 коррекция в $s_k^\perp$, разрешающая классическую несовместность симметрии и одновременного сохранения нескольких секущих условий [30].
5. Bounded deterioration в композитной форме для SS-U (Лемма 3.12) и условная Q-сверхлинейная сходимость SS-U по критерию Денниса–Море (теорема 3.9).

Методология и методы исследования

В работе используются методы вычислительной линейной алгебры (разложения QR и SVD, теория проекторов, оценки чисел обусловленности грамиана) и классической теории квазиньютоновских методов (свойства обновлений ранга 1 и 2, критерий сверхлинейности Dennis–More [13]). Численные эксперименты проведены в Python с использованием NumPy; задачи взяты из стандартного тестового набора [24].

Степень достоверности и апробация результатов

Все теоретические результаты снабжены полными доказательствами. Утверждения о скорости сходимости подтверждены численными экспериментами на стандартных тестовых задачах с единым критерием останова. Исходный код экспериментов и скрипты построения всех представленных рисунков открыты и доступны в публичном репозитории **Projected Broyden**.¹

¹<https://github.com/mojaevr/secant-conditions>

Структура и объём работы

Работа состоит из введения, трёх глав, заключения и списка литературы.

- В **главе 1** («Приближение якобиана») вводится язык квазиньютоновских обновлений и формулируется общее семейство мультисекантных обновлений. Анализируется выбор матрицы направлений V_m и базовой матрицы $\hat{B}_k$.
- В **главе 2** («Мультисекунций Бройдена») рассматривается мультисекунтное обновление Бройдена $B_{k+1} = B_k + (Y_p - B_k S_p) G_p^{-1} S_p^\top$, доказывается теорема об ограниченной деградации с точным разложением и расширенным проектором, выводится количественная $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов; ранг-1 специализация (Projected Broyden Гэя–Шнабеля) используется для limited-memory реализации L-РВ; приводятся численные эксперименты для нелинейных систем.
- В **главе 3** идея сохранения прошлых секунций условий переносится на симметричные методы. Строится SS-U, доказывается сверхлинейная сходимость, исследуется устойчивая сходимость на модельных задачах.

Глава 1

Квазиньютоновские методы и мультисекующие обновления

В настоящей главе изложен контекст работы: основная итерационная схема (§1.1), краткая сводка классических квазиньютоновских обновлений (§1.2) и локальной теории сверхлинейной сходимости (§1.3), общее семейство мультисекующих обновлений с таксономией по матрице направлений и базовой матрице (§§1.4–1.5), обзор подходов к глобализации и limited-memory вариантам (§1.6), а также состояние литературы по симметричным multi-secant расширениям (§1.7). Завершает главу позиционирование настоящей работы относительно перечисленных направлений (§1.8).

1.1 Постановка задачи

Рассмотрим задачу решения нелинейной системы

$$F(x) = 0, \quad F: \mathbb{R}^n \rightarrow \mathbb{R}^n. \quad (1)$$

Квазиньютоновские методы строят последовательность $\{x_k\}$ по правилу

$$x_{k+1} = x_k + d_k, \quad B_k d_k = -F(x_k), \quad (2)$$

где $B_k \in \mathbb{R}^{n \times n}$ — аппроксимация якобиана $J(x_k) = F'(x_k)$. На каждой итерации B_k пересчитывается через обновление, использующее последнюю пару

$$s_k = x_{k+1} - x_k = d_k, \quad y_k = F(x_{k+1}) - F(x_k).$$

Для задач безусловной минимизации $\min_{x \in \mathbb{R}^n} f(x)$ при $f \in C^2$ та же схема применяется с $F = \nabla f$, и B_k становится аппроксимацией гессиана; во втором случае от B_k часто

дополнительно требуется симметрия и положительная определённость.

1.2 Классические квазиньютоновские обновления

Все классические квазиньютоновские обновления удовлетворяют последней секущей $B_{k+1}s_k = y_k$ и различаются дополнительными свойствами (симметрия, ранг, выбор нормы изменения). Сводка основных формул приведена в таблице 1.

Таблица 1. Классические квазиньютоновские обновления, удовлетворяющие секущей $B_{k+1}s_k = y_k$. Через $\bar{y}_k = y_k - B_k s_k$ обозначена невязка секущей перед обновлением.

Метод	Формула обновления $B_{k+1} - B_k$	Симм.	Ранг
Broyden ("good") [6]	$\bar{y}_k s_k^\top / \ s_k\ ^2$	нет	1
Broyden ("bad") [6]	$\bar{y}_k y_k^\top / (y_k^\top s_k)$ (для H_{k+1} обратной)	нет	1
SR1 [10, 26]	$\bar{y}_k \bar{y}_k^\top / (\bar{y}_k^\top s_k)$	да	1
PSB [28, 13]	$\frac{\bar{y}_k s_k^\top + s_k \bar{y}_k^\top}{\ s_k\ ^2} - \frac{(s_k^\top \bar{y}_k) s_k s_k^\top}{\ s_k\ ^4}$	да	2
DFP [11, 13]	ранг-2 формула на H_{k+1} , $H_{k+1}y_k = s_k$	да	2
BFGS [26]	$\frac{y_k y_k^\top}{y_k^\top s_k} - \frac{B_k s_k s_k^\top B_k}{s_k^\top B_k s_k}$	да	2

Метод Бройдена [6] был исторически первым обобщением текущего метода на многомерный случай; его обновление есть проекция B_k на аффинное подпространство $\{B : B s_k = y_k\}$ в норме Фробениуса. В гладкой оптимизации параллельную роль играет вариационно-метрическое семейство, восходящее к Davidon (переиздание [11]): DFP даёт ранг-2 симметричное положительно определённое обновление на обратной матрице, BFGS — двойственное к нему на прямой матрице, а критерий совместности $s_k^\top y_k > 0$ обеспечивает сохранение положительной определённости [26]. Симметричное ранг-1 (SR1) обновление не гарантирует положительной определённости, но даёт более точную аппроксимацию гессиана и корректно работает в trust-region схемах [10]; ранг-2 PSB [28] есть симметричный аналог Бройдена в смысле минимума Фробениуса.

Параллельно с плотными обновлениями развивались структурные модификации: Schubert [31] построил версию Бройдена для систем со спарсным якобианом, сохраняющую заданный шаблон ненулевых элементов; общая теория ранг-1 обновлений в семействе $B_{k+1} = B_k + \bar{y}_k v_k^\top / (v_k^\top s_k)$ с произвольным вектором направления v_k изложена в [17]. Эти работы заложили язык, в котором обновление параметризуется не столько конкрет-

ной формулой, сколько выбором матрицы направлений и базовой матрицы — унифицированную форму этой параметризации (§1.4) систематически развил Шнабель [30].

1.3 Локальная теория сверхлинейной сходимости

Стандартный аппарат локального анализа квазиньютоновских методов сложился в работах [7, 12, 13, 14]. Центральный результат Dennis–Moré [12]: при липшицевости якобиана и невырожденности $J^* = J(x^*)$ итерация (2) сходится Q-сверхлинейно тогда и только тогда, когда выполнено условие

$$\lim_{k \rightarrow \infty} \frac{\|(B_k - J^*) s_k\|}{\|s_k\|} = 0. \quad (3)$$

Доказательство сверхлинейности конкретного метода сводится тем самым к проверке (3); ключевой инструмент — *ограниченная деградация* (bounded deterioration) [7, 14]: при движении вблизи корня норма ошибки $E_k = B_k - J^*$ может расти не быстрее, чем с линейной добавкой, пропорциональной расстоянию до корня. Для классического Бройдена эта оценка получается из равенства

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \pi_k\|_F^2 + \Delta_k, \quad \pi_k = \frac{s_k s_k^\top}{\|s_k\|^2}, \quad (4)$$

где проектор π_k — ранга 1, а $\Delta_k = \|y_k - J^* s_k\|^2 / \|s_k\|^2 = O(\rho_k^2)$ ($\rho_k = \max(\|x_k - x^*\|, \|x_{k+1} - x^*\|)$) суммируем при R-линейной сходимости итераций к корню. Тожество (4) вместе с (3) даёт классическую теорему Broyden–Dennis–Moré о локальной Q-сверхлинейности обновления [7].

Структурная особенность (4) — ранг проектора π_k : отрицательный член разложения «вычитает» ошибку только вдоль направления текущего шага. На подпространстве $s_k^\perp$ ошибка переносится из E_k в E_{k+1} без изменений (с точностью до липшицевой поправки), что формально фиксирует утверждение 1.1 ниже: ранг-1 обновление разрушает прошлые секущие на $s_k^\perp$. Усиление локальной теории за счёт расширения проектора π_k с ранга 1 до более высокого ранга — естественный путь, реализуемый сохранением нескольких секущих условий одновременно, к которому и ведёт мультисекущая формулировка [30, 18].

Для классических симметричных обновлений локальный анализ устроен параллельно: Powell [29] установил Q-сверхлинейность DFP в подходящих условиях, конструктивное Dennis–Moré доказательство [13, 14] переносится на BFGS и PSB; для SR1 близкая по технике локальная теория получена существенно позже [10]. Источник дополнительной техники в симметричном случае — сохранение положительной определённости и устойчивая работа оценки $\|E_k\|_F$ под симметричным обновлением.

1.4 Мультисекунционные обновления: общая формула и таксономия

Пусть заданы m секующих условий $B_{k+1}S_m = Y_m$, где

$$S_m = [s_{k-m+1} \mid \cdots \mid s_k] \in \mathbb{R}^{n \times m}, \quad Y_m = [y_{k-m+1} \mid \cdots \mid y_k] \in \mathbb{R}^{n \times m}.$$

Параметр m — ранг общей мультисекантной формулы, используется только в настоящей главе; начиная с гл. 2 обозначение переходит в p — глубину сохраняемых *прошлых* секующих ($S_p \in \mathbb{R}^{n \times (p+1)}$ за счёт включения текущей s_k); см. раздел «Обозначения и сокращения».

Семейство обновлений, удовлетворяющих всем m секующим условиям, описывается унифицированной формулой Шнабеля [30, ур. (2.5)]:

$$B_{k+1} = \widehat{B}_k + (Y_m - \widehat{B}_k S_m) (V_m^\top S_m)^{-1} V_m^\top \quad (5)$$

где $\widehat{B}_k \in \mathbb{R}^{n \times n}$ — базовая матрица, $V_m \in \mathbb{R}^{n \times m}$ — матрица направлений ($V_m^\top S_m$ невырождена). Прямая подстановка даёт $B_{k+1}S_m = Y_m$ при любом допустимом V_m ; ранг $\Delta_k = B_{k+1} - \widehat{B}_k$ не превосходит m .

Частный случай: $m = 1$

При $m = 1$ имеем $S_m = s_k$, $Y_m = y_k$, $V_m = v_k \in \mathbb{R}^n$, и формула (5) принимает вид

$$B_{k+1} = \widehat{B}_k + \frac{(y_k - \widehat{B}_k s_k) v_k^\top}{v_k^\top s_k}. \quad (6)$$

Это ранг-1 обновление, удовлетворяющее единственному секущему условию $B_{k+1}s_k = y_k$. При дополнительном ограничении $v_k^\top s_k = 1$ знаменатель исчезает:

$$B_{k+1} = \widehat{B}_k + (y_k - \widehat{B}_k s_k) v_k^\top. \quad (7)$$

Разрушение прошлых секующих ранг-1 обновлением

Прежде чем переходить к выбору матрицы направлений V_m , отметим характерную патологию ранг-1 ветви (6): текущее секущее условие $B_{k+1}s_k = y_k$ выполняется по построению, однако *прошлые* секующие в общем случае нарушаются. Это и есть основная мотивация перехода от классической ранг-1 формулы к мультисекущим расширениям [30, 18], рассматриваемым в гл. 2.

Утверждение 1.1.

Пусть B_{k+1} задано ранг-1 обновлением (6) в режиме накопления $\widehat{B}_k = B_k$ с произволь-

ным v_k ($v_k^\top s_k \neq 0$),

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k) v_k^\top}{v_k^\top s_k}.$$

Тогда для любого $j < k$:

$$B_{k+1} s_j = B_k s_j + (y_k - B_k s_k) \frac{v_k^\top s_j}{v_k^\top s_k}.$$

В частности, если $y_k \neq B_k s_k$ (т.е. текущая секущая ещё не выполнена), то $B_{k+1} s_j = B_k s_j$ тогда и только тогда, когда $v_k^\top s_j = 0$.

Доказательство.

Прямое вычисление даёт

$$B_{k+1} s_j = B_k s_j + (y_k - B_k s_k) \frac{v_k^\top s_j}{v_k^\top s_k}.$$

При $y_k \neq B_k s_k$ второе слагаемое зануляется тогда и только тогда, когда $v_k^\top s_j = 0$. ■

Следствие 1.1.

В классическом методе Бroyдена ($v_k = s_k$), если на предыдущем шаге выполнялось $B_k s_j = y_j$ и $y_k \neq B_k s_k$, то $B_{k+1} s_j = y_j$ тогда и только тогда, когда $s_k^\top s_j = 0$. В общем случае равенство нарушается.

Естественный способ устранить это нарушение — потребовать сохранения *всех* прошлых секущих в окне: $B_{k+1} s_j = y_j$ для $j = k-p, \dots, k$. Это и приводит к мультисекущему обновлению Бroyдена [30] (гл. 2) и к его симметричному аналогу SS- $\mathcal{U}$ (гл. 3); именно сохранение прошлых секущих расширяет проектор bounded deterioration с ранга 1 до ранга $p+1$, что и составляет центральный объект анализа последующих глав.

Выбор V_m : что минимизирует обновление

При фиксированных $\hat{B}_k$, S_m , Y_m выбор V_m определяет форму обновления Δ_k . Различные V_m удовлетворяют одним и тем же секущим условиям, но отличаются по норме изменения $\|\Delta_k\|_F = \|B_{k+1} - \hat{B}_k\|_F$.

$V_m = S_m$: минимум нормы Фробениуса. Обновление принимает вид

$$B_{k+1} = \hat{B}_k + (Y_m - \hat{B}_k S_m) (S_m^\top S_m)^{-1} S_m^\top. \quad (9)$$

Это единственное решение задачи $\min_B \|B - \hat{B}_k\|_F$ при $B S_m = Y_m$ — проекция $\hat{B}_k$ на аффинное подпространство, задаваемое секущими условиями, в норме Фробениуса;

строгая выпуклость гарантирует единственность. Ранг обновления не превосходит m .

$m = 1$, $v_k = s_k$: **классический метод Бroyдена**. Частный случай при $m = 1$:

$$B_{k+1} = \hat{B}_k + \frac{(y_k - \hat{B}_k s_k) s_k^\top}{\|s_k\|^2}. \quad (9)$$

Это решение $\min_B \|B - \hat{B}_k\|_F$ при $B s_k = y_k$; при $\hat{B}_k = B_k$ — классический метод Бройдена [6], ранг 1, $O(n^2)$ на шаг. Другие варианты — “bad Broyden” ($v_k = y_k$), отвечающий $\min \|H_{k+1} - H_k\|_F$ при $H_{k+1} y_k = s_k$ для обратного якобиана [6, 14], и произвольный v_k с $v_k^\top s_k \neq 0$ [17] — в настоящей работе не используются и упоминаются для полноты семейства (6).

1.5 Базовая матрица и связь с ускорением Андерсона

Второй параметр семейства (5) — базовая матрица $\hat{B}_k$. При $\hat{B}_k = B_k$ (*накопление*) вся прошлая информация сохраняется неявно в B_k ; этот режим — стандартный для метода Бройдена и основной в настоящей работе. Локальная теория ограниченной деградации и условие Денниса–Море [12, 14] для B_k обсуждаются в гл. 2 для расширенного окна секущих.

При $\hat{B}_k = B_0$ (*пересборка*, обычно $B_0 = I$) обновление зависит только от B_0 и окна m пар, история за его пределами стирается. В частности, при $V_m = S_m$ и $B_0 = I$ формула (8) принимает вид

$$B_{k+1} = I + (Y_m - S_m) (S_m^\top S_m)^{-1} S_m^\top, \quad (10)$$

и шаг $x_{k+1} = x_k - B_{k+1}^{-1} F(x_k)$ совпадает с ускорением Андерсона типа I при коэффициенте релаксации $\beta = 1$ [1, 34, 16]. Современную таксономию мультисекундных ускорителей развивают Fang–Saad [16], выделяя два класса (Type-I/Type-II), эквивалентных, соответственно, Бройдену и Андерсону, а локальную теорию сходимости Андерсона — Toth–Kelley [33]. В режиме накопления, основном для гл. 2, обновление наследует поведение Бройдена с расширенным окном; в Алгоритме гл. 2 режим пересборки активируется опцией `accumulate = false` и используется в численных экспериментах для сравнения.

1.6 Глобализация и limited-memory варианты

Локальная теория §1.3 гарантирует сверхлинейную сходимость лишь из достаточно малой окрестности корня x^* (или локального минимума). Для практического применения нужна *глобализация*: стратегия, обеспечивающая сходимость к корню

из произвольной начальной точки в разумной области сходимости. Параллельная задача в крупномасштабном режиме — *limited-memory* реализация, позволяющая работать с B_k , не храня плотной матрицы $n \times n$.

1.6.1 Глобализация для нелинейных систем и оптимизации

В гладкой оптимизации глобализация классических квазиньютоновских методов опирается на монотонное убывание целевой функции f и линейный поиск, удовлетворяющий условиям Армихо [2] или Вольфа [35]; общая теория глобальной сходимости направления спуска восходит к Zoutendijk [36]. Сохранение положительной определённости BFGS под условием Вольфа даёт сходимость на достаточно широком классе задач, тогда как для PSB и SR1 теория глобальной сходимости заметно слабее: их обновления не сохраняют знакоопределённости, что требует trust-region схем или гибридизации. Альтернативный подход к глобализации для оптимизации — регуляризация (Levenberg–Marquardt [23]) в приложении к нелинейным наименьшим квадратам; в общем оптимизационном контексте регуляризация естественно проявляется как trust-region ограничение на шаг.

Для нелинейных систем $F(x) = 0$ ситуация существенно отличается: монотонной функции, минимум которой автоматически соответствует корню, нет (минимум $\frac{1}{2}\|F\|^2$ не обязан совпадать с $F = 0$ в неэллиптическом случае). Классический эмпирический анализ показывает, что даже на хорошо обусловленных задачах поведение метода Бройдена чувствительно к начальному приближению [32, 24]. Стандартные стратегии глобализации в этом классе — линейный поиск по $\|F\|$ с условием типа Армихо и неточные ньютоновские шаги (inexact Newton). Нестандартный, но важный для настоящей работы инструмент — *немонотонный* линейный поиск, допускающий временный рост невязки $\|F\|$ при условии возврата к монотонной траектории через скользящее среднее или максимум по окну предыдущих значений; такой поиск, в частности, использован Бурдаковым и Каманди [8] в глобализованном multipoint secant методе для $F(x) = 0$. Их работа — ближайший прецедент глобализации мультисекундных обновлений для нелинейных систем; ключевое отличие от режима, рассматриваемого в настоящей работе, — в технике переноса bounded deterioration через вспомогательную аппроксимацию якобиана на шаге $k + 1$, что не требует повторного анализа разложения (4) для каждого варианта линейного поиска.

1.6.2 Limited-memory реализации

Для крупномасштабных задач хранение плотного $B_k \in \mathbb{R}^{n \times n}$ ($O(n^2)$ памяти) исключено уже при $n \sim 10^5$. Канонический limited-memory вариант квазиньютоновского

метода для оптимизации — L-BFGS Носдала [25]: вместо плотной B_k хранятся последние m пар (s_j, y_j) , через которые $B_k v$ или $H_k v$ восстанавливаются процедурой two-loop рекурсии за $O(mn)$ операций. Liu и Nocedal [22] продемонстрировали практическую эффективность L-BFGS на крупномасштабных задачах; Byrd, Nocedal и Schnabel [9] получили компактное матричное представление L-BFGS и L-SR1, удобное для trust-region схем и теоретического анализа.

Для несимметричных задач (нелинейные системы (1)) канонической limited-меморгу формы классического Бройдена в литературе *не сложилось*: прямое сокращение хранения через окно m пар (s_j, y_j) ведёт к потере текущих условий вне окна (ср. утв. 1.1), и теория ограниченной деградации для такой «скользящей» версии Бройдена существенно слабее, чем для L-BFGS. Мультисекунная формулировка (5) в режиме накопления естественно даёт ранг- $(p+1)$ обновление, согласованное сразу со всеми парами окна, что открывает путь к limited-меморгу варианту с теоретическими гарантиями, не деградирующими с ростом n . Этот путь реализуется в гл. 2, §2.2 в виде L-PB.

1.7 Симметричные multi-secant подходы

Перенос идеи сохранения нескольких текущих условий на симметричный случай (для гладкой оптимизации) наталкивается на классическое препятствие, явно зафиксированное у Шнабеля [30]: система $B_{k+1} S_m = Y_m$ при $B_{k+1} = B_{k+1}^\top$ совместна тогда и только тогда, когда $S_m^\top Y_m$ симметрична, что в общем случае не выполняется. Дословный перенос мультисекунной формулы с симметризацией невозможен, и литература последних лет предлагает различные стратегии *компромисса* между симметрией и точным выполнением прошлых текущих условий.

- Gratton, Malmedy, Toint [21]: *weighted secant equations* — текущие условия по прошлым парам выполняются приближённо с явными весами, симметрия обновления сохраняется; задача сводится к взвешенной фробениусовой проекции с квадратичным критерием.
- Boutet, Haelterman, Degroote [4, 5, 3]: семейство симметричных PSB-расширений (SUpPSB, gPSB, grouped/ordered PSB), различающихся способом регуляризации совместности; общая черта — замена точного выполнения прошлых текущих на некоторое статистическое или групповое условие, сохраняющее симметрию ранг-2 коррекции.
- Scieur, Liu, Pumi, Boumal [19]: regularized least-squares форма с явной регуляризацией грамиана и общим обобщённым обоснованием как для несимметричного, так и для

симметричного случая; точное выполнение секущих условий приносится в жертву устойчивости при плохо обусловленном окне.

Каждый из перечисленных подходов сохраняет симметрию (а часто и положительную определённость) ценой ослабления секущих условий — текущего, прошлых или того и другого. В гл. 3 рассматривается альтернативная стратегия компромисса $SS\mathcal{U}$: точное выполнение *текущей* секущей $B_{k+1}s_k = y_k$ и симметрии, а прошлые секущие стабилизируются ранг-1 коррекцией в подпространстве $s_k^\perp$; детальное сравнение $SS\mathcal{U}$ с работами [21, 4, 5, 3, 19] проведено в §3.4.

1.8 Место настоящей работы

Изложенный обзор позволяет точно зафиксировать место настоящей диссертации. Объект анализа — мультисекущее обновление Бройдена в форме (5) при $\hat{B}_k = B_k$, $V_m = S_m$, $m = p+1$ (режим накопления, минимум-Фробениус); этот объект введён Шнабелем [30], а ранг-1 специализация под индуктивным инвариантом $B_k s_j = y_j$ для $j < k$ — Гэем и Шнабелем [18]. Развиваемое в гл. 2 направление: количественная форма теоремы об ограниченной деградации с явной константой через геометрию окна $\kappa_p = \kappa(S_p)$, точное разложение (4) с проектором ранга $p+1$ (вместо ранга 1 у классического Бройдена), $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов, а также limited-memory реализация L-PB через ранг-1 запись Гэя–Шнабеля.

Для симметричного случая (гл. 3) предлагается конструкция $SS\mathcal{U}$ как ранг-1 коррекция в $s_k^\perp$, сохраняющая симметрию и точную текущую секущую; разрешение классической несовместности [30] достигается не ослаблением секущих условий (как в [21, 4, 5, 3, 19]), а стабилизацией прошлых секущих в ортогональном дополнении к s_k .

Резюме. Общая мультисекантная формула (5) параметризуется матрицей направлений V_m (форма обновления: минимум по Фробениусу при $V_m = S_m$, классический Бройден при $m = 1$, $v_k = s_k$; (8), (9)) и базовой матрицей $\hat{B}_k$ (накопление или пересборка, последняя эквивалентна Андерсону; (10)). Локальная теория сверхлинейной сходимости [7, 12, 13] сводит вопрос к критерию Денниса–Море (3) и разложению bounded deterioration (4) с проектором ранга 1 для классических обновлений; разрушение прошлых секущих ранг-1 обновлением (утв. 1.1) мотивирует переход к мультисекущим расширениям. Дальнейший анализ ведётся в режиме накопления с расширенным окном секущих — мультисекущим обновлением Бройдена [30] (гл. 2) и его симметричным аналогом $SS\mathcal{U}$ (гл. 3).

Глава 2

Мультисекущий Бroyден

В этой главе анализируется мультисекущее обновление Бройдена — квазиньютоновский метод решения системы $F(x) = 0$, в котором новая аппроксимация якобиана B_{k+1} удовлетворяет $p+1$ секущим условиям из текущего окна последних шагов вместо одного, как в классическом Бройдене. Замкнутая матричная форма мультисекущего обновления для несимметричного бройденовского семейства приведена Шнабелем [30]; здесь она подвергается локальному анализу в форме теоремы об ограниченном ухудшении (bounded deterioration). Исторический предшественник — Projected Broyden Гэя и Шнабеля [18], ранг-1 специализация мультисекущего обновления при сохранении инварианта $B_k s_j = y_j$ ($j < k$) — обсуждается в §2.2 в связи с limited-memory реализацией.

Основные результаты главы: теорема 2.10 — точное разложение и оценка bounded deterioration по фробениусовой норме ошибки $E_k = B_k - J^*$ с явной геометрической константой $C_{PB} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$, где $\kappa_p = \kappa(S_p)$ — обусловленность окна шагов; следствие 2.12 — безусловная $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов $\text{col } S_p$ (структурное преимущество над классическим Бройденом). Численные эксперименты (§2.3) и limited-memory вариант L-PB (§2.2) дополняют теоретическую часть.

Обозначения и предположения главы. Рассматривается задача поиска корня $F(x) = 0$ с непрерывно-дифференцируемым отображением $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$ и якобианом $J(x) = F'(x)$. Обозначим x^* — корень системы ($F(x^*) = 0$), $J^* = J(x^*)$, $s_k = x_{k+1} - x_k$, $y_k = F(x_{k+1}) - F(x_k)$, $E_k = B_k - J^*$ — ошибку аппроксимации якобиана. Во всех теоретических утверждениях главы 2 предполагается, что якобиан липшицев на некоторой открытой окрестности $\mathcal{O} \subset \mathbb{R}^n$ точки x^* :

$$\|J(x) - J(y)\| \leq L \|x - y\|, \quad x, y \in \mathcal{O}. \quad (11)$$

Это стандартное предположение для анализа локальной сходимости квазиньютоновских методов; см. [13, 14].

Идея мультисекундного обновления: вместо одного секундного условия $B_{k+1}s_k = y_k$, удовлетворяемого классическим Бройденом, потребуем, чтобы B_{k+1} согласовывалось со *всеми* парами (s_j, y_j) из текущего окна $j = k-p, \dots, k$, то есть $B_{k+1} S_p = Y_p$. Среди всех матриц с этим свойством выбирается ближайшая к B_k по фробениусовой норме — это и есть мультисекундная форма Шнабеля [30], замкнутый вид которой приведён ниже.

Определение 2.1 (Мультисекундное обновление Бройдена).

Пусть задана глубина окна $p \geq 0$ и пусть шаги $s_k, s_{k-1}, \dots, s_{k-p}$ линейно независимы; обозначим

$$S_p = [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}] \in \mathbb{R}^{n \times (p+1)}, \quad Y_p = [y_k \mid y_{k-1} \mid \dots \mid y_{k-p}], \quad G_p = S_p^\top S_p.$$

Мультисекундное обновление (MS-обновление) задаётся формулой

$$B_{k+1} = B_k + (Y_p - B_k S_p) G_p^{-1} S_p^\top. \quad (12)$$

Замечание 2.2 (Соглашение об обозначениях). Параметр p обозначает число *прошлых* секундных, входящих в окно наряду с текущей; всего окно содержит $p+1$ пару. Текущий шаг s_k стоит *первым* столбцом матрицы S_p . В отличие от этого, в общей формуле (5) столбцы S_m расположены в хронологическом порядке: от старых к новым.

Замечание 2.3 (Минимум-Фробениус характеристика). Формула (12) есть единственная матрица B_{k+1} , удовлетворяющая $B_{k+1} S_p = Y_p$ и минимизирующая $\|B_{k+1} - B_k\|_F$; ранг обновления $B_{k+1} - B_k = (Y_p - B_k S_p) G_p^{-1} S_p^\top$ не превосходит $p+1$. Это — классическая характеристика мультисекундной формы для несимметричного бройденовского семейства [30, ур. (2.5)]; ср. также унифицированную классификацию Type-I/Type-II у Фана и Саада [16, ур. (26)], где Type-II вариант оказывается эквивалентным ускорению Андерсона. При $p=0$ матрица $G_0 = \|s_k\|^2$ и формула (12) переходит в классическое обновление Бройдена (9).

Замечание 2.4 (Численная форма). Прямое обращение G_p нежелательно при плохой обусловленности. Поскольку $G_p \succ 0$, на практике используются: (i) разложение Холецкого $G_p = LL^\top$ с двумя треугольными подстановками для решения $G_p X = S_p^\top$ (стоимость $O(p^3)$); (ii) тонкое QR-разложение $S_p = QR$, дающее $G_p^{-1} S_p^\top = R^{-1} Q^\top$ и более устойчивое при умеренно плохой обусловленности [20, §5.3.3]. Качество обновления зависит от обусловленности $\kappa_p = \kappa(S_p)$ окна шагов, которая входит в оценку теоремы 2.10 (см. замечание 2.11).

Замечание 2.5 (Историческая привязка). Мультисекундное обновление в форме (12) выписано Шнабелем в техотчёте 1983 [30] как часть унифицированного рассмотрения

мультисекундных расширений сразу для четырёх семейств (Бройден, PSB, DFP, BFGS). Исторически ранее Гэй и Шнабель [18] рассматривали ранг-1 *Projected Broyden* (Algorithm II), сохраняющий прошлые секунды напрямую через проектирование направления v_k на ортогональное дополнение к $\text{span}(s_{k-1}, \dots, s_{k-p})$; их Theorem 2.1 показывает, что эта ранг-1 конструкция совпадает с (12) при выполнении индуктивного инварианта $B_k s_j = y_j$ ($j < k$) и даёт минимум-Фробениус обновление в указанном классе. В настоящей работе формулировка (12) выбрана за основу как чисто алгебраическая (не требует индуктивного инварианта), а ранг-1 специализация возвращается в §2.2 ради limited-memory реализации через формулу Шермана–Моррисона. Установленные у Гэя и Шнабеля свойства — bounded deterioration (Th. 4.2) и локальная Q-сверхлинейная сходимость (Th. 4.5) — в настоящей главе уточняются: теорема 2.10 даёт точное разложение Фробениус-нормы ошибки и явную геометрическую константу, а следствие 2.12 — безусловный $O(\rho_k)$ -контроль ошибки на всём подпространстве $\text{col } S_p$ (в [18] в явном виде эти факты не приводятся).

Полный алгоритм приведён в Алгоритме 1.

Algorithm 1 Мультисекундный Бройден ($F, x_0, p_{\max}, \tilde{B}, \varepsilon, \text{accumulate}$)

Require: $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$, $p_{\max} \geq 0$, $\tilde{B} \in \mathbb{R}^{n \times n} \succ$ опорная матрица алгоритма, куда происходит сброс в режиме пересборки; обычно I_n . Не путать с базовой матрицей $\hat{B}_k$ в формуле обновления., $\varepsilon > 0$, $\text{accumulate} \in \{\text{true}, \text{false}\}$

$B_0 \leftarrow \tilde{B}, \quad k \leftarrow 0$

while $\|F(x_k)\| \geq \varepsilon$ **do**

 Решить $B_k d_k = -F(x_k)$

$x_{k+1} \leftarrow x_k + d_k$

$s_k \leftarrow d_k, \quad y_k \leftarrow F(x_{k+1}) - F(x_k)$

$p \leftarrow \min(p_{\max}, k)$

MS-обновление якобиана:

if accumulate **then**

$\hat{B}_k \leftarrow B_k$

else

$\hat{B}_k \leftarrow \tilde{B}$

$S_p \leftarrow [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}], \quad Y_p \leftarrow [y_k \mid y_{k-1} \mid \dots \mid y_{k-p}]$

$G_p \leftarrow S_p^\top S_p \quad \triangleright (p+1) \times (p+1), \text{ симметричный, } \succ 0$

$B_{k+1} \leftarrow \hat{B}_k + (Y_p - \hat{B}_k S_p) G_p^{-1} S_p^\top \triangleright \text{ранг} \leq p+1; \text{ при } p=0 \text{ — классический Бройден}$

$k \leftarrow k + 1$

return x_k

Замечание 2.6 (Связь с таксономией обновлений). Опция `accumulate` переключает между двумя строками классификации Fang–Saad [16] для мультисекундных бройденовских обновлений. При `accumulate = true` (базовый режим всех экспериментов главы) в качестве опорной матрицы $\widehat{B}_k$ берётся текущее B_k , накопившее историю прошлых обновлений; при `accumulate = false` — фиксированное $\widetilde{B}$ (типично I), и обновление становится Туре-II вариантом, эквивалентным ускорению Андерсона [1] (см. ур. (26) в [16]). В обоих случаях формула обновления одна и та же — ранг- $(p+1)$ мультисекундная.

Замечание 2.7 (Сложность). Доминирующие операции на итерацию: формирование $\widehat{B}_k S_p$ (плотное матрично-матричное произведение, $O(n^2 p)$); решение $(p+1) \times (p+1)$ -системы $G_p X = S_p^\top$ через разложение Холецкого ($O(p^3)$); решение $B_k d_k = -F(x_k)$ через LU ($O(n^3)$). При $p \ll n$ доминирует LU. Limited-memory вариант §2.2 убирает $O(n^2)$ -память и $O(n^3)$ -стоимость LU за счёт специализации к ранг-1 случаю с Шерманом–Моррисоном.

2.1 Качество аппроксимации якобиана

Лемма 2.8 (Локальная оценка длины шага через расстояние до корня).

Пусть якобиан J удовлетворяет условию Липшица (11) с константой L на шаре $B(x^*, \delta_0) := \{x : \|x - x^*\| \leq \delta_0\}$, $F(x^*) = 0$, и пусть B_j обратима с $\|B_j^{-1}\| \leq M$ для всех $j \in \{k-p, \dots, k\}$. Тогда для каждого $j \in \{k-p, \dots, k\}$ с $x_j \in B(x^*, \delta_0)$ длина шага $s_j = -B_j^{-1}F(x_j)$ удовлетворяет

$$\|s_j\| \leq C_s \|x_j - x^*\|, \quad C_s := M \left(\|J^*\| + \frac{L}{2} \delta_0 \right), \quad (13)$$

где $\|J^*\|$ — спектральная (операторная) норма $J(x^*)$.

Доказательство.

По интегральной формуле Ньютона–Лейбница и $F(x^*) = 0$:

$$F(x_j) = F(x_j) - F(x^*) = \left(\int_0^1 J(x^* + t(x_j - x^*)) dt \right) (x_j - x^*).$$

Применяя оценку Липшица $\|J(x^* + \tau(x_j - x^*)) - J^*\| \leq L \tau \|x_j - x^*\|$ и интегрируя:

$$\left\| \int_0^1 J(x^* + t(x_j - x^*)) dt \right\| \leq \|J^*\| + \frac{L}{2} \|x_j - x^*\| \leq \|J^*\| + \frac{L}{2} \delta_0.$$

Отсюда $\|F(x_j)\| \leq (\|J^*\| + \frac{L}{2} \delta_0) \|x_j - x^*\|$. По условию леммы $\|s_j\| \leq M \|F(x_j)\|$, что даёт (13). ■

Замечание 2.9 (Локальная фаза и пребывание траектории в шаре). Лемма 2.8 требует $x_j \in B(x^*, \delta_0)$ для всех j из рассматриваемого окна. Индуктивное обоснование пребывания траектории в шаре — стандартный шаг локальной теории квазиньютоновских методов (Dennis–Schnabel, [14, Th. 8.2.1]; ср. также [26, §6.4]): при достаточно близком старте x_0 и достаточно малом $\|E_0\|$ оценка теоремы 2.10 ниже гарантирует, что $\{x_k\}$ не покидает $B(x^*, \delta_0)$. В настоящей работе анализ ограничен этой локальной фазой; для всего последующего анализа пребывание окна $x_{k-p}, \dots, x_k \in B(x^*, \delta_0)$ принимается как стандартное допущение локального анализа.

Теорема 2.10 (Bounded deterioration для мультисекущего Бройдена).

Пусть $S_p \in \mathbb{R}^{n \times (p+1)}$ имеет полный столбцовый ранг, Y_p и $G_p = S_p^\top S_p$ определены как в опр. 2.1, а B_{k+1} задано MS-обновлением (12). Пусть якобиан $J(x)$ удовлетворяет условию Липшица (11) с константой L на открытой окрестности $\mathcal{O} \subset \mathbb{R}^n$, содержащей x^* , все точки x_j и отрезки $\{x_j + ts_j : t \in [0, 1]\}$ для $j = k-p, \dots, k$. Обозначим $J^* = J(x^*)$, $E_k = B_k - J^*$,

$$\Pi_k = S_p G_p^{-1} S_p^\top \quad (\text{ортogonalный проектор на } \text{col } S_p), \quad \Pi_k^\perp = I - \Pi_k.$$

Тогда:

(а) **Точное разложение.**

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k, \quad (14)$$

где

$$\Delta_k = \text{tr}(G_p^{-1} (Y_p - J^* S_p)^\top (Y_p - J^* S_p)). \quad (15)$$

(б) **Bounded deterioration.** Пусть, дополнительно, выполнены условия леммы 2.8 с константой C_s и $B(x^*, \delta_0) \subset \mathcal{O}$, так что $\|s_j\| \leq C_s \|x_j - x^*\|$ для $j = k-p, \dots, k$. Обозначим

$$\rho_k := \max_{k-p \leq j \leq k} \|x_j - x^*\|, \quad \kappa_p := \kappa(S_p) = \frac{\sigma_{\max}(S_p)}{\sigma_{\min}(S_p)}. \quad (16)$$

Тогда

$$\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + C_{\text{PB}}^2 \rho_k^2, \quad C_{\text{PB}} := L(1 + C_s/2) \sqrt{p+1} \kappa_p. \quad (17)$$

Замечание 2.11 (Расшифровка C_{PB}). Структура константы C_{PB} прозрачна: L — константа Липшица якобиана; C_s — типичный размер шага относительно расстояния до корня (лемма 2.8); $\sqrt{p+1}$ — цена расширения окна секущих; $\kappa_p = \kappa(S_p)$ — обуслов-

ленность окна последних $p + 1$ шагов как наблюдаемая характеристика траектории. Теоретическая оценка не накладывает априорных границ на κ_p ; формальный контроль обусловленности (через отбор шагов или регуляризацию окна, ср. [8]) выходит за рамки настоящего локального анализа, эмпирическая проверка ограниченности проведена в §2.3. В классической форме Бройдена ($p = 0$, $\Pi_k = s_k s_k^\top / \|s_k\|^2$, $\kappa_0 = 1$) оценка переходит в стандартную bounded deterioration с $C_{\text{Br}} = L(1 + C_s/2)$, ср. [7, 14]. Константа $M = \sup_j \|B_j^{-1}\|_2$ из леммы 2.8, входящая в C_s , конечна при $\|E_j\|_2 < \sigma_{\min}(J^*)$ (неравенство Вейля для спектральной нормы); поскольку $\|E_j\|_2 \leq \|E_j\|_F$, в оценке теоремы 2.10 достаточно условия $\|E_j\|_F < \sigma_{\min}(J^*)$.

Доказательство.

Шаг 1: разложение E_{k+1} . Подставим определение MS-обновления (12):

$$\begin{aligned} E_{k+1} &= B_k - J^* + (Y_p - B_k S_p) G_p^{-1} S_p^\top \\ &= E_k + [(Y_p - J^* S_p) - E_k S_p] G_p^{-1} S_p^\top \\ &= E_k (I - S_p G_p^{-1} S_p^\top) + (Y_p - J^* S_p) G_p^{-1} S_p^\top. \end{aligned} \quad (18)$$

То есть:

$$E_{k+1} = E_k \Pi_k^\perp + R_k, \quad R_k = (Y_p - J^* S_p) G_p^{-1} S_p^\top. \quad (19)$$

Шаг 2: ортогональность строк. Покажем, что $\text{tr}((E_k \Pi_k^\perp)^\top R_k) = 0$.

Для каждого $i = 1, \dots, n$ рассмотрим i -ю строку каждого слагаемого, записанную как столбец транспонированной матрицы (через стандартный базисный вектор $e^{(i)} \in \mathbb{R}^n$).

Строка i матрицы $E_k \Pi_k^\perp$:

$$(E_k \Pi_k^\perp)^\top e^{(i)} = \Pi_k^\perp E_k^\top e^{(i)} \in (\text{col } S_p)^\perp,$$

поскольку $\text{im } \Pi_k^\perp = (\text{col } S_p)^\perp$.

Строка i матрицы R_k :

$$R_k^\top e^{(i)} = S_p G_p^{-1} (Y_p - J^* S_p)^\top e^{(i)} \in \text{col } S_p,$$

поскольку вектор является линейной комбинацией столбцов S_p .

Скалярное произведение i -х строк:

$$\begin{aligned} &(\Pi_k^\perp E_k^\top e^{(i)})^\top (S_p G_p^{-1} (Y_p - J^* S_p)^\top e^{(i)}) \\ &= (E_k^\top e^{(i)})^\top \underbrace{\Pi_k^\perp S_p}_{=0} G_p^{-1} (Y_p - J^* S_p)^\top e^{(i)} = 0, \end{aligned}$$

где $\Pi_k^\perp S_p = (I - S_p G_p^{-1} S_p^\top) S_p = S_p - S_p G_p^{-1} G_p = 0$. Суммируя по i :

$$\text{tr}((E_k \Pi_k^\perp)^\top R_k) = \sum_{i=1}^n ((E_k \Pi_k^\perp)^\top e^{(i)})^\top (R_k^\top e^{(i)}) = 0. \quad (20)$$

Шаг 3: теорема Пифагора. Из (19) и (20):

$$\|E_{k+1}\|_F^2 = \|E_k \Pi_k\|_F^2 + \|R_k\|_F^2. \quad (21)$$

Аналогично, разложение $E_k = E_k \Pi_k + E_k \Pi_k^\perp$ даёт ортогональные (по строкам) слагаемые, поскольку строка i матрицы $E_k \Pi_k$ лежит в $\text{col } S_p$, а строка i матрицы $E_k \Pi_k^\perp$ — в $(\text{col } S_p)^\perp$. Следовательно:

$$\|E_k\|_F^2 = \|E_k \Pi_k\|_F^2 + \|E_k \Pi_k^\perp\|_F^2. \quad (22)$$

Подставляя $\|E_k \Pi_k^\perp\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2$ в (21):

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \|R_k\|_F^2. \quad (23)$$

Шаг 4: вычисление $\|R_k\|_F^2$. Обозначим $A_k = Y_p - J^* S_p$. Тогда $R_k = A_k G_p^{-1} S_p^\top$ и:

$$\begin{aligned} \|R_k\|_F^2 &= \text{tr}(S_p G_p^{-1} A_k^\top A_k G_p^{-1} S_p^\top) \\ &= \text{tr}(G_p^{-1} S_p^\top S_p G_p^{-1} A_k^\top A_k) \quad (\text{цикличность следа}) \\ &= \text{tr}(G_p^{-1} G_p G_p^{-1} A_k^\top A_k) = \text{tr}(G_p^{-1} A_k^\top A_k). \end{aligned} \quad (24)$$

Это доказывает (14) с $\Delta_k = \|R_k\|_F^2$.

Шаг 5: оценка Δ_k сверху. Матрицы G_p^{-1} и $A_k^\top A_k$ положительно полуопределены. По неравенству $\text{tr}(MN) \leq \lambda_{\max}(M) \text{tr}(N)$ для положительно полуопределённых M, N (см. [20, §8.3]):

$$\Delta_k = \text{tr}(G_p^{-1} A_k^\top A_k) \leq \lambda_{\max}(G_p^{-1}) \|A_k\|_F^2 = \frac{\|A_k\|_F^2}{\lambda_{\min}(G_p)} = \frac{\|A_k\|_F^2}{\sigma_{\min}^2(S_p)}. \quad (25)$$

Оценим $\|A_k\|_F^2$. Столбец матрицы A_k , отвечающий индексу j , равен $a_j = y_j - J^* s_j$. По теореме о среднем значении:

$$y_j - J^* s_j = \left(\int_0^1 [J(x_j + t s_j) - J^*] dt \right) s_j.$$

Поскольку $x_j + t s_j \in \mathcal{O}$ для $t \in [0, 1]$ и $J^* = J(x^*)$, по условию Липшица (11) и неравенству треугольника:

$$\|J(x_j + t s_j) - J^*\| \leq L \|x_j + t s_j - x^*\| \leq L (\|x_j - x^*\| + t \|s_j\|).$$

Интегрируя по $t \in [0, 1]$:

$$\left\| \int_0^1 [J(x_j + t s_j) - J^*] dt \right\| \leq L \|x_j - x^*\| + \frac{L}{2} \|s_j\|. \quad (26)$$

Следовательно:

$$\|a_j\| = \|y_j - J^* s_j\| \leq \left(L \|x_j - x^*\| + \frac{L}{2} \|s_j\| \right) \|s_j\|. \quad (27)$$

По лемме 2.8 $\|s_j\| \leq C_s \|x_j - x^*\|$ для всех $j = k - p, \dots, k$. Подставляя в (27):

$$\|a_j\|^2 \leq L^2 (1 + C_s/2)^2 \|x_j - x^*\|^2 \|s_j\|^2 \leq L^2 (1 + C_s/2)^2 \rho_k^2 \|s_j\|^2, \quad (28)$$

где $\rho_k = \max_j \|x_j - x^*\|$ из (16). Суммируя по j и пользуясь $\sum_j \|s_j\|^2 = \|S_p\|_F^2 \leq (p + 1) \sigma_{\max}^2(S_p)$:

$$\|A_k\|_F^2 \leq L^2 (1 + C_s/2)^2 (p + 1) \sigma_{\max}^2(S_p) \rho_k^2. \quad (29)$$

Подставляя в (25), получаем

$$\Delta_k \leq \frac{\|A_k\|_F^2}{\sigma_{\min}^2(S_p)} \leq L^2 (1 + C_s/2)^2 (p + 1) \kappa_p^2 \rho_k^2 = C_{\text{PB}}^2 \rho_k^2. \quad (30)$$

Подстановка в (23) даёт (17). ■

Следствие 2.12 (Подпространственная аппроксимация якобиана).

В условиях теоремы 2.10

$$\|E_{k+1} S_p\|_F \leq L (1 + C_s/2) \sqrt{p + 1} \sigma_{\max}(S_p) \rho_k. \quad (31)$$

В частности, B_{k+1} аппроксимирует J^* на всём подпространстве $\text{col } S_p$ с точностью $O(\rho_k)$, зависящей лишь от локальной липшицевой константы и расстояния до корня (не от $\|E_k\|_F$ на $\text{col } S_p$).

Доказательство.

По (19) $E_{k+1} = E_k \Pi_k^\perp + R_k$. Поскольку $\Pi_k^\perp S_p = 0$ (Шаг 2 доказательства теоремы 2.10)

и $G_p^{-1}G_p = I$,

$$E_{k+1} S_p = E_k \Pi_k^\perp S_p + R_k S_p = 0 + (Y_p - J^* S_p) G_p^{-1} S_p^\top S_p = Y_p - J^* S_p.$$

Оценка (29) даёт (31). ■

Замечание 2.13 (Сравнение с классическим Бroyденом). Для классического обновления Бroyдена первого типа ($B_{k+1}^{\text{Br}} = B_k + (y_k - B_k s_k) s_k^\top / \|s_k\|^2$, получается из (12) при $p = 0$) известное разложение [14, Th. 8.2.2] имеет вид:

$$\|E_{k+1}^{\text{Br}}\|_F^2 = \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + \frac{\|y_k - J^* s_k\|^2}{\|s_k\|^2}. \quad (32)$$

MS-обновление с $p \geq 1$ имеет три взаимосвязанных структурных преимущества над классическим Бroyденом:

(i) *Расширенный проектор ранга $p+1$* . В (32) вычитается проекция ошибки на одномерное направление s_k , в (14) — на $(p+1)$ -мерное подпространство $\text{col } S_p$. Поскольку $\text{span}(s_k) \subset \text{col } S_p$, имеем $\Pi_k - s_k s_k^\top / \|s_k\|^2 \succeq 0$ и

$$\|E_k \Pi_k\|_F^2 \geq \frac{\|E_k s_k\|^2}{\|s_k\|^2}, \quad (33)$$

причём неравенство строгое всякий раз, когда E_k имеет нетривиальную проекцию на ортогональное дополнение $\text{span}(s_k)$ внутри $\text{col } S_p$, т. е. на $\text{col } S_p \cap \text{span}(s_k)^\perp$.

(ii) *Удовлетворение $p+1$ текущих условий*. По построению MS-обновления (12) имеет место $B_{k+1} S_p = Y_p$, то есть $B_{k+1} s_j = y_j$ для всех $j = k-p, \dots, k$, тогда как классический Бroyден удовлетворяет лишь текущему равенству $B_{k+1}^{\text{Br}} s_k = y_k$. Для $j < k$ ошибка якобиана у классического Бroyдена наследует прошлую невязку: $E_{k+1}^{\text{Br}} s_j = E_k s_j + (y_k - B_k s_k) (s_k^\top s_j / \|s_k\|^2)$, без какого-либо механизма её подавления.

(iii) *Подпространственная аппроксимация якобиана*. Прямое следствие (ii) — следствие 2.12: на всём $(p+1)$ -мерном подпространстве $\text{col } S_p$ ошибка E_{k+1} оценивается локальной липшицевой константой и расстоянием до корня. Аналогичный безусловный $O(\rho_k)$ -контроль для классического Бroyдена существует только в одномерном направлении s_k ($\|E_{k+1}^{\text{Br}} s_k\| = \|y_k - J^* s_k\| = O(\rho_k) \|s_k\|$); на $\text{col } S_p \cap \text{span}(s_k)^\perp$ ошибка определяется глобальной историей.

2.2 Limited-memory: ранг-1 специализация и L-PB

Мотивация. Прямая реализация Алгоритма 1 хранит плотную матрицу $B_k \in \mathbb{R}^{n \times n}$, что требует $O(n^2)$ памяти и $O(n^3)$ операций на решение системы $B_k d = -F(x_k)$ через

LU-факторизацию. При $n = 10^4$ это $\approx 8 \cdot 10^8$ чисел двойной точности (≈ 800 МБ) и $\approx 10^{12}$ flops на итерацию, что делает прямую форму неприменимой к крупномасштабным задачам.

Ранг-1 специализация под индуктивным инвариантом. В режиме `accumulate = true` Алгоритма 1 обновление (12) индуктивно сохраняет прошлые секущие: если $B_k s_j = y_j$ для $j = k-p, \dots, k-1$, то в матрице $Y_p - B_k S_p$ обнуляются столбцы со 2-го по $(p+1)$ -й, и она факторизуется в $(y_k - B_k s_k) e_1^\top$. Подстановка в (12):

$$B_{k+1} = B_k + (y_k - B_k s_k) v_k^\top, \quad v_k := S_p G_p^{-1} e_1. \quad (34)$$

Свойства v_k — следствия определения: $v_k^\top s_k = 1$ (из $S_p^\top s_k = G_p e_1$, откуда $v_k^\top s_k = e_1^\top G_p^{-1} G_p e_1 = 1$) и $v_k^\top s_j = 0$ для $j < k$. Это в точности *Projected Broyden* Гэя и Шнабеля [18] (Algorithm II); дальнейшая теория §2.1 применима к ранг-1 форме без изменений (она даёт ту же B_{k+1} , что и MS-форма). Limited-memory реализация ниже использует именно эту ранг-1 запись через формулу Шермана–Моррисона.

Шерман–Моррисон-форма. Из ранг-1 формы (34), $B_{k+1} = B_k + u_k v_k^\top$ с $u_k = y_k - B_k s_k$ и $v_k^\top s_k = 1$, формула Шермана–Моррисона [14, §3.4] даёт явное обновление обратной матрицы $H_k := B_k^{-1}$:

$$H_{k+1} = H_k + \frac{(s_k - H_k y_k) v_k^\top H_k}{v_k^\top H_k y_k}, \quad d_k = -H_k F(x_k). \quad (35)$$

Хранение H_k остаётся $O(n^2)$, но шаг d_k вычисляется как матрично-векторное произведение за $O(n^2)$ flops вместо $O(n^3)$. Знаменатель $v_k^\top H_k y_k$ в (35) равен $1 + v_k^\top H_k u_k$ из общей формы Шермана–Моррисона — после подстановки $u_k = y_k - B_k s_k$ и $v_k^\top s_k = 1$. Условие невырожденности $\det B_{k+1} \neq 0$ эквивалентно $v_k^\top H_k y_k \neq 0$.

Limited-memory L-PB. Для $n \gtrsim 10^4$ хранить плотную H_k невозможно даже в форме (35). По аналогии с limited-memory BFGS [25, 22] предлагается limited-memory вариант, в котором базовая матрица $H_0 = I$ *никогда не формируется явно*. Вместо этого хранится скользящее окно последних m принятых троек $\{(s_j, y_j, v_j)\}_{j=k-m+1}^k$.

Применение H_k к произвольному вектору g реализуется прямым проходом по окну (Алгоритм 2). Здесь H_k обозначает L-PB-аппроксимацию, получаемую последовательной композицией обновлений (35) к $H_{k-m} = I$ только по m корректировкам текущего окна. Эта аппроксимация совпадает с обратной плотной формой B_k^{-1} лишь до первого выталкивания пары из окна, т. е. при $k \leq m$; при $k > m$ матрицы расходятся

(утверждение 2.1 и замечание 2.15, эмпирически — §2.3):

$$H_k g = H_{k-m} g + \sum_{j=k-m+1}^k \frac{(s_j - H_{j-1} y_j) (v_j^\top H_{j-1} g)}{v_j^\top H_{j-1} y_j}, \quad H_{k-m} = I. \quad (36)$$

Algorithm 2 Применение $H_k g$ для L-PB (прямой проход по окну)

Require: окно $\{(s_j, y_j, v_j)\}_{j=1}^m$, входной вектор g

Ensure: $z = H_k g$

```

1:  $z \leftarrow g$  ▷  $H_0 = I$ 
2: for  $j = 1, 2, \dots, m$  do
3:    $w \leftarrow y_j$  ▷ вычислим  $H_j y_j$ 
4:   for  $i = 1, \dots, j-1$  do
5:      $\beta_i \leftarrow (v_i^\top w) / \alpha_i$ 
6:      $w \leftarrow w + \xi_i \beta_i$ 
7:    $\alpha_j \leftarrow v_j^\top w$ 
8:    $\xi_j \leftarrow s_j - w$ 
9:    $\beta_j \leftarrow (v_j^\top z) / \alpha_j$ 
10:   $z \leftarrow z + \xi_j \beta_j$ 
11: return  $z$ 

```

Полный шаг L-PB выглядит так: на итерации k вычисляется $d_k = -\text{APPLYH}(F(x_k); \text{window}_k)$; делается backtracking-Армихо или полный шаг $x_{k+1} = x_k + d_k$; формируется текущая $(s_k, y_k) = (x_{k+1} - x_k, F(x_{k+1}) - F(x_k))$; формирование S_p, G_p выполняется по правилам Алгоритма 1 (с $p = \min(p_{\max}, k)$), после чего $v_k := S_p G_p^{-1} e_1$ согласно (34); тройка (s_k, y_k, v_k) добавляется в очередь, а самая старая тройка выталкивается, если длина $> m$.

Сложность L-PB. Память: окно из m троек (s_j, y_j, v_j) занимает $3nm$ чисел с плавающей точкой; во время одного обращения Алгоритма 2 дополнительно формируются m векторов $\xi_j = s_j - H_{j-1} y_j$ (nm чисел) и m скаляров α_j ; рабочие векторы z, w занимают $2n$. Эти вспомогательные величины пересчитываются при каждом обращении и не сохраняются между итерациями (см. замечание 2.14). Итоговая память

$$\mathcal{M}_{\text{L-PB}} = O(nm). \quad (37)$$

Время: тело внешнего цикла Алгоритма 2 выполняется m раз, внутреннего — до $m-1$ раз; стоимость одного обращения $H_k g$ составляет $O(nm^2)$ flops. На итерацию прихо-

дится 2 обращения (одно для d_k , одно для $H_k y_k$ при расчёте знаменателя α_k), итого $O(nm^2)$ flops/iter. При $m \ll n$ это асимптотически дешевле, чем $O(n^2)$ одного матрично-векторного произведения у плотной формы (35), и тем более чем $O(n^3)$ LU-решения у прямой формы Алгоритма 1; память $O(nm)$ против $O(n^2)$ обратной матрицы (35) обеспечивает применимость метода к режиму $n \gtrsim 10^4$, в котором плотная форма исчерпывает доступную оперативную память (ср. §2.3).

Замечание 2.14 (Полный пересчёт vs. кэширование). Величины $\xi_j = s_j - H_{j-1} y_j$ и $\alpha_j = v_j^\top H_{j-1} y_j$ из внутреннего цикла Алгоритма 2 зависят только от $\{(s_i, y_i, v_i)\}_{i \leq j}$, и потому могут показаться допускающими кэширование между итерациями. Однако при выталкивании самой старой пары из окна они становятся *несогласованными* с усечённой историей: произведение $H_{i-1} y_i$ вычислялось относительно полного префикса $0, \dots, i-1$, не обрезанного. Поэтому на каждом обращении $H_k g$ величины ξ_i, α_i *пересчитываются заново* из текущего окна. То же требование удерживает и L-BFGS two-loop [26, §7.2], где коэффициенты ρ_i хранятся (это скаляры), но кэширование произведений $H_{i-1} y_i$ исключено по той же причине.

Утверждение 2.1 (Сохранение последних $p_{\max} + 1$ секущих в L-PB).

Пусть в Алгоритме 2 ёмкость окна $m \geq p_{\max} + 1$, и тройки (s_j, y_j, v_j) формируются по правилу $v_j = S_p^{(j)} G_p^{(j)-1} e_1$ из ранг-1 специализации (34). Обозначим через B_k оператор, неявно задаваемый рекурсией (36): композицией m ранг-1 обновлений к $B_{k-m} = I$. Тогда для каждого $k \geq 0$

$$B_k s_j = y_j, \quad j \in \{\max(0, k - p_{\max} - 1), \dots, k - 1\}, \quad (38)$$

то есть последние $\min(p_{\max} + 1, k)$ секущих условий выдерживаются B_k точно. Как следствие, разложение $E_k = B_k - J^*$ из теоремы 2.10 переносится на L-PB с тем же проектором $\Pi_k = S_p^{(k)} G_p^{(k)-1} (S_p^{(k)})^\top$, и оценка *bounded deterioration* (17) удерживается в той же структурной форме с константой $C_{\text{PB}} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$, где C_s через $M = \sup_j \|B_j^{-1}\|$ берётся для L-PB-оператора и численно может отличаться от плотной формы.

Доказательство.

Зафиксируем $k \geq 1$ и раскрутим L-PB-рекурсию (36) как композицию ранг-1 шагов. Обозначим $k_{\min} := \max(0, k - m)$ и введём промежуточные операторы $\tilde{B}_l$, $l = k_{\min}, \dots, k$, заданные индуктивно: $\tilde{B}_{k_{\min}} := I$, и для каждого $l > k_{\min}$

$$\tilde{B}_l := \tilde{B}_{l-1} + (y_{l-1} - \tilde{B}_{l-1} s_{l-1}) v_{l-1}^\top.$$

По определению рекурсии (36) итоговый L-PB-оператор есть $B_k = \tilde{B}_k$ (с $H_k = \tilde{B}_k^{-1}$

через Шермана–Моррисона).

Утверждение: для каждого $l \in \{k_{\min}+1, \dots, k\}$ выполнено

$$\tilde{B}_l s_j = y_j, \quad j \in J_l := \{l-1-p_{\max}, \dots, l-1\} \cap [k_{\min}, l-1]. \quad (39)$$

При $l = k$ это даёт формулировку утверждения: $J_k = \{k-1-p_{\max}, \dots, k-1\} \cap [k_{\min}, k-1] = \{\max(k_{\min}, k-1-p_{\max}), \dots, k-1\}$, что в режиме $m \geq p_{\max} + 1$ совпадает с $\{\max(0, k-1-p_{\max}), \dots, k-1\}$.

Индукция по l . База ($l = k_{\min} + 1$). $\tilde{B}_l = I + (y_{k_{\min}} - s_{k_{\min}})v_{k_{\min}}^\top$. Из $v_{k_{\min}}^\top s_{k_{\min}} = 1$ имеем $\tilde{B}_l s_{k_{\min}} = s_{k_{\min}} + (y_{k_{\min}} - s_{k_{\min}}) = y_{k_{\min}}$; других элементов в $J_l = \{k_{\min}\}$ нет.

Шаг от l к $l+1$. Применим $\tilde{B}_{l+1} = \tilde{B}_l + (y_l - \tilde{B}_l s_l)v_l^\top$ к s_j для $j \in J_{l+1}$.

(i) $j = l$. $\tilde{B}_{l+1} s_l = \tilde{B}_l s_l + (y_l - \tilde{B}_l s_l)(v_l^\top s_l) = y_l$ по $v_l^\top s_l = 1$ (следует из $S_p^{(l),\top} v_l = e_1$, см. (34)).

(ii) $j \in J_{l+1} \setminus \{l\} = \{l-p_{\max}, \dots, l-1\} \cap [k_{\min}, l-1]$. Вектор s_j входит в окно $S_p^{(l)}$ алгоритма 1 как столбец с номером $i = l-j+1 \in \{2, \dots, p_{\max}+1\}$; из $S_p^{(l),\top} v_l = e_1$ получаем $v_l^\top s_j = (e_1)_i = 0$. Поэтому $\tilde{B}_{l+1} s_j = \tilde{B}_l s_j$. По индукционной гипотезе для $\tilde{B}_l$ достаточно показать $j \in J_l$: при $l \geq k_{\min} + 1$ и $j \geq l-p_{\max}$ имеем $j \geq l-p_{\max} = (l-1)-p_{\max} - (-1) \geq (l-1)-p_{\max}$ и $j \leq l-1$, т. е. $j \in J_l$ (с учётом $j \geq k_{\min}$). Применяя индукционную гипотезу, $\tilde{B}_l s_j = y_j$, откуда $\tilde{B}_{l+1} s_j = y_j$.

Условие $m \geq p_{\max} + 1$ обеспечивает, что для каждого l окно $S_p^{(l)}$, участвующее в формуле v_l , целиком лежит в L-РВ-окне $\{s_{k_{\min}}, \dots, s_l\}$ (необходимо для существования v_l в хранимых данных). База индукции: $k = 0$ даёт $B_0 = I$, $J_0 = \emptyset$, утверждение вакуумно. ■

Замечание 2.15 (L-РВ не эквивалентен плотной форме при $k > m$). Утверждение 2.1 гарантирует совпадение действий B_k^{LPB} и плотного B_k^{dense} из (12) только на $\text{col } S_p^{(k)}$ — линейной оболочке последних $p_{\max} + 1$ секущих. На ортогональном дополнении матрицы различаются: плотная форма накапливает ранг-1 поправки от всех k принятых обновлений, тогда как L-РВ-рекурсия применяет лишь последние m , неявно полагая $B_{k-m}^{\text{LPB}} = I$ (тогда как $B_{k-m}^{\text{dense}} \neq I$). Поэтому полная эквивалентность имеет место лишь до первого выталкивания — при $k \leq m$. При $k > m$ траектории L-РВ и плотной формы расходятся ровно с итерации $k = m + 1$ (см. §2.3); зазор растёт по мере накопления выталкиваемых пар и монотонно убывает по m .

При $m < p_{\max} + 1$ требование $v_k^\top s_j = 0$ для $j \in S_p^{(k)}$ не поддержано данными окна: $S_p^{(k)}$ ссылается на уже вытолкнутые s_j , и даже база утверждения 2.1 не выполняется. Эмпирически такая конфигурация приводит к резкому ухудшению (стагнации либо отсутствию сходимости, см. §2.3), поэтому в работе всегда полагается $m \geq p_{\max} + 1$.

Замечание 2.16 (Связь с L-BFGS). Limited-memory BFGS [25, 22, 9] применим к мини-

мизации гладкой f при симметричном положительно определённом гессиане и использует two-loop рекурсию с $4nm$ flops/iter. Соотношение L-BFGS $\leftrightarrow$ dense BFGS известно: точной эквивалентности нет, ограничение глубины окна m задаёт retention последних m секущих пар, и приближение к плотной форме монотонно по m [26, §7.2]. Та же картина имеет место для L-PB $\leftrightarrow$ плотный PB (замечание 2.15): при $m \geq p_{\max} + 1$ оператор B_k^{LPB} воспроизводит последние $\min(p_{\max} + 1, k)$ секущих условий плотной формы, но не весь оператор B_k^{dense} . Структурное отличие L-PB от L-BFGS: метод не требует ни симметрии, ни знакоопределённости и применим напрямую к $F(x) = 0$ без сведения к merit-функции $\psi(x) = \frac{1}{2}\|F(x)\|^2$ (последнее потребовало бы дополнительных якобиан-векторных произведений $\nabla\psi = J^\top F$). Цена несимметрии — $O(nm^2)$ flops/iter у L-PB против $O(nm)$ у L-BFGS: векторы $\xi_j = s_j - H_{j-1}y_j$ зависят от всей предшествующей истории через H_{j-1} и не допускают кэширования между итерациями (замечание 2.14), тогда как в L-BFGS аналогичный объект $\rho_i = 1/(y_i^\top s_i)$ — скаляр и хранится.

Замечание 2.17 (Связь с limited-memory “good Broyden”). Limited-memory вариант классического Бройдена [9], обозначаемый далее L-Broyden, хранит окно $\{(s_j, y_j)\}_{j=k-m+1}^k$ и рекурсивно применяет (35) с $v_k = s_k$. От L-PB он отличается выбором направления обновления: при $v_k = s_k$ прошлые секущие условия $B_{k+1}s_j = y_j$, $j < k$, в общем случае не удерживаются даже внутри окна (Утверждение 1.1). L-PB заменяет s_k на спроецированный вектор $v_k = S_p G_p^{-1} e_1 \in \text{col}(S_p) \setminus \{s_k\}^\perp$, что эквивалентно сохранению $p + 1$ секущих условий на текущем окне (§2.2). Это — центральное теоретическое отличие семейства L-PB от L-Broyden и основание для применимости теоремы 2.10 с расширенным проектором.

Замечание 2.18 (Связь с Burdakov–Kamandi 2018). Burdakov и Kamandi [8] построили globalized multi-secant метод для $F(x) = 0$ с плотным $O(n^2)$ -хранением матрицы B_k и nonmonotone line search Ли–Фукушимы; виртуальная матрица A_{k+1} , точно интерполирующая ΔF на окне, используется как технический объект в доказательстве bounded deterioration через декомпозицию $\|B_{k+1} - J^*\| \leq \|B_{k+1} - A_{k+1}\| + \|A_{k+1} - J^*\|$. В настоящей работе A_{k+1} концептуально совпадает с плотным мультисекущим обновлением (12) (для которого теорема 2.10 даёт прямую оценку без декомпозиции), а limited-memory B_k из L-PB — с ранг-1 специализацией (34) того же объекта. Перенос аргумента globalization [8] на L-PB (с необходимостью отслеживать выталкивание окна) и численное сравнение с их семейством — естественные направления развития, обсуждаемые в Заключение.

Замечание 2.19 (Связь с Anderson(m, β)). Anderson(m, β) [1, 34, 33] — alternative limited-memory метод без явной модели якобиана; окно $\{x_j, F(x_j)\}$ используется для построения мульти-секущей подгонки, но объект $\|(B_k - J(x_k))d_k\|$, контролируемый Следствием 2.12 для L-PB, в Anderson формально не определён. Из эквивалентности (10) [34,

16] Anderson типа I при $B_0 = I$, $\beta = 1$ соответствует L-PB в режиме *пересборки* (`accumulate = false`), тогда как L-PB по умолчанию работает в режиме *накопления* от текущего B_k — это структурно иной режим управления историей (§1.4, гл. 1).

Замечание 2.20 (Связь с Schubert). Sparse-Broyden Шуберта [31] — limited-memory rank-1 вариант для $F(x) = 0$ с разрежённым якобианом известной структуры: на каждом шаге обновляется лишь подмножество элементов B_k в рамках заданного шаблона. Инвариант L-PB (сохранение $p + 1$ текущих условий) и инвариант Schubert (сохранение шаблона sparsity) ортогональны: L-PB не использует структуру задачи, а Schubert не использует историю шагов. Их комбинация — sparse limited-memory с сохранением прошлых текущих — в настоящей работе не рассматривается.

2.3 Численные эксперименты

В этом разделе представлены численные эксперименты по двум направлениям: (I) сравнение скорости сходимости мультисекундного обновления с разными $p_{\max}$ и классического Бройдена ($p_{\max} = 0$) на стандартной тестовой задаче (Рис. 1); (II) применимость limited-memory варианта Алгоритма 2 из §2.2 в режиме $n \gtrsim 10^4$, где плотная форма исчерпывает память, и эмпирическая оценка деградации L-PB по m относительно плотной формы (Рис. 2). Во всех экспериментах настоящего параграфа реализуется ранг-1 запись обновления (34), эквивалентная плотному MS-обновлению Алгоритма 1 в режиме `accumulate = true`.

Тестовая задача и схема стартов. В качестве нелинейной модели используется задача Discrete BVP из стандартного набора More–Гэрбоу–Хиллстрёма [24] — конечно-разностная дискретизация краевой задачи $-u'' + (u + t + 1)^3/2 = 0$, $u(0) = u(1) = 0$ с шагом $h = 1/(n + 1)$ на сетке $t_i = ih$, $i = 1, \dots, n$. Размер $n = 100$. Якобиан $J(x_k)$ при необходимости считается аналитически. Дефолтный старт по [24] $x_0^{\text{def}} \in \mathbb{R}^n$ задан покомпонентно $(x_0^{\text{def}})_i = 0,1 t_i(t_i - 1)$. Для оценки устойчивости поведения к выбору x_0 используется ансамбль из 20 случайных возмущений

$$x_0^{(i)} = x_0^{\text{def}} + 0,05 u_i, \quad u_i = \tilde{u}_i / \|\tilde{u}_i\|, \quad \tilde{u}_i \sim \mathcal{N}(0, I_n),$$

с фиксированным seed. На всех графиках с трекингом по итерациям изображена медиана по 20 стартам, затенённая полоса — интерквартильный интервал; хвост обрезается на первой итерации, на которой более половины стартов уже завершились (то же правило применяется к Рис. 2).

(I) **Trade-off по $p_{\max}$.** Рис. 1 показывает поведение метода при $p_{\max} \in \{0, 1, 2, 5, 10\}$ (критерий останова $\|F\|_2 \leq 10^{-10}$, `maxit` = 600, шаг принимается полным: $x_{k+1} = x_k - B_k^{-1}F(x_k)$, без backtracking-Армихо — задача исследует ровно локальный режим теоремы 2.10); обе оси — в относительных единицах: левая панель — ошибка якобиана $\|B_k - J(x_k)\|_F / \|J(x_k)\|_F$, правая — относительная невязка $\|F(x_k)\|_2 / \|F(x_0)\|_2$.

Левая панель (а) — эмпирический контроль ошибки аппроксимации якобиана $\|B_k - J(x_k)\|_F$ вдоль траектории; теорема 2.10 гарантирует ограниченность $\|E_k\|_F = \|B_k - J^*\|_F$ из (17), и по неравенству треугольника $\|B_k - J(x_k)\|_F \leq \|E_k\|_F + L \|x_k - x^*\| \sqrt{n}$ ограниченность переносится на отображаемую величину в окрестности x^* . Для всех $p_{\max}$ относительная ошибка аппроксимации якобиана остаётся ограниченной вдоль траектории. Классический Бroyден ($p_{\max} = 0$) выходит на ненулевой уровень относительной ошибки $\sim 0,3$ и не достигает сходимости (см. ниже); расширение окна сдвигает этот уровень ниже, причём прирост насыщается с ростом $p_{\max}$.

Правая панель (б) — реальная скорость метода по невязке. Здесь видна *качественная разница* между классическим Бroyденом и расширенным обновлением: классический Бroyден за отведённый бюджет не достигает порога $\|F\|_2 \leq 10^{-10}$ ни на одном из 20 стартов (невязка медленно дрейфует вблизи уровня 10^{-3} – 10^{-1} и в ряде стартов численно срывается до останова по NaN). Ограниченность $\|E_k\|_F$ по теореме 2.10, формально гарантируя локальную теорию, эмпирически не транслируется в сходимость по F на этой задаче. Уже при $p_{\max} = 1$ метод устойчиво сходится на всех 20 стартах; дальнейшее увеличение $p_{\max}$ ускоряет сходимость с насыщением к $p_{\max} \sim 5$. Картина согласуется со структурой константы из замечания 2.11: расширенный проектор сильнее *вычитает* ошибку, но при росте p множитель $\sqrt{p+1} \kappa_p$ в $C_{\text{РВ}}$ растёт, и выигрыш от расширения окна выходит на насыщение.

(II) **Применимость L-РВ в высокой размерности.** Для оценки качества limited-memory аппроксимации относительно плотной формы проведено сравнение на задаче Broyden Banded (MGN #31, [24]) при $n \in \{10^4, 10^5\}$ для случайных стартов $x_0 = -0,1 \cdot \mathbf{1} + 0,05 u_i$ с единичными $u_i \in \mathbb{R}^n$ (фиксированный seed). При $n = 10^4$ плотный Projected Broyden-SM ($p \leq 5$) выступает baseline'ом ($n^2 = 10^8$ чисел с плавающей точкой ≈ 800 МБ оперативной памяти, 6 стартов); при $n = 10^5$ плотная форма принципиально неприменима ($n^2 = 10^{10}$ чисел с плавающей точкой ≈ 80 ГБ). L-РВ запускается с $m \in \{3, 5, 10, 20\}$ ($n = 10^4$, 16 стартов; случай $m = 3 < p_{\max} + 1 = 6$ намеренно нарушает условие совпадения действия L-РВ и плотной формы из утверждения 2.1 и демонстрирует прогнозируемое замедление) и $m \in \{10, 20\}$ ($n = 10^5$, 8 стартов). Все методы — с backtracking-Армихо в эффективной форме $\psi(x + \alpha d) \leq (1 - 2c_1\alpha)\psi(x)$, $\psi = \frac{1}{2} \|F\|_2^2$, $c_1 = 10^{-4}$ (эквивалентна классическому Армихо при $d = -J^{-1}F$ и асимптотически




Рисунок 1. Discrete BVP, $n = 100$, $B_0 = I$, $\|F\|_2 \leq 10^{-10}$, $\text{maxit} = 600$, 20 случайных стартов; медиана $\pm$ IQR. Пунктирная линия на панели (б) — перевод абсолютного критерия 10^{-10} в относительную шкалу через медиану $\|F(x_0)\|_2$. (а) относительная ошибка якобиана $\|B_k - J(x_k)\|_F / \|J(x_k)\|_F$ для всех $p_{\max}$ остаётся ограниченной — косвенная иллюстрация ограниченности $\|E_k\|_F = \|B_k - J^*\|_F$ из теоремы 2.10 ((17); величины связаны через $\|B_k - J(x_k)\|_F \leq \|E_k\|_F + L \|x_k - x^*\| \sqrt{n}$). (б) относительная невязка $\|F(x_k)\|_2 / \|F(x_0)\|_2$: классический Бройден ($p_{\max} = 0$) за отведённый бюджет не достигает tol ни на одном из 20 стартов, тогда как PB при $p_{\max} \geq 1$ устойчиво сходится на всех 20 стартах; рост $p_{\max}$ до 5 дополнительно ускоряет сходимость. Расширение окна не только усиливает проектор Π_k в разложении теоремы 2.10, но и переводит метод из режима «ошибка ограничена, сходимости нет» в режим сверхлинейной сходимости.

приближается к ней при $B_k \rightarrow J^*$); дополнительно используется техническая защита от первого слишком длинного шага $\|d_k\| \leq 50 \max(\|x_k\|, 1)$ (x_0 -зависимая нормировка), не активная в асимптотическом режиме. Критерий $\|F\|_2 \leq 10^{-10}$.

При $n = 10^4$ плотный Projected Broyden-SM сходится за ~ 50 итераций; L-PB при $m = 20$ — за ~ 75 , при $m = 10$ — за ~ 85 . Деградация по m согласуется с замечанием 2.15: L-PB и плотная форма не эквивалентны при $k > m$, поскольку рекурсия (36) неявно полагает $B_{k-m}^{\text{LPB}} = I$, тогда как B_{k-m}^{dense} накопил историю обновлений (это типовая ситуация limited-memory методов, ср. L-BFGS 2.16). Утверждение 2.1 гарантирует совпадение лишь действия на $\text{col } S_p^{(k)}$ — последние $p_{\max} + 1$ текущих условий — что и обеспечивает сходимость L-PB при $m \geq p_{\max} + 1$. При недостаточной ёмкости окна ($m \in \{3, 5\} < p_{\max} + 1 = 6$) обе соответствующие траектории выходят на плато на уровне $\sim 10^{-9}$ и не достигают $\text{tol} = 10^{-10}$ за 300 итераций — прогнозируемый эффект потери ортогональности $v_k^\top s_j = 0$ для уже вытолкнутых s_j , входящих в текущий $S_p^{(k)}$. Кривая $m = 5$ медленнее $m = 3$ во всей пре-асимптотической фазе: при $m = 5$ формула $v_k = S_p G_p^{-1} e_1$ строится из частично-устаревших столбцов (4 предыдущих текущих хранятся, но v_k предполагает их ортогональность к уже вытолкнутым), что создаёт более согласованную, но неверную структуру; при $m = 3$ обновление эффективно близко к ранг-1 Бройдену (используется $p_{\text{eff}} = 2$ из-за короткого буфера) и работает хуже




Рисунок 2. Broyden Banded, $\|F\|_2 \leq 10^{-10}$, backtracking-Армихо ($c_1 = 10^{-4}$, ψ -форма). Медианная траектория $\|F(x_k)\|_2 + \text{IQR}$ по случайным стартам $x_0 = -0,1 \cdot \mathbf{1} + 0,05 u_i$. Слева — $n = 10^4$, 16 стартов; плотный Projected Broyden-SM ($p \leq 5$, чёрный пунктир, 6 стартов) — baseline. Справа — $n = 10^5$, 8 стартов; плотная форма требует ≈ 80 ГБ оперативной памяти и неприменима.

асимптотически, но устойчивее в средней фазе. При $n = 10^5$ L-РВ устойчиво сходится при $m \in \{10, 20\}$ за ~ 85 итераций; число итераций до сходимости *не растёт* с n , что демонстрирует применимость метода в режиме, где плотная форма исчерпывает память (≈ 80 ГБ при $n = 10^5$).

Резюме. В главе введён мультисекунный Бройден — ранг- $(p+1)$ обновление, для которого теорема 2.10 даёт точное разложение Фробениус-нормы ошибки $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$ и явную геометрическую константу $C_{\text{РВ}}$, а следствие 2.12 — безусловный $O(\rho_k)$ -контроль ошибки на всём подпространстве $\text{col } S_p$. В режиме `accumulate = true` обновление специализируется к ранг-1 форме (34), что через Шермана–Моррисона (35) ведёт к limited-memory варианту L-РВ с памятью и временем $O(nm)$ и $O(nm^2)$ соответственно. Численные эксперименты иллюстрируют структурное преимущество расширенного обновления: рост p_{max} переводит метод из режима « $\|E_k\|_F$ ограничена, по F сходимости нет» (классический Бройден) в режим сверхлинейной сходимости (Рис. 1). Limited-memory вариант L-РВ при $m \geq p_{\text{max}} + 1$ сохраняет последние $p_{\text{max}} + 1$ секущих условий плотной формы (утверждение 2.1), демонстрируя ожидаемую для limited-memory методов умеренную деградацию по m относительно плотной формы; число итераций до сходимости не растёт с n вплоть до $n = 10^5$, в режиме которого плотная форма уже неприменима по памяти (Рис. 2).

Глава 3

Симметричные квазиньютоновские обновления с контролем текущих условий

3.1 Мотивация

В предыдущих разделах мультисекущий Бройден решил задачу сохранения текущих условий для общих систем $F(x) = 0$, однако матрица B_k при этом несимметрична. Для задач безусловной оптимизации, где $F = \nabla f$ и $J^* = \nabla^2 f(x^*)$ симметричен, естественно требовать $B_k = B_k^\top$.

Классические симметричные квазиньютоновские обновления — SR1 (*symmetric rank-one*, Дэвидон [11]) и PSB (*Powell symmetric Broyden*, Пауэлл [28]) — удовлетворяют текущему секущему условию $B_{k+1}s_k = y_k$, но не контролируют невязку прошлых секущих $R_{\text{past}} = B_k S_{\text{past}} - Y_{\text{past}}$. Классический результат Шнабеля [30] показывает, что одновременное точное выполнение всех секущих и симметрии в общем случае невозможно; ниже воспроизведена компактная формулировка этой леммы в форме, удобной для дальнейшего анализа.

Лемма 3.1 (Шнабель [30]; необходимое условие совместности симметрии и одновременного сохранения всех секущих).

Пусть $B_k \in \mathbb{R}^{n \times n}$ удовлетворяет всем прошлым секущим условиям $B_k s_j = y_j$ ($j = 0, \dots, k-1$), и пусть симметричное обновление $B_{k+1} = B_k + \Delta B$, $\Delta B = \Delta B^\top$, сохраняет все секущие до k -й включительно:

$$B_{k+1}s_j = y_j \quad (j = 0, \dots, k-1), \quad B_{k+1}s_k = y_k.$$

В терминах поправки ΔB это означает

$$\Delta B s_j = 0 \quad (j = 0, \dots, k-1), \quad \Delta B s_k = r_k, \quad r_k := y_k - B_k s_k.$$

Тогда остаток r_k обязан быть ортогонален всем прошлым шагам:

$$s_j^\top r_k = 0 \quad \forall j < k. \quad (40)$$

Доказательство.

Для произвольного $j < k$:

$$s_j^\top r_k \stackrel{(1)}{=} s_j^\top (\Delta B s_k) \stackrel{(2)}{=} s_j^\top \Delta B^\top s_k \stackrel{(3)}{=} (\Delta B s_j)^\top s_k \stackrel{(4)}{=} 0, \quad (41)$$

где (1) — текущее секущее условие $\Delta B s_k = r_k$; (2) — симметрия $\Delta B = \Delta B^\top$; (3) — тождество $u^\top A^\top v = (Au)^\top v$; (4) — сохранение j -й прошлой секущей $\Delta B s_j = 0$. ■

Замечание 3.2 (Когда условие (40) выполнено). Пусть $F = \nabla f$, $f \in C^2$. По интегральной форме теоремы о среднем для градиента

$$y_j = \nabla f(x_j + s_j) - \nabla f(x_j) = \bar{H}_j s_j, \quad \bar{H}_j := \int_0^1 \nabla^2 f(x_j + t s_j) dt,$$

где $\bar{H}_j$ — средний гессиан вдоль j -го шага (симметричен). Если B_k симметричен и удерживает прошлые секущие $B_k s_j = y_j$, то $s_j^\top B_k = (B_k s_j)^\top = (\bar{H}_j s_j)^\top = s_j^\top \bar{H}_j$, и левая часть (40) принимает вид

$$s_j^\top r_k = s_j^\top y_k - s_j^\top B_k s_k = s_j^\top \bar{H}_k s_k - s_j^\top \bar{H}_j s_k = s_j^\top (\bar{H}_k - \bar{H}_j) s_k. \quad (42)$$

Случай квадратичной f . Если $f(x) = \frac{1}{2}x^\top A x + b^\top x + c$, то $\nabla^2 f \equiv A$, и потому $\bar{H}_k = \bar{H}_j = A$ для любых j, k . Правая часть (42) обращается в нуль тождественно, условие (40) выполнено автоматически — симметричное обновление, одновременно удерживающее все секущие, существует.

Случай неквадратичной f . Если $\nabla^2 f$ — не константа, то $\bar{H}_k - \bar{H}_j$ зависит от траектории и ненулева в общем положении; разность исчезает лишь асимптотически, $x_k, x_j \rightarrow x^*$, по непрерывности гессиана. Поэтому в произвольной конечной окрестности условие (40) не выполнено — симметричного обновления, точно удерживающего все секущие, в общем случае не существует. Это и есть та жёсткость, которую в §3.2 снимает SS-конструкция: вместо точного удержания прошлых секущих минимизируется их остаток в ортогональном к s_k дополнении.

3.2 Конструкция и алгоритм SS- $\mathcal{U}$

Определение 3.3 (Секантно-стабилизированное обновление).

Пусть $\mathcal{U}$ — базовое симметричное квазиньютоновское обновление, удовлетворяющее текущему секущему условию $\mathcal{U}(B_k, s_k, y_k) s_k = y_k$, $B'_k := \mathcal{U}(B_k, s_k, y_k)$, $R'_k := B'_k S_p - Y_p$. Секантно-стабилизированное расширение SS- $\mathcal{U}$ задаётся ранг-1 коррекцией

$$B_{k+1} = B'_k + \sigma_k^* u_k^* u_k^{*\top}, \quad u_k^* \perp s_k, \quad \|u_k^*\| = 1, \quad (43)$$

направленной на минимизацию остатка прошлых секущих в $s_k^\perp$,

$$(\sigma_k^*, u_k^*) \in \arg \min \{ \|R'_k + \sigma u u^\top S_p\|_F^2 : \|u\| = 1, u \perp s_k, \sigma \in \mathbb{R} \}. \quad (44)$$

Точная задача (44) не имеет замкнутой формы (Лемма 3.4, п. 2); в Алгоритме 3 применяется гибридная стратегия. Сначала u_k^* — ведущий по $|\lambda|$ собственный вектор симметричной матрицы $P_k M'_k P_k$ на $s_k^\perp$, где $P_k = I - \hat{s}_k \hat{s}_k^\top$, $M'_k := \frac{1}{2}(R'_k S_p^\top + S_p R'_k)$; выбор u_k^* отвечает упрощённой задаче после замены знаменателя $\|S_p^\top u\|^2$ на $\|u\|^2 = 1$ в (46) (Лемма 3.4, п. 3). Затем при зафиксированном $u = u_k^*$ коэффициент σ_k^* берётся *точным* условным оптимумом функционала (44):

$$\sigma_k^* = -\frac{u_k^{*\top} R'_k S_p^\top u_k^*}{\|S_p^\top u_k^*\|^2}. \quad (45)$$

В результате пара (u_k^*, σ_k^*) — точный условный минимум по σ при приближённо найденном направлении u_k^* ; устойчивость знаменателя обеспечивается safeguard (A3) Леммы 3.12.

Лемма 3.4 (Условный оптимум σ и характеристикация u_k^* в Алгоритме 3).

Пусть $R'_k = B'_k S_p - Y_p$, $M'_k = \frac{1}{2}(R'_k S_p^\top + S_p R'_k)$, S_p — полного столбцового ранга, $\Phi(\sigma, u) := \|R'_k + \sigma u u^\top S_p\|_F^2$. Тогда:

1. для каждого $u \in s_k^\perp$ с $\|u\| = 1$ и $\|S_p^\top u\| \neq 0$ условный оптимум σ при фиксированном u равен $\sigma_k^*(u) = -(u^\top M'_k u) / \|S_p^\top u\|^2$, и подстановка даёт

$$\min_{\sigma} \Phi(\sigma, u) = \|R'_k\|_F^2 - \frac{(u^\top M'_k u)^2}{\|S_p^\top u\|^2}; \quad (46)$$

2. точная минимизация (46) по $u \in s_k^\perp \cap S^{n-1}$ приводит к самосогласованной нелинейной задаче

$$P_k (M'_k - \lambda(u) S_p S_p^\top) u = \frac{1}{2} (u^\top M'_k u) u, \quad \lambda(u) := \frac{u^\top M'_k u}{2 \|S_p^\top u\|^2},$$

которая, в отличие от стандартной обобщённой задачи на собственные значения, не допускает замкнутого решения (множители $\lambda(u)$ и $\frac{1}{2}u^\top M'_k u$ зависят от u);

3. замена $\|S_p^\top u\|^2 \rightarrow \|u\|^2 = 1$ в знаменателе (46) сводит задачу к максимизации $(u^\top M'_k u)^2$ на $s_k^\perp \cap S^{n-1}$, у которой ведущий по $|\lambda|$ собственный вектор $P_k M'_k P_k$ на $s_k^\perp$ доставляет точный максимум λ_*^2 (тождество Куранта–Фишера для $P_k M'_k P_k$). В Алгоритме 3 в качестве u_k^* берётся именно этот собственный вектор; соответствующее $\sigma_k^* := \sigma_k^*(u_k^*)$ задано формулой (45) из п. 1.

Доказательство.

П. 1. Раскрытие $\|R'_k + \sigma u u^\top S_p\|_F^2$ через $\|A + B\|_F^2 = \|A\|_F^2 + 2 \operatorname{tr}(A^\top B) + \|B\|_F^2$ даёт

$$\Phi(\sigma, u) = \|R'_k\|_F^2 + 2\sigma (u^\top M'_k u) + \sigma^2 \|S_p^\top u\|^2, \quad (47)$$

где использованы $\operatorname{tr}(R'_k u u^\top S_p) = u^\top S_p R'_k u = u^\top M'_k u$ (полусумма скаляров $u^\top R'_k S_p^\top u = u^\top S_p R'_k u$) и $\|u u^\top S_p\|_F^2 = \|u\|^2 \|S_p^\top u\|^2 = \|S_p^\top u\|^2$ при $\|u\| = 1$. Стационарность по σ : $\partial_\sigma \Phi = 0$ даёт $\sigma_k^*(u)$; подстановка в (47) — (46).

П. 2. Обозначим $\rho(u) := (u^\top M'_k u)^2 / \|S_p^\top u\|^2$, $f := u^\top M'_k u$, $g := \|S_p^\top u\|^2$. Случай $f = 0$ соответствует глобальному минимуму $\rho(u) = 0$ и достигается на любом $u \perp s_k$ с $u^\top M'_k u = 0$; ниже рассматриваем нетривиальный случай $f \neq 0$.

По правилу множителей Лагранжа стационарность ρ на $\|u\| = 1, u \perp s_k$ эквивалентна $\nabla \rho = 2\alpha u + \beta s_k$ для некоторых $\alpha, \beta \in \mathbb{R}$. Скалярно умножая на u (с использованием $u \perp s_k, \|u\| = 1$): $u^\top \nabla \rho = 2\alpha$. Прямой расчёт $\nabla \rho = (4f/g) M'_k u - (2f^2/g^2) S_p S_p^\top u$ даёт $u^\top \nabla \rho = 4f^2/g - 2f^2/g = 2f^2/g = 2\rho(u)$, откуда $\alpha = \rho(u) = f^2/g > 0$ при $f \neq 0$. Подстановка $\alpha = \rho(u)$ в $\nabla \rho - 2\alpha u - \beta s_k = 0$ и проектирование на $s_k^\perp$ ($P_k u = u$) дают

$$P_k [(4f/g) M'_k - (2f^2/g^2) S_p S_p^\top] u = (2f^2/g) u.$$

Деление на $4f/g$ и подстановка $\lambda = f/(2g)$: $P_k (M'_k - \lambda S_p S_p^\top) u = (f/2) u$. Поскольку λ и $f/2$ зависят от u , эта задача не является обобщённой задачей на собственные значения.

П. 3. Подстановка $\|S_p^\top u\|^2 \equiv 1$ в (46) сводит её к $\|R'_k\|_F^2 - (u^\top M'_k u)^2$, и задача превращается в максимизацию $h(u) := (u^\top M'_k u)^2$ на $\{u \in \mathbb{R}^n : \|u\| = 1, u \perp s_k\}$. Поскольку $P_k u = u$ на $s_k^\perp$, имеем $u^\top M'_k u = u^\top P_k M'_k P_k u =: u^\top A_k u$, где $A_k := P_k M'_k P_k$ симметрична. Стационарность h под ограничениями $\|u\| = 1, u \perp s_k$ по правилу множителей Лагранжа эквивалентна $\nabla h = 2\lambda u + \mu s_k$ с $\nabla h = 4(u^\top A_k u) A_k u$; проектируя на $s_k^\perp$ (P_k , причём $P_k A_k u = A_k u$): $4(u^\top A_k u) A_k u = 2\lambda u$, т. е. $A_k u = \mu_* u$ с $\mu_* = \lambda/(2u^\top A_k u)$. Таким образом, стационарные точки совпадают с собственными векторами A_k на $s_k^\perp$ (стандартный факт о экстремумах квадратичной формы на сфере; ср. Голуб–ван Лоан [20, §8.1]). В каждом

стационарном векторе u имеем $u^\top A_k u = \mu_*$, поэтому $h(u) = \mu_*^2$; максимум достигается ведущим по $|\mu_*|$ собственным вектором, давая $h_{\max} = \lambda_*^2 := \max_{i: v_i \perp s_k} \mu_i^2$. ■

Замечание 3.5 (Качество упрощения при условии safeguard). Точное решение (44) (Лемма 3.4, п. 2) и используемое в Алгоритме 3 упрощение (п. 3) отличаются заменой $\|S_p^\top u\|^2$ на $\|u\|^2 = 1$ в знаменателе условного оптимума по σ . При safeguard (A3) Леммы 3.12 ($\|S_p^\top u\|^2 \geq \varepsilon_S$) знаменатель условного оптимума ограничен снизу, и оценка bounded deterioration (Лемма 3.12) корректно опирается на точное σ_k^* из (45) независимо от того, является ли выбранный u_k^* точным максимизатором $\rho(u)$ или ведущим собственным вектором $P_k M'_k P_k$.

Базовые обновления $\mathcal{U}$. Алгоритм SS- $\mathcal{U}$, приведённый ниже, не зависит от выбора $\mathcal{U}$, кроме явного вычисления $B'_k = \mathcal{U}(B_k, s_k, y_k)$. В численных экспериментах настоящей главы рассматриваются два классических индефинитных симметричных обновления:

$$\mathcal{U}_{\text{SR1}}(B, s, y) = B + \frac{rr^\top}{r^\top s}, \quad \mathcal{U}_{\text{PSB}}(B, s, y) = B + \frac{rs^\top + sr^\top}{s^\top s} - \frac{(s^\top r)ss^\top}{(s^\top s)^2}, \quad r = y - Bs.$$

SR1 требует skip-rule [26, §6.2]: при $|s^\top r| < \varepsilon_{\text{skip}} \|s\| \|r\|$ обновление пропускается, $B'_k = B_k$. PSB skip-правил не требует. SS-расширение строится по единому шаблону (43), ниже — общий псевдокод.

Численные защиты вне теории — вырождение u_k^* после репроекции на $s_k^\perp$ (порог ε_u), устойчивость знаменателя σ_k^* (порог ε_S) и собственный skip-rule базового $\mathcal{U}$ (для $\mathcal{U} = \text{SR1}$) — обсуждаются в замечании 3.7; в псевдокоде эти пороги опущены ради ясности и заменены проверкой $u_k^* \neq 0$, $S_p^\top u_k^* \neq 0$. Ключевое наблюдение для собственной задачи $P_k M'_k P_k$: $M'_k = \frac{1}{2}(R'_k S_p^\top + S_p R'_k{}^\top)$ — сумма двух матриц ранга $\leq p + 1$, поэтому

$$\text{rank}(P_k M'_k P_k) \leq \text{rank}(M'_k) \leq 2(p + 1), \quad (48)$$

и весь ненулевой спектр $A_k = P_k M'_k P_k$ лежит в $\text{range}(P_k [S_p, R'_k])$. Собственная задача переносится из $\mathbb{R}^n$ в подпространство размерности $r \leq 2(p + 1)$ через QR-ортогонализацию этого базиса (приём, стандартный для блочных Ланцош-итераций [27, Гл. 13]; ср. также подход Fang–Saad [16] для мультисекантных схем). Алгоритм 3 непосредственно реализует эту редукцию; эквивалентность с прямой формой $\text{eigh}(A_k)$ и детализация стоимости — в Замечании 3.6.

Algorithm 3 SS- $\mathcal{U}$ (∇f , x_0 , $p_{\max}$, ε ; $\mathcal{U}$)

Require: $\nabla f: \mathbb{R}^n \rightarrow \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$, $p_{\max} \geq 0$, $\varepsilon > 0$

Require: базовое симметричное обновление $\mathcal{U}(B, s, y)$, удерживающее текущую секую $\mathcal{U}(B, s, y)$ $s = y$ (например, $\mathcal{U}_{\text{SR1}}$ со skip-rule или $\mathcal{U}_{\text{PSB}}$)

```

 $B_0 \leftarrow I_n, \quad k \leftarrow 0$ 
while  $\|\nabla f(x_k)\| \geq \varepsilon$  do
    Решить  $B_k d_k = -\nabla f(x_k)$ 
     $x_{k+1} \leftarrow x_k + d_k, \quad s_k \leftarrow d_k, \quad y_k \leftarrow \nabla f(x_{k+1}) - \nabla f(x_k)$ 
     $B'_k \leftarrow \mathcal{U}(B_k, s_k, y_k) \triangleright$  базовая симметричная итерация (с её собственным skip-rule)
     $p \leftarrow \min(p_{\max}, k), \quad S_p \leftarrow [s_k \mid \dots \mid s_{k-p}], \quad Y_p \leftarrow [y_k \mid \dots \mid y_{k-p}]$ 
     $R'_k \leftarrow B'_k S_p - Y_p, \quad M'_k \leftarrow \frac{1}{2}(R'_k S_p^\top + S_p R_k'^\top)$ 
     $\hat{s}_k \leftarrow s_k / \|s_k\|, \quad P_k \leftarrow I - \hat{s}_k \hat{s}_k^\top$ 
     $(\lambda_k^*, u_k^*) \leftarrow$  ведущая по  $|\lambda|$  собственная пара  $P_k M'_k P_k; \|u_k^*\| = 1 \triangleright \text{rank} \leq 2(p+1) -$ 
    замечание 3.6
    if  $u_k^* \neq 0$  and  $S_p^\top u_k^* \neq 0$  then
         $\sigma_k^* \leftarrow -(u_k^{*\top} R'_k S_p^\top u_k^*) / \|S_p^\top u_k^*\|^2$ 
         $B_{k+1} \leftarrow B'_k + \sigma_k^* u_k^* u_k^{*\top}$ 
    else
         $B_{k+1} \leftarrow B'_k \triangleright$  коррекция пропущена (включая  $k=0$ , окно пусто)
     $k \leftarrow k + 1$ 
return  $x_k$ 

```

Замечание 3.6 (Стоимость и эквивалентность с прямой формой). Псевдокод оставляет вычисление ведущей пары (λ_k^*, u_k^*) матрицы $P_k M'_k P_k$ абстрактным. В реализации используется редукция к пространству $\text{range}(P_k [S_p, R'_k])$: ортогонализация $W = (I - \hat{s}_k \hat{s}_k^\top) [S_p \mid R'_k] \in \mathbb{R}^{n \times 2(p+1)}$ тонким QR в $Q \in \mathbb{R}^{n \times r}, r \leq 2(p+1)$, и эрмитов собственный разбор $\tilde{M} = Q^\top M'_k Q \in \mathbb{R}^{r \times r}$; поднятие $u_k^* = Q v_{j^*}, j^* = \arg \max_i |\lambda_i|$. Стоимость: $R'_k - O(n^2 p)$ на плотном B'_k , QR — $O(np^2)$, $\text{eigh}(\tilde{M}) - O(p^3)$; суммарно $O(n^2 p + np^2 + p^3)$ на итерацию, память $O(np)$ против $O(n^2)$ при хранении полного A_k .

Эквивалентная прямая форма — собрать $A_k = P_k M'_k P_k \in \mathbb{R}^{n \times n}$ явно и вызвать $\text{eigh}(A_k)$ напрямую (QR-итерация на трёхдиагонализированной форме [20, §8.3], $O(n^3)$); в силу оценки ранга (48) обе формы дают ту же ведущую собственную пару (λ^*, u_k^*) с различием порядка машинной точности. В численных экспериментах главы $n \leq 50$, и обе формы пренебрежимы по стоимости относительно вычисления ∇f и LU-решения системы $B_k d_k = -\nabla f$ (последнее — $O(n^3)$); фактически используется прямая форма $\text{eigh}(A_k)$. Редукция (48) становится существенной при $n \gg p$ (типично $p \leq 10, n \gtrsim 100$ даёт $\sim n/p$ -кратное ускорение).

Замечание 3.7 (Статус численных порогов). Дефолты $\varepsilon_{\text{skip}} = 10^{-8}$ (skip-rule базового $\mathcal{U} = \text{SR1}$, ср. [26, §6.2]), $\varepsilon_u = 10^{-12}$ и $\varepsilon_S = 10^{-15}$ ((45)) выбраны как мягкие численные защиты вблизи машинной точности — цель каждого охранника: не допустить деление на малое / потерю ортогональности после репроекции на $s_k^\perp$. Дефолты не основаны на параметрическом анализе чувствительности и могут потребовать адаптации для новых

классов задач, особенно с экстремальной обусловленностью гессиана либо в смешанной точности. Качественно: $\varepsilon_{\text{skip}}$ контролирует консервативность skip-rule (увеличение даёт более частый skip); $\varepsilon_u, \varepsilon_S$ срабатывают редко на гладких задачах настоящей работы. Систематический sweep по $(\varepsilon_{\text{skip}}, \varepsilon_u, \varepsilon_S)$ выходит за рамки локального анализа и обозначен как направление дальнейших исследований.

3.3 Свойства

Теорема 3.8 (Свойства SS- $\mathcal{U}$).

Обновление (43) обладает следующими свойствами:

1. **Текущее секущее условие:** $B_{k+1}s_k = y_k$ (точно).
2. **Симметрия:** если $\mathcal{U}$ сохраняет симметрию, то $B_{k+1} = B_{k+1}^\top$.
3. **Монотонность невязки секущих.** Обозначим $R_{k+1} := B_{k+1}S_p - Y_p$ (невязка всех $p+1$ секущих после композитного шага); в силу п. 1 первый столбец R_{k+1} (отвечающий s_k) и R'_k нулевой, поэтому $\|R_{k+1}\|_F$ и $\|R'_k\|_F$ совпадают с нормами невязок прошлых секущих. Тогда

$$\|R_{k+1}\|_F^2 = \|R'_k\|_F^2 - \frac{(u_k^{*\top} M'_k u_k^*)^2}{\|S_p^\top u_k^*\|^2} = \|R'_k\|_F^2 - (\sigma_k^*)^2 \|S_p^\top u_k^*\|^2.$$

4. **Ранг обновления:** $\text{rank}(B_{k+1} - B_k) \leq \text{rank}(\mathcal{U}) + 1$.

Доказательство.

1. Из $u_k^* \perp s_k$: $B_{k+1}s_k = B'_k s_k + \sigma_k^*(u_k^{*\top} s_k) u_k^* = y_k + 0 = y_k$.
2. $B_{k+1} = B'_k + \sigma_k^* u_k^* u_k^{*\top}$ — сумма двух симметричных матриц.
3. Пусть $\tilde{B} = B'_k + \sigma u u^\top$. Тогда $\|\tilde{B}S_p - Y_p\|_F^2 = \|R'_k\|_F^2 + 2\sigma(u^\top M' u) + \sigma^2 \|S_p^\top u\|^2$. Подстановка σ_k^* из (45) — точного условного оптимума по σ — даёт убывание ровно на $(u^\top M' u)^2 / \|S_p^\top u\|^2 = (\sigma_k^*)^2 \|S_p^\top u\|^2$ (равенство, не неравенство).
4. $B_{k+1} - B_k = \underbrace{(B'_k - B_k)}_{\text{rank} \leq \text{rank}(\mathcal{U})} + \underbrace{\sigma_k^* u_k^* u_k^{*\top}}_{\text{rank} \leq 1}$, и $\text{rank}(A + B) \leq \text{rank}(A) + \text{rank}(B)$. ■

3.4 Связь с известными подходами

Несовместность симметрии и одновременного выполнения нескольких секущих условий [30] (Лемма 3.1) разрешается в литературе по симметричным multi-secant квазиньютоновским обновлениям по разным траекториям; конструкция SS- $\mathcal{U}$ из (43) занимает в этом ряду характерную позицию.

Gratton, Malmedy и Toint [21] вводят весовую multi-secant модификацию: B_{k+1} — решение задачи $\min \|B - B_k\|_F^2$ при штрафе $\sum_j w_j \|Bs_j - y_j\|^2$ за невязку прошлых секущих и ограничении симметрии; текущая секущая выполняется только в смысле того же штрафа, не точно. Boutet, Haelterman и Degroote [4] конкретизируют эту схему как расширение PSB через весовую multi-secant невязку; решение имеет ранг $\leq 2(p+1)$ и получается из уравнения Сильвестра. В последующих работах те же авторы развивают подход в двух направлениях: gPSB [5] жертвует точной симметрией ради точного выполнения нескольких секущих, а grouped/ordered [3] разрешает противоречие иерархически — через лексикографическое выполнение упорядоченных групп секущих, без явной декомпозиции $\mathbb{R}^n = \text{span}(s_k) \oplus s_k^\perp$.

Scieur, Liu, Pumi и Boumal [19] формулируют симметричный multi-secant как задачу наименьших квадратов на всём окне с PSD-регуляризацией μI ; все секущие, включая текущую, выполняются приближённо, направления коррекции выделенной структуры в $s_k^\perp$ не имеют.

Конструкция (43) отличается от перечисленных схем тремя структурными признаками. *Во-первых*, текущая секущая $B_{k+1}s_k = y_k$ и симметрия выполняются *точно* — по построению базы $B'_k = \mathcal{U}(B_k, s_k, y_k)$ и ортогональности $u_k^* \perp s_k$ (теорема 3.8, п. 1–2); *во-вторых*, коррекция имеет ранг 1 ($\sigma_k^* u_k^* u_k^{*\top}$), а не ранг $\leq 2(p+1)$ как у [21, 4]; *в-третьих*, целевая функция — невязка прошлых секущих $\|R'_k + \sigma u u^\top S_p\|_F^2$ в подпространстве $s_k^\perp$, а не близость к B_k , что приводит к обобщённой собственной задаче $M'_k u = \lambda S_p S_p^\top u$ на $s_k^\perp$ (Лемма 3.4). Двухэтапная схема «симметричное базовое $\mathcal{U}$ — затем rank-1 надстройка в $s_k^\perp$ » оставляет выбор базы независимым: в настоящей работе $\mathcal{U} \in \{\text{SR1}, \text{PSB}\}$ (§3.2), но алгоритм 3 применим к любому симметричному обновлению, удерживающему текущую секущую.

3.5 Сверхлинейная сходимость

Теорема 3.9 (Условная Q-сверхлинейная сходимость SS- $\mathcal{U}$).

Пусть выполнены предположения:

(H1) $F = \nabla f$, гессиан $\nabla^2 f$ липшицев в окрестности x^* с константой L_H ;

(H2) метод SS- $\mathcal{U}$ сходится: $x_k \rightarrow x^*$, $s_k \rightarrow 0$, $\nabla f(x^*) = 0$;

(H3) предельный гессиан $J^* := \nabla^2 f(x^*)$ невырожден;

(H4) начиная с некоторого k_0 глобализация выдаёт полный квазиньютоновский шаг $s_k = -B_k^{-1} \nabla f(x_k)$, причём $\|B_k^{-1}\| \leq M_*$ равномерно при $k \geq k_0$;

(H5) *bounded deterioration* в форме Денниса–Море: обозначим $E_k := B_k - J^*$ — ошибку аппроксимации гессиана; существует последовательность $\beta_k \geq 0$ с $\sum_{k \geq k_0} \beta_k < \infty$ такая, что в окрестности x^*

$$\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + \beta_k.$$

Тогда:

1. (условие Денниса–Море для B_k)

$$\frac{\|(B_k - J^*) s_k\|}{\|s_k\|} \xrightarrow{k \rightarrow \infty} 0;$$

2. (Q-сверхлинейность) $\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \rightarrow 0$.

Доказательство.

Шаг 1 (*telescoping* (H5) даёт сходимость ряда). Суммируя (H5) от k_0 до N :

$$\sum_{k=k_0}^N \frac{\|E_k s_k\|^2}{\|s_k\|^2} \leq \|E_{k_0}\|_F^2 - \|E_{N+1}\|_F^2 + \sum_{k=k_0}^N \beta_k \leq \|E_{k_0}\|_F^2 + \sum_{k \geq k_0} \beta_k < \infty,$$

где использована неотрицательность $\|E_{N+1}\|_F^2$ и суммируемость β_k . Переходя к пределу $N \rightarrow \infty$, получаем $\sum_{k \geq k_0} \|E_k s_k\|^2 / \|s_k\|^2 < \infty$, откуда необходимое условие сходящегося ряда даёт

$$\frac{\|(B_k - J^*) s_k\|}{\|s_k\|} = \frac{\|E_k s_k\|}{\|s_k\|} \xrightarrow{k \rightarrow \infty} 0, \quad (49)$$

т.е. пункт 1 теоремы (условие Денниса–Море для B_k).

Шаг 2 (*Q-сверхлинейность через характеристику Денниса–Море*). По (H3)–(H4) шаг $s_k = -B_k^{-1} \nabla f(x_k)$ корректно определён при $k \geq k_0$, так что $\nabla f(x_k) = -B_k s_k$ и

$$\|\nabla f(x_k) + J^* s_k\| = \|(J^* - B_k) s_k\| = \|(B_k - J^*) s_k\|.$$

Согласно характеристике Денниса–Море [12, Th. 2.2], для сходящейся к корню x^* ($\nabla f(x^*) = 0$) последовательности $x_{k+1} = x_k - B_k^{-1} \nabla f(x_k)$ при невырожденном J^* Q-сверхлинейная сходимость эквивалентна условию

$$\frac{\|\nabla f(x_k) + J^* s_k\|}{\|s_k\|} \xrightarrow{k \rightarrow \infty} 0,$$

т.е. в наших обозначениях ровно ДМ-условию пункта 1, установленному на Шаге 1. Применяя эквивалентность, получаем $\|x_{k+1} - x^*\| / \|x_k - x^*\| \rightarrow 0$. ■

Замечание 3.10 (Содержательная роль теоремы). Теорема 3.9 утверждает скорость сходимости *при условии* (H2) — самой сходимости итерации $x_k \rightarrow x^*$, которая для базовых indefinitных обновлений ($\mathcal{U} \in \{\text{SR1}, \text{PSB}\}$) без стабилизирующей MS-коррекции в общем случае не гарантирована (см. [10] и Замечание 3.11). Если итерация сходится (что эмпирически обеспечивается MS-коррекцией и backtracking-Армихо), то скорость — Q-сверхлинейная.

Замечание 3.11 (Роль предположений). Предположения (H3) и (H4) суть стандартные локальные допущения о хорошей обусловленности задачи: невырожденность J^* нужна для применимости Денниса–Море [12], а допустимость полного шага в окрестности x^* — классическое следствие условия Армихо с $c_1 < 1/2$ для дважды-дифференцируемой f ([26], Th. 3.6).

Условие (H5) воспроизводит классическую форму bounded deterioration по Деннису–Море [12, Th. 2.2] и наследуется от выбранного базового обновления $\mathcal{U}$: для $\mathcal{U} \in \{\text{BFGS}, \text{PSB}\}$ оно установлено в [26] и [14, Th. 8.2.4], для $\mathcal{U} = \text{SR1}$ со skip-rule — в [10]. Для композитного обновления $\mathcal{U} \rightarrow \text{SS-}\mathcal{U}$ сохранение (H5) формально установлено в Лемме 3.12 (см. ниже) при дополнительном предположении (A4) о входной Q-линейной сходимости. Без MS-коррекции SR1 может нарушать (H5) с теоретически возможными расходимостями в условиях плохо обусловленных задач [10]. На рассматриваемых режимах §3.6 skip-rule SR1 оказывается достаточен для сходимости, и SS-SR1 эмпирически не даёт выигрыша по доле сходимости и числу итераций (это согласуется с ролью MS-коррекции как ограничителя накопленной невязки прошлых секущих, см. обсуждение в §3.6: преимущество проявляется там, где базовое обновление действительно деградирует, — у пары PSB / SS-PSB).

Лемма 3.12 (Композитное bounded deterioration для SS- $\mathcal{U}$).

Пусть выполнены следующие условия в окрестности $B_\delta(x^*) = \{x : \|x - x^*\| \leq \delta\}$:

(A1) $F = \nabla f$, $\nabla^2 f$ липшицев с константой L_H в $B_\delta(x^*)$;

(A2) базовое обновление $\mathcal{U}$ удовлетворяет Lipschitz-контролируемому bounded deterioration: существует $c_{\mathcal{U}} \geq 0$ такая, что в $B_\delta(x^*)$

$$\|E'_k\|_F^2 \leq \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + c_{\mathcal{U}} L_H \alpha_k, \quad \alpha_k := \frac{1}{2}(\|x_k - x^*\| + \|x_{k+1} - x^*\|); \quad (50)$$

(Деннис–Шнабель [14, Th. 8.2.4] для $\mathcal{U} = \text{PSB}$; Конн–Гулд–Тойнт [10] для $\mathcal{U} = \text{SR1}_{\text{skip}}$);

(A3) Алгоритм 3 применяет SS-коррекцию только при $\|S_p^\top u_k^*\|^2 \geq \varepsilon_S$; в противном случае $B_{k+1} = B'_k$ и SS-вклад равен нулю;

(A4) начальная точка достаточно близка к x^* : $\|E_{k_0}\|_F < \delta'$ и $\|x_{k_0} - x^*\| < \delta''$, где $\delta', \delta'' > 0$ зависят от $L_H, \|J^*\|_2, \|(J^*)^{-1}\|_2, \varepsilon_S, c_{\mathcal{U}}, p$ (явный выбор дан в Шаге 7 доказательства).

Здесь $E_k := B_k - J^*$, $E'_k := B'_k - J^*$, $E_{k+1} := B_{k+1} - J^*$ — ошибки аппроксимации до базового шага $\mathcal{U}$, после него и после композитной SS-коррекции соответственно. Тогда существуют темп $\rho_* \in [0, 1)$, константа $\Sigma = \Sigma(\rho_*, L_H, \varepsilon_S, p, c_{\mathcal{U}}, \|E_{k_0}\|_F, \|x_{k_0} - x^*\|) < \infty$ и неотрицательная последовательность β_k с $\sum_{k \geq k_0} \beta_k \leq \Sigma$ такие, что для всех $k \geq k_0$:

$$\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + \beta_k, \quad (51)$$

а итерация $\{x_k\}$ Q -линейно сходится к x^* с темпом ρ_* : $\|x_{k+1} - x^*\| \leq \rho_* \|x_k - x^*\|$. В частности, $\|E_k\|_F \leq \sqrt{\|E_{k_0}\|_F^2 + \Sigma}$ равномерно по $k \geq k_0$.

Доказательство.

Без ограничения общности предположим, что safeguard (A3) не срабатывает — иначе $B_{k+1} = B'_k$, и (51) сразу следует из (50).

Шаг 1 (декомпозиция и проектируемое тождество). SS-коррекция:

$$B_{k+1} = B'_k + \Delta_k^{SS}, \quad \Delta_k^{SS} := \sigma_k^* u_k^* u_k^{*\top}, \quad u_k^* \perp s_k, \quad \|u_k^*\| = 1.$$

Соответственно $E_{k+1} = E'_k + \Delta_k^{SS}$. Из $u_k^* \perp s_k$:

$$E_{k+1} s_k = E'_k s_k + \sigma_k^* u_k^* (u_k^{*\top} s_k) = E'_k s_k, \quad (52)$$

т.е. SS-коррекция не меняет направленный остаток вдоль s_k .

По линейности скалярного произведения Фробениуса:

$$\|E_{k+1}\|_F^2 = \|E'_k\|_F^2 + 2\sigma_k^* \langle E'_k, u_k^* u_k^{*\top} \rangle_F + (\sigma_k^*)^2 \|u_k^* u_k^{*\top}\|_F^2.$$

Поскольку $\langle E'_k, u u^\top \rangle_F = \text{tr}(E_k'^\top u u^\top) = u^\top E'_k u$ (скаляр) и $\|u u^\top\|_F^2 = \|u\|^4 = 1$:

$$\|E_{k+1}\|_F^2 = \|E'_k\|_F^2 + 2\sigma_k^* (u_k^{*\top} E'_k u_k^*) + (\sigma_k^*)^2. \quad (53)$$

Шаг 2 (оценка SS-возмущения через треугольное неравенство). По Коши–Шварцу и $\|u_k^*\| = 1$: $|u_k^{*\top} E'_k u_k^*| \leq \|E'_k\|_2 \leq \|E'_k\|_F$. Поэтому из (53):

$$\|E_{k+1}\|_F^2 \leq \|E'_k\|_F^2 + 2|\sigma_k^*| \|E'_k\|_F + (\sigma_k^*)^2. \quad (54)$$

Объединяя с базовым (50) (тождество (52) $E_{k+1} s_k = E'_k s_k$ удерживается как отдельный

инвариант, используемый ниже при переходе к условию Денниса–Море):

$$\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + \underbrace{c_{\mathcal{U}} L_H \alpha_k}_{=:\beta_k^{(\mathcal{U})}} + \underbrace{2|\sigma_k^*| \|E'_k\|_F + (\sigma_k^*)^2}_{=:\beta_k^{(SS)}}. \quad (55)$$

Полный композитный $\beta_k := \beta_k^{(\mathcal{U})} + \beta_k^{(SS)} \geq 0$.

Шаг 3 (оценка $|\sigma_k^*|$ через $\|R'_k\|_F$). По формуле (45) и Коши–Шварцу:

$$|\sigma_k^*| = \frac{|u_k^{*\top} R'_k S_p^\top u_k^*|}{\|S_p^\top u_k^*\|^2} \leq \frac{\|R'_k\|_2 \|S_p^\top u_k^*\|}{\|S_p^\top u_k^*\|^2} \leq \frac{\|R'_k\|_F}{\|S_p^\top u_k^*\|}.$$

Применяя safeguard (A3) $\|S_p^\top u_k^*\|^2 \geq \varepsilon_S$:

$$|\sigma_k^*|^2 \leq \varepsilon_S^{-1} \|R'_k\|_F^2. \quad (56)$$

Шаг 4 (оценка $\|R'_k\|_F$ через $\|E'_k\|_F$ и Lipschitz). Пусть $e_i \in \mathbb{R}^{p+1}$ — i -й канонический базисный вектор; тогда i -й столбец R'_k ($i = 0, 1, \dots, p$) имеет вид

$$R'_k e_i = B'_k s_{k-i} - y_{k-i} = E'_k s_{k-i} - q_{k-i}, \quad q_{k-i} := y_{k-i} - J^* s_{k-i}.$$

По интегральной форме теоремы о среднем и (A1): $y_{k-i} = \left(\int_0^1 \nabla^2 f(x_{k-i} + t s_{k-i}) dt \right) s_{k-i}$, откуда

$$\|q_{k-i}\| = \left\| \int_0^1 [\nabla^2 f(x_{k-i} + t s_{k-i}) - J^*] dt \cdot s_{k-i} \right\| \leq L_H \bar{\alpha}_{k-i} \|s_{k-i}\|,$$

где $\bar{\alpha}_{k-i} := \max_{t \in [0,1]} \|x_{k-i} + t s_{k-i} - x^*\| \leq \max(\|x_{k-i} - x^*\|, \|x_{k-i+1} - x^*\|) \leq D_k$, $D_k := \max_{j \in W_k} \|x_j - x^*\|$, $W_k := \{k-p, \dots, k+1\}$. Поэтому

$$\|R'_k e_i\|^2 \leq 2 \|E'_k\|_2^2 \|s_{k-i}\|^2 + 2 L_H^2 D_k^2 \|s_{k-i}\|^2,$$

и суммируя по i :

$$\|R'_k\|_F^2 = \sum_{i=0}^p \|R'_k e_i\|^2 \leq 2 \|S_p\|_F^2 (\|E'_k\|_F^2 + L_H^2 D_k^2). \quad (57)$$

Шаг 5 (явная асимптотика β_k под (A4)). Подставляя (57) в (56):

$$(\sigma_k^*)^2 \leq 2\varepsilon_S^{-1} \|S_p\|_F^2 (\|E'_k\|_F^2 + L_H^2 D_k^2).$$

Для смешанного члена $2|\sigma_k^*|\|E'_k\|_F$ применяем $|\sigma_k^*| \leq \varepsilon_S^{-1/2}\sqrt{2}\|S_p\|_F(\|E'_k\|_F + L_H D_k)$ и АМ–ГМ на смешанный остаток $L_H D_k\|E'_k\|_F \leq \frac{1}{2}(L_H^2 D_k^2 + \|E'_k\|_F^2)$:

$$2|\sigma_k^*|\|E'_k\|_F \leq 2\sqrt{2}\varepsilon_S^{-1/2}\|S_p\|_F(\|E'_k\|_F^2 + L_H D_k\|E'_k\|_F) \leq 3\sqrt{2}\varepsilon_S^{-1/2}\|S_p\|_F\|E'_k\|_F^2 + \sqrt{2}\varepsilon_S^{-1/2}L_H^2\|S_p\|_F^2$$

Складывая:

$$\beta_k^{(SS)} \leq C_E(\|S_p\|_F)\|E'_k\|_F^2 + C_D(\|S_p\|_F)D_k^2, \quad (58)$$

с

$$C_E(\xi) := 3\sqrt{2}\varepsilon_S^{-1/2}\xi + 2\varepsilon_S^{-1}\xi^2, \quad C_D(\xi) := L_H^2(\sqrt{2}\varepsilon_S^{-1/2}\xi + 2\varepsilon_S^{-1}\xi^2).$$

Шаг 6 (суммируемость при Q-линейном темпе ρ_*). Шаги 6 и 7 проводятся совместно: пусть $\rho_* \in [0, 1)$ — темп, который будет установлен индуктивно в Шаге 7. По индуктивной гипотезе Q-линейности (I.b) Шага 7 при $j = k_0, \dots, k$: $\|x_j - x^*\| \leq \rho_*^{j-k_0}\|x_{k_0} - x^*\|$, поэтому

$$\|s_j\| \leq \|x_{j+1} - x^*\| + \|x_j - x^*\| \leq (1 + \rho_*)\rho_*^{j-k_0}\|x_{k_0} - x^*\|.$$

Отсюда:

$$\begin{aligned} \alpha_k &\leq \rho_*^{k-k_0}\|x_{k_0} - x^*\|, \\ D_k &= \max_{j \in W_k} \|x_j - x^*\| \leq \rho_*^{k-p-k_0}\|x_{k_0} - x^*\|, \\ \|S_p^{(k)}\|_F^2 &= \sum_{i=0}^p \|s_{k-i}\|^2 \leq (1 + \rho_*)^2\|x_{k_0} - x^*\|^2 \sum_{i=0}^p \rho_*^{2(k-i-k_0)} \leq C_{\rho_*} \rho_*^{2(k-p-k_0)}\|x_{k_0} - x^*\|^2, \end{aligned} \quad (59)$$

где $C_{\rho_*} := (1 + \rho_*)^2/(1 - \rho_*^2) = (1 + \rho_*)/(1 - \rho_*)$ зависит только от ρ_* (не от p): сумма $\sum_{i=0}^p \rho_*^{2(p-i)} \leq 1/(1 - \rho_*^2)$ оценивается равномерно по p . Все три величины убывают геометрически со скоростью $\rho_*^k, \rho_*^{k-p}, \rho_*^{k-p}$ соответственно.

Шаг 7 (совместная индукция: ограниченность $\|E_k\|_F$ и Q-линейность). Положим $M_{k_0} := \|E_{k_0}\|_F$, $M := 2M_{k_0}$ и зафиксируем кандидат

$$\rho_* := 2\|(J^*)^{-1}\|_2 M + \|(J^*)^{-1}\|_2 L_H \delta''. \quad (60)$$

Покажем, что при достаточно малых $\delta', \delta'' > 0$ одновременно выполняются два инварианта для всех $k \geq k_0$:

$$(I.a) \quad \|E_k\|_F \leq M;$$

$$(I.b) \quad \|x_{k+1} - x^*\| \leq \rho_* \|x_k - x^*\| \text{ с } \rho_* < 1.$$

Параметры δ', δ'' подчиним двум условиям:

$$\delta' < \frac{1}{4} \|(J^*)^{-1}\|_2^{-1}, \quad 4 \|(J^*)^{-1}\|_2 (\delta' + \frac{1}{4} L_H \delta'') < 1, \quad (61)$$

что обеспечивает $\rho_* < 1$ (поскольку $M = 2M_{k_0} < 2\delta'$), и ещё одно условие на малость Σ (см. ниже (63)).

База ($k = k_0$). (I.a) выполнена по определению M . Для (I.b): из $\|E_{k_0}\|_F < \delta' < \frac{1}{2} \|(J^*)^{-1}\|_2^{-1}$ лемма Банаха о возмущении обратимого оператора даёт $\|B_{k_0}^{-1}\|_2 \leq 2 \|(J^*)^{-1}\|_2$. Раскладывая $\nabla f(x_{k_0}) = J^*(x_{k_0} - x^*) + r_{k_0}$ с $\|r_{k_0}\| \leq \frac{1}{2} L_H \|x_{k_0} - x^*\|^2$ (из (A1) через интегральную форму остатка Тейлора), получаем

$$x_{k_0+1} - x^* = (I - B_{k_0}^{-1} J^*)(x_{k_0} - x^*) - B_{k_0}^{-1} r_{k_0},$$

и $\|I - B_{k_0}^{-1} J^*\|_2 = \|B_{k_0}^{-1} E_{k_0}\|_2 \leq 2 \|(J^*)^{-1}\|_2 M$. Отсюда $\|x_{k_0+1} - x^*\| \leq \rho_* \|x_{k_0} - x^*\|$ при ρ_* из (60), причём $\rho_* < 1$ по выбору (61).

Индуктивный шаг. Пусть (I.a), (I.b) выполнены для всех $j = k_0, \dots, k$. Тогда телескопически $\|x_j - x^*\| \leq \rho_*^{j-k_0} \|x_{k_0} - x^*\|$, и Шаги 5–6 с параметром ρ_* дают (с $\xi_j := \|S_p^{(j)}\|_F \leq \sqrt{C_{\rho_*}} \rho_*^{j-p-k_0} \|x_{k_0} - x^*\|$): из (50) $\|E'_j\|_F \leq M' := \sqrt{M^2 + c_{\mathcal{U}} L_H \|x_{k_0} - x^*\|}$, и (58) приводит к оценке

$$\beta_j \leq c_{\mathcal{U}} L_H \alpha_j + (3\sqrt{2} \varepsilon_S^{-1/2} \xi_j + 2\varepsilon_S^{-1} \xi_j^2) (M')^2 + L_H^2 (\sqrt{2} \varepsilon_S^{-1/2} \xi_j + 2\varepsilon_S^{-1} \xi_j^2) D_j^2.$$

Доминирующие слагаемые: $\xi_j (M')^2 = O(\rho_*^j)$ и $\xi_j D_j^2 = O(\rho_*^{3j})$ (квадратичные $\xi_j^2(\cdot)$ ещё быстрее); все — геометрические со знаменателем $\rho_* < 1$, суммируются:

$$\Sigma := \sum_{j \geq k_0} \beta_j \leq \frac{c_{\mathcal{U}} L_H \|x_{k_0} - x^*\|}{1 - \rho_*} + A_1(\rho_*, p, \varepsilon_S, L_H, \|x_{k_0} - x^*\|) (M')^2 + A_2(\rho_*, p, \varepsilon_S, L_H, \|x_{k_0} - x^*\|) \quad (62)$$

где $A_1, A_2 = O(\|x_{k_0} - x^*\|)$ при $\|x_{k_0} - x^*\| \rightarrow 0$.

Замыкание (I.a) на шаге $k+1$. Телескопия (55) от k_0 до k даёт $\|E_{k+1}\|_F^2 \leq \|E_{k_0}\|_F^2 + \sum_{j=k_0}^k \beta_j \leq M_{k_0}^2 + \Sigma$. Для $\|E_{k+1}\|_F \leq M = 2M_{k_0}$ достаточно

$$\Sigma \leq 3M_{k_0}^2. \quad (63)$$

Из оценки (62) и явных выражений для A_1, A_2 из Шага 6 следует $\Sigma \leq K \|x_{k_0} - x^*\| (1 + M_{k_0}^2)$ с константой $K = K(L_H, \|J^*\|_2, \|(J^*)^{-1}\|_2, \varepsilon_S, p, c_{\mathcal{U}}, \rho_*)$, зависящей только от параметров задачи (не от старта). Подставляя $M_{k_0} < \delta'$ и $\|x_{k_0} - x^*\| < \delta''$, получаем $\Sigma \leq K \delta'' (1 + \delta'^2)$; для выполнения (63) при всех допустимых $M_{k_0} \leq \delta'$ достаточно,

чтобы δ'', δ' удовлетворяли соотношению

$$K \delta'' (1 + \delta'^2) \leq 3 \delta'^2. \quad (64)$$

Это связывает δ'' с δ' : например, выбор $\delta' \leq \frac{1}{4} \|(J^*)^{-1}\|_2^{-1}$ из (61) и $\delta'' \leq 3\delta'^2/(K(1 + \delta'^2))$ обеспечивает (63) вместе с (61) одновременно при $M_{k_0} < \delta'$, $\|x_{k_0} - x^*\| < \delta''$. В этом смысле радиус δ'' масштабируется как δ'^2 ; такая связь типична для локального анализа квазиньютоновских методов (ср. Деннис–Шнабель [14, Th. 8.2.2]).

Замыкание (I.b) на шаге $k + 1$. Из (I.a) на шаге $k + 1$: $\|E_{k+1}\|_F \leq M < 2\delta' < \frac{1}{2} \|(J^*)^{-1}\|_2^{-1}$, поэтому $\|B_{k+1}^{-1}\|_2 \leq 2 \|(J^*)^{-1}\|_2$. Тот же аргумент Тейлора с x_{k+1} вместо x_{k_0} (используя $\|x_{k+1} - x^*\| \leq \rho_*^{k+1-k_0} \|x_{k_0} - x^*\| < \delta''$) и $\|I - B_{k+1}^{-1}J^*\|_2 \leq 2 \|(J^*)^{-1}\|_2 M$ дают $\|x_{k+2} - x^*\| \leq \rho_* \|x_{k+1} - x^*\|$. Индукция замыкается.

Таким образом, (I.a) обеспечивает (51), а (I.b) — Q-линейную сходимость $\{x_k\}$ с темпом $\rho_* \in [0, 1)$ как следствие, не как входное предположение. ■

Замечание 3.13 (Об условии (A4) как структурной гипотезе локальной близости). Условие (A4) формулируется как требование локальной близости старта ($\|E_{k_0}\|_F < \delta'$, $\|x_{k_0} - x^*\| < \delta''$), а не как предположение о Q-линейной сходимости итерации. Q-линейность с темпом $\rho_* \in [0, 1)$ — *выходное свойство* Леммы 3.12, устанавливаемое совместной индукцией Шага 7 одновременно с ограниченностью $\|E_k\|_F$.

Механизм совместной индукции — стандартный возмущенный аргумент локального анализа квазиньютоновских методов: при малом $\|E_k\|_F \leq M$ лемма Банаха даёт $\|B_k^{-1}\|_2 \leq 2 \|(J^*)^{-1}\|_2$, разложение ∇f вокруг x^* с Lipschitz-остатком (из (A1)) даёт сжатие $\|x_{k+1} - x^*\| \leq \rho_* \|x_k - x^*\|$ с $\rho_* = 2 \|(J^*)^{-1}\|_2 M + \|(J^*)^{-1}\|_2 L_H \delta''$ (ср. Бройден–Деннис–Море [7, Th. 3.1] или Деннис–Шнабель [14, Th. 5.4.1]). Композитная BD-оценка, в свою очередь, при ρ_* -геометрии $\|s_k\|$ даёт $\sum \beta_k < \infty$, сохраняя $\|E_{k+1}\|_F \leq M$.

Совокупный результат: SS- $\mathcal{U}$ локально Q-линейна в окрестности x^* при условии достаточной близости $\|E_{k_0}\|_F < \delta'$, $\|x_{k_0} - x^*\| < \delta''$; темп ρ_* и радиусы δ', δ'' явно выражены в Шаге 7 через $L_H, \|J^*\|_2, \|(J^*)^{-1}\|_2, \varepsilon_S, c_{\mathcal{U}}, p$.

Замечание 3.14 (Замыкание (H5) Теоремы 3.9). Лемма 3.12 закрывает аргумент сохранения (H5) под SS-коррекцией строгой цепочкой: $(A1)+(A2)+(A3)+(A4) \implies (H5)$ в композитной форме $\xRightarrow{\text{telescoping}}$ Денниса–Море для B_k $\xRightarrow{\text{характеризация}}$ Q-сверхлинейность. В совместной формулировке Леммы 3.12 и Теоремы 3.9 условие (H5) перестаёт быть гипотезой — вместо него выступают (A2) [базовое BD] и (A4) [локальная близость старта]; гипотеза (H1) — Lipschitz $\nabla^2 f$ — сохраняется для применения Шага 4 доказательства Леммы (оценка $\|q_{k-i}\|$ через L_H); гипотезы (H3), (H4) остаются без изменений. Q-линейная сходимость итерации с некоторым $\rho_* < 1$ — выходное свойство Леммы

(см. Замечание 3.13), устанавливаемое совместной индукцией одновременно с ограниченностью $\|E_k\|_F$; тем самым снимается кажущаяся цикличность “Q-линейность $\rightarrow$ Q-сверхлинейность” и весь аргумент Теоремы 3.9 держится на одном структурном допущении (A4) о локальной близости старта.

Замечание 3.15 (Связь с SS-инвариантом теоремы 3.8). Хотя теорема 3.8 п. 3 доказывает *строгое* равенство $\|R_{k+1}\|_F^2 = \|R'_k\|_F^2 - (\sigma_k^*)^2 \|S_p^\top u_k^*\|^2$ — структурное сокращение накопленной невязки на одном и том же окне S_p , — в Лемме 3.12 эта монотонность не используется. Шагу 4 достаточно одностороннего верхнего ограничителя (57), который выражается через $\|E'_k\|_F$ и D_k без ссылки на SS-механизм; так разделяются два контура: геометрия сокращения невязки (п. 3 теоремы) и передача bounded deterioration (Лемма). Эмпирическая роль монотонности отражена на рис. 5 как прямая верификация того, что MS-коррекция действительно ограничивает $\|B_k S_p - Y_p\|_F$ в численных режимах.

Замечание 3.16 (Минимальность гипотез). Гипотеза (A4) о локальной близости старта — *достаточная* для замыкания совместной индукции Шага 7 и извлечения Q-линейного темпа $\rho_* < 1$. Альтернативная посылка « $\sum \|s_k\|^2 < \infty$ » (что эмпирически наблюдается в численных экспериментах § 3.6) дала бы тот же вывод суммируемости $\sum \beta_k < \infty$ без возмущенного аргумента; однако формулировка через (δ', δ'') согласуется со стандартным циклом локального анализа квазиньютоновских методов и явно фиксирует область применимости.

Гипотеза (A1) о Липшице гессиана — *использована* в Шаге 4 (оценка $\|q_{k-i}\|$) и в Шаге 7 (оценка остатка Тейлора r_k); ослабление до « $\nabla^2 f$ непрерывен в x^* » даёт $\|q_{k-i}\| = o(\|s_{k-i}\|)$ вместо $O(\|s_{k-i}\| \cdot D_k)$, что нарушает геометрическое убывание в Шаге 6 и количественную оценку ρ_* в Шаге 7. Поэтому (A1) в Lipschitz-форме сохраняется как *рабочая*, а не излишняя гипотеза.

Замечание 3.17 (Роль MS-коррекции: стабилизация без изменения асимптотической скорости). MS-коррекция не влияет на сверхлинейную скорость: Δ_k^{SS} действует в $s_k^\perp$ (так как $u_k^* \perp s_k$), а условие Денниса–Море $\|(B_k - J^*)s_k\|/\|s_k\| \rightarrow 0$ — только в направлении s_k . Роль коррекции — стабилизация B_k (условие (H5) и невырожденность B_k), обеспечивающая устойчивую сходимость на практике. Более того, доказательство Th. 3.9 использует от SS- $\mathcal{U}$ только текущее секущее условие $B_{k+1}s_k = y_k$, выполняемое и базовым обновлением; поэтому при выполнении (H1)–(H5) тем же аргументом Q-сверхлинейная скорость следует и для базового SR1 (классический результат Конна–Гулда–Тойнта, Халфана–Бёрда–Шнабеля). Узкое место в этом случае — посылка (H2) (сходимость траектории) и условие (H5), ровно те два пункта, которые и предназначена закрывать MS-коррекция.

Замечание 3.18 (Следствие для дизайна численных экспериментов). Поскольку асимптотическая скорость, заявленная в Th. 3.9, разделяется с базовым обновлением (Замечание 3.17), *отдельная* визуализация скорости в гл. 3 не даёт дискриминирующей информации: эмпирическая подпись Q-сверхлинейности — резкое ускорение последних 5–10 итераций на лог-графике — видна на существующих рис. 3 и 4 для любой сошедшейся траектории (SR1, SS-SR1, PSB, SS-PSB). Дискриминатор SS-конструкции — предпосылка (H2), т. е. *наличие* сходимости, а не её скорость; этот аспект закрыт существующими convergence- и grast-фигурами.

3.6 Численные результаты

Постановка статистического эксперимента. Для общего случая ведущий собственный вектор u_k^* матрицы $P_k M'_k P_k$ (см. Опр. 3.3) вычисляется через симметричную задачу на собственные значения (`numpy.linalg.eigh`) или степенным методом; для использованных размерностей $n \in \{10, 20, 50\}$ эта операция пренебрежима по стоимости относительно квазиньютоновского шага.

Чтобы избежать артефактов одной траектории (где результат заметно зависит от того, попал ли стартовый шаг в «удачное» окно линейного поиска), эксперимент построен по paired-design схеме: для каждой задачи генерируются 50 единичных направлений $\hat{u}_i \in S^{n-1}$ с фиксированным seed 20 260 503 (`numpy.random.default_rng`), и стартовая точка $x_0^{(i)} = R_0 \hat{u}_i$ берётся на сфере радиуса $R_0 = \|x_0^{\text{std}}\|$, где x_0^{std} — стандартная стартовая точка задачи. Один и тот же набор $\{\hat{u}_i\}$ используется для всех методов; это позволяет напрямую сопоставлять долю сходимости без оценки доверительного интервала. Все методы используют общий backtracking-Armijo ($c_1 = 10^{-4}$, откат $\alpha/2$, до 40 откатов), $B_0 = I$, параметр окна $p_{\max} = 5$ (фактическое окно растёт как $p = \min(p_{\max}, k)$ по алгоритму 3), критерий остановки $\|\nabla f\|_2 \leq 10^{-8}$ или 500 итераций; направление шага $d_k = -B_k^{-1} \nabla f(x_k)$ через LU-разложение системы.

Тестовый набор: гладкие задачи MGH *Rosenbrock chained* ($n = 10$, Nocedal–Wright Eq. 2.22) и *Extended Rosenbrock* ($n = 10$, MGH #21) — контроль на отсутствие дегенерации; задача с узкой искривлённой долиной *Extended Curved Valley* (блочно по 2 координаты, $f_{\text{блок}}(x_1, x_2) = \frac{\alpha}{2}(x_2 - \beta x_1^2)^2 + \frac{1}{2}(x_1^2 + x_2^2)$, $\alpha = 100$, $\beta = 1,5$, x_0^{std} блочно = (1,8; 1,8)) — стресс-тест на стабилизацию, прогоняемый при $n \in \{10, 20, 50\}$ для оценки масштабируемости.

Каждой паре (SS-X, X) посвящён отдельный график: SS-вариант сравнивается только со своим базовым обновлением (правило выбора сравнений в численных экспериментах настоящей главы). Ниже последовательно разбираются обе пары — SR1/SS-SR1 и PSB/SS-PSB.

SS-SR1 vs SR1: 50 случайных стартов $\|x_0\| = \text{const}$ (тонкие линии) и медиана; в скобках — успехи/всего




Рисунок 3. SS-SR1 vs SR1: сходимость $\|\nabla f(x_k)\|_2$ на пяти тестовых конфигурациях. Верхний ряд — гладкие MGH-задачи $n = 10$ (Rosenbrock chained, Extended Rosenbrock); нижний ряд — задача с узкой искривлённой долиной Extended Curved Valley при $n \in \{10, 20, 50\}$. По 50 случайных стартов на сфере $\|x_0\| = R_0 = \|x_0^{\text{std}}\|$ (тонкие линии), медиана жирной линией. На гладких задачах SS-SR1 в медиане незначительно медленнее SR1 по числу итераций (возмущение траектории под MS-коррекцией; на ECV оба метода сходятся устойчиво).

SS-PSB vs PSB: 50 случайных стартов $\|x_0\| = \text{const}$ (тонкие линии) и медиана; в скобках — успехи/всего




Рисунок 4. SS-PSB vs PSB: те же пять конфигураций, что на рис. 3. Чистый PSB деградирует уже на гладких MGH-задачах и практически не сходится на ECV; SS-PSB обеспечивает устойчивую сходимость на всех конфигурациях и на гладких задачах обходит PSB по медиане числа итераций. Иллюстрация того, что MS-коррекция способна спасти indefinitные базовые обновления с сильной деградацией. Расходящиеся и преждевременно сошедшиеся траектории включены в медиану через pad-by-last (заморозка на последнем наблюждённом $\|\nabla f\|$).

Прямая иллюстрация теоремы 3.8, п. 3: динамика накопленной невязки на паре PSB / SS-PSB. Convergence-кривые рис. 3 и 4 показывают итоговую долю сходимости и медианное число итераций, но оставляют открытым прямой вопрос: действительно ли MS-коррекция *ограничивает* накопленную невязку $\|B_k S_p - Y_p\|_F$ в смысле теоремы 3.8, п. 3? Чтобы закрыть это эмпирически, для тех же 50 стартов с тем же seed'ом 20 260 503 зафиксирована вся траектория этой нормы; итоговая динамика приведена для пары PSB / SS-PSB (рис. 5; медиана жирной линией, заливка — межквартильный размах $q_{25}-q_{75}$ по 50 стартам; расходящиеся траектории включены через rad-by-last).

Пара PSB / SS-PSB выбрана как чистая иллюстрация по двум причинам. Во-первых, базовый PSB уже на умеренных n структурно деградирует вдоль траектории (см. рис. 4); это даёт MS-коррекции достаточно *материала* для работы и делает разрыв $\|B_k S_p - Y_p\|_F$ визуально разрешимым. Во-вторых, для пары SR1 / SS-SR1 базовый SR1 на использованных режимах часто и без MS-коррекции удерживает $\|B_k S_p - Y_p\|_F$ на приемлемом уровне (что отражает ограничение самой теоремы Th. 3.9: MS-коррекция нужна там, где SR1 *реально* деградирует, и не создаёт преимущества там, где уже не деградирует), так что прямая gplot-картинка для этой пары читается хуже, чем косвенная сходимостная метрика рис. 3; пара оставлена иллюстрироваться через convergence на рис. 3.

Картина на рис. 5 согласуется со структурным предсказанием. На всех пяти конфигурациях SS-PSB системно держит медиану $\|B_k S_p - Y_p\|_F$ ниже, чем PSB; качественный разрыв особенно ясен на режиме ECV, где PSB теряет устойчивость, а SS-PSB монотонно снижает невязку. Это прямая эмпирическая поддержка утверждения 3 теоремы 3.8: оценка $\|R_{k+1}\|_F^2 \leq \|R'_k\|_F^2 - (u_k^{*\top} M'_k u_k^*)^2 / \|S_p^\top u_k^*\|^2$ выполнена по построению на каждом шаге; интегральный эффект — системно меньшая медиана $\|B_k S_p - Y_p\|_F$ — наблюдается именно там, где базовое обновление действительно теряет устойчивость.

Изолированная роль гипотезы (H4): эксперименты без Armijo. Теорема 3.9 формулирует Q-сверхлинейность при условии (H4): после некоторого k_0 глобализация выдаёт полный QN-шаг $s_k = -B_k^{-1} \nabla f(x_k)$. В основных экспериментах §3.6 (H4) обеспечивается backtracking-Армихо и отдельно не визуализирована. Чтобы изолировать её роль, повторим paired-дизайн (тот же seed 20 260 503, 50 стартов) с полным шагом $x_{k+1} = x_k + d_k$ без backtracking, на двух типах задач: выпуклой квадратике, где (H4) выполнено тривиально, и Rosenbrock chained, где (H4) нетривиально.

Квадратика $f(x) = \frac{1}{2} x^\top A x$, $A = Q \text{diag}(\lambda_1, \dots, \lambda_n) Q^\top$, $Q \in O(n)$, $\lambda_i = \kappa^{(i-1)/(n-1)}$ — логарифмически равномерный спектр с $\lambda_1 = 1, \lambda_n = \kappa$ (так что $\kappa(A) = \kappa$ при произвольном n , и устроена непустая малая часть спектра); $x^* = 0$, $\|x_0\| = R$. На рис. 6 приведены два режима: ($n = 20, \kappa = 10^3$) — оба метода сходятся,

SS-PSB vs PSB: накопленная невязка прошлых секущих $\|B_k S_p - Y_p\|_F$. 50 стартов; медиана (жирная) и IQR (q25-q75, заливка)




Рисунок 5. Накопленная невязка прошлых секущих $\|B_k S_p - Y_p\|_F$ для пары PSB / SS-PSB на тех же пяти конфигурациях, что и рис. 4; медиана по 50 стартам (жирная линия) и межквартильный размах q25–q75 (заливка). Контраст резкий на всех режимах: SS-PSB системно держит медиану ниже, чем PSB. На ECV PSB теряет устойчивость — структурная причина отказа базового обновления, против которой и работает MS-коррекция. Прямая эмпирическая поддержка теоремы 3.8, п. 3.

и ($n = 50, \kappa = 10^2$) — PSB не сходится за отведённый бюджет итераций, а SS-PSB сходится. SR1-семейство из рисунка опущено: по замечанию 3.17 асимптотическая Q-сверхлинейная скорость SS совпадает с базовой, а на квадратике SR1 со skip-rule имеет конечную сходимость за $\leq n + 1$ шагов [10], так что для SR1-пары MS-добавке нечего улучшать.

Картина одинакова для радиусов $R \in [0.1, 3]$ (рисунок построен при $R = 0.3$): на локальной выпуклой квадратике поведение определяется парой (n, κ) , не радиусом старта. На режиме $(n = 20, \kappa = 10^3)$ SS-PSB видимо ускоряет пре-асимптотическую фазу PSB; на более крупной размерности $(n = 50, \kappa = 10^2)$ — правая панель — PSB уже не достигает сходимости за бюджет итераций, тогда как SS-PSB сходится (и это даже при меньшей κ). Это эмпирическая поддержка теоремы 3.9 в режиме, где (H4) выполнено тривиально: SS-коррекция не меняет асимптотическую скорость (замечание 3.17), но улучшает пре-асимптотический режим за счёт лучшего приближения $\nabla^2 f(x^*)$ матрицей B_k на окне прошлых текущих и расширяет диапазон (n, κ) , в котором базовое обновление вообще достигает сходимости без line search.

Локальная сходимость без Armijo: $f(x) = \frac{1}{2} x^\top A x$, $\|x_0\| = 0.3$, 50 стартов; медиана и межквартильный коридор




Рисунок 6. Локальная сходимость без Armijo на выпуклой квадратике $f(x) = \frac{1}{2} x^\top A x$, $\|x_0\| = 0.3$, 50 стартов; медиана $\|\nabla f(x_k)\|$ и межквартильный коридор; расходящиеся траектории включены через pad-by-last (заморозка на последнем конечном значении). Слева — режим, где оба обновления сходятся: SS-PSB укорачивает пре-асимптотическую фазу PSB в несколько раз. Справа — режим, где PSB не сходится за бюджет итераций, а SS-PSB сходится: расширение области устойчивого поведения. SR1-семейство опущено: на квадратике SR1 имеет конечную сходимость за $\leq n + 1$ шагов [10], а SS-добавка по rate-invariance (замечание 3.17) её не улучшает.

Rosenbrock chained, $n = 10$, $x^* = \mathbf{1}$, 50 стартов $x_0 = x^* + R \cdot u$, $u \in S^{n-1}$, при разных радиусах R . На рис. 7 приведена доля сошедшихся стартов против R . PSB не сходится ни на одном из тестируемых радиусов; SS-PSB сходится на существенной части стартов уже при умеренно малых R . SR1 и SS-SR1 показаны для контекста: обе

кривые ведут себя практически одинаково (что согласуется с rate-invariance, зам. 3.17) и сходятся лишь в непосредственной окрестности $R \lesssim 0,03$, оставаясь существенно ниже SS-PSB во всём диапазоне — основной эффект MS-коррекции в этом эксперименте проявляется именно на паре PSB / SS-PSB. Картина прямо свидетельствует, что (H4) на невыпуклых задачах не дается даром: полный QN-шаг расходится даже из непосредственной окрестности x^* , и без line search SS-коррекция *не* глобализует, а лишь расширяет локальную область устойчивой сходимости (особенно у PSB-семейства). Глобализация в теореме 3.9 — содержательное предположение, не факультативная инженерная деталь.




Рисунок 7. Доля сошедшихся стартов (из 50) на Rosenbrock chained, $n = 10$, $x^* = \mathbf{1}$, против радиуса $R = \|x_0 - x^*\|$, без backtracking-Армихо. PSB не сходится ни на одном из тестируемых радиусов; SS-PSB расширяет область устойчивой сходимости при умеренно малых R . Прямое визуальное подтверждение нетривиальности (H4) на невыпуклых задачах.

Резюме. На SR1 и PSB SS-коррекция эмпирически подтверждает роль ограничителя накопленной невязки $\|B_k S_p - Y_p\|_F$ (теорема 3.8, п. 3, и Лемма 3.12): на рис. 5 медиана $\|B_k S_p - Y_p\|_F$ у SS-PSB системно ниже PSB, а на ECV $n = 20$ PSB не сходится, тогда как SS-PSB монотонно снижает невязку. Эксперименты без backtracking (§3.6) подтверждают также нетривиальность гипотезы (H4) Теоремы 3.9: на локально-выпуклой квадратике SS-PSB укорачивает пре-асимптотическую фазу PSB; на Rosenbrock chained полный QN-шаг расходится даже из окрестности x^* , и MS-коррекция расширяет лишь область устойчивости, не подменяя глобализацию. Дальнейшие направления — формальная глобализация и перенос на негладкий случай — обсуждаются в Заключение.

Заключение

Основные результаты работы

В работе развита единая точка зрения на квазиньютоновские обновления с памятью прошлых секущих условий и последовательно применена к задачам нелинейных систем и гладкой оптимизации. Ключевые результаты по главам перечислены ниже.

Глава 1 (приближение якобиана). Выведена общая формула семейства мультисекантных обновлений

$$B_{k+1} = \widehat{B}_k + (Y_m - \widehat{B}_k S_m) (V_m^\top S_m)^{-1} V_m^\top,$$

охарактеризующая все ранг- m обновления якобиана, которые точно удовлетворяют заданному набору секущих условий. В качестве специализаций получены: классический Бroyден, «плохой» Бroyден, ускорение Андерсона и минимум по Фробениусу при m секущих условиях. Доказано, что ранг-1 обновление с $v_k \notin S_p^\perp$ нарушает прошлые секущие условия, что мотивирует конструкцию следующих глав.

Глава 2 (мультисекущий Бroyден). Рассматривается мультисекущее обновление Бroyдена [30]

$$B_{k+1} = B_k + (Y_p - B_k S_p) G_p^{-1} S_p^\top, \quad G_p = S_p^\top S_p,$$

S_p, Y_p — окно текущего и p прошлых секущих пар. Ранг-1 специализация под индуктивным инвариантом $B_k s_j = y_j$ ($j < k$) совпадает с Projected Broyden Гэя–Шнабеля [18] и используется в §2.2 для limited-memory варианта L-PB через формулу Шермана–Моррисона.

Основной результат главы — **теорема об ограниченной деградации с расширенным проектором (2.10)**: точное равенство

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$$

с проектором Π_k ранга $p+1$ на $\text{col}(S_p)$ (у классического Бroyдена — ранга 1, на $\text{span}(s_k)$)

и явной геометрической константой $C_{PB} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$, где $\kappa_p = \kappa(S_p)$ — обусловленность окна шагов. У Гэя–Шнабеля для ранг-1 специализации оценка bounded deterioration установлена в виде неравенства сверху (Th. 4.2); здесь равенство с явной геометрической константой и переход к мультисекунной форме сделаны впервые. Доказано неравенство $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$: отрицательный член снимает с матрицы ошибки *не меньше* информации, чем у классического Бройдена, и сохраняются $p+1$ секующих условий $B_{k+1}s_j = y_j$, $j = k-p, \dots, k$.

В качестве следствия установлена количественная $O(\rho_k)$ -**аппроксимация якобиана на подпространстве прошлых шагов** $\text{col}(S_p)$ (2.12) — структурное преимущество над классическим Бройденом, у которого аппроксимация контролируется лишь вдоль одномерного направления s_k .

На задаче Discrete BVP ($n=100$) мультисекунный Бройден работает устойчиво там, где классический Бройден неустойчив или сходится медленнее. Limited-memory вариант L-PB при $m \geq p_{\max}+1$ устойчиво сходится на Broyden Banded при $n \in \{10^4, 10^5\}$ за число итераций, не зависящее от n ; зазор с плотной формой умеренный и монотонно сокращается с ростом m , что отражает типичную для limited-memory методов картину (ср. L-BFGS).

Глава 3 (SS-U и SS-SR1). Воспроизведён классический результат Шнабеля [30] о несовместности точного сохранения p прошлых секующих условий с требованием симметрии (лемма 3.1): систему одновременно нельзя удовлетворить в общем положении. Предложено разрешение несовместности через конструкцию SS-U: симметричная ранг-1 коррекция $\sigma_k^* u_k^* (u_k^*)^\top$ в ортогональном дополнении $s_k^\perp$, подавляющая накопленные невязки прошлых секующих условий. Установлены:

- точное выполнение текущего секующего условия и симметрия (3.8);
- монотонное убывание невязки в $s_k^\perp$ по оптимальному направлению u_k^* ;
- bounded deterioration в композитной форме для SS-U под Lipschitz-непрерывным гессианом и входной Q-линейной сходимостью (Лемма 3.12);
- сверхлинейная сходимость по критерию Dennis–More (3.9);
- эмпирически наблюдаемая устойчивая сходимость на семействе Curved Valley (см. §3.6).

Связь результатов

Главы работы связаны сквозной идеей: выбор направления обновления v_k , сохраняющий прошлые секующие условия, расширяет проектор bounded deterioration с ранга 1

до ранга $p+1$, что, в свою очередь, последовательно отражается на наблюдаемых и гарантированных свойствах итерационного процесса. В нелинейных системах (глава 2) это даёт усиленную оценку bounded deterioration с явной геометрической константой $C_{\text{PB}} = L(1+C_s/2)\sqrt{p+1}\kappa_p$, зависящей от обусловленности окна κ_p , а не от размерности n ; в оптимизации (глава 3) идея переносится через композитное обновление SS- $\mathcal{U}$ с bounded deterioration в форме Леммы 3.12 и условной Q-сверхлинейной сходимостью по Денниса–Море. Расширение проектора с ранга 1 (классический Бroyден) до ранга $p+1$ (мультисекунный Бroyден) вместе с сохранением $p+1$ секущих условий — содержательное уточнение классического анализа, дающее на каждой итерации строго не меньше информации об ошибке аппроксимации якобиана.

В литературе закрыты следующие пробелы: количественная форма bounded deterioration для общей мультисекунной формы Шнабеля [30] (у Гэя–Шнабеля [18] — только неравенство сверху для ранг-1 специализации); явная зависимость константы оценки от геометрии окна κ_p , не от n — основание для применимости в высокой размерности; перенос идеи сохранения прошлых секущих на симметричный случай через коррекцию в $s_k^\perp$ с bounded deterioration в композитной форме (Лемма 3.12). Полученные количественные оценки ошибки $\|B_k - J(x_k)\|$ входят константой в оценки скорости сходимости методов более высокого уровня, где аппроксимация якобиана используется как технический блок [15].

Направления дальнейших исследований

- **Высокая размерность и limited memory.** L-PB-вариант (§2.2), построенный на ранг-1 специализации с Шерманом–Моррисоном, проверен на Broyden Banded при $n \in \{10^4, 10^5\}$. Дальнейшее направление — сравнение с L-BFGS и preconditioned Anderson на расширенном тестовом наборе.
- **Обобщение SS-U на не гладкие задачи.** Построить негладкий аналог SS-U (proximal-SS-U) для композитных задач $\min f(x) + g(x)$ и исследовать его скорость на задачах с разреженной регуляризацией.
- **Практическая валидация на прикладных задачах.** Применить мультисекунный Бroyден к задачам обучения (нелинейные системы, возникающие в физически-информированных нейронных сетях), а также к равновесным моделям из экономики.
- **Глобализация и сравнение стратегий шага.** Формальный анализ глобализации мультисекунного Бroyдена и SS- $\mathcal{U}$ (backtracking-Армихо, условия Вольфа, trust-region-модификации) и систематическое численное сравнение этих стратегий на широком

тестовом наборе Moré–Garbow–Hillstom — естественное продолжение локальной теории, развитой в гл. 2 и гл. 3.

- **Корректная реализация и сравнение с современным Anderson.** Переделать реализацию Anderson-acceleration из [34] с релаксацией и мультисекантной подгонкой в L^2 -норме и провести честное сравнение с мультисекантным Бройденом на всём тестовом наборе Broyden.

Список использованных источников

- [1] Anderson, D. G. Iterative procedures for nonlinear integral equations [Text] // [Journal of the ACM](#). — 1965. — Vol. 12, no. 4. — P. 547–560.
- [2] Armijo, L. Minimization of functions having Lipschitz continuous first partial derivatives [Text] // [Pacific Journal of Mathematics](#). — 1966. — Vol. 16, no. 1. — P. 1–3.
- [3] Boutet, N. A symmetric grouped and ordered multi-secant quasi-Newton update formula [Text] / Boutet, N., Degroote, J., and Haelterman, R. // [Optimization Methods and Software](#). — 2022. — Vol. 37, no. 6. — P. 1965–1986.
- [4] Boutet, N. Secant update version of quasi-Newton PSB with weighted multisecant equations [Text] / Boutet, N., Haelterman, R., and Degroote, J. // [Computational Optimization and Applications](#). — 2020. — Vol. 75, no. 2. — P. 441–466.
- [5] Boutet, N. Secant Update generalized version of PSB: a new approach [Text] / Boutet, N., Haelterman, R., and Degroote, J. // [Computational Optimization and Applications](#). — 2021. — Vol. 78, no. 3. — P. 953–982.
- [6] Broyden, C. G. A class of methods for solving nonlinear simultaneous equations [Text] // [Mathematics of Computation](#). — 1965. — Vol. 19, no. 92. — P. 577–593.
- [7] Broyden, C. G. On the local and superlinear convergence of quasi-Newton methods [Text] / Broyden, C. G., Dennis, J. E., and Moré, J. J. // [Journal of the Institute of Mathematics and its Applications](#). — 1973. — Vol. 12, no. 3. — P. 223–245.
- [8] Burdakov, O. Multipoint secant and interpolation methods with nonmonotone line search for solving systems of nonlinear equations [Text] / Burdakov, O. and Kamandi, A. // [Applied Mathematics and Computation](#). — 2018. — Vol. 338. — P. 421–431.
- [9] Byrd, R. H. Representations of quasi-Newton matrices and their use in limited memory methods [Text] / Byrd, R. H., Nocedal, J., and Schnabel, R. B. // [Mathematical Programming](#). — 1994. — Vol. 63, no. 1–3. — P. 129–156.

- [10] Conn, A. R. Convergence of quasi-Newton matrices generated by the symmetric rank one update [Text] / Conn, A. R., Gould, N. I. M., and Toint, Ph. L. // **Mathematical Programming**. — 1991. — Vol. 50, no. 1–3. — P. 177–195.
- [11] Davidon, W. C. Variable metric method for minimization [Text] // **SIAM Journal on Optimization**. — 1991. — Vol. 1, no. 1. — P. 1–17. — Originally: AEC Research and Development Report ANL-5990, Argonne National Laboratory, 1959.
- [12] Dennis, J. E. A characterization of superlinear convergence and its application to quasi-Newton methods [Text] / Dennis, J. E. and Moré, J. J. // **Mathematics of Computation**. — 1974. — Vol. 28, no. 126. — P. 549–560.
- [13] Dennis, J. E. Quasi-Newton methods, motivation and theory [Text] / Dennis, J. E. and Moré, J. J. // **SIAM Review**. — 1977. — Vol. 19, no. 1. — P. 46–89.
- [14] Dennis, J. E. **Numerical Methods for Unconstrained Optimization and Nonlinear Equations** [Text] / Dennis, J. E. and Schnabel, R. B. — Philadelphia : SIAM, 1996.
- [15] Exploring Jacobian inexactness in second-order methods for variational inequalities: lower bounds, optimal algorithms and quasi-Newton approximations [Text] / Agafonov, A., Kamzolov, D., Gasnikov, A., Antonakopoulos, K., Cevher, V., and Takáč, M. // arXiv preprint. — 2024. — Vol. arXiv:2405.15990. — Access mode: <https://arxiv.org/abs/2405.15990>.
- [16] Fang, H.-R. Two classes of multisection methods for nonlinear acceleration [Text] / Fang, H.-R. and Saad, Y. // **Numerical Linear Algebra with Applications**. — 2009. — Vol. 16, no. 3. — P. 197–221.
- [17] Gay, D. M. Some convergence properties of Broyden’s method [Text] // **SIAM Journal on Numerical Analysis**. — 1979. — Vol. 16, no. 4. — P. 623–630.
- [18] Gay, D. M. Solving systems of nonlinear equations by Broyden’s method with projected updates [Text] / Gay, D. M. and Schnabel, R. B. // **Nonlinear Programming 3** / ed. by Mangasarian, O. L., Meyer, R. R., Robinson, S. M. — New York : Academic Press, 1978. — P. 245–281.
- [19] Generalization of quasi-Newton methods: application to robust symmetric multisection updates [Text] / Scieur, D., Liu, L., Pumiř, T., and Boumal, N. // **Proceedings of the 24th International Conference on Artificial Intelligence and Statistics (AISTATS)** / ed. by Banerjee, A., Fukumizu, K. — [S. l.] : PMLR. — 2021. — Vol. 130 of **Proceedings of Machine Learning Research**. — P. 550–558. — Access mode: <https://proceedings.mlr.press/v130/scieur21a.html>.

- [20] Golub, G. H. Matrix Computations [Text] / Golub, G. H. and Van Loan, C. F. — 4 ed. — Baltimore : Johns Hopkins University Press, 2013. — ISBN: 978-1-4214-0794-4. — Access mode: <https://jhupbooks.press.jhu.edu/title/matrix-computations>.
- [21] Gratton, S. Quasi-Newton updates with weighted secant equations [Text] / Gratton, S., Malmedy, V., and Toint, Ph. L. // [Optimization Methods and Software](#). — 2015. — Vol. 30, no. 4. — P. 748–755.
- [22] Liu, D. C. On the limited memory BFGS method for large scale optimization [Text] / Liu, D. C. and Nocedal, J. // [Mathematical Programming](#). — 1989. — Vol. 45, no. 1–3. — P. 503–528.
- [23] Marquardt, D. W. An algorithm for least-squares estimation of nonlinear parameters [Text] // [Journal of the Society for Industrial and Applied Mathematics](#). — 1963. — Vol. 11, no. 2. — P. 431–441.
- [24] Moré, J. J. Testing unconstrained optimization software [Text] / Moré, J. J., Garbow, B. S., and Hillstom, K. E. // [ACM Transactions on Mathematical Software](#). — 1981. — Vol. 7, no. 1. — P. 17–41.
- [25] Nocedal, J. Updating quasi-Newton matrices with limited storage [Text] // [Mathematics of Computation](#). — 1980. — Vol. 35, no. 151. — P. 773–782.
- [26] Nocedal, J. [Numerical Optimization](#) [Text] / Nocedal, J. and Wright, S. J. — 2 ed. — New York : Springer, 2006.
- [27] Parlett, B. N. [The Symmetric Eigenvalue Problem](#) [Text]. — Philadelphia : SIAM, 1998. — Vol. 20 of Classics in Applied Mathematics.
- [28] Powell, M. J. D. [A new algorithm for unconstrained optimization](#) [Text] // Nonlinear Programming / ed. by Rosen, J. B., Mangasarian, O. L., Ritter, K. — New York : Academic Press, 1970. — P. 31–65.
- [29] Powell, M. J. D. On the convergence of the variable metric algorithm [Text] // [Journal of the Institute of Mathematics and its Applications](#). — 1971. — Vol. 7, no. 1. — P. 21–36.
- [30] Quasi-Newton Methods Using Multiple Secant Equations [Text] : Rep. : CU-CS-247-83 / Department of Computer Science, University of Colorado at Boulder ; executor: Schnabel, R. B. : 1983.
- [31] Schubert, L. K. Modification of a quasi-Newton method for nonlinear equations with a sparse Jacobian [Text] // [Mathematics of Computation](#). — 1970. — Vol. 24, no. 109. — P. 27–30.

- [32] Shanno, D. F. Matrix conditioning and nonlinear optimization [Text] / Shanno, D. F. and Phua, K. H. // [Mathematical Programming](#). — 1978. — Vol. 14, no. 1. — P. 149–160.
- [33] Toth, A. Convergence analysis for Anderson acceleration [Text] / Toth, A. and Kelley, C. T. // [SIAM Journal on Numerical Analysis](#). — 2015. — Vol. 53, no. 2. — P. 805–819.
- [34] Walker, H. F. Anderson acceleration for fixed-point iterations [Text] / Walker, H. F. and Ni, P. // [SIAM Journal on Numerical Analysis](#). — 2011. — Vol. 49, no. 4. — P. 1715–1735.
- [35] Wolfe, P. Convergence conditions for ascent methods [Text] // [SIAM Review](#). — 1969. — Vol. 11, no. 2. — P. 226–235.
- [36] Zoutendijk, G. Nonlinear programming, computational methods [Text] // Integer and Nonlinear Programming / ed. by Abadie, J. — Amsterdam : North-Holland, 1970. — P. 37–86. — Access mode: <https://www.sciencedirect.com/book/9780720420845>.