

Федеральное государственное автономное  
образовательное учреждение высшего образования  
«Московский физико-технический институт  
(национальный исследовательский университет)»

Физтех-школа прикладной математики и информатики  
Кафедра проблем передачи информации и анализа данных

Направление подготовки: 09.04.01 Информатика и вычислительная техника

# ИССЛЕДОВАНИЕ ГЛОБАЛЬНЫХ КВАЗИНЬЮТОНОВСКИХ МЕТОДОВ ОПТИМИЗАЦИИ ДЛЯ ЗАДАЧ МАТЕМАТИЧЕСКОГО ПРОГРАММИРОВАНИЯ

(магистерская диссертация)

Студент:

Можаев Р. М.  
группа М05-404а

---

(подпись студента)

Научный руководитель: Камзолов Д. И.

---

(подпись научного руководителя)

Долгопрудный  
2026

# Аннотация

**Цель** — развить количественный локальный анализ мультисекущего обновления Бройдена [31] для нелинейных систем и построить его секантно-стабилизированный симметричный аналог для гладкой оптимизации.

**Задачи:** получить точное разложение и явную константу для оценки bounded deterioration мультисекущего обновления через обусловленность окна шагов; вывести  $O(\rho_k)$ -аппроксимацию якобиана на подпространстве прошлых шагов; построить симметричный аналог SS-U с условной Q-сверхлинейной сходимостью; провести численную верификацию.

**Результаты.** Оценка bounded deterioration для мультисекущего обновления, у Гэя–Шнабеля [18] данная в форме неравенства сверху для ранг-1 специализации, усилена до точного равенства с проектором ранга  $p+1$  и явной константой  $C_{\text{РВ}} = L(1+C_s/2)\sqrt{p+1}\kappa_p$ , не зависящей от размерности  $n$ ; установлена  $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов. Для симметричного случая построена конструкция SS-U — ранг-1 коррекция в  $s_k^\perp$ , сохраняющая текущее секущее условие и симметрию, с условной Q-сверхлинейной сходимостью по Dennis–More; bounded deterioration композитного обновления установлено отдельной леммой.

**Рекомендации.** Мультисекущий Бройден и его limited-memory вариант L-PB рекомендованы вместо классического в задачах, где последний неустойчив или сходится медленно, включая крупномасштабные; SS-U — для гладкой оптимизации в задачах, на которых SR1 теряет устойчивость.

# Содержание

|                                                                          |           |
|--------------------------------------------------------------------------|-----------|
| <b>Аннотация</b>                                                         | <b>2</b>  |
| <b>Обозначения и сокращения</b>                                          | <b>5</b>  |
| Базовые объекты . . . . .                                                | 5         |
| Квазиньютоновские обновления . . . . .                                   | 5         |
| Мультисекунций Бройден и SS-U . . . . .                                  | 6         |
| Соглашения . . . . .                                                     | 6         |
| <b>Введение</b>                                                          | <b>7</b>  |
| Актуальность темы . . . . .                                              | 7         |
| Объект и предмет исследования . . . . .                                  | 8         |
| Цель и задачи работы . . . . .                                           | 8         |
| Научная новизна . . . . .                                                | 9         |
| Теоретическая и практическая значимость . . . . .                        | 10        |
| Положения, выносимые на защиту . . . . .                                 | 11        |
| Методология и методы исследования . . . . .                              | 11        |
| Степень достоверности и апробация результатов . . . . .                  | 11        |
| Структура и объём работы . . . . .                                       | 12        |
| <b>1. Квазиньютоновские методы и мультисекунционные обновления</b>       | <b>13</b> |
| 1.1. Задачи оптимизации и нелинейные системы . . . . .                   | 13        |
| 1.2. От метода Ньютона к квазиньютоновским обновлениям . . . . .         | 14        |
| 1.3. Классические квазиньютоновские обновления . . . . .                 | 15        |
| 1.4. Локальная теория сверхлинейной сходимости . . . . .                 | 17        |
| 1.5. Мультисекунционные обновления: общая формула и таксономия . . . . . | 18        |
| 1.6. Базовая матрица и связь с ускорением Андерсона . . . . .            | 20        |
| 1.7. Глобализация и limited-memory варианты . . . . .                    | 20        |
| 1.7.1. Глобализация для нелинейных систем и оптимизации . . . . .        | 21        |
| 1.7.2. Limited-memory реализации . . . . .                               | 21        |
| 1.8. Симметричные multi-secant подходы . . . . .                         | 22        |
| 1.9. Место настоящей работы . . . . .                                    | 23        |

|                                                                                 |           |
|---------------------------------------------------------------------------------|-----------|
| <b>2. Мультисекунций Бройден</b>                                                | <b>24</b> |
| 2.1. Качество аппроксимации якобиана . . . . .                                  | 27        |
| 2.2. Limited-memory: ранг-1 специализация и L-PB . . . . .                      | 32        |
| 2.3. Численные эксперименты . . . . .                                           | 38        |
| <b>3. Симметричные квазиньютоновские обновления с контролем текущих условий</b> | <b>42</b> |
| 3.1. Мотивация . . . . .                                                        | 42        |
| 3.2. Конструкция и алгоритм $SS-\mathcal{U}$ . . . . .                          | 44        |
| 3.3. Свойства . . . . .                                                         | 48        |
| 3.4. Связь с известными подходами . . . . .                                     | 48        |
| 3.5. Сверхлинейная сходимость . . . . .                                         | 49        |
| 3.6. Численные результаты . . . . .                                             | 58        |
| <b>Заключение</b>                                                               | <b>65</b> |
| Основные результаты работы . . . . .                                            | 65        |
| Связь результатов . . . . .                                                     | 66        |
| Направления дальнейших исследований . . . . .                                   | 67        |
| <b>Список использованных источников</b>                                         | <b>69</b> |

# Обозначения и сокращения

## Базовые объекты

|        |                                                                                                                                                  |
|--------|--------------------------------------------------------------------------------------------------------------------------------------------------|
| $F$    | отображение $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$ в задаче $F(x) = 0$ (главы 1, 2) или градиент $F = \nabla f$ задачи оптимизации (глава 3) |
| $f$    | скалярная целевая функция $f: \mathbb{R}^n \rightarrow \mathbb{R}$ в оптимизации                                                                 |
| $J(x)$ | якобиан $F$ в точке $x$ ; в задаче оптимизации — гессиан $\nabla^2 f(x)$                                                                         |
| $J^*$  | якобиан в решении: $J^* = J(x^*) = \nabla F(x^*)$                                                                                                |
| $x^*$  | решение: $F(x^*) = 0$                                                                                                                            |

## Квазиньютоновские обновления

|                 |                                                                                                                                                       |
|-----------------|-------------------------------------------------------------------------------------------------------------------------------------------------------|
| $x_k$           | приближение к решению на $k$ -й итерации                                                                                                              |
| $s_k$           | шаг: $s_k = x_{k+1} - x_k$                                                                                                                            |
| $y_k$           | разность значений: $y_k = F(x_{k+1}) - F(x_k)$                                                                                                        |
| $d_k$           | направление поиска: $B_k d_k = -F(x_k)$                                                                                                               |
| $B_k$           | текущая аппроксимация якобиана                                                                                                                        |
| $\hat{B}_k$     | базовая матрица в формуле обновления (накопление: $\hat{B}_k = B_k$ ; пересборка: $\hat{B}_k = \tilde{B}$ , обычно $I$ )                              |
| $\tilde{B}$     | опорная матрица — параметр алгоритма мультисекундного Бройдена, не зависящий от $k$ ; к ней производится сброс при пересборке                         |
| $\Delta_k$      | изменение матрицы: $\Delta_k = B_{k+1} - \hat{B}_k$                                                                                                   |
| $S_m, Y_m, V_m$ | матрицы прошлых шагов, разностей и направлений обновления в общей мультисекундной формуле (7); $V_m$ ( $m$ — ранг обновления) параметризует семейство |

$E_k$  ошибка аппроксимации якобиана:  $E_k = B_k - J^*$

## Мультисекующий Бройден и SS-U

|               |                                                                                                                                                                                                                                        |
|---------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $m$           | ранг мультисекующего обновления в общей формуле главы 1 ( $m$ секующих условий $B_{k+1}S_m = Y_m$ ); используется только в главе 1                                                                                                     |
| $p$           | глубина сохраняемых <i>прошлых</i> секующих условий в мультисекующем Бройдене и его вариантах (главы 2, 3); число столбцов окна на одну больше, чем $p - S_p \in \mathbb{R}^{n \times (p+1)}$ за счёт включения текущей секующей $s_k$ |
| $S_p, Y_p$    | окно текущего и $p$ прошлых шагов и разностей, $S_p = [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}] \in \mathbb{R}^{n \times (p+1)}$                                                                                                      |
| $G_p$         | грамиан окна: $G_p = S_p^\top S_p$                                                                                                                                                                                                     |
| $\Pi_k$       | ортогональный проектор на $\text{col}(S_p)$ : $\Pi_k = S_p G_p^{-1} S_p^\top$ ; $\Pi_k^\perp = I - \Pi_k$                                                                                                                              |
| $u_k^*$       | ведущий собственный вектор коррекции SS-U (в $s_k^\perp$ )                                                                                                                                                                             |
| $\sigma_k^*$  | коэффициент ранг-1 коррекции SS-U                                                                                                                                                                                                      |
| $\mathcal{U}$ | базовое симметричное квазиньютоновское обновление (SR1, PSB) в конструкции SS-U                                                                                                                                                        |

## Соглашения

- Индекс  $k$  нумерует итерации алгоритма; индексы внутри окна пробегают  $j = k - p, \dots, k$ .
- $I$  — единичная матрица подходящей размерности;  $e_1 = (1, 0, \dots, 0)^\top$  — первый базисный вектор.
- Если контекст не указан явно, все нормы матриц — фробениусовы ( $\|\cdot\|_F$ ), все нормы векторов — евклидовы ( $\|\cdot\|$ ).
- Константы обозначаются прописными латинскими буквами ( $L, C_d$ ); параметры алгоритма — строчными греческими ( $\bar{\rho}$ ); индексы  $k$  указывают итерационную зависимость.

# Введение

## Актуальность темы

Квазиньютоновские методы занимают центральное место в вычислительной оптимизации с момента работы Broyden (1965) [6] и последующих классических работ Dennis и More [13, 14]. Они дают сверхлинейную скорость сходимости без вычисления якобиана (или гессиана), что особенно важно для задач, в которых явное дифференцирование дорого или недоступно: крупномасштабных систем уравнений, задач обучения нейронных сетей, равновесных и экономических моделей. На геометрически сложных ландшафтах (изогнутые долины, овраги, неквадратичные сильно нелинейные функции) поведение классических алгоритмов Broyden, SR1 и BFGS, однако, оказывается чувствительным к выбору начального приближения [24, 14, 10, 33], хотя теория гарантирует сверхлинейность в локальном режиме [7, 12].

Стандартный инструмент анализа сходимости квазиньютоновских методов — оценка ограниченной деградации (bounded deterioration [7, 14]), описывающая рост нормы матрицы ошибки  $E_k = B_k - J(x^*)$  через проектор вдоль текущего шага. У классических обновлений ранга 1 (Бройден, SR1) и ранга 2 (BFGS) этот проектор имеет ранг 1: из  $p$  прошлых секущих условий  $B_{k+1}s_j = y_j$ ,  $j = k-p, \dots, k-1$ , на следующую итерацию переходит лишь текущее. Естественный путь усиления оценки — сохранение прошлых секущих условий, расширяющее проектор ограниченной деградации с ранга 1 до ранга  $p+1$ , как для нелинейных систем, так и для гладкой оптимизации. Точность аппроксимации якобиана не является чисто теоретической характеристикой: в современных второпорядковых методах для вариационных неравенств [15] скорость глобальной сходимости явно зависит от нормы ошибки  $\|B_k - J(x_k)\|$ , и любое количественное усиление оценки этой ошибки непосредственно переносится в оценку метода более высокого уровня. В настоящей диссертации количественный анализ ограниченной деградации развивается для мультисекущего обновления Бройдена [31] на классе нелинейных систем  $F(x) = 0$  (ранг-1 специализация Projected Broyden Гэя–Шнабеля [18] включена как имплементационная форма для limited-memory варианта); для гладкой минимизации построено секантно-стабилизированное

обновление  $\text{SS-}\mathcal{U}$  как симметричный аналог. Получаемая константа ограниченной деградации  $C_{\text{PB}} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$  зависит от обусловленности окна  $\kappa_p = \kappa(S_p)$ , а не от размерности  $n$  — что открывает дорогу к limited-memory варианту L-PB на крупномасштабных задачах.

## Объект и предмет исследования

**Объект исследования** — численные методы решения двух взаимосвязанных классов задач: нелинейных систем уравнений  $F(x) = 0$  и безусловной гладкой оптимизации  $\min_{x \in \mathbb{R}^n} f(x)$ .

**Предмет исследования** — глобальные квазиньютоновские обновления приближённого якобиана  $B_k$ , сохраняющие на каждой итерации  $p$  прошлых секущих условий  $B_{k+1}s_j = y_j$ ,  $j = k-p, \dots, k$ , и порождающие расширенный (ранг  $p+1$ ) проектор bounded deterioration; в частности, мультисекущее обновление Бройдена для нелинейных систем и его симметричный аналог SS-U для оптимизации.

## Цель и задачи работы

**Цель работы:** развить теоретический анализ мультисекущего обновления Бройдена [31] для нелинейных систем и построить его секантно-стабилизированный симметричный аналог для гладкой оптимизации.

### Задачи:

1. Сформулировать мультисекущее обновление Бройдена [31] как обновление ранга  $p+1$ ; согласовать режимы `accumulate`  $\in \{\text{true}, \text{false}\}$  с таксономией Fang–Saad [16]; зафиксировать ранг-1 специализацию [18] как имплементационную форму для limited-memory варианта.
2. Получить точное разложение и оценку bounded deterioration для мультисекущего обновления:  $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$  с проектором  $\Pi_k$  ранга  $p+1$  (у классического Бройдена — ранга 1) и явной геометрической константой  $C_{\text{PB}} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$ , где  $\kappa_p = \kappa(S_p)$  — обусловленность окна шагов; вывести неравенство  $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$  и количественную  $O(\rho_k)$ -аппроксимацию якобиана на подпространстве прошлых шагов; усилить тем самым оценку Гэя–Шнабеля (Th. 4.2 из [18]).
3. Перенести идею сохранения прошлых секущих условий на симметричные методы (SR1, PSB): отталкиваясь от классической несовместности симметрии и сохранения



нескольких текущих условий [31], построить секантно-стабилизированные обновления SS-U с коррекцией в ортогональном дополнении  $s_k^\perp$ , исследовать сверхлинейность и устойчивую сходимость на модельных задачах.

4. Подтвердить теоретические результаты численными экспериментами на стандартных тестовых задачах.

## Научная новизна

1. Для мультисекущего обновления Бройдена [31]  $B_{k+1} = B_k + (Y_p - B_k S_p) G_p^{-1} S_p^\top$  получено *точное разложение* bounded deterioration

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$$

с проектором  $\Pi_k = S_p G_p^{-1} S_p^\top$  ранга  $p+1$  на  $\text{col}(S_p)$  (у классического Бройдена — ранга 1, на  $\text{span}(s_k)$ ) и локальной оценкой  $\Delta_k = O(\rho_k^2)$ ,  $\rho_k = \max_{k-p \leq j \leq k} \|x_j - x^*\|$ , причём константа в  $O(\cdot)$  выписана явно через геометрию окна:  $C_{\text{РВ}} = L(1 + C_s/2)\sqrt{p+1} \kappa_p$ , где  $\kappa_p = \kappa(S_p)$  — обусловленность окна шагов. В литературе количественная форма оценки ограниченной деградации для общей мультисекущей формы [31] ранее не приводилась; для ранг-1 специализации Projected Broyden Гэя–Шнабеля [18] установлены минимум-Фробениус характеристика (Th. 2.1), оценка bounded deterioration в виде неравенства сверху (Th. 4.2) и Q-суперлинейная сходимость (Th. 4.5); приведённые ниже результаты усиливают этот анализ *количественно* и переносят на мультисекущую (общую несимметричную) форму:

- (а) равенство (а не оценка сверху) для  $\|E_{k+1}\|_F^2$  через явный отрицательный член  $\|E_k \Pi_k\|_F^2$ ;
  - (б) неравенство  $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$ , показывающее, что отрицательный член проекции мультисекущего обновления строго не меньше соответствующего одномерного члена в анализе классического Бройдена;
  - (с) покомпонентное разложение ошибки  $E_k$  по подпространствам  $\text{col}(S_p)$  и  $\text{col}(S_p)^\perp$  с количественной  $O(\rho_k)$ -оценкой аппроксимации якобиана на  $\text{col}(S_p)$  (см. следствие 2.12).
2. Для симметричного случая, отталкиваясь от классической несовместности симметрии и одновременного сохранения нескольких текущих условий [31], предложена конструкция SS-U — ранг-1 коррекция в  $s_k^\perp$ , не нарушающая ни текущего текущего условия, ни симметрии и стабилизирующая невязку прошлых текущих в смысле минимизации в  $s_k^\perp$ . В отличие от ранее известных симметричных

multi-secant подходов — весовой Frobenius-формы Gratton–Malmedy–Toint [21], SupPSB [4], gPSB [5] и grouped/ordered PSB [3] семейства, регуляризованной LS-формы Scieur и др. [19] — SS-U сохраняет точное выполнение текущей секущей и симметрии, а коррекция имеет ранг 1 (см. §3.4). Установлены композитное bounded deterioration в Lipschitz-форме под входной Q-линейной сходимостью (Лемма 3.12) и условная Q-сверхлинейность SS-U по Денниса–Море; численно продемонстрирована устойчивая сходимость на модельных задачах.

## Теоретическая и практическая значимость

**Теоретическая значимость.** Получено точное разложение  $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$  для мультисекущего обновления Бройдена — равенство в форме, в которой у Гэя–Шнабеля [18] получено лишь неравенство сверху (Th. 4.2) для ранг-1 специализации. Расширение проектора  $\Pi_k$  с одномерного  $s_k s_k^\top / \|s_k\|^2$  (классический Бройден) до ранга  $p+1$  на  $\text{col}(S_p)$  для мультисекущего обновления позволяет дополнительно установить количественную  $O(\rho_k)$ -аппроксимацию якобиана на  $\text{col}(S_p)$  — структурное преимущество над классическим Бройденом. Отрицательный член точного разложения для мультисекущего обновления не меньше соответствующего члена классического Бройдена. В симметричной квазиньютоновской теории, отталкиваясь от классической несовместности симметрии и одновременного сохранения нескольких секущих условий [31], предложена конструкция SS-U как ранг-1 коррекция в  $s_k^\perp$ , разрешающая это препятствие; для неё установлена Q-сверхлинейность по критерию Денниса–Море.

**Практическая значимость.** Limited-memory вариант L-PB хранит  $O(nm)$  векторов вместо плотной матрицы  $O(n^2)$  и применим к нелинейным системам высокой размерности, где плотные квазиньютоновские формы исчерпывают память; формальное основание применимости даёт явный вид константы  $C_{PB}$ , которая зависит от обусловленности окна  $\kappa_p$ , а не от размерности  $n$  — ограниченная деградация теоретически не ухудшается с ростом  $n$ . По числу итераций до сходимости L-PB сходится за количество итераций, не зависящее от размерности  $n$  на стандартных тестовых задачах вплоть до  $n = 10^5$ ; в режиме  $m \geq p_{\max} + 1$  зазор с плотной ранг-1 PB-формой умеренный и монотонно сокращается с ростом  $m$ . По сравнению с классическим Бройденом расширенное окно секущих сокращает медианное число итераций до сходимости и сужает разброс по случайным стартам. В оптимизационной части семейство SS-U восстанавливает устойчивую сходимость симметричных обновлений PSB и SR1 на задачах, где базовое обновление структурно деградирует, не ухудшая сходимость на задачах, где деградации нет.

## Положения, выносимые на защиту

1. Формулировка мультисекущего обновления Бройдена [31] как ранг- $(p+1)$  обновления в Алгоритме 1 и согласованное с таксономией Fang–Saad [16] описание режимов накопления; ранг-1 специализация  $B_{k+1} = B_k + (y_k - B_k s_k) (S_p G_p^{-1} e_1)^\top$  под индуктивным инвариантом  $B_k s_j = y_j$  ( $j < k$ ) как имплементационная форма для limited-memory варианта L-PB (§2.2).
2. Теорема об ограниченной деградации с расширенным проектором для мультисекущего обновления (см. теорему 2.10): точное равенство  $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$  с проектором  $\Pi_k$  ранга  $p+1$  (у классического Бройдена — ранга 1) и явной локальной оценкой  $\Delta_k$  через геометрию окна ( $C_{PB} = L(1 + C_s/2)\sqrt{p+1} \kappa_p$ ,  $\kappa_p = \kappa(S_p)$ ); неравенство  $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$ .
3. Количественная  $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов  $\text{col}(S_p)$  для мультисекущего обновления (следствие 2.12).
4. Конструкция секантно-стабилизированного обновления SS-U для симметричного случая: ранг-1 коррекция в  $s_k^\perp$ , разрешающая классическую несовместность симметрии и одновременного сохранения нескольких секущих условий [31].
5. Bounded deterioration в композитной форме для SS-U (Лемма 3.12) и условная Q-сверхлинейная сходимость SS-U по критерию Денниса–Море (теорема 3.9).

## Методология и методы исследования

В работе используются методы вычислительной линейной алгебры (разложения QR и SVD, теория проекторов, оценки чисел обусловленности грамиана) и классической теории квазиньютоновских методов (свойства обновлений ранга 1 и 2, критерий сверхлинейности Dennis–More [13]). Численные эксперименты проведены в Python с использованием NumPy; задачи взяты из стандартного тестового набора [24].

## Степень достоверности и апробация результатов

Все теоретические результаты снабжены полными доказательствами. Утверждения о скорости сходимости подтверждены численными экспериментами на стандартных тестовых задачах с единым критерием останова. Исходный код экспериментов и скрипты построения всех представленных рисунков открыты и доступны в публичном репозитории Projected Broyden.<sup>1</sup>

<sup>1</sup><https://github.com/mojaevr/secant-conditions>

## Структура и объём работы

Работа состоит из введения, трёх глав, заключения и списка литературы.

- В **главе 1** вводится язык квазиньютоновских обновлений: от постановки задач оптимизации и нелинейных систем и вывода квазиньютоновской итерации из модели Ньютона к упорядоченной сводке классических обновлений и общему семейству мультисекантных обновлений с анализом выбора матрицы направлений  $V_m$  и базовой матрицы  $\hat{B}_k$ .
- В **главе 2** рассматривается мультисекантное обновление Бройдена  $B_{k+1} = B_k + (Y_p - B_k S_p) G_p^{-1} S_p^\top$ , доказывается теорема об ограниченной деградации с точным разложением и расширенным проектором, выводится количественная  $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов; ранг-1 специализация (Projected Broyden Гэя–Шнабеля) используется для limited-memory реализации L-PB; приводятся численные эксперименты для нелинейных систем.
- В **главе 3** идея сохранения прошлых секующих условий переносится на симметричные методы. Строится SS-U, доказывается сверхлинейная сходимость, исследуется устойчивая сходимость на модельных задачах.

# Глава 1

## Квазиньютоновские методы и мультисекунные обновления

Глава вводит язык, на котором ведётся весь дальнейший анализ, и отводит настоящей работе место среди известных результатов. Изложение движется от постановки задач безусловной оптимизации и решения нелинейных систем (§1.1) к выводу квазиньютоновской итерации из модели метода Ньютона (§1.2) и упорядоченной сводке классических обновлений (§1.3). Далее следуют локальная теория сверхлинейной сходимости (§1.4), общее семейство мультисекунных обновлений с таксономией по матрице направлений и базовой матрице (§§1.5–1.6), обзор подходов к глобализации и limited-методу вариантам (§1.7) и состояние литературы по симметричным multi-secant расширениям (§1.8). Завершает главу позиционирование настоящей работы относительно перечисленных направлений (§1.9).

### 1.1 Задачи оптимизации и нелинейные системы

Отправная точка — безусловная минимизация гладкой функции

$$\min_{x \in \mathbb{R}^n} f(x), \quad f: \mathbb{R}^n \rightarrow \mathbb{R}, \quad f \in C^2, \quad (1)$$

к которой сводятся оценка параметров моделей, обучение и широкий класс вариационных задач. В точке минимума выполнено условие стационарности  $\nabla f(x) = 0$  — система  $n$  уравнений с  $n$  неизвестными, частный случай более общей задачи поиска корня нелинейного отображения

$$F(x) = 0, \quad F: \mathbb{R}^n \rightarrow \mathbb{R}^n. \quad (2)$$

При  $F = \nabla f$  задача (2) есть условие стационарности для (1); в общем случае  $F$  возникает самостоятельно — при дискретизации краевых задач, в равновесных и эко-

номических моделях, а также как оператор оптимальности седловых (минимаксных) задач  $\min_x \max_y \Phi(x, y)$ , где  $F(z) = (\nabla_x \Phi, -\nabla_y \Phi)$ ,  $z = (x, y)$ , и вариационных неравенств (ВН) [15].

Структурное различие между этими двумя источниками — симметрия производной. Для (1) матрицей системы  $\nabla f(x) = 0$  служит гессиан  $\nabla^2 f(x)$ , симметричный по построению; для общей системы (2) якобиан  $J(x) = F'(x)$  в общем случае несимметричен (в частности, для минимаксного оператора выше). Это различие определяет, какие квазиньютоновские обновления применимы, и задаёт структуру работы (таблица 1).

Таблица 1 — Два класса задач, структура производной и отвечающие им квазиньютоновские обновления.

| Класс задачи                                | Производная                        | Обновления                                |
|---------------------------------------------|------------------------------------|-------------------------------------------|
| Оптимизация $\min f$ ,<br>$\nabla f(x) = 0$ | гессиан $\nabla^2 f$ — симметричен | симметричные: SR1, PSB, DFP, BFGS (гл. 3) |
| Система $F(x) = 0$<br>(вкл. минимакс, ВН)   | якобиан $F'$ — несимметричен       | несимметричные: Бroyден (гл. 2)           |

Простейшая итерация для (1) — градиентный спуск  $x_{k+1} = x_k - \alpha \nabla f(x_k)$ , использующий лишь первый порядок и не учитывающий кривизну. Метод Ньютона учитывает её через гессиан, но требует его вычисления и обращения на каждом шаге. Квазиньютоновские методы занимают промежуточное положение: они заменяют производную дешёвой аппроксимацией  $B_k$ , обновляемой по ходу итераций (градиентный спуск отвечает вырожденному выбору  $B_k = \alpha^{-1}I$  без информации о кривизне). Вывод этой схемы из модели Ньютона — предмет следующего параграфа.

## 1.2 От метода Ньютона к квазиньютоновским обновлениям

Метод Ньютона для системы (2) строит шаг из линеаризации  $F(x_k + d) \approx F(x_k) + J(x_k) d$ , приравнивая правую часть нулю:  $J(x_k) d_k = -F(x_k)$ . Он сходится локально квадратично, но требует якобиана  $J(x_k)$  и решения линейной системы с ним на каждой итерации, что часто неприемлемо дорого. Квазиньютоновская идея — заменить  $J(x_k)$  аппроксимацией  $B_k$ , не требующей явного дифференцирования:

$$x_{k+1} = x_k + d_k, \quad B_k d_k = -F(x_k), \quad (3)$$

где  $B_k \in \mathbb{R}^{n \times n}$  — текущая аппроксимация якобиана  $J(x_k) = F'(x_k)$  (для (1) — гессиана  $\nabla^2 f(x_k)$ ); из (3) шаг совпадает с направлением,  $s_k = d_k$ .

Условие, которому подчиняется обновление  $B_k \mapsto B_{k+1}$ , проще всего получить из квадратичной модели минимизации [26, §6.1]. Приближим  $f$  вблизи  $x_{k+1}$  моделью

$$m_{k+1}(d) = f(x_{k+1}) + \nabla f(x_{k+1})^\top d + \frac{1}{2} d^\top B_{k+1} d$$

и потребуем, чтобы её градиент совпадал с истинным не только в  $x_{k+1}$  (что выполнено автоматически), но и в предыдущей точке  $x_k$ :  $\nabla m_{k+1}(-s_k) = \nabla f(x_k)$ , где

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f(x_{k+1}) - \nabla f(x_k).$$

Подстановка  $\nabla m_{k+1}(d) = \nabla f(x_{k+1}) + B_{k+1}d$  при  $d = -s_k$  даёт *секущее условие*

$$B_{k+1} s_k = y_k. \tag{4}$$

Для общей системы (2) та же пара определяется через  $y_k = F(x_{k+1}) - F(x_k)$ , и условие (4) выражает требование, чтобы  $B_{k+1}$  воспроизводило конечную разность  $F$  вдоль последнего шага — многомерный аналог секущего метода. Поскольку (4) — это  $n$  уравнений на  $n^2$  элементов  $B_{k+1}$ , обновление недоопределено; разные способы доопределения порождают семейство классических обновлений (§1.3) и его мультисекующие расширения (§1.5).

### 1.3 Классические квазиньютоновские обновления

Секущее условие (4) — это  $n$  линейных уравнений на  $n^2$  элементов  $B_{k+1}$ ; классические обновления различаются тем, как доопределяется эта недоопределённая система (симметрия, ранг коррекции, выбор минимизируемой нормы). Введём их по порядку — от одномерного прообраза к ранг-2 симметричным формам; итоговая сводка формул приведена в таблице 2.

**Одномерный прообраз.** В скалярном случае ( $n = 1$ ) секущий метод заменяет производную разностью  $B_{k+1} = y_k/s_k$ , что однозначно определяет  $B_{k+1}$  из (4). В  $\mathbb{R}^n$  одного условия недостаточно, и требуется дополнительный принцип отбора.

**Метод Бroyдена.** Естественный принцип — минимальное изменение: среди всех  $B_{k+1}$ , удовлетворяющих (4), выбирается ближайшая к  $B_k$  по норме Фробениуса. Решение — метод Бroyдена [6], исторически первое обобщение секущего метода на многомерный случай; его обновление ранга 1 есть проекция  $B_k$  на аффинное подпространство

$\{B : Bs_k = y_k\}$  в норме Фробениуса. Симметрия не налагается, что отвечает общим несимметричным системам (2).

**Симметричные обновления для оптимизации.** Для (1) гессиан симметричен, и от  $B_{k+1}$  естественно требовать  $B_{k+1} = B_{k+1}^\top$ . Симметричный аналог бройденовской проекции по Фробениусу — ранг-2 обновление PSB Пауэлла [29]. Симметричное ранг-1 обновление (SR1) [10, 26] даёт наиболее точную аппроксимацию гессиана и корректно работает в trust-region схемах, но не гарантирует положительной определённости. Положительную определённость обеспечивает вариационно-метрическое семейство, восходящее к Davidon (переиздание [11]): DFP — ранг-2 обновление на обратной матрице ( $H_{k+1}y_k = s_k$ ), BFGS — двойственное к нему на прямой матрице, причём критерий совместности  $s_k^\top y_k > 0$  сохраняет положительную определённость [26].

Таблица 2 — Классические квазиньютоновские обновления, удовлетворяющие текущей  $B_{k+1}s_k = y_k$ . Через  $\bar{y}_k = y_k - B_k s_k$  обозначена невязка текущей перед обновлением.

| Метод                   | Формула обновления $B_{k+1} - B_k$                                                                                | Симм. | Ранг |
|-------------------------|-------------------------------------------------------------------------------------------------------------------|-------|------|
| Broyden<br>("good") [6] | $\bar{y}_k s_k^\top / \ s_k\ ^2$                                                                                  | нет   | 1    |
| Broyden<br>("bad") [6]  | $\bar{y}_k y_k^\top / (y_k^\top s_k)$ (для $H_{k+1}$ обратной)                                                    | нет   | 1    |
| SR1 [10, 26]            | $\bar{y}_k \bar{y}_k^\top / (\bar{y}_k^\top s_k)$                                                                 | да    | 1    |
| PSB [29, 13]            | $\frac{\bar{y}_k s_k^\top + s_k \bar{y}_k^\top}{\ s_k\ ^2} - \frac{(s_k^\top \bar{y}_k) s_k s_k^\top}{\ s_k\ ^4}$ | да    | 2    |
| DFP [11, 13]            | ранг-2 формула на $H_{k+1}$ ,<br>$H_{k+1}y_k = s_k$                                                               | да    | 2    |
| BFGS [26]               | $\frac{y_k y_k^\top}{y_k^\top s_k} - \frac{B_k s_k s_k^\top B_k}{s_k^\top B_k s_k}$                               | да    | 2    |

Параллельно с плотными обновлениями развивались структурные модификации: Schubert [32] построил версию Бройдена для систем со спарсным якобианом, сохраняющую заданный шаблон ненулевых элементов; общая теория ранг-1 обновлений в семействе  $B_{k+1} = B_k + \bar{y}_k v_k^\top / (v_k^\top s_k)$  с произвольным вектором направления  $v_k$  изложена в [17]. Эти работы заложили язык, в котором обновление параметризуется не столько конкретной формулой, сколько выбором матрицы направлений и базовой матрицы — унифицированную форму этой параметризации (§1.5) систематически развил Шнабель [31].



## 1.4 Локальная теория сверхлинейной сходимости

Стандартный аппарат локального анализа квазиньютоновских методов сложился в работах [7, 12, 13, 14]. Центральный результат Dennis–Moré [12]: при липшицевости якобиана и невырожденности  $J^* = J(x^*)$  итерация (3) сходится Q-сверхлинейно тогда и только тогда, когда выполнено условие

$$\lim_{k \rightarrow \infty} \frac{\|(B_k - J^*) s_k\|}{\|s_k\|} = 0. \quad (5)$$

Доказательство сверхлинейности конкретного метода сводится тем самым к проверке (5); ключевой инструмент — *ограниченная деградация* (bounded deterioration) [7, 14]: при движении вблизи корня норма ошибки  $E_k = B_k - J^*$  может расти не быстрее, чем с линейной добавкой, пропорциональной расстоянию до корня. Для классического Бройдена эта оценка получается из равенства

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \pi_k\|_F^2 + \Delta_k, \quad \pi_k = \frac{s_k s_k^\top}{\|s_k\|^2}, \quad (6)$$

где проектор  $\pi_k$  — ранга 1, а  $\Delta_k = \|y_k - J^* s_k\|^2 / \|s_k\|^2 = O(\rho_k^2)$  ( $\rho_k = \max(\|x_k - x^*\|, \|x_{k+1} - x^*\|)$ ) суммируем при R-линейной сходимости итераций к корню. Тожество (6) вместе с (5) даёт классическую теорему Broyden–Dennis–Moré о локальной Q-сверхлинейности обновления [7].

Структурная особенность (6) — ранг проектора  $\pi_k$ : отрицательный член разложения «вычитает» ошибку только вдоль направления текущего шага. На подпространстве  $s_k^\perp$  ошибка переносится из  $E_k$  в  $E_{k+1}$  без изменений (с точностью до липшицевой поправки), что формально фиксирует утверждение 1.1 ниже: ранг-1 обновление разрушает прошлые секущие на  $s_k^\perp$ . Усиление локальной теории за счёт расширения проектора  $\pi_k$  с ранга 1 до более высокого ранга — естественный путь, реализуемый сохранением нескольких секущих условий одновременно, к которому и ведёт мультисекущая формулировка [31, 18].

Для классических симметричных обновлений локальный анализ устроен параллельно: Powell [30] установил Q-сверхлинейность DFP в подходящих условиях, конструктивное Dennis–Moré доказательство [13, 14] переносится на BFGS и PSB; для SR1 близкая по технике локальная теория получена существенно позже [10]. Источник дополнительной техники в симметричном случае — сохранение положительной определённости и устойчивая работа оценки  $\|E_k\|_F$  под симметричным обновлением.

## 1.5 Мультисекунные обновления: общая формула и таксономия

Пусть заданы  $m$  секущих условий  $B_{k+1}S_m = Y_m$ , где

$$S_m = [s_{k-m+1} \mid \cdots \mid s_k] \in \mathbb{R}^{n \times m}, \quad Y_m = [y_{k-m+1} \mid \cdots \mid y_k] \in \mathbb{R}^{n \times m}.$$

Параметр  $m$  — ранг общей мультисекантной формулы, используется только в настоящей главе; начиная с гл. 2 обозначение переходит в  $p$  — глубину сохраняемых *прошлых* секущих ( $S_p \in \mathbb{R}^{n \times (p+1)}$  за счёт включения текущей  $s_k$ ); см. раздел «Обозначения и сокращения».

Семейство обновлений, удовлетворяющих всем  $m$  секущим условиям, описывается унифицированной формулой Шнабеля [31, ур. (2.5)]:

$$B_{k+1} = \widehat{B}_k + (Y_m - \widehat{B}_k S_m) (V_m^\top S_m)^{-1} V_m^\top \quad (7)$$

где  $\widehat{B}_k \in \mathbb{R}^{n \times n}$  — базовая матрица,  $V_m \in \mathbb{R}^{n \times m}$  — матрица направлений ( $V_m^\top S_m$  невырождена). Прямая подстановка даёт  $B_{k+1}S_m = Y_m$  при любом допустимом  $V_m$ ; ранг  $\Delta_k = B_{k+1} - \widehat{B}_k$  не превосходит  $m$ .

Частный случай:  $m = 1$

При  $m = 1$  имеем  $S_m = s_k$ ,  $Y_m = y_k$ ,  $V_m = v_k \in \mathbb{R}^n$ , и формула (7) принимает вид

$$B_{k+1} = \widehat{B}_k + \frac{(y_k - \widehat{B}_k s_k) v_k^\top}{v_k^\top s_k}. \quad (8)$$

Это ранг-1 обновление, удовлетворяющее единственному секущему условию  $B_{k+1}s_k = y_k$ . При дополнительном ограничении  $v_k^\top s_k = 1$  знаменатель исчезает:

$$B_{k+1} = \widehat{B}_k + (y_k - \widehat{B}_k s_k) v_k^\top. \quad (9)$$

### Разрушение прошлых секущих ранг-1 обновлением

Прежде чем переходить к выбору матрицы направлений  $V_m$ , отметим характерную патологию ранг-1 ветви (8): текущее секущее условие  $B_{k+1}s_k = y_k$  выполняется по построению, однако *прошлые* секущие в общем случае нарушаются. Это и есть основная мотивация перехода от классической ранг-1 формулы к мультисекунным расширениям [31, 18], рассматриваемым в гл. 2.

#### Утверждение 1.1.

Пусть  $B_{k+1}$  задано ранг-1 обновлением (8) в режиме накопления  $\widehat{B}_k = B_k$  с произволь-

ным  $v_k$  ( $v_k^\top s_k \neq 0$ ),

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k) v_k^\top}{v_k^\top s_k}.$$

Тогда для любого  $j < k$ :

$$B_{k+1} s_j = B_k s_j + (y_k - B_k s_k) \frac{v_k^\top s_j}{v_k^\top s_k}.$$

В частности, если  $y_k \neq B_k s_k$  (т.е. текущая секущая ещё не выполнена), то  $B_{k+1} s_j = B_k s_j$  тогда и только тогда, когда  $v_k^\top s_j = 0$ .

### Доказательство.

Прямое вычисление даёт

$$B_{k+1} s_j = B_k s_j + (y_k - B_k s_k) \frac{v_k^\top s_j}{v_k^\top s_k}.$$

При  $y_k \neq B_k s_k$  второе слагаемое зануляется тогда и только тогда, когда  $v_k^\top s_j = 0$ . ■

### Следствие 1.1.

В классическом методе Бroyдена ( $v_k = s_k$ ), если на предыдущем шаге выполнялось  $B_k s_j = y_j$  и  $y_k \neq B_k s_k$ , то  $B_{k+1} s_j = y_j$  тогда и только тогда, когда  $s_k^\top s_j = 0$ . В общем случае равенство нарушается.

Естественный способ устранить это нарушение — потребовать сохранения *всех* прошлых секущих в окне:  $B_{k+1} s_j = y_j$  для  $j = k-p, \dots, k$ . Это и приводит к мультисекущему обновлению Бroyдена [31] (гл. 2) и к его симметричному аналогу SS- $\mathcal{U}$  (гл. 3); именно сохранение прошлых секущих расширяет проектор bounded deterioration с ранга 1 до ранга  $p+1$ , что и составляет центральный объект анализа последующих глав.

Выбор  $V_m$ : что минимизирует обновление

При фиксированных  $\hat{B}_k$ ,  $S_m$ ,  $Y_m$  выбор  $V_m$  определяет форму обновления  $\Delta_k$ . Различные  $V_m$  удовлетворяют одним и тем же секущим условиям, но отличаются по норме изменения  $\|\Delta_k\|_F = \|B_{k+1} - \hat{B}_k\|_F$ .

$V_m = S_m$ : минимум нормы Фробениуса. Обновление принимает вид

$$B_{k+1} = \hat{B}_k + (Y_m - \hat{B}_k S_m) (S_m^\top S_m)^{-1} S_m^\top. \quad (10)$$

Это единственное решение задачи  $\min_B \|B - \hat{B}_k\|_F$  при  $B S_m = Y_m$  — проекция  $\hat{B}_k$  на аффинное подпространство, задаваемое секущими условиями, в норме Фробениуса;

строгая выпуклость гарантирует единственность. Ранг обновления не превосходит  $m$ .

$m = 1$ ,  $v_k = s_k$ : **классический метод Бroyдена**. Частный случай при  $m = 1$ :

$$B_{k+1} = \hat{B}_k + \frac{(y_k - \hat{B}_k s_k) s_k^\top}{\|s_k\|^2}. \quad (11)$$

Это решение  $\min_B \|B - \hat{B}_k\|_F$  при  $B s_k = y_k$ ; при  $\hat{B}_k = B_k$  — классический метод Бройдена [6], ранг 1,  $O(n^2)$  на шаг. Другие варианты — “bad Broyden” ( $v_k = y_k$ ), отвечающий  $\min \|H_{k+1} - H_k\|_F$  при  $H_{k+1} y_k = s_k$  для обратного якобиана [6, 14], и произвольный  $v_k$  с  $v_k^\top s_k \neq 0$  [17] — в настоящей работе не используются и упоминаются для полноты семейства (8).

## 1.6 Базовая матрица и связь с ускорением Андерсона

Второй параметр семейства (7) — базовая матрица  $\hat{B}_k$ . При  $\hat{B}_k = B_k$  (*накопление*) вся прошлая информация сохраняется неявно в  $B_k$ ; этот режим — стандартный для метода Бройдена и основной в настоящей работе. Локальная теория ограниченной деградации и условие Денниса–Море [12, 14] для  $B_k$  обсуждаются в гл. 2 для расширенного окна секущих.

При  $\hat{B}_k = B_0$  (*пересборка*, обычно  $B_0 = I$ ) обновление зависит только от  $B_0$  и окна  $m$  пар, история за его пределами стирается. В частности, при  $V_m = S_m$  и  $B_0 = I$  формула (10) принимает вид

$$B_{k+1} = I + (Y_m - S_m) (S_m^\top S_m)^{-1} S_m^\top, \quad (12)$$

и шаг  $x_{k+1} = x_k - B_{k+1}^{-1} F(x_k)$  совпадает с ускорением Андерсона типа I при коэффициенте релаксации  $\beta = 1$  [1, 35, 16]. Современную таксономию мультисекундных ускорителей развивают Fang–Saad [16], выделяя два класса (Type-I/Type-II), эквивалентных, соответственно, Бройдену и Андерсону, а локальную теорию сходимости Андерсона — Toth–Kelley [34]. В режиме накопления, основном для гл. 2, обновление наследует поведение Бройдена с расширенным окном; в Алгоритме гл. 2 режим пересборки активируется опцией `accumulate = false` и используется в численных экспериментах для сравнения.

## 1.7 Глобализация и limited-memory варианты

Локальная теория §1.4 гарантирует сверхлинейную сходимость лишь из достаточно малой окрестности корня  $x^*$  (или локального минимума). Для практического применения нужна *глобализация*: стратегия, обеспечивающая сходимость к корню

из произвольной начальной точки в разумной области сходимости. Параллельная задача в крупномасштабном режиме — *limited-memory* реализация, позволяющая работать с  $B_k$ , не храня плотной матрицы  $n \times n$ .

### 1.7.1 Глобализация для нелинейных систем и оптимизации

В гладкой оптимизации глобализация классических квазиньютоновских методов опирается на монотонное убывание целевой функции  $f$  и линейный поиск, удовлетворяющий условиям Армихо [2] или Вольфа [36]; общая теория глобальной сходимости направления спуска восходит к Zoutendijk [37]. Сохранение положительной определённости BFGS под условием Вольфа даёт сходимость на достаточно широком классе задач, тогда как для PSB и SR1 теория глобальной сходимости заметно слабее: их обновления не сохраняют знакоопределённости, что требует trust-region схем или гибридизации. Альтернативный подход к глобализации для оптимизации — регуляризация (Levenberg–Marquardt [23]) в приложении к нелинейным наименьшим квадратам; в общем оптимизационном контексте регуляризация естественно проявляется как trust-region ограничение на шаг.

Для нелинейных систем  $F(x) = 0$  ситуация существенно отличается: монотонной функции, минимум которой автоматически соответствует корню, нет. Классический эмпирический анализ показывает, что даже на хорошо обусловленных задачах поведение метода Бroyдена чувствительно к начальному приближению [33, 24]. Стандартные стратегии глобализации в этом классе — линейный поиск по  $\|F\|$  с условием типа Армихо и неточные ньютоновские шаги (inexact Newton). Нестандартный, но важный для настоящей работы инструмент — *немонотонный* линейный поиск, допускающий временный рост невязки  $\|F\|$  при условии возврата к монотонной траектории через скользящее среднее или максимум по окну предыдущих значений; такой поиск, в частности, использован Бурдаковым и Каманди [8] в глобализованном multipoint secant методе для  $F(x) = 0$ . Их работа — ближайший прецедент глобализации мультисекундных обновлений для нелинейных систем; ключевое отличие от режима, рассматриваемого в настоящей работе, — в технике переноса bounded deterioration через вспомогательную аппроксимацию якобиана на шаге  $k + 1$ , что не требует повторного анализа разложения (6) для каждого варианта линейного поиска.

### 1.7.2 Limited-memory реализации

Для крупномасштабных задач хранение плотного  $B_k \in \mathbb{R}^{n \times n}$  ( $O(n^2)$  памяти) исключено уже при  $n \sim 10^5$ . Канонический limited-memory вариант квазиньютоновского метода для оптимизации — L-BFGS Носдала [25]: вместо плотной  $B_k$  хранятся послед-

ние  $m$  пар  $(s_j, y_j)$ , через которые  $B_kv$  или  $H_kv$  восстанавливаются процедурой two-loop рекурсии за  $O(mn)$  операций. Liu и Nocedal [22] продемонстрировали практическую эффективность L-BFGS на крупномасштабных задачах; Byrd, Nocedal и Schnabel [9] получили компактное матричное представление L-BFGS и L-SR1, удобное для trust-region схем и теоретического анализа.

Для несимметричных задач (нелинейные системы (2)) канонической limited-memory формы классического Бройдена в литературе *не сложилось*: прямое сокращение хранения через окно  $m$  пар  $(s_j, y_j)$  ведёт к потере текущих условий вне окна (ср. утв. 1.1), и теория ограниченной деградации для такой «скользящей» версии Бройдена существенно слабее, чем для L-BFGS. Мультисекунная формулировка (7) в режиме накопления естественно даёт ранг- $(p+1)$  обновление, согласованное сразу со всеми парами окна, что открывает путь к limited-memory варианту с теоретическими гарантиями, не деградирующими с ростом  $n$ . Этот путь реализуется в гл. 2, §2.2 в виде L-PB.

## 1.8 Симметричные multi-secant подходы

Перенос идеи сохранения нескольких текущих условий на симметричный случай (для гладкой оптимизации) наталкивается на классическое препятствие, явно зафиксированное у Шнабеля [31]: система  $B_{k+1}S_m = Y_m$  при  $B_{k+1} = B_{k+1}^\top$  совместна тогда и только тогда, когда  $S_m^\top Y_m$  симметрична, что в общем случае не выполняется. Дословный перенос мультисекунной формулы с симметризацией невозможен, и литература последних лет предлагает различные стратегии *компромисса* между симметрией и точным выполнением прошлых текущих условий.

- Gratton, Malmedy, Toint [21]: *weighted secant equations* — текущие условия по прошлым парам выполняются приближённо с явными весами, симметрия обновления сохраняется; задача сводится к взвешенной фробениусовой проекции с квадратичным критерием.
- Boutet, Haelterman, Degroote [4, 5, 3]: семейство симметричных PSB-расширений (SUpPSB, gPSB, grouped/ordered PSB), различающихся способом регуляризации совместности; общая черта — замена точного выполнения прошлых текущих на некоторое статистическое или групповое условие, сохраняющее симметрию ранг-2 коррекции.
- Scieur, Liu, Pumi, Boumal [19]: regularized least-squares форма с явной регуляризацией грамиана и общим обобщённым обоснованием как для несимметричного, так и для

симметричного случая; точное выполнение секущих условий приносится в жертву устойчивости при плохо обусловленном окне.

Каждый из перечисленных подходов сохраняет симметрию (а часто и положительную определённость) ценой ослабления секущих условий — текущего, прошлых или того и другого. В гл. 3 рассматривается альтернативная стратегия компромисса  $SS\mathcal{U}$ : точное выполнение *текущей* секущей  $B_{k+1}s_k = y_k$  и симметрии, а прошлые секущие стабилизируются ранг-1 коррекцией в подпространстве  $s_k^\perp$ ; детальное сравнение  $SS\mathcal{U}$  с работами [21, 4, 5, 3, 19] проведено в §3.4.

## 1.9 Место настоящей работы

Изложенный обзор позволяет точно зафиксировать место настоящей диссертации. Объект анализа — мультисекущее обновление Бройдена в форме (7) при  $\hat{B}_k = B_k$ ,  $V_m = S_m$ ,  $m = p+1$  (режим накопления, минимум-Фробениус); этот объект введён Шнабелем [31], а ранг-1 специализация под индуктивным инвариантом  $B_k s_j = y_j$  для  $j < k$  — Гэем и Шнабелем [18]. Развиваемое в гл. 2 направление: количественная форма теоремы об ограниченной деградации с явной константой через геометрию окна  $\kappa_p = \kappa(S_p)$ , точное разложение (6) с проектором ранга  $p+1$  (вместо ранга 1 у классического Бройдена),  $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов, а также limited-memory реализация L-PB через ранг-1 запись Гэя–Шнабеля.

Для симметричного случая (гл. 3) предлагается конструкция  $SS\mathcal{U}$  как ранг-1 коррекция в  $s_k^\perp$ , сохраняющая симметрию и точную текущую секущую; разрешение классической несовместности [31] достигается не ослаблением секущих условий (как в [21, 4, 5, 3, 19]), а стабилизацией прошлых секущих в ортогональном дополнении к  $s_k$ .

**Резюме.** Общая мультисекантная формула (7) параметризуется матрицей направлений  $V_m$  (форма обновления: минимум по Фробениусу при  $V_m = S_m$ , классический Бройден при  $m = 1$ ,  $v_k = s_k$ ; (10), (11)) и базовой матрицей  $\hat{B}_k$  (накопление или пересборка, последняя эквивалентна Андерсону; (12)). Локальная теория сверхлинейной сходимости [7, 12, 13] сводит вопрос к критерию Денниса–Море (5) и разложению bounded deterioration (6) с проектором ранга 1 для классических обновлений; разрушение прошлых секущих ранг-1 обновлением (утв. 1.1) мотивирует переход к мультисекущим расширениям. Дальнейший анализ ведётся в режиме накопления с расширенным окном секущих — мультисекущим обновлением Бройдена [31] (гл. 2) и его симметричным аналогом  $SS\mathcal{U}$  (гл. 3).

## Глава 2

# Мультисекующий Бroyден

В этой главе анализируется мультисекующее обновление Бройдена — квазиньютоновский метод решения системы  $F(x) = 0$ , в котором новая аппроксимация якобиана  $B_{k+1}$  удовлетворяет  $p+1$  секущим условиям из текущего окна последних шагов вместо одного, как в классическом Бройдене. Замкнутая матричная форма мультисекующего обновления для несимметричного бройденовского семейства приведена Шнабелем [31]; здесь она подвергается локальному анализу в форме теоремы об ограниченном ухудшении (bounded deterioration). Исторический предшественник — Projected Broyden Гэя и Шнабеля [18], ранг-1 специализация мультисекующего обновления при сохранении инварианта  $B_k s_j = y_j$  ( $j < k$ ) — обсуждается в §2.2 в связи с limited-memory реализацией.

Основные результаты главы: теорема 2.10 — точное разложение и оценка bounded deterioration по фробениусовой норме ошибки  $E_k = B_k - J^*$  с явной геометрической константой  $C_{PB} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$ , где  $\kappa_p = \kappa(S_p)$  — обусловленность окна шагов; следствие 2.12 — безусловная  $O(\rho_k)$ -аппроксимация якобиана на подпространстве прошлых шагов  $\text{col } S_p$  (структурное преимущество над классическим Бройденом). Численные эксперименты (§2.3) и limited-memory вариант L-PB (§2.2) дополняют теоретическую часть.

**Обозначения и предположения главы.** Рассматривается задача поиска корня  $F(x) = 0$  с непрерывно-дифференцируемым отображением  $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$  и якобианом  $J(x) = F'(x)$ . Обозначим  $x^*$  — корень системы ( $F(x^*) = 0$ ),  $J^* = J(x^*)$ ,  $s_k = x_{k+1} - x_k$ ,  $y_k = F(x_{k+1}) - F(x_k)$ ,  $E_k = B_k - J^*$  — ошибку аппроксимации якобиана. Во всех теоретических утверждениях главы 2 предполагается, что якобиан липшицев на некоторой открытой окрестности  $\mathcal{O} \subset \mathbb{R}^n$  точки  $x^*$ :

$$\|J(x) - J(y)\| \leq L \|x - y\|, \quad x, y \in \mathcal{O}. \quad (13)$$

Это стандартное предположение для анализа локальной сходимости квазиньютоновских методов; см. [13, 14].



Идея мультисекундного обновления: вместо одного секундного условия  $B_{k+1}s_k = y_k$ , удовлетворяемого классическим Бройденом, потребуем, чтобы  $B_{k+1}$  согласовывалось со *всеми* парами  $(s_j, y_j)$  из текущего окна  $j = k-p, \dots, k$ , то есть  $B_{k+1} S_p = Y_p$ . Среди всех матриц с этим свойством выбирается ближайшая к  $B_k$  по фробениусовой норме — это и есть мультисекундная форма Шнабеля [31], замкнутый вид которой приведён ниже.

**Определение 2.1** (Мультисекундное обновление Бройдена).

Пусть задана глубина окна  $p \geq 0$  и пусть шаги  $s_k, s_{k-1}, \dots, s_{k-p}$  линейно независимы; обозначим

$$S_p = [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}] \in \mathbb{R}^{n \times (p+1)}, \quad Y_p = [y_k \mid y_{k-1} \mid \dots \mid y_{k-p}], \quad G_p = S_p^\top S_p.$$

*Мультисекундное обновление* (MS-обновление) задаётся формулой

$$B_{k+1} = B_k + (Y_p - B_k S_p) G_p^{-1} S_p^\top. \quad (14)$$

*Замечание 2.2* (Соглашение об обозначениях). Параметр  $p$  обозначает число *прошлых* секундных, входящих в окно наряду с текущей; всего окно содержит  $p+1$  пару. Текущий шаг  $s_k$  стоит *первым* столбцом матрицы  $S_p$ . В отличие от этого, в общей формуле (7) столбцы  $S_m$  расположены в хронологическом порядке: от старых к новым.

*Замечание 2.3* (Минимум-Фробениус характеристикация). Формула (14) есть единственная матрица  $B_{k+1}$ , удовлетворяющая  $B_{k+1} S_p = Y_p$  и минимизирующая  $\|B_{k+1} - B_k\|_F$ ; ранг обновления  $B_{k+1} - B_k = (Y_p - B_k S_p) G_p^{-1} S_p^\top$  не превосходит  $p+1$ . Это — классическая характеристикация мультисекундной формы для несимметричного бройденовского семейства [31, ур. (2.5)]; ср. также унифицированную классификацию Type-I/Type-II у Фана и Саада [16, ур. (26)], где Type-II вариант оказывается эквивалентным ускорению Андерсона. При  $p=0$  матрица  $G_0 = \|s_k\|^2$  и формула (14) переходит в классическое обновление Бройдена (11).

*Замечание 2.4* (Численная форма). Прямое обращение  $G_p$  нежелательно при плохой обусловленности. Поскольку  $G_p \succ 0$ , на практике используются: (i) разложение Холецкого  $G_p = LL^\top$  с двумя треугольными подстановками для решения  $G_p X = S_p^\top$  (стоимость  $O(p^3)$ ); (ii) тонкое QR-разложение  $S_p = QR$ , дающее  $G_p^{-1} S_p^\top = R^{-1} Q^\top$  и более устойчивое при умеренно плохой обусловленности [20, §5.3.3]. Качество обновления зависит от обусловленности  $\kappa_p = \kappa(S_p)$  окна шагов, которая входит в оценку теоремы 2.10 (см. замечание 2.11).

*Замечание 2.5* (Историческая привязка). Мультисекундное обновление в форме (14) выписано Шнабелем в техотчёте 1983 [31] как часть унифицированного рассмотрения

мультисекундных расширений сразу для четырёх семейств (Бройден, PSB, DFP, BFGS). Исторически ранее Гэй и Шнабель [18] рассматривали ранг-1 *Projected Broyden* (Algorithm II), сохраняющий прошлые секунды напрямую через проектирование направления  $v_k$  на ортогональное дополнение к  $\text{span}(s_{k-1}, \dots, s_{k-p})$ ; их Theorem 2.1 показывает, что эта ранг-1 конструкция совпадает с (14) при выполнении индуктивного инварианта  $B_k s_j = y_j$  ( $j < k$ ) и даёт минимум-Фробениус обновление в указанном классе. В настоящей работе формулировка (14) выбрана за основу как чисто алгебраическая (не требует индуктивного инварианта), а ранг-1 специализация возвращается в §2.2 ради limited-memory реализации через формулу Шермана–Моррисона. Установленные у Гэя и Шнабеля свойства — bounded deterioration (Th. 4.2) и локальная Q-сверхлинейная сходимость (Th. 4.5) — в настоящей главе уточняются: теорема 2.10 даёт точное разложение Фробениус-нормы ошибки и явную геометрическую константу, а следствие 2.12 — безусловный  $O(\rho_k)$ -контроль ошибки на всём подпространстве  $\text{col } S_p$  (в [18] в явном виде эти факты не приводятся).

Полный алгоритм приведён в Алгоритме 1.

---

**Algorithm 1** Мультисекундный Бройден ( $F, x_0, p_{\max}, \tilde{B}, \varepsilon, \text{accumulate}$ )

---

**Require:**  $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$ ,  $x_0 \in \mathbb{R}^n$ ,  $p_{\max} \geq 0$ ,  $\tilde{B} \in \mathbb{R}^{n \times n} \succ$  опорная матрица алгоритма, куда происходит сброс в режиме пересборки; обычно  $I_n$ . Не путать с базовой матрицей  $\hat{B}_k$  в формуле обновления.,  $\varepsilon > 0$ ,  $\text{accumulate} \in \{\text{true}, \text{false}\}$

$B_0 \leftarrow \tilde{B}, \quad k \leftarrow 0$

**while**  $\|F(x_k)\| \geq \varepsilon$  **do**

    Решить  $B_k d_k = -F(x_k)$

$x_{k+1} \leftarrow x_k + d_k$

$s_k \leftarrow d_k, \quad y_k \leftarrow F(x_{k+1}) - F(x_k)$

$p \leftarrow \min(p_{\max}, k)$

**MS-обновление якобиана:**

**if**  $\text{accumulate}$  **then**

$\hat{B}_k \leftarrow B_k$

**else**

$\hat{B}_k \leftarrow \tilde{B}$

$S_p \leftarrow [s_k \mid s_{k-1} \mid \dots \mid s_{k-p}], \quad Y_p \leftarrow [y_k \mid y_{k-1} \mid \dots \mid y_{k-p}]$

$G_p \leftarrow S_p^\top S_p \quad \triangleright (p+1) \times (p+1), \text{ симметричный, } \succ 0$

$B_{k+1} \leftarrow \hat{B}_k + (Y_p - \hat{B}_k S_p) G_p^{-1} S_p^\top \triangleright \text{ранг} \leq p+1; \text{ при } p=0 \text{ — классический Бройден}$

$k \leftarrow k + 1$

**return**  $x_k$

---

*Замечание 2.6* (Связь с таксономией обновлений). Опция `accumulate` переключает между двумя строками классификации Fang–Saad [16] для мультисекундных бройденовских обновлений. При `accumulate = true` (базовый режим всех экспериментов главы) в качестве опорной матрицы  $\widehat{B}_k$  берётся текущее  $B_k$ , накопившее историю прошлых обновлений; при `accumulate = false` — фиксированное  $\widetilde{B}$  (типично  $I$ ), и обновление становится Туре-II вариантом, эквивалентным ускорению Андерсона [1] (см. ур. (26) в [16]). В обоих случаях формула обновления одна и та же — ранг- $(p+1)$  мультисекундная.

*Замечание 2.7* (Сложность). Доминирующие операции на итерацию: формирование  $\widehat{B}_k S_p$  (плотное матрично-матричное произведение,  $O(n^2 p)$ ); решение  $(p+1) \times (p+1)$ -системы  $G_p X = S_p^\top$  через разложение Холецкого ( $O(p^3)$ ); решение  $B_k d_k = -F(x_k)$  через LU ( $O(n^3)$ ). При  $p \ll n$  доминирует LU. Limited-memory вариант §2.2 убирает  $O(n^2)$ -память и  $O(n^3)$ -стоимость LU за счёт специализации к ранг-1 случаю с Шерманом–Моррисоном.

## 2.1 Качество аппроксимации якобиана

**Лемма 2.8** (Локальная оценка длины шага через расстояние до корня).

Пусть якобиан  $J$  удовлетворяет условию Липшица (13) с константой  $L$  на шаре  $B(x^*, \delta_0) := \{x : \|x - x^*\| \leq \delta_0\}$ ,  $F(x^*) = 0$ , и пусть  $B_j$  обратима с  $\|B_j^{-1}\| \leq M$  для всех  $j \in \{k-p, \dots, k\}$ . Тогда для каждого  $j \in \{k-p, \dots, k\}$  с  $x_j \in B(x^*, \delta_0)$  длина шага  $s_j = -B_j^{-1}F(x_j)$  удовлетворяет

$$\|s_j\| \leq C_s \|x_j - x^*\|, \quad C_s := M \left( \|J^*\| + \frac{L}{2} \delta_0 \right), \quad (15)$$

где  $\|J^*\|$  — спектральная (операторная) норма  $J(x^*)$ .

### Доказательство.

По интегральной формуле Ньютона–Лейбница и  $F(x^*) = 0$ :

$$F(x_j) = F(x_j) - F(x^*) = \left( \int_0^1 J(x^* + t(x_j - x^*)) dt \right) (x_j - x^*).$$

Применяя оценку Липшица  $\|J(x^* + \tau(x_j - x^*)) - J^*\| \leq L \tau \|x_j - x^*\|$  и интегрируя:

$$\left\| \int_0^1 J(x^* + t(x_j - x^*)) dt \right\| \leq \|J^*\| + \frac{L}{2} \|x_j - x^*\| \leq \|J^*\| + \frac{L}{2} \delta_0.$$

Отсюда  $\|F(x_j)\| \leq (\|J^*\| + \frac{L}{2} \delta_0) \|x_j - x^*\|$ . По условию леммы  $\|s_j\| \leq M \|F(x_j)\|$ , что даёт (15). ■

*Замечание 2.9* (Локальная фаза и пребывание траектории в шаре). Лемма 2.8 требует  $x_j \in B(x^*, \delta_0)$  для всех  $j$  из рассматриваемого окна. Индуктивное обоснование пребывания траектории в шаре — стандартный шаг локальной теории квазиньютоновских методов (Dennis–Schnabel, [14, Th. 8.2.1]; ср. также [26, §6.4]): при достаточно близком старте  $x_0$  и достаточно малом  $\|E_0\|$  оценка теоремы 2.10 ниже гарантирует, что  $\{x_k\}$  не покидает  $B(x^*, \delta_0)$ . В настоящей работе анализ ограничен этой локальной фазой; для всего последующего анализа пребывание окна  $x_{k-p}, \dots, x_k \in B(x^*, \delta_0)$  принимается как стандартное допущение локального анализа.

**Теорема 2.10** (Bounded deterioration для мультисекущего Бройдена).

Пусть  $S_p \in \mathbb{R}^{n \times (p+1)}$  имеет полный столбцовый ранг,  $Y_p$  и  $G_p = S_p^\top S_p$  определены как в опр. 2.1, а  $B_{k+1}$  задано MS-обновлением (14). Пусть якобиан  $J(x)$  удовлетворяет условию Липшица (13) с константой  $L$  на открытой окрестности  $\mathcal{O} \subset \mathbb{R}^n$ , содержащей  $x^*$ , все точки  $x_j$  и отрезки  $\{x_j + ts_j : t \in [0, 1]\}$  для  $j = k-p, \dots, k$ . Обозначим  $J^* = J(x^*)$ ,  $E_k = B_k - J^*$ ,

$$\Pi_k = S_p G_p^{-1} S_p^\top \quad (\text{ортгональный проектор на } \text{col } S_p), \quad \Pi_k^\perp = I - \Pi_k.$$

Тогда:

(а) **Точное разложение.**

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k, \quad (16)$$

где

$$\Delta_k = \text{tr}(G_p^{-1} (Y_p - J^* S_p)^\top (Y_p - J^* S_p)). \quad (17)$$

(б) **Bounded deterioration.** Пусть, дополнительно, выполнены условия леммы 2.8 с константой  $C_s$  и  $B(x^*, \delta_0) \subset \mathcal{O}$ , так что  $\|s_j\| \leq C_s \|x_j - x^*\|$  для  $j = k-p, \dots, k$ . Обозначим

$$\rho_k := \max_{k-p \leq j \leq k} \|x_j - x^*\|, \quad \kappa_p := \kappa(S_p) = \frac{\sigma_{\max}(S_p)}{\sigma_{\min}(S_p)}. \quad (18)$$

Тогда

$$\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + C_{\text{PB}}^2 \rho_k^2, \quad C_{\text{PB}} := L(1 + C_s/2) \sqrt{p+1} \kappa_p. \quad (19)$$

*Замечание 2.11* (Расшифровка  $C_{\text{PB}}$ ). Структура константы  $C_{\text{PB}}$  прозрачна:  $L$  — константа Липшица якобиана;  $C_s$  — типичный размер шага относительно расстояния до корня (лемма 2.8);  $\sqrt{p+1}$  — цена расширения окна секущих;  $\kappa_p = \kappa(S_p)$  — обуслов-

ленность окна последних  $p + 1$  шагов как наблюдаемая характеристика траектории. Теоретическая оценка не накладывает априорных границ на  $\kappa_p$ ; формальный контроль обусловленности (через отбор шагов или регуляризацию окна, ср. [8]) выходит за рамки настоящего локального анализа, эмпирическая проверка ограниченности проведена в §2.3. В классической форме Бройдена ( $p = 0$ ,  $\Pi_k = s_k s_k^\top / \|s_k\|^2$ ,  $\kappa_0 = 1$ ) оценка переходит в стандартную bounded deterioration с  $C_{\text{Br}} = L(1 + C_s/2)$ , ср. [7, 14]. Константа  $M = \sup_j \|B_j^{-1}\|_2$  из леммы 2.8, входящая в  $C_s$ , конечна при  $\|E_j\|_2 < \sigma_{\min}(J^*)$  (неравенство Вейля для спектральной нормы); поскольку  $\|E_j\|_2 \leq \|E_j\|_F$ , в оценке теоремы 2.10 достаточно условия  $\|E_j\|_F < \sigma_{\min}(J^*)$ .

### Доказательство.

**Шаг 1: разложение  $E_{k+1}$ .** Подставим определение MS-обновления (14):

$$\begin{aligned} E_{k+1} &= B_k - J^* + (Y_p - B_k S_p) G_p^{-1} S_p^\top \\ &= E_k + [(Y_p - J^* S_p) - E_k S_p] G_p^{-1} S_p^\top \\ &= E_k (I - S_p G_p^{-1} S_p^\top) + (Y_p - J^* S_p) G_p^{-1} S_p^\top. \end{aligned} \quad (20)$$

То есть:

$$E_{k+1} = E_k \Pi_k^\perp + R_k, \quad R_k = (Y_p - J^* S_p) G_p^{-1} S_p^\top. \quad (21)$$

**Шаг 2: ортогональность строк.** Покажем, что  $\text{tr}((E_k \Pi_k^\perp)^\top R_k) = 0$ .

Для каждого  $i = 1, \dots, n$  рассмотрим  $i$ -ю строку каждого слагаемого, записанную как столбец транспонированной матрицы (через стандартный базисный вектор  $e^{(i)} \in \mathbb{R}^n$ ).

Строка  $i$  матрицы  $E_k \Pi_k^\perp$ :

$$(E_k \Pi_k^\perp)^\top e^{(i)} = \Pi_k^\perp E_k^\top e^{(i)} \in (\text{col } S_p)^\perp,$$

поскольку  $\text{im } \Pi_k^\perp = (\text{col } S_p)^\perp$ .

Строка  $i$  матрицы  $R_k$ :

$$R_k^\top e^{(i)} = S_p G_p^{-1} (Y_p - J^* S_p)^\top e^{(i)} \in \text{col } S_p,$$

поскольку вектор является линейной комбинацией столбцов  $S_p$ .

Скалярное произведение  $i$ -х строк:

$$\begin{aligned} &(\Pi_k^\perp E_k^\top e^{(i)})^\top (S_p G_p^{-1} (Y_p - J^* S_p)^\top e^{(i)}) \\ &= (E_k^\top e^{(i)})^\top \underbrace{\Pi_k^\perp S_p}_{=0} G_p^{-1} (Y_p - J^* S_p)^\top e^{(i)} = 0, \end{aligned}$$

где  $\Pi_k^\perp S_p = (I - S_p G_p^{-1} S_p^\top) S_p = S_p - S_p G_p^{-1} G_p = 0$ . Суммируя по  $i$ :

$$\text{tr}((E_k \Pi_k^\perp)^\top R_k) = \sum_{i=1}^n ((E_k \Pi_k^\perp)^\top e^{(i)})^\top (R_k^\top e^{(i)}) = 0. \quad (22)$$

**Шаг 3: теорема Пифагора.** Из (21) и (22):

$$\|E_{k+1}\|_F^2 = \|E_k \Pi_k^\perp\|_F^2 + \|R_k\|_F^2. \quad (23)$$

Аналогично, разложение  $E_k = E_k \Pi_k + E_k \Pi_k^\perp$  даёт ортогональные (по строкам) слагаемые, поскольку строка  $i$  матрицы  $E_k \Pi_k$  лежит в  $\text{col } S_p$ , а строка  $i$  матрицы  $E_k \Pi_k^\perp$  — в  $(\text{col } S_p)^\perp$ . Следовательно:

$$\|E_k\|_F^2 = \|E_k \Pi_k\|_F^2 + \|E_k \Pi_k^\perp\|_F^2. \quad (24)$$

Подставляя  $\|E_k \Pi_k^\perp\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2$  в (23):

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \|R_k\|_F^2. \quad (25)$$

**Шаг 4: вычисление  $\|R_k\|_F^2$ .** Обозначим  $A_k = Y_p - J^* S_p$ . Тогда  $R_k = A_k G_p^{-1} S_p^\top$  и:

$$\begin{aligned} \|R_k\|_F^2 &= \text{tr}(S_p G_p^{-1} A_k^\top A_k G_p^{-1} S_p^\top) \\ &= \text{tr}(G_p^{-1} S_p^\top S_p G_p^{-1} A_k^\top A_k) \quad (\text{цикличность следа}) \\ &= \text{tr}(G_p^{-1} G_p G_p^{-1} A_k^\top A_k) = \text{tr}(G_p^{-1} A_k^\top A_k). \end{aligned} \quad (26)$$

Это доказывает (16) с  $\Delta_k = \|R_k\|_F^2$ .

**Шаг 5: оценка  $\Delta_k$  сверху.** Матрицы  $G_p^{-1}$  и  $A_k^\top A_k$  положительно полуопределены. По неравенству  $\text{tr}(MN) \leq \lambda_{\max}(M) \text{tr}(N)$  для положительно полуопределённых  $M, N$  (см. [20, §8.3]):

$$\Delta_k = \text{tr}(G_p^{-1} A_k^\top A_k) \leq \lambda_{\max}(G_p^{-1}) \|A_k\|_F^2 = \frac{\|A_k\|_F^2}{\lambda_{\min}(G_p)} = \frac{\|A_k\|_F^2}{\sigma_{\min}^2(S_p)}. \quad (27)$$

Оценим  $\|A_k\|_F^2$ . Столбец матрицы  $A_k$ , отвечающий индексу  $j$ , равен  $a_j = y_j - J^* s_j$ . По теореме о среднем значении:

$$y_j - J^* s_j = \left( \int_0^1 [J(x_j + t s_j) - J^*] dt \right) s_j.$$

Поскольку  $x_j + t s_j \in \mathcal{O}$  для  $t \in [0, 1]$  и  $J^* = J(x^*)$ , по условию Липшица (13) и неравенству треугольника:

$$\|J(x_j + t s_j) - J^*\| \leq L \|x_j + t s_j - x^*\| \leq L (\|x_j - x^*\| + t \|s_j\|).$$

Интегрируя по  $t \in [0, 1]$ :

$$\left\| \int_0^1 [J(x_j + t s_j) - J^*] dt \right\| \leq L \|x_j - x^*\| + \frac{L}{2} \|s_j\|. \quad (28)$$

Следовательно:

$$\|a_j\| = \|y_j - J^* s_j\| \leq \left( L \|x_j - x^*\| + \frac{L}{2} \|s_j\| \right) \|s_j\|. \quad (29)$$

По лемме 2.8  $\|s_j\| \leq C_s \|x_j - x^*\|$  для всех  $j = k - p, \dots, k$ . Подставляя в (29):

$$\|a_j\|^2 \leq L^2 (1 + C_s/2)^2 \|x_j - x^*\|^2 \|s_j\|^2 \leq L^2 (1 + C_s/2)^2 \rho_k^2 \|s_j\|^2, \quad (30)$$

где  $\rho_k = \max_j \|x_j - x^*\|$  из (18). Суммируя по  $j$  и пользуясь  $\sum_j \|s_j\|^2 = \|S_p\|_F^2 \leq (p + 1) \sigma_{\max}^2(S_p)$ :

$$\|A_k\|_F^2 \leq L^2 (1 + C_s/2)^2 (p + 1) \sigma_{\max}^2(S_p) \rho_k^2. \quad (31)$$

Подставляя в (27), получаем

$$\Delta_k \leq \frac{\|A_k\|_F^2}{\sigma_{\min}^2(S_p)} \leq L^2 (1 + C_s/2)^2 (p + 1) \kappa_p^2 \rho_k^2 = C_{\text{PB}}^2 \rho_k^2. \quad (32)$$

Подстановка в (25) даёт (19). ■

**Следствие 2.12** (Подпространственная аппроксимация якобиана).

В условиях теоремы 2.10

$$\|E_{k+1} S_p\|_F \leq L (1 + C_s/2) \sqrt{p + 1} \sigma_{\max}(S_p) \rho_k. \quad (33)$$

В частности,  $B_{k+1}$  аппроксимирует  $J^*$  на всём подпространстве  $\text{col } S_p$  с точностью  $O(\rho_k)$ , зависящей лишь от локальной липшицевой константы и расстояния до корня (не от  $\|E_k\|_F$  на  $\text{col } S_p$ ).

**Доказательство.**

По (21)  $E_{k+1} = E_k \Pi_k^\perp + R_k$ . Поскольку  $\Pi_k^\perp S_p = 0$  (Шаг 2 доказательства теоремы 2.10)

и  $G_p^{-1}G_p = I$ ,

$$E_{k+1} S_p = E_k \Pi_k^\perp S_p + R_k S_p = 0 + (Y_p - J^* S_p) G_p^{-1} S_p^\top S_p = Y_p - J^* S_p.$$

Оценка (31) даёт (33). ■

*Замечание 2.13* (Сравнение с классическим Бroyденом). Для классического обновления Бroyдена первого типа ( $B_{k+1}^{\text{Br}} = B_k + (y_k - B_k s_k) s_k^\top / \|s_k\|^2$ , получается из (14) при  $p = 0$ ) известное разложение [14, Th. 8.2.2] имеет вид:

$$\|E_{k+1}^{\text{Br}}\|_F^2 = \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + \frac{\|y_k - J^* s_k\|^2}{\|s_k\|^2}. \quad (34)$$

MS-обновление с  $p \geq 1$  имеет три взаимосвязанных структурных преимущества над классическим Бroyденом:

(i) *Расширенный проектор ранга  $p+1$* . В (34) вычитается проекция ошибки на одномерное направление  $s_k$ , в (16) — на  $(p+1)$ -мерное подпространство  $\text{col } S_p$ . Поскольку  $\text{span}(s_k) \subset \text{col } S_p$ , имеем  $\Pi_k - s_k s_k^\top / \|s_k\|^2 \succeq 0$  и

$$\|E_k \Pi_k\|_F^2 \geq \frac{\|E_k s_k\|^2}{\|s_k\|^2}, \quad (35)$$

причём неравенство строгое всякий раз, когда  $E_k$  имеет нетривиальную проекцию на ортогональное дополнение  $\text{span}(s_k)$  внутри  $\text{col } S_p$ , т. е. на  $\text{col } S_p \cap \text{span}(s_k)^\perp$ .

(ii) *Удовлетворение  $p+1$  текущих условий*. По построению MS-обновления (14) имеет место  $B_{k+1} S_p = Y_p$ , то есть  $B_{k+1} s_j = y_j$  для всех  $j = k-p, \dots, k$ , тогда как классический Бroyден удовлетворяет лишь текущему равенству  $B_{k+1}^{\text{Br}} s_k = y_k$ . Для  $j < k$  ошибка якобиана у классического Бroyдена наследует прошлую невязку:  $E_{k+1}^{\text{Br}} s_j = E_k s_j + (y_k - B_k s_k) (s_k^\top s_j / \|s_k\|^2)$ , без какого-либо механизма её подавления.

(iii) *Подпространственная аппроксимация якобиана*. Прямое следствие (ii) — следствие 2.12: на всём  $(p+1)$ -мерном подпространстве  $\text{col } S_p$  ошибка  $E_{k+1}$  оценивается локальной липшицевой константой и расстоянием до корня. Аналогичный безусловный  $O(\rho_k)$ -контроль для классического Бroyдена существует только в одномерном направлении  $s_k$  ( $\|E_{k+1}^{\text{Br}} s_k\| = \|y_k - J^* s_k\| = O(\rho_k) \|s_k\|$ ); на  $\text{col } S_p \cap \text{span}(s_k)^\perp$  ошибка определяется глобальной историей.

## 2.2 Limited-memory: ранг-1 специализация и L-PB

**Мотивация.** Прямая реализация Алгоритма 1 хранит плотную матрицу  $B_k \in \mathbb{R}^{n \times n}$ , что требует  $O(n^2)$  памяти и  $O(n^3)$  операций на решение системы  $B_k d = -F(x_k)$  через



LU-факторизацию. При  $n = 10^4$  это  $\approx 8 \cdot 10^8$  чисел двойной точности ( $\approx 800$  МБ) и  $\approx 10^{12}$  flops на итерацию, что делает прямую форму неприменимой к крупномасштабным задачам.

**Ранг-1 специализация под индуктивным инвариантом.** В режиме `accumulate = true` Алгоритма 1 обновление (14) индуктивно сохраняет прошлые секущие: если  $B_k s_j = y_j$  для  $j = k-p, \dots, k-1$ , то в матрице  $Y_p - B_k S_p$  обнуляются столбцы со 2-го по  $(p+1)$ -й, и она факторизуется в  $(y_k - B_k s_k) e_1^\top$ . Подстановка в (14):

$$B_{k+1} = B_k + (y_k - B_k s_k) v_k^\top, \quad v_k := S_p G_p^{-1} e_1. \quad (36)$$

Свойства  $v_k$  — следствия определения:  $v_k^\top s_k = 1$  (из  $S_p^\top s_k = G_p e_1$ , откуда  $v_k^\top s_k = e_1^\top G_p^{-1} G_p e_1 = 1$ ) и  $v_k^\top s_j = 0$  для  $j < k$ . Это в точности *Projected Broyden* Гэя и Шнабеля [18] (Algorithm II); дальнейшая теория §2.1 применима к ранг-1 форме без изменений (она даёт ту же  $B_{k+1}$ , что и MS-форма). Limited-memory реализация ниже использует именно эту ранг-1 запись через формулу Шермана–Моррисона.

**Шерман–Моррисон-форма.** Из ранг-1 формы (36),  $B_{k+1} = B_k + u_k v_k^\top$  с  $u_k = y_k - B_k s_k$  и  $v_k^\top s_k = 1$ , формула Шермана–Моррисона [14, §3.4] даёт явное обновление обратной матрицы  $H_k := B_k^{-1}$ :

$$H_{k+1} = H_k + \frac{(s_k - H_k y_k) v_k^\top H_k}{v_k^\top H_k y_k}, \quad d_k = -H_k F(x_k). \quad (37)$$

Хранение  $H_k$  остаётся  $O(n^2)$ , но шаг  $d_k$  вычисляется как матрично-векторное произведение за  $O(n^2)$  flops вместо  $O(n^3)$ . Знаменатель  $v_k^\top H_k y_k$  в (37) равен  $1 + v_k^\top H_k u_k$  из общей формы Шермана–Моррисона — после подстановки  $u_k = y_k - B_k s_k$  и  $v_k^\top s_k = 1$ . Условие невырожденности  $\det B_{k+1} \neq 0$  эквивалентно  $v_k^\top H_k y_k \neq 0$ .

**Limited-memory L-PB.** Для  $n \gtrsim 10^4$  хранить плотную  $H_k$  невозможно даже в форме (37). По аналогии с limited-memory BFGS [25, 22] предлагается limited-memory вариант, в котором базовая матрица  $H_0 = I$  *никогда не формируется явно*. Вместо этого хранится скользящее окно последних  $m$  принятых троек  $\{(s_j, y_j, v_j)\}_{j=k-m+1}^k$ .

Применение  $H_k$  к произвольному вектору  $g$  реализуется прямым проходом по окну (Алгоритм 2). Здесь  $H_k$  обозначает L-PB-аппроксимацию, получаемую последовательной композицией обновлений (37) к  $H_{k-m} = I$  только по  $m$  корректировкам текущего окна. Эта аппроксимация совпадает с обратной плотной формой  $B_k^{-1}$  лишь до первого выталкивания пары из окна, т. е. при  $k \leq m$ ; при  $k > m$  матрицы расходятся

(утверждение 2.1 и замечание 2.15, эмпирически — §2.3):

$$H_k g = H_{k-m} g + \sum_{j=k-m+1}^k \frac{(s_j - H_{j-1} y_j) (v_j^\top H_{j-1} g)}{v_j^\top H_{j-1} y_j}, \quad H_{k-m} = I. \quad (38)$$

---

**Algorithm 2** Применение  $H_k g$  для L-PB (прямой проход по окну)

---

**Require:** окно  $\{(s_j, y_j, v_j)\}_{j=1}^m$ , входной вектор  $g$

**Ensure:**  $z = H_k g$

```

1:  $z \leftarrow g$  ▷  $H_0 = I$ 
2: for  $j = 1, 2, \dots, m$  do
3:    $w \leftarrow y_j$  ▷ вычислим  $H_j y_j$ 
4:   for  $i = 1, \dots, j - 1$  do
5:      $\beta_i \leftarrow (v_i^\top w) / \alpha_i$ 
6:      $w \leftarrow w + \xi_i \beta_i$ 
7:    $\alpha_j \leftarrow v_j^\top w$ 
8:    $\xi_j \leftarrow s_j - w$ 
9:    $\beta_j \leftarrow (v_j^\top z) / \alpha_j$ 
10:   $z \leftarrow z + \xi_j \beta_j$ 
11: return  $z$ 

```

---

Полный шаг L-PB выглядит так: на итерации  $k$  вычисляется  $d_k = -\text{APPLYH}(F(x_k); \text{window}_k)$ ; делается backtracking-Армихо или полный шаг  $x_{k+1} = x_k + d_k$ ; формируется текущая  $(s_k, y_k) = (x_{k+1} - x_k, F(x_{k+1}) - F(x_k))$ ; формирование  $S_p, G_p$  выполняется по правилам Алгоритма 1 (с  $p = \min(p_{\max}, k)$ ), после чего  $v_k := S_p G_p^{-1} e_1$  согласно (36); тройка  $(s_k, y_k, v_k)$  добавляется в очередь, а самая старая тройка выталкивается, если длина  $> m$ .

**Сложность L-PB.** Память: окно из  $m$  троек  $(s_j, y_j, v_j)$  занимает  $3nm$  чисел с плавающей точкой; во время одного обращения Алгоритма 2 дополнительно формируются  $m$  векторов  $\xi_j = s_j - H_{j-1} y_j$  ( $nm$  чисел) и  $m$  скаляров  $\alpha_j$ ; рабочие векторы  $z, w$  занимают  $2n$ . Эти вспомогательные величины пересчитываются при каждом обращении и не сохраняются между итерациями (см. замечание 2.14). Итоговая память

$$\mathcal{M}_{\text{L-PB}} = O(nm). \quad (39)$$

Время: тело внешнего цикла Алгоритма 2 выполняется  $m$  раз, внутреннего — до  $m - 1$  раз; стоимость одного обращения  $H_k g$  составляет  $O(nm^2)$  flops. На итерацию прихо-

дится 2 обращения (одно для  $d_k$ , одно для  $H_k y_k$  при расчёте знаменателя  $\alpha_k$ ), итого  $O(nm^2)$  flops/iter. При  $m \ll n$  это асимптотически дешевле, чем  $O(n^2)$  одного матрично-векторного произведения у плотной формы (37), и тем более чем  $O(n^3)$  LU-решения у прямой формы Алгоритма 1; память  $O(nm)$  против  $O(n^2)$  обратной матрицы (37) обеспечивает применимость метода к режиму  $n \gtrsim 10^4$ , в котором плотная форма исчерпывает доступную оперативную память (ср. §2.3).

*Замечание 2.14* (Полный пересчёт vs. кэширование). Величины  $\xi_j = s_j - H_{j-1} y_j$  и  $\alpha_j = v_j^\top H_{j-1} y_j$  из внутреннего цикла Алгоритма 2 зависят только от  $\{(s_i, y_i, v_i)\}_{i \leq j}$ , и потому могут показаться допускающими кэширование между итерациями. Однако при выталкивании самой старой пары из окна они становятся *несогласованными* с усечённой историей: произведение  $H_{i-1} y_i$  вычислялось относительно полного префикса  $0, \dots, i-1$ , не обрезанного. Поэтому на каждом обращении  $H_k g$  величины  $\xi_i, \alpha_i$  *пересчитываются заново* из текущего окна. То же требование удерживает и L-BFGS two-loop [26, §7.2], где коэффициенты  $\rho_i$  хранятся (это скаляры), но кэширование произведений  $H_{i-1} y_i$  исключено по той же причине.

**Утверждение 2.1** (Сохранение последних  $p_{\max} + 1$  секущих в L-PB).

*Пусть в Алгоритме 2 ёмкость окна  $m \geq p_{\max} + 1$ , и тройки  $(s_j, y_j, v_j)$  формируются по правилу  $v_j = S_p^{(j)} G_p^{(j)-1} e_1$  из ранг-1 специализации (36). Обозначим через  $B_k$  оператор, неявно задаваемый рекурсией (38): композицией  $m$  ранг-1 обновлений к  $B_{k-m} = I$ . Тогда для каждого  $k \geq 0$*

$$B_k s_j = y_j, \quad j \in \{\max(0, k - p_{\max} - 1), \dots, k - 1\}, \quad (40)$$

*то есть последние  $\min(p_{\max} + 1, k)$  секущих условий выдерживаются  $B_k$  точно. Как следствие, разложение  $E_k = B_k - J^*$  из теоремы 2.10 переносится на L-PB с тем же проектором  $\Pi_k = S_p^{(k)} G_p^{(k)-1} (S_p^{(k)})^\top$ , и оценка bounded deterioration (19) удерживается в той же структурной форме с константой  $C_{\text{PB}} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$ , где  $C_s$  через  $M = \sup_j \|B_j^{-1}\|$  берётся для L-PB-оператора и численно может отличаться от плотной формы.*

**Доказательство.**

Зафиксируем  $k \geq 1$  и раскрутим L-PB-рекурсию (38) как композицию ранг-1 шагов. Обозначим  $k_{\min} := \max(0, k - m)$  и введём промежуточные операторы  $\tilde{B}_l$ ,  $l = k_{\min}, \dots, k$ , заданные индуктивно:  $\tilde{B}_{k_{\min}} := I$ , и для каждого  $l > k_{\min}$

$$\tilde{B}_l := \tilde{B}_{l-1} + (y_{l-1} - \tilde{B}_{l-1} s_{l-1}) v_{l-1}^\top.$$

По определению рекурсии (38) итоговый L-PB-оператор есть  $B_k = \tilde{B}_k$  (с  $H_k = \tilde{B}_k^{-1}$

через Шермана–Моррисона).

Утверждение: для каждого  $l \in \{k_{\min}+1, \dots, k\}$  выполнено

$$\tilde{B}_l s_j = y_j, \quad j \in J_l := \{l-1-p_{\max}, \dots, l-1\} \cap [k_{\min}, l-1]. \quad (41)$$

При  $l = k$  это даёт формулировку утверждения:  $J_k = \{k-1-p_{\max}, \dots, k-1\} \cap [k_{\min}, k-1] = \{\max(k_{\min}, k-1-p_{\max}), \dots, k-1\}$ , что в режиме  $m \geq p_{\max} + 1$  совпадает с  $\{\max(0, k-1-p_{\max}), \dots, k-1\}$ .

Индукция по  $l$ . База ( $l = k_{\min} + 1$ ).  $\tilde{B}_l = I + (y_{k_{\min}} - s_{k_{\min}})v_{k_{\min}}^\top$ . Из  $v_{k_{\min}}^\top s_{k_{\min}} = 1$  имеем  $\tilde{B}_l s_{k_{\min}} = s_{k_{\min}} + (y_{k_{\min}} - s_{k_{\min}}) = y_{k_{\min}}$ ; других элементов в  $J_l = \{k_{\min}\}$  нет.

Шаг от  $l$  к  $l+1$ . Применим  $\tilde{B}_{l+1} = \tilde{B}_l + (y_l - \tilde{B}_l s_l)v_l^\top$  к  $s_j$  для  $j \in J_{l+1}$ .

(i)  $j = l$ .  $\tilde{B}_{l+1} s_l = \tilde{B}_l s_l + (y_l - \tilde{B}_l s_l)(v_l^\top s_l) = y_l$  по  $v_l^\top s_l = 1$  (следует из  $S_p^{(l),\top} v_l = e_1$ , см. (36)).

(ii)  $j \in J_{l+1} \setminus \{l\} = \{l-p_{\max}, \dots, l-1\} \cap [k_{\min}, l-1]$ . Вектор  $s_j$  входит в окно  $S_p^{(l)}$  алгоритма 1 как столбец с номером  $i = l-j+1 \in \{2, \dots, p_{\max}+1\}$ ; из  $S_p^{(l),\top} v_l = e_1$  получаем  $v_l^\top s_j = (e_1)_i = 0$ . Поэтому  $\tilde{B}_{l+1} s_j = \tilde{B}_l s_j$ . По индукционной гипотезе для  $\tilde{B}_l$  достаточно показать  $j \in J_l$ : при  $l \geq k_{\min} + 1$  и  $j \geq l-p_{\max}$  имеем  $j \geq l-p_{\max} = (l-1)-p_{\max} - (-1) \geq (l-1)-p_{\max}$  и  $j \leq l-1$ , т. е.  $j \in J_l$  (с учётом  $j \geq k_{\min}$ ). Применяя индукционную гипотезу,  $\tilde{B}_l s_j = y_j$ , откуда  $\tilde{B}_{l+1} s_j = y_j$ .

Условие  $m \geq p_{\max} + 1$  обеспечивает, что для каждого  $l$  окно  $S_p^{(l)}$ , участвующее в формуле  $v_l$ , целиком лежит в L-PB-окне  $\{s_{k_{\min}}, \dots, s_l\}$  (необходимо для существования  $v_l$  в хранимых данных). База индукции:  $k = 0$  даёт  $B_0 = I$ ,  $J_0 = \emptyset$ , утверждение вакуумно. ■

*Замечание 2.15* (L-PB не эквивалентен плотной форме при  $k > m$ ). Утверждение 2.1 гарантирует совпадение действий  $B_k^{\text{LPB}}$  и плотного  $B_k^{\text{dense}}$  из (14) только на  $\text{col } S_p^{(k)}$  — линейной оболочке последних  $p_{\max} + 1$  секущих. На ортогональном дополнении матрицы различаются: плотная форма накапливает ранг-1 поправки от всех  $k$  принятых обновлений, тогда как L-PB-рекурсия применяет лишь последние  $m$ , неявно полагая  $B_{k-m}^{\text{LPB}} = I$  (тогда как  $B_{k-m}^{\text{dense}} \neq I$ ). Поэтому полная эквивалентность имеет место лишь до первого выталкивания — при  $k \leq m$ . При  $k > m$  траектории L-PB и плотной формы расходятся ровно с итерации  $k = m + 1$  (см. §2.3); зазор растёт по мере накопления выталкиваемых пар и монотонно убывает по  $m$ .

При  $m < p_{\max} + 1$  требование  $v_k^\top s_j = 0$  для  $j \in S_p^{(k)}$  не поддержано данными окна:  $S_p^{(k)}$  ссылается на уже вытолкнутые  $s_j$ , и даже база утверждения 2.1 не выполняется. Эмпирически такая конфигурация приводит к резкому ухудшению (стагнации либо отсутствию сходимости, см. §2.3), поэтому в работе всегда полагается  $m \geq p_{\max} + 1$ .

*Замечание 2.16* (Связь с L-BFGS). Limited-memory BFGS [25, 22, 9] применим к мини-

мизации гладкой  $f$  при симметричном положительно определённом гессиане и использует two-loop рекурсию с  $4nm$  flops/iter. Соотношение L-BFGS  $\leftrightarrow$  dense BFGS известно: точной эквивалентности нет, ограничение глубины окна  $m$  задаёт retention последних  $m$  секущих пар, и приближение к плотной форме монотонно по  $m$  [26, §7.2]. Та же картина имеет место для L-PB  $\leftrightarrow$  плотный PB (замечание 2.15): при  $m \geq p_{\max} + 1$  оператор  $B_k^{\text{LPB}}$  воспроизводит последние  $\min(p_{\max} + 1, k)$  секущих условий плотной формы, но не весь оператор  $B_k^{\text{dense}}$ . Структурное отличие L-PB от L-BFGS: метод не требует ни симметрии, ни знакоопределённости и применим напрямую к  $F(x) = 0$  без сведения к merit-функции  $\psi(x) = \frac{1}{2}\|F(x)\|^2$  (последнее потребовало бы дополнительных якобиан-векторных произведений  $\nabla\psi = J^\top F$ ). Цена несимметрии —  $O(nm^2)$  flops/iter у L-PB против  $O(nm)$  у L-BFGS: векторы  $\xi_j = s_j - H_{j-1}y_j$  зависят от всей предшествующей истории через  $H_{j-1}$  и не допускают кэширования между итерациями (замечание 2.14), тогда как в L-BFGS аналогичный объект  $\rho_i = 1/(y_i^\top s_i)$  — скаляр и хранится.

*Замечание 2.17* (Связь с limited-memory “good Broyden”). Limited-memory вариант классического Бройдена [9], обозначаемый далее L-Broyden, хранит окно  $\{(s_j, y_j)\}_{j=k-m+1}^k$  и рекурсивно применяет (37) с  $v_k = s_k$ . От L-PB он отличается выбором направления обновления: при  $v_k = s_k$  прошлые секущие условия  $B_{k+1}s_j = y_j$ ,  $j < k$ , в общем случае не удерживаются даже внутри окна (Утверждение 1.1). L-PB заменяет  $s_k$  на спроецированный вектор  $v_k = S_p G_p^{-1} e_1 \in \text{col}(S_p) \setminus \{s_k\}^\perp$ , что эквивалентно сохранению  $p + 1$  секущих условий на текущем окне (§2.2). Это — центральное теоретическое отличие семейства L-PB от L-Broyden и основание для применимости теоремы 2.10 с расширенным проектором.

*Замечание 2.18* (Связь с Burdakov–Kamandi 2018). Burdakov и Kamandi [8] построили globalized multi-secant метод для  $F(x) = 0$  с плотным  $O(n^2)$ -хранением матрицы  $B_k$  и nonmonotone line search Ли–Фукушимы; виртуальная матрица  $A_{k+1}$ , точно интерполирующая  $\Delta F$  на окне, используется как технический объект в доказательстве bounded deterioration через декомпозицию  $\|B_{k+1} - J^*\| \leq \|B_{k+1} - A_{k+1}\| + \|A_{k+1} - J^*\|$ . В настоящей работе  $A_{k+1}$  концептуально совпадает с плотным мультисекущим обновлением (14) (для которого теорема 2.10 даёт прямую оценку без декомпозиции), а limited-memory  $B_k$  из L-PB — с ранг-1 специализацией (36) того же объекта. Перенос аргумента globalization [8] на L-PB (с необходимостью отслеживать выталкивание окна) и численное сравнение с их семейством — естественные направления развития, обсуждаемые в Заключение.

*Замечание 2.19* (Связь с Anderson( $m, \beta$ )). Anderson( $m, \beta$ ) [1, 35, 34] — alternative limited-memory метод без явной модели якобиана; окно  $\{x_j, F(x_j)\}$  используется для построения мульти-секущей подгонки, но объект  $\|(B_k - J(x_k))d_k\|$ , контролируемый Следствием 2.12 для L-PB, в Anderson формально не определён. Из эквивалентности (12) [35,

16] Anderson типа I при  $B_0 = I$ ,  $\beta = 1$  соответствует L-PB в режиме *пересборки* (`accumulate = false`), тогда как L-PB по умолчанию работает в режиме *накопления* от текущего  $B_k$  — это структурно иной режим управления историей (§1.5, гл. 1).

*Замечание 2.20* (Связь с Schubert). Sparse-Broyden Шуберта [32] — limited-memory rank-1 вариант для  $F(x) = 0$  с разрежённым якобианом известной структуры: на каждом шаге обновляется лишь подмножество элементов  $B_k$  в рамках заданного шаблона. Инвариант L-PB (сохранение  $p + 1$  текущих условий) и инвариант Schubert (сохранение шаблона sparsity) ортогональны: L-PB не использует структуру задачи, а Schubert не использует историю шагов. Их комбинация — sparse limited-memory с сохранением прошлых текущих — в настоящей работе не рассматривается.

## 2.3 Численные эксперименты

В этом разделе представлены численные эксперименты по двум направлениям: (I) сравнение скорости сходимости мультисекундного обновления с разными  $p_{\max}$  и классического Бройдена ( $p_{\max} = 0$ ) на стандартной тестовой задаче (Рис. 1); (II) применимость limited-memory варианта Алгоритма 2 из §2.2 в режиме  $n \gtrsim 10^4$ , где плотная форма исчерпывает память, и эмпирическая оценка деградации L-PB по  $m$  относительно плотной формы (Рис. 2). Во всех экспериментах настоящего параграфа реализуется ранг-1 запись обновления (36), эквивалентная плотному MS-обновлению Алгоритма 1 в режиме `accumulate = true`.

**Тестовая задача и схема стартов.** В качестве нелинейной модели используется задача Discrete BVP (MGH #28) из стандартного набора Море–Гэрбоу–Хиллстрёма [24] — конечно-разностная дискретизация краевой задачи  $-u'' + (u+t+1)^3/2 = 0$ ,  $u(0) = u(1) = 0$  с шагом  $h = 1/(n+1)$  на сетке  $t_i = ih$ ,  $i = 1, \dots, n$ . Размер  $n = 100$ . Якобиан  $J(x_k)$  при необходимости считается аналитически. Дефолтный старт по [24]  $x_0^{\text{def}} \in \mathbb{R}^n$  задан покомпонентно  $(x_0^{\text{def}})_i = 0,1 t_i(t_i - 1)$ . Для оценки устойчивости поведения к выбору  $x_0$  используется ансамбль из 20 случайных возмущений

$$x_0^{(i)} = x_0^{\text{def}} + 0,05 u_i, \quad u_i = \tilde{u}_i / \|\tilde{u}_i\|, \quad \tilde{u}_i \sim \mathcal{N}(0, I_n),$$

с фиксированным seed. На всех графиках с трекингом по итерациям изображена медиана по 20 стартам, затенённая полоса — интерквартильный интервал; хвост обрезается на первой итерации, на которой более половины стартов уже завершились (то же правило применяется к Рис. 2).

(I) **Trade-off по  $p_{\max}$ .** Рис. 1 показывает поведение метода при  $p_{\max} \in \{0, 1, 2, 5, 10\}$  (критерий останова  $\|F\|_2 \leq 10^{-10}$ ,  $\text{maxit} = 600$ , шаг принимается полным:  $x_{k+1} = x_k - B_k^{-1}F(x_k)$ , без backtracking-Армихо — задача исследует ровно локальный режим теоремы 2.10); обе оси — в относительных единицах: левая панель — ошибка якобиана  $\|B_k - J(x_k)\|_F / \|J(x_k)\|_F$ , правая — относительная невязка  $\|F(x_k)\|_2 / \|F(x_0)\|_2$ .

Левая панель (а) — эмпирический контроль ошибки аппроксимации якобиана  $\|B_k - J(x_k)\|_F$  вдоль траектории; теорема 2.10 гарантирует ограниченность  $\|E_k\|_F = \|B_k - J^*\|_F$  из (19), и по неравенству треугольника  $\|B_k - J(x_k)\|_F \leq \|E_k\|_F + L \|x_k - x^*\| \sqrt{n}$  ограниченность переносится на отображаемую величину в окрестности  $x^*$ . Для всех  $p_{\max}$  относительная ошибка аппроксимации якобиана остаётся ограниченной вдоль траектории. Классический Бroyден ( $p_{\max} = 0$ ) выходит на ненулевой уровень относительной ошибки  $\sim 0,3$  и не достигает сходимости (см. ниже); расширение окна сдвигает этот уровень ниже, причём прирост насыщается с ростом  $p_{\max}$ .

Правая панель (б) — реальная скорость метода по невязке. Здесь видна *качественная разница* между классическим Бroyденом и расширенным обновлением: классический Бroyден за отведённый бюджет не достигает порога  $\|F\|_2 \leq 10^{-10}$  ни на одном из 20 стартов (невязка медленно дрейфует вблизи уровня  $10^{-3}$ – $10^{-1}$  и в ряде стартов численно срывается до останова по NaN). Ограниченность  $\|E_k\|_F$  по теореме 2.10, формально гарантируя локальную теорию, эмпирически не транслируется в сходимость по  $F$  на этой задаче. Уже при  $p_{\max} = 1$  метод устойчиво сходится на всех 20 стартах; дальнейшее увеличение  $p_{\max}$  ускоряет сходимость с насыщением к  $p_{\max} \sim 5$ . Картина согласуется со структурой константы из замечания 2.11: расширенный проектор сильнее *вычитает* ошибку, но при росте  $p$  множитель  $\sqrt{p+1} \kappa_p$  в  $C_{\text{РВ}}$  растёт, и выигрыш от расширения окна выходит на насыщение.

(II) **Применимость L-РВ в высокой размерности.** Для оценки качества limited-memory аппроксимации относительно плотной формы проведено сравнение на задаче Broyden Banded (MGN #31, [24]) при  $n \in \{10^4, 10^5\}$  для случайных стартов  $x_0 = -0,1 \cdot \mathbf{1} + 0,05 u_i$  с единичными  $u_i \in \mathbb{R}^n$  (фиксированный seed). При  $n = 10^4$  плотный Projected Broyden-SM ( $p \leq 5$ ) выступает baseline'ом ( $n^2 = 10^8$  чисел с плавающей точкой  $\approx 800$  МБ оперативной памяти, 6 стартов); при  $n = 10^5$  плотная форма принципиально неприменима ( $n^2 = 10^{10}$  чисел с плавающей точкой  $\approx 80$  ГБ). L-РВ запускается с  $m \in \{3, 5, 10, 20\}$  ( $n = 10^4$ , 16 стартов; случай  $m = 3 < p_{\max} + 1 = 6$  намеренно нарушает условие совпадения действия L-РВ и плотной формы из утверждения 2.1 и демонстрирует прогнозируемое замедление) и  $m \in \{10, 20\}$  ( $n = 10^5$ , 8 стартов). Все методы — с backtracking-Армихо в эффективной форме  $\psi(x + \alpha d) \leq (1 - 2c_1\alpha)\psi(x)$ ,  $\psi = \frac{1}{2} \|F\|_2^2$ ,  $c_1 = 10^{-4}$  (эквивалентна классическому Армихо при  $d = -J^{-1}F$  и асимптотически




Рисунок 1 — Discrete BVP,  $n = 100$ ,  $B_0 = I$ ,  $\|F\|_2 \leq 10^{-10}$ ,  $\text{maxit} = 600$ , 20 случайных стартов; медиана  $\pm$  IQR. Пунктирная линия на панели (б) — перевод абсолютного критерия  $10^{-10}$  в относительную шкалу через медиану  $\|F(x_0)\|_2$ . (а) относительная ошибка якобиана  $\|B_k - J(x_k)\|_F / \|J(x_k)\|_F$  для всех  $p_{\max}$  остаётся ограниченной — косвенная иллюстрация ограниченности  $\|E_k\|_F = \|B_k - J^*\|_F$  из теоремы 2.10 ((19); величины связаны через  $\|B_k - J(x_k)\|_F \leq \|E_k\|_F + L \|x_k - x^*\| \sqrt{n}$ ). (б) относительная невязка  $\|F(x_k)\|_2 / \|F(x_0)\|_2$ : классический Бройден ( $p_{\max} = 0$ ) за отведённый бюджет не достигает  $\text{tol}$  ни на одном из 20 стартов, тогда как РВ при  $p_{\max} \geq 1$  устойчиво сходится на всех 20 стартах; рост  $p_{\max}$  до 5 дополнительно ускоряет сходимость. Расширение окна не только усиливает проектор  $\Pi_k$  в разложении теоремы 2.10, но и переводит метод из режима «ошибка ограничена, сходимости нет» в режим сверхлинейной сходимости.

приближается к ней при  $B_k \rightarrow J^*$ ); дополнительно используется техническая защита от первого слишком длинного шага  $\|d_k\| \leq 50 \max(\|x_k\|, 1)$  ( $x_0$ -зависимая нормировка), не активная в асимптотическом режиме. Критерий  $\|F\|_2 \leq 10^{-10}$ .

При  $n = 10^4$  плотный Projected Broyden-SM сходится за медианных 47 итераций; L-PB при  $m = 20$  — за 75, при  $m = 10$  — за 81 (все 16 стартов сошлись). Деградация по  $m$  согласуется с замечанием 2.15: L-PB и плотная форма не эквивалентны при  $k > m$ , поскольку рекурсия (38) неявно полагает  $B_{k-m}^{\text{LPB}} = I$ , тогда как  $B_{k-m}^{\text{dense}}$  накопил историю обновлений (это типовая ситуация limited-memory методов, ср. L-BFGS 2.16). Утверждение 2.1 гарантирует совпадение лишь действия на  $\text{col } S_p^{(k)}$  — последние  $p_{\max} + 1$  текущих условий — что и обеспечивает сходимость L-PB при  $m \geq p_{\max} + 1$ . При недостаточной ёмкости окна ( $m \in \{3, 5\} < p_{\max} + 1 = 6$ ) проявляется прогнозируемая деградация: L-PB с  $m = 5$  срывается чаще всего (сходимость лишь у 6/16 стартов, остальные останавливаются на уровне  $\|F\| \in [10^{-10}, 10^{-8}]$ ), тогда как  $m = 3$  сходится у 14/16 стартов за медианных 139 итераций. Парадоксальный порядок объясняется так: формула  $v_k = S_p^{(k)} G_p^{-1} e_1$  строится из всего доступного буфера  $S_p^{(k)}$  длины  $\min(p_{\max} + 1, m + 1)$  (текущая текущая плюс все хранящиеся), а после применения обновления и тримминга самая старая пара выпадает; согласованность  $v_k$  с оставшейся памятью теряется при  $m < p_{\max} + 1$ . При  $m = 5$  окно  $S_p^{(k)}$  содержит 6 текущих (все доступные «слоты»), и каждый шаг ровно






Рисунок 2 — Broyden Banded,  $\|F\|_2 \leq 10^{-10}$ , `maxit` = 300, backtracking-Армихо ( $c_1 = 10^{-4}$ ,  $\psi$ -форма). Медианная траектория  $\|F(x_k)\|_2 + \text{IQR}$  по случайным стартам  $x_0 = -0,1 \cdot \mathbf{1} + 0,05 u_i$ . Слева —  $n = 10^4$ , 16 стартов; L-PB при  $m \in \{3, 5, 10, 20\}$  и плотный Projected Broyden-SM ( $p \leq 5$ , чёрный пунктир, 6 стартов) — baseline.  $m \in \{3, 5\} < p_{\max} + 1 = 6$  нарушают условие утверждения 2.1 и демонстрируют прогнозируемую деградацию (особенно  $m = 5$ , см. текст). Справа —  $n = 10^5$ , 8 стартов; плотная форма требует  $\approx 80$  ГБ оперативной памяти и неприменима.

одна попадает в рассогласование, что систематически накапливается. При  $m = 3$  окно короче (4 секущих), эффективное  $p_{\text{eff}} = 3$  при  $p_{\max} = 5$ , и обновление действует как L-PB с меньшим  $p$ : качество аппроксимации ниже, но структура согласована. При  $n = 10^5$  L-PB устойчиво сходится при  $m \in \{10, 20\}$  за медианных 93 ( $m = 10$ ) и 83 ( $m = 20$ ) итераций; число итераций до сходимости *не растёт* с  $n$  (увеличение лишь на 10–15% при переходе  $n = 10^4 \rightarrow 10^5$ ), что демонстрирует применимость метода в режиме, где плотная форма исчерпывает память ( $\approx 80$  ГБ при  $n = 10^5$ ).

**Резюме.** В главе введён мультисекущий Бройден — ранг- $(p+1)$  обновление, для которого теорема 2.10 даёт точное разложение Фробениус-нормы ошибки  $\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$  и явную геометрическую константу  $C_{\text{PB}}$ , а следствие 2.12 — безусловный  $O(\rho_k)$ -контроль ошибки на всём подпространстве  $\text{col } S_p$ . В режиме `accumulate` = true обновление специализируется к ранг-1 форме (36), что через Шермана–Моррисона (37) ведёт к limited-memory варианту L-PB с памятью и временем  $O(nm)$  и  $O(nm^2)$  соответственно. Численные эксперименты иллюстрируют структурное преимущество расширенного обновления: рост  $p_{\max}$  переводит метод из режима « $\|E_k\|_F$  ограничена, по  $F$  сходимости нет» (классический Бройден) в режим сверхлинейной сходимости (Рис. 1). Limited-memory вариант L-PB при  $m \geq p_{\max} + 1$  сохраняет последние  $p_{\max} + 1$  секущих плотной формы (утверждение 2.1) при умеренной деградации по  $m$ ; число итераций до сходимости не растёт с  $n$  вплоть до  $n = 10^5$ , где плотная форма уже неприменима по памяти (Рис. 2).

## Глава 3

# Симметричные квазиньютоновские обновления с контролем текущих условий

### 3.1 Мотивация

В предыдущих разделах мультисекунций Бройден решил задачу сохранения текущих условий для общих систем  $F(x) = 0$ , однако матрица  $B_k$  при этом несимметрична. Для задач безусловной оптимизации, где  $F = \nabla f$  и  $J^* = \nabla^2 f(x^*)$  симметричен, естественно требовать  $B_k = B_k^\top$ .

Классические симметричные квазиньютоновские обновления — SR1 (*symmetric rank-one*, Дэвидон [11]) и PSB (*Powell symmetric Broyden*, Пауэлл [29]) — удовлетворяют текущему текущему условию  $B_{k+1}s_k = y_k$ , но не контролируют невязку прошлых текущих  $R_{\text{past}} = B_k S_{\text{past}} - Y_{\text{past}}$ . Классический результат Шнабеля [31] показывает, что одновременное точное выполнение всех текущих и симметрии в общем случае невозможно; ниже воспроизведена компактная формулировка этой леммы в форме, удобной для дальнейшего анализа.

**Лемма 3.1** (Шнабель [31]; необходимое условие совместности симметрии и одновременного сохранения всех текущих).

Пусть  $B_k \in \mathbb{R}^{n \times n}$  удовлетворяет всем прошлым текущим условиям  $B_k s_j = y_j$  ( $j = 0, \dots, k-1$ ), и пусть симметричное обновление  $B_{k+1} = B_k + \Delta B$ ,  $\Delta B = \Delta B^\top$ , сохраняет все текущие до  $k$ -й включительно:

$$B_{k+1}s_j = y_j \quad (j = 0, \dots, k-1), \quad B_{k+1}s_k = y_k.$$

В терминах поправки  $\Delta B$  это означает

$$\Delta B s_j = 0 \quad (j = 0, \dots, k-1), \quad \Delta B s_k = r_k, \quad r_k := y_k - B_k s_k.$$

Тогда остаток  $r_k$  обязан быть ортогонален всем прошлым шагам:

$$s_j^\top r_k = 0 \quad \forall j < k. \quad (42)$$

### Доказательство.

Для произвольного  $j < k$ :

$$s_j^\top r_k \stackrel{(1)}{=} s_j^\top (\Delta B s_k) \stackrel{(2)}{=} s_j^\top \Delta B^\top s_k \stackrel{(3)}{=} (\Delta B s_j)^\top s_k \stackrel{(4)}{=} 0, \quad (43)$$

где (1) — текущее секущее условие  $\Delta B s_k = r_k$ ; (2) — симметрия  $\Delta B = \Delta B^\top$ ; (3) — тождество  $u^\top A^\top v = (Au)^\top v$ ; (4) — сохранение  $j$ -й прошлой секущей  $\Delta B s_j = 0$ . ■

*Замечание 3.2* (Когда условие (42) выполнено). Пусть  $F = \nabla f$ ,  $f \in C^2$ . По интегральной форме теоремы о среднем для градиента

$$y_j = \nabla f(x_j + s_j) - \nabla f(x_j) = \bar{H}_j s_j, \quad \bar{H}_j := \int_0^1 \nabla^2 f(x_j + t s_j) dt,$$

где  $\bar{H}_j$  — средний гессиан вдоль  $j$ -го шага (симметричен). Если  $B_k$  симметричен и удерживает прошлые секущие  $B_k s_j = y_j$ , то  $s_j^\top B_k = (B_k s_j)^\top = (\bar{H}_j s_j)^\top = s_j^\top \bar{H}_j$ , и левая часть (42) принимает вид

$$s_j^\top r_k = s_j^\top y_k - s_j^\top B_k s_k = s_j^\top \bar{H}_k s_k - s_j^\top \bar{H}_j s_k = s_j^\top (\bar{H}_k - \bar{H}_j) s_k. \quad (44)$$

*Случай квадратичной  $f$ .* Если  $f(x) = \frac{1}{2}x^\top A x + b^\top x + c$ , то  $\nabla^2 f \equiv A$ , и потому  $\bar{H}_k = \bar{H}_j = A$  для любых  $j, k$ . Правая часть (44) обращается в нуль тождественно, условие (42) выполнено автоматически — симметричное обновление, одновременно удерживающее все секущие, существует.

*Случай неквадратичной  $f$ .* Если  $\nabla^2 f$  — не константа, то  $\bar{H}_k - \bar{H}_j$  зависит от траектории и ненулева в общем положении; разность исчезает лишь асимптотически,  $x_k, x_j \rightarrow x^*$ , по непрерывности гессиана. Поэтому в произвольной конечной окрестности условие (42) не выполнено — симметричного обновления, точно удерживающего все секущие, в общем случае не существует. Это и есть та жёсткость, которую в §3.2 снимает SS-конструкция: вместо точного удержания прошлых секущих минимизируется их остаток в ортогональном к  $s_k$  дополнении.

### 3.2 Конструкция и алгоритм SS- $\mathcal{U}$

**Определение 3.3** (Секантно-стабилизированное обновление).

Пусть  $\mathcal{U}$  — базовое симметричное квазиньютоновское обновление, удовлетворяющее текущему секущему условию  $\mathcal{U}(B_k, s_k, y_k) s_k = y_k$ ,  $B'_k := \mathcal{U}(B_k, s_k, y_k)$ ,  $R'_k := B'_k S_p - Y_p$ . Секантно-стабилизированное расширение SS- $\mathcal{U}$  задаётся ранг-1 коррекцией

$$B_{k+1} = B'_k + \sigma_k^* u_k^* u_k^{*\top}, \quad u_k^* \perp s_k, \quad \|u_k^*\| = 1, \quad (45)$$

направленной на минимизацию остатка прошлых секущих в  $s_k^\perp$ ,

$$(\sigma_k^*, u_k^*) \in \arg \min \{ \|R'_k + \sigma u u^\top S_p\|_F^2 : \|u\| = 1, u \perp s_k, \sigma \in \mathbb{R} \}. \quad (46)$$

Точная задача (46) не имеет замкнутой формы (Лемма 3.4, п. 2); в Алгоритме 3 применяется гибридная стратегия. Сначала  $u_k^*$  — ведущий по  $|\lambda|$  собственный вектор симметричной матрицы  $P_k M'_k P_k$  на  $s_k^\perp$ , где  $P_k = I - \hat{s}_k \hat{s}_k^\top$ ,  $M'_k := \frac{1}{2}(R'_k S_p^\top + S_p R'_k)$ ; выбор  $u_k^*$  отвечает упрощённой задаче после замены знаменателя  $\|S_p^\top u\|^2$  на  $\|u\|^2 = 1$  в (48) (Лемма 3.4, п. 3). Затем при зафиксированном  $u = u_k^*$  коэффициент  $\sigma_k^*$  берётся *точным* условным оптимумом функционала (46):

$$\sigma_k^* = -\frac{u_k^{*\top} R'_k S_p^\top u_k^*}{\|S_p^\top u_k^*\|^2}. \quad (47)$$

В результате пара  $(u_k^*, \sigma_k^*)$  — точный условный минимум по  $\sigma$  при приближённо найденном направлении  $u_k^*$ ; устойчивость знаменателя обеспечивается safeguard (A3) Леммы 3.12.

**Лемма 3.4** (Условный оптимум  $\sigma$  и характеристикация  $u_k^*$  в Алгоритме 3).

Пусть  $R'_k = B'_k S_p - Y_p$ ,  $M'_k = \frac{1}{2}(R'_k S_p^\top + S_p R'_k)$ ,  $S_p$  — полного столбцового ранга,  $\Phi(\sigma, u) := \|R'_k + \sigma u u^\top S_p\|_F^2$ . Тогда:

1. для каждого  $u \in s_k^\perp$  с  $\|u\| = 1$  и  $\|S_p^\top u\| \neq 0$  условный оптимум  $\sigma$  при фиксированном  $u$  равен  $\sigma_k^*(u) = -(u^\top M'_k u) / \|S_p^\top u\|^2$ , и подстановка даёт

$$\min_{\sigma} \Phi(\sigma, u) = \|R'_k\|_F^2 - \frac{(u^\top M'_k u)^2}{\|S_p^\top u\|^2}; \quad (48)$$

2. точная минимизация (48) по  $u \in s_k^\perp \cap S^{n-1}$  приводит к нелинейной задаче на собственные значения с зависимостью от собственного вектора (NEPv [27])

$$P_k (M'_k - \lambda(u) S_p S_p^\top) u = \frac{1}{2} (u^\top M'_k u) u, \quad \lambda(u) := \frac{u^\top M'_k u}{2 \|S_p^\top u\|^2},$$

которая, в отличие от стандартной обобщённой задачи на собственные значения, не допускает замкнутого решения (множители  $\lambda(u)$  и  $\frac{1}{2}u^\top M'_k u$  зависят от  $u$ );

3. замена  $\|S_p^\top u\|^2 \rightarrow \|u\|^2 = 1$  в знаменателе (48) сводит задачу к максимизации  $(u^\top M'_k u)^2$  на  $s_k^\perp \cap S^{n-1}$ , у которой ведущий по  $|\lambda|$  собственный вектор  $P_k M'_k P_k$  на  $s_k^\perp$  реализует точный максимум  $\lambda_*^2$  (тождество Куранта–Фишера для  $P_k M'_k P_k$ ). В Алгоритме 3 в качестве  $u_k^*$  берётся именно этот собственный вектор; соответствующее  $\sigma_k^* := \sigma_k^*(u_k^*)$  задано формулой (47) из п. 1.

## Доказательство.

**П. 1.** Раскрытие  $\|R'_k + \sigma u u^\top S_p\|_F^2$  через  $\|A + B\|_F^2 = \|A\|_F^2 + 2 \operatorname{tr}(A^\top B) + \|B\|_F^2$  даёт

$$\Phi(\sigma, u) = \|R'_k\|_F^2 + 2\sigma (u^\top M'_k u) + \sigma^2 \|S_p^\top u\|^2, \quad (49)$$

где использованы  $\operatorname{tr}(R'_k u u^\top S_p) = u^\top S_p R'_k u = u^\top M'_k u$  (полусумма скаляров  $u^\top R'_k S_p^\top u = u^\top S_p R'_k u$ ) и  $\|u u^\top S_p\|_F^2 = \|u\|^2 \|S_p^\top u\|^2 = \|S_p^\top u\|^2$  при  $\|u\| = 1$ . Стационарность по  $\sigma$ :  $\partial_\sigma \Phi = 0$  даёт  $\sigma_k^*(u)$ ; подстановка в (49) — (48).

**П. 2.** Обозначим  $\rho(u) := (u^\top M'_k u)^2 / \|S_p^\top u\|^2$ ,  $f := u^\top M'_k u$ ,  $g := \|S_p^\top u\|^2$ . Случай  $f = 0$  соответствует глобальному минимуму  $\rho(u) = 0$  и достигается на любом  $u \perp s_k$  с  $u^\top M'_k u = 0$ ; ниже рассматриваем нетривиальный случай  $f \neq 0$ .

По правилу множителей Лагранжа стационарность  $\rho$  на  $\|u\| = 1, u \perp s_k$  эквивалентна  $\nabla \rho = 2\alpha u + \beta s_k$  для некоторых  $\alpha, \beta \in \mathbb{R}$ . Скалярно умножая на  $u$  (с использованием  $u \perp s_k, \|u\| = 1$ ):  $u^\top \nabla \rho = 2\alpha$ . Прямой расчёт  $\nabla \rho = (4f/g) M'_k u - (2f^2/g^2) S_p S_p^\top u$  даёт  $u^\top \nabla \rho = 4f^2/g - 2f^2/g = 2f^2/g = 2\rho(u)$ , откуда  $\alpha = \rho(u) = f^2/g > 0$  при  $f \neq 0$ . Подстановка  $\alpha = \rho(u)$  в  $\nabla \rho - 2\alpha u - \beta s_k = 0$  и проектирование на  $s_k^\perp$  ( $P_k u = u$ ) дают

$$P_k [(4f/g) M'_k - (2f^2/g^2) S_p S_p^\top] u = (2f^2/g) u.$$

Деление на  $4f/g$  и подстановка  $\lambda = f/(2g)$ :  $P_k (M'_k - \lambda S_p S_p^\top) u = (f/2) u$ . Поскольку  $\lambda$  и  $f/2$  зависят от  $u$ , эта задача не является обобщённой задачей на собственные значения.

**П. 3.** Подстановка  $\|S_p^\top u\|^2 \equiv 1$  в (48) сводит её к  $\|R'_k\|_F^2 - (u^\top M'_k u)^2$ , и задача превращается в максимизацию  $h(u) := (u^\top M'_k u)^2$  на  $\{u \in \mathbb{R}^n : \|u\| = 1, u \perp s_k\}$ . Поскольку  $P_k u = u$  на  $s_k^\perp$ , имеем  $u^\top M'_k u = u^\top P_k M'_k P_k u =: u^\top A_k u$ , где  $A_k := P_k M'_k P_k$  симметрична. Стационарность  $h$  под ограничениями  $\|u\| = 1, u \perp s_k$  по правилу множителей Лагранжа эквивалентна  $\nabla h = 2\lambda u + \mu s_k$  с  $\nabla h = 4(u^\top A_k u) A_k u$ ; проектируя на  $s_k^\perp$  ( $P_k$ , причём  $P_k A_k u = A_k u$ ):  $4(u^\top A_k u) A_k u = 2\lambda u$ , т. е.  $A_k u = \mu_* u$  с  $\mu_* = \lambda/(2u^\top A_k u)$ . Таким образом, стационарные точки совпадают с собственными векторами  $A_k$  на  $s_k^\perp$  (стандартный факт о экстремумах квадратичной формы на сфере; ср. Голуб–ван Лоан [20, §8.1]). В каждом

стационарном векторе  $u$  имеем  $u^\top A_k u = \mu_*$ , поэтому  $h(u) = \mu_*^2$ ; максимум достигается ведущим по  $|\mu_*|$  собственным вектором, давая  $h_{\max} = \lambda_*^2 := \max_{i: v_i \perp s_k} \mu_i^2$ .  $\blacksquare$

*Замечание 3.5* (Качество упрощения при условии safeguard). Точное решение (46) (Лемма 3.4, п. 2) и используемое в Алгоритме 3 упрощение (п. 3) отличаются заменой  $\|S_p^\top u\|^2$  на  $\|u\|^2 = 1$  в знаменателе условного оптимума по  $\sigma$ . При safeguard (A3) Леммы 3.12 ( $\|S_p^\top u\|^2 \geq \varepsilon_S$ ) знаменатель условного оптимума ограничен снизу, и оценка bounded deterioration (Лемма 3.12) корректно опирается на точное  $\sigma_k^*$  из (47) независимо от того, является ли выбранный  $u_k^*$  точным максимизатором  $\rho(u)$  или ведущим собственным вектором  $P_k M'_k P_k$ .

**Базовые обновления  $\mathcal{U}$ .** Алгоритм SS- $\mathcal{U}$ , приведённый ниже, не зависит от выбора  $\mathcal{U}$ , кроме явного вычисления  $B'_k = \mathcal{U}(B_k, s_k, y_k)$ . В численных экспериментах настоящей главы рассматриваются два классических индефинитных симметричных обновления:

$$\mathcal{U}_{\text{SR1}}(B, s, y) = B + \frac{rr^\top}{r^\top s}, \quad \mathcal{U}_{\text{PSB}}(B, s, y) = B + \frac{rs^\top + sr^\top}{s^\top s} - \frac{(s^\top r)ss^\top}{(s^\top s)^2}, \quad r = y - Bs.$$

SR1 требует skip-rule [26, §6.2]: при  $|s^\top r| < \varepsilon_{\text{skip}} \|s\| \|r\|$  обновление пропускается,  $B'_k = B_k$ . PSB skip-правил не требует. SS-расширение строится по единому шаблону (45), ниже — общий псевдокод.

Численные защиты вне теории — вырождение  $u_k^*$  после репроекции на  $s_k^\perp$  (порог  $\varepsilon_u$ ), устойчивость знаменателя  $\sigma_k^*$  (порог  $\varepsilon_S$ ) и собственный skip-rule базового  $\mathcal{U}$  (для  $\mathcal{U} = \text{SR1}$ ) — обсуждаются в замечании 3.7; в псевдокоде эти пороги опущены ради ясности и заменены проверкой  $u_k^* \neq 0$ ,  $S_p^\top u_k^* \neq 0$ . Ключевое наблюдение для собственной задачи  $P_k M'_k P_k$ :  $M'_k = \frac{1}{2}(R'_k S_p^\top + S_p R'_k{}^\top)$  — сумма двух матриц ранга  $\leq p + 1$ , поэтому

$$\text{rank}(P_k M'_k P_k) \leq \text{rank}(M'_k) \leq 2(p + 1), \quad (50)$$

и весь ненулевой спектр  $A_k = P_k M'_k P_k$  лежит в  $\text{range}(P_k [S_p, R'_k])$ . Собственная задача переносится из  $\mathbb{R}^n$  в подпространство размерности  $r \leq 2(p + 1)$  через QR-ортогонализацию этого базиса (приём, стандартный для блочных Ланцош-итераций [28, Гл. 13]; ср. также подход Fang–Saad [16] для мультисекантных схем). Алгоритм 3 непосредственно реализует эту редукцию; эквивалентность с прямой формой  $\text{eigh}(A_k)$  и детализация стоимости — в Замечании 3.6.

---

**Algorithm 3** SS- $\mathcal{U}$  ( $\nabla f$ ,  $x_0$ ,  $p_{\max}$ ,  $\varepsilon$ ;  $\mathcal{U}$ )

---

**Require:**  $\nabla f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ ,  $x_0 \in \mathbb{R}^n$ ,  $p_{\max} \geq 0$ ,  $\varepsilon > 0$

**Require:** базовое симметричное обновление  $\mathcal{U}(B, s, y)$ , удерживающее текущую секую  $\mathcal{U}(B, s, y)$   $s = y$  (например,  $\mathcal{U}_{\text{SR1}}$  со skip-rule или  $\mathcal{U}_{\text{PSB}}$ )

```

 $B_0 \leftarrow I_n, \quad k \leftarrow 0$ 
while  $\|\nabla f(x_k)\| \geq \varepsilon$  do
    Решить  $B_k d_k = -\nabla f(x_k)$ 
     $x_{k+1} \leftarrow x_k + d_k, \quad s_k \leftarrow d_k, \quad y_k \leftarrow \nabla f(x_{k+1}) - \nabla f(x_k)$ 
     $B'_k \leftarrow \mathcal{U}(B_k, s_k, y_k) \triangleright$  базовая симметричная итерация (с её собственным skip-rule)
     $p \leftarrow \min(p_{\max}, k), \quad S_p \leftarrow [s_k \mid \dots \mid s_{k-p}], \quad Y_p \leftarrow [y_k \mid \dots \mid y_{k-p}]$ 
     $R'_k \leftarrow B'_k S_p - Y_p, \quad M'_k \leftarrow \frac{1}{2}(R'_k S_p^\top + S_p R_k'^\top)$ 
     $\hat{s}_k \leftarrow s_k / \|s_k\|, \quad P_k \leftarrow I - \hat{s}_k \hat{s}_k^\top$ 
     $(\lambda_k^*, u_k^*) \leftarrow$  ведущая по  $|\lambda|$  собственная пара  $P_k M'_k P_k; \|u_k^*\| = 1 \triangleright \text{rank} \leq 2(p+1)$  —
    замечание 3.6
    if  $u_k^* \neq 0$  and  $S_p^\top u_k^* \neq 0$  then
         $\sigma_k^* \leftarrow -(u_k^{*\top} R'_k S_p^\top u_k^*) / \|S_p^\top u_k^*\|^2$ 
         $B_{k+1} \leftarrow B'_k + \sigma_k^* u_k^* u_k^{*\top}$ 
    else
         $B_{k+1} \leftarrow B'_k \triangleright$  коррекция пропущена (включая  $k=0$ , окно пусто)
     $k \leftarrow k + 1$ 
return  $x_k$ 

```

---

*Замечание 3.6* (Стоимость и эквивалентность с прямой формой). Псевдокод оставляет вычисление ведущей пары  $(\lambda_k^*, u_k^*)$  матрицы  $P_k M'_k P_k$  абстрактным. В реализации используется редукция к пространству  $\text{range}(P_k [S_p, R'_k])$ : ортогонализация  $W = (I - \hat{s}_k \hat{s}_k^\top) [S_p \mid R'_k] \in \mathbb{R}^{n \times 2(p+1)}$  тонким QR в  $Q \in \mathbb{R}^{n \times r}, r \leq 2(p+1)$ , и эрмитов собственный разбор  $\tilde{M} = Q^\top M'_k Q \in \mathbb{R}^{r \times r}$ ; поднятие  $u_k^* = Q v_{j^*}, j^* = \arg \max_i |\lambda_i|$ . Стоимость:  $R'_k - O(n^2 p)$  на плотном  $B'_k$ , QR —  $O(np^2)$ ,  $\text{eigh}(\tilde{M}) - O(p^3)$ ; суммарно  $O(n^2 p + np^2 + p^3)$  на итерацию, память  $O(np)$  против  $O(n^2)$  при хранении полного  $A_k$ .

Эквивалентная прямая форма — собрать  $A_k = P_k M'_k P_k \in \mathbb{R}^{n \times n}$  явно и вызвать  $\text{eigh}(A_k)$  напрямую (QR-итерация на трёхдиагонализированной форме [20, §8.3],  $O(n^3)$ ); в силу оценки ранга (50) обе формы дают ту же ведущую собственную пару  $(\lambda^*, u_k^*)$  с различием порядка машинной точности. В численных экспериментах главы  $n \leq 50$ , и обе формы пренебрежимы по стоимости относительно вычисления  $\nabla f$  и LU-решения системы  $B_k d_k = -\nabla f$  (последнее —  $O(n^3)$ ); фактически используется прямая форма  $\text{eigh}(A_k)$ . Редукция (50) становится существенной при  $n \gg p$  (типично  $p \leq 10, n \gtrsim 100$  даёт  $\sim n/p$ -кратное ускорение).

*Замечание 3.7* (Статус численных порогов). Дефолты  $\varepsilon_{\text{skip}} = 10^{-8}$  (skip-rule базового  $\mathcal{U} = \text{SR1}$ , ср. [26, §6.2]),  $\varepsilon_u = 10^{-12}$  и  $\varepsilon_S = 10^{-15}$  ((47)) выбраны как мягкие численные защиты вблизи машинной точности — цель каждого охранника: не допустить деление на малое / потерю ортогональности после репроекции на  $s_k^\perp$ . Дефолты не основаны на параметрическом анализе чувствительности и могут потребовать адаптации для новых

классов задач, особенно с экстремальной обусловленностью гессиана либо в смешанной точности. Качественно:  $\varepsilon_{\text{skip}}$  контролирует консервативность skip-rule (увеличение даёт более частый skip);  $\varepsilon_u, \varepsilon_S$  срабатывают редко на гладких задачах настоящей работы. Систематический sweep по  $(\varepsilon_{\text{skip}}, \varepsilon_u, \varepsilon_S)$  выходит за рамки локального анализа и обозначен как направление дальнейших исследований.

### 3.3 Свойства

#### Теорема 3.8 (Свойства SS- $\mathcal{U}$ ).

Обновление (45) обладает следующими свойствами:

1. **Текущее секущее условие:**  $B_{k+1}s_k = y_k$  (точно).
2. **Симметрия:** если  $\mathcal{U}$  сохраняет симметрию, то  $B_{k+1} = B_{k+1}^\top$ .
3. **Монотонность невязки секущих.** Обозначим  $R_{k+1} := B_{k+1}S_p - Y_p$  (невязка всех  $p+1$  секущих после композитного шага); в силу п. 1 первый столбец  $R_{k+1}$  (отвечающий  $s_k$ ) и  $R'_k$  нулевой, поэтому  $\|R_{k+1}\|_F$  и  $\|R'_k\|_F$  совпадают с нормами невязок прошлых секущих. Тогда

$$\|R_{k+1}\|_F^2 = \|R'_k\|_F^2 - \frac{(u_k^{*\top} M'_k u_k^*)^2}{\|S_p^\top u_k^*\|^2} = \|R'_k\|_F^2 - (\sigma_k^*)^2 \|S_p^\top u_k^*\|^2.$$

4. **Ранг обновления:**  $\text{rank}(B_{k+1} - B_k) \leq \text{rank}(\mathcal{U}) + 1$ .

#### Доказательство.

1. Из  $u_k^* \perp s_k$ :  $B_{k+1}s_k = B'_k s_k + \sigma_k^*(u_k^{*\top} s_k) u_k^* = y_k + 0 = y_k$ .
2.  $B_{k+1} = B'_k + \sigma_k^* u_k^* u_k^{*\top}$  — сумма двух симметричных матриц.
3. Пусть  $\tilde{B} = B'_k + \sigma u u^\top$ . Тогда  $\|\tilde{B}S_p - Y_p\|_F^2 = \|R'_k\|_F^2 + 2\sigma(u^\top M' u) + \sigma^2 \|S_p^\top u\|^2$ . Подстановка  $\sigma_k^*$  из (47) — точного условного оптимума по  $\sigma$  — даёт убывание ровно на  $(u^\top M' u)^2 / \|S_p^\top u\|^2 = (\sigma_k^*)^2 \|S_p^\top u\|^2$  (равенство, не неравенство).
4.  $B_{k+1} - B_k = \underbrace{(B'_k - B_k)}_{\text{rank} \leq \text{rank}(\mathcal{U})} + \underbrace{\sigma_k^* u_k^* u_k^{*\top}}_{\text{rank} \leq 1}$ , и  $\text{rank}(A + B) \leq \text{rank}(A) + \text{rank}(B)$ . ■

### 3.4 Связь с известными подходами

Несовместность симметрии и одновременного выполнения нескольких секущих условий [31] (Лемма 3.1) разрешается в литературе по симметричным multi-secant квазиньютоновским обновлениям по разным траекториям; конструкция SS- $\mathcal{U}$  из (45) занимает в этом ряду характерную позицию.



Gratton, Malmedy и Toint [21] вводят весовую multi-secant модификацию:  $B_{k+1}$  — решение задачи  $\min \|B - B_k\|_F^2$  при штрафе  $\sum_j w_j \|Bs_j - y_j\|^2$  за невязку прошлых секущих и ограничении симметрии; текущая секущая выполняется только в смысле того же штрафа, не точно. Boutet, Haelterman и Degroote [4] конкретизируют эту схему как расширение PSB через весовую multi-secant невязку; решение имеет ранг  $\leq 2(p+1)$  и получается из уравнения Сильвестра. В последующих работах те же авторы развивают подход в двух направлениях: gPSB [5] жертвует точной симметрией ради точного выполнения нескольких секущих, а grouped/ordered [3] разрешает противоречие иерархически — через лексикографическое выполнение упорядоченных групп секущих, без явной декомпозиции  $\mathbb{R}^n = \text{span}(s_k) \oplus s_k^\perp$ .

Scieur, Liu, Pumi и Boumal [19] формулируют симметричный multi-secant как задачу наименьших квадратов на всём окне с PSD-регуляризацией  $\mu I$ ; все секущие, включая текущую, выполняются приближённо, направления коррекции выделенной структуры в  $s_k^\perp$  не имеют.

Конструкция (45) отличается от перечисленных схем тремя структурными признаками. *Во-первых*, текущая секущая  $B_{k+1}s_k = y_k$  и симметрия выполняются *точно* — по построению базы  $B'_k = \mathcal{U}(B_k, s_k, y_k)$  и ортогональности  $u_k^* \perp s_k$  (теорема 3.8, п. 1–2); *во-вторых*, коррекция имеет ранг 1 ( $\sigma_k^* u_k^* u_k^{*\top}$ ), а не ранг  $\leq 2(p+1)$  как у [21, 4]; *в-третьих*, целевая функция — невязка прошлых секущих  $\|R'_k + \sigma u u^\top S_p\|_F^2$  в подпространстве  $s_k^\perp$ , а не близость к  $B_k$ , что приводит к обобщённой собственной задаче  $M'_k u = \lambda S_p S_p^\top u$  на  $s_k^\perp$  (Лемма 3.4). Двухэтапная схема «симметричное базовое  $\mathcal{U}$  — затем rank-1 надстройка в  $s_k^\perp$ » оставляет выбор базы независимым: в настоящей работе  $\mathcal{U} \in \{\text{SR1}, \text{PSB}\}$  (§3.2), но алгоритм 3 применим к любому симметричному обновлению, удерживающему текущую секущую.

### 3.5 Сверхлинейная сходимость

**Теорема 3.9** (Условная Q-сверхлинейная сходимость SS- $\mathcal{U}$ ).

Пусть выполнены предположения:

- (H1)  $F = \nabla f$ , гессиан  $\nabla^2 f$  липшицев в окрестности  $x^*$  с константой  $L_H$ ;
- (H2) метод SS- $\mathcal{U}$  сходится:  $x_k \rightarrow x^*$ ,  $s_k \rightarrow 0$ ,  $\nabla f(x^*) = 0$ ;
- (H3) предельный гессиан  $J^* := \nabla^2 f(x^*)$  невырожден;
- (H4) начиная с некоторого  $k_0$  глобализация выдаёт полный квазиньютоновский шаг  $s_k = -B_k^{-1} \nabla f(x_k)$ , причём  $\|B_k^{-1}\| \leq M_*$  равномерно при  $k \geq k_0$ ;

(H5) *bounded deterioration* в форме Денниса–Море: обозначим  $E_k := B_k - J^*$  — ошибку аппроксимации гессиана; существует последовательность  $\beta_k \geq 0$  с  $\sum_{k \geq k_0} \beta_k < \infty$  такая, что в окрестности  $x^*$

$$\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + \beta_k.$$

Тогда:

1. (условие Денниса–Море для  $B_k$ )

$$\frac{\|(B_k - J^*) s_k\|}{\|s_k\|} \xrightarrow{k \rightarrow \infty} 0;$$

2. (Q-сверхлинейность)  $\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \rightarrow 0$ .

**Доказательство.**

Шаг 1 (*telescoping* (H5) даёт сходимость ряда). Суммируя (H5) от  $k_0$  до  $N$ :

$$\sum_{k=k_0}^N \frac{\|E_k s_k\|^2}{\|s_k\|^2} \leq \|E_{k_0}\|_F^2 - \|E_{N+1}\|_F^2 + \sum_{k=k_0}^N \beta_k \leq \|E_{k_0}\|_F^2 + \sum_{k \geq k_0} \beta_k < \infty,$$

где использована неотрицательность  $\|E_{N+1}\|_F^2$  и суммируемость  $\beta_k$ . Переходя к пределу  $N \rightarrow \infty$ , получаем  $\sum_{k \geq k_0} \|E_k s_k\|^2 / \|s_k\|^2 < \infty$ , откуда необходимое условие сходящегося ряда даёт

$$\frac{\|(B_k - J^*) s_k\|}{\|s_k\|} = \frac{\|E_k s_k\|}{\|s_k\|} \xrightarrow{k \rightarrow \infty} 0, \quad (51)$$

т.е. пункт 1 теоремы (условие Денниса–Море для  $B_k$ ).

Шаг 2 (*Q-сверхлинейность через характеристику Денниса–Море*). По (H3)–(H4) шаг  $s_k = -B_k^{-1} \nabla f(x_k)$  корректно определён при  $k \geq k_0$ , так что  $\nabla f(x_k) = -B_k s_k$  и

$$\|\nabla f(x_k) + J^* s_k\| = \|(J^* - B_k) s_k\| = \|(B_k - J^*) s_k\|.$$

Согласно характеристике Денниса–Море [12, Th. 2.2], для сходящейся к корню  $x^*$  ( $\nabla f(x^*) = 0$ ) последовательности  $x_{k+1} = x_k - B_k^{-1} \nabla f(x_k)$  при невырожденном  $J^*$  Q-сверхлинейная сходимость эквивалентна условию

$$\frac{\|\nabla f(x_k) + J^* s_k\|}{\|s_k\|} \xrightarrow{k \rightarrow \infty} 0,$$

т.е. в наших обозначениях ровно ДМ-условию пункта 1, установленному на Шаге 1. Применяя эквивалентность, получаем  $\|x_{k+1} - x^*\| / \|x_k - x^*\| \rightarrow 0$ . ■

*Замечание 3.10* (Содержательная роль теоремы). Теорема 3.9 утверждает скорость сходимости *при условии* (H2) — самой сходимости итерации  $x_k \rightarrow x^*$ , которая для базовых indefinitных обновлений ( $\mathcal{U} \in \{\text{SR1}, \text{PSB}\}$ ) без стабилизирующей MS-коррекции в общем случае не гарантирована (см. [10] и Замечание 3.11). Если итерация сходится (что эмпирически обеспечивается MS-коррекцией и backtracking-Армихо), то скорость — Q-сверхлинейная.

*Замечание 3.11* (Роль предположений). Предположения (H3) и (H4) суть стандартные локальные допущения о хорошей обусловленности задачи: невырожденность  $J^*$  нужна для применимости Денниса–Море [12], а допустимость полного шага в окрестности  $x^*$  — классическое следствие условия Армихо с  $c_1 < 1/2$  для дважды-дифференцируемой  $f$  ([26], Th. 3.6).

Условие (H5) воспроизводит классическую форму bounded deterioration по Деннису–Море [12, Th. 2.2] и наследуется от выбранного базового обновления  $\mathcal{U}$ : для  $\mathcal{U} \in \{\text{BFGS}, \text{PSB}\}$  оно установлено в [26] и [14, Th. 8.2.4], для  $\mathcal{U} = \text{SR1}$  со skip-rule — в [10]. Для композитного обновления  $\mathcal{U} \rightarrow \text{SS-}\mathcal{U}$  сохранение (H5) формально установлено в Лемме 3.12 (см. ниже) при дополнительном предположении (A4) о входной Q-линейной сходимости. Без MS-коррекции SR1 может нарушать (H5) с теоретически возможными расходимостями в условиях плохо обусловленных задач [10]. На рассматриваемых режимах §3.6 skip-rule SR1 оказывается достаточен для сходимости, и SS-SR1 эмпирически не даёт выигрыша по доле сходимости и числу итераций (это согласуется с ролью MS-коррекции как ограничителя накопленной невязки прошлых секущих, см. обсуждение в §3.6: преимущество проявляется там, где базовое обновление действительно деградирует, — у пары PSB / SS-PSB).

**Лемма 3.12** (Композитное bounded deterioration для SS- $\mathcal{U}$ ).

Пусть выполнены следующие условия в окрестности  $B_\delta(x^*) = \{x : \|x - x^*\| \leq \delta\}$ :

(A1)  $F = \nabla f$ ,  $\nabla^2 f$  липшицев с константой  $L_H$  в  $B_\delta(x^*)$ ;

(A2) базовое обновление  $\mathcal{U}$  удовлетворяет Lipschitz-контролируемому bounded deterioration: существует  $c_{\mathcal{U}} \geq 0$  такая, что в  $B_\delta(x^*)$

$$\|E'_k\|_F^2 \leq \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + c_{\mathcal{U}} L_H \alpha_k, \quad \alpha_k := \frac{1}{2}(\|x_k - x^*\| + \|x_{k+1} - x^*\|); \quad (52)$$

(Деннис–Шнабель [14, Th. 8.2.4] для  $\mathcal{U} = \text{PSB}$ ; Конн–Гулд–Тойнт [10] для  $\mathcal{U} = \text{SR1}_{\text{skip}}$ );

(A3) Алгоритм 3 применяет SS-коррекцию только при  $\|S_p^\top u_k^*\|^2 \geq \varepsilon_S$ ; в противном случае  $B_{k+1} = B'_k$  и SS-вклад равен нулю;

(A4) начальная точка достаточно близка к  $x^*$ :  $\|E_{k_0}\|_F < \delta'$  и  $\|x_{k_0} - x^*\| < \delta''$ , где  $\delta', \delta'' > 0$  зависят от  $L_H, \|J^*\|_2, \|(J^*)^{-1}\|_2, \varepsilon_S, c_U, p$  (явный выбор дан в Шаге 7 доказательства).

Здесь  $E_k := B_k - J^*$ ,  $E'_k := B'_k - J^*$ ,  $E_{k+1} := B_{k+1} - J^*$  — ошибки аппроксимации до базового шага  $\mathcal{U}$ , после него и после композитной SS-коррекции соответственно. Тогда существуют темп  $\rho_* \in [0, 1)$ , константа  $\Sigma = \Sigma(\rho_*, L_H, \varepsilon_S, p, c_U, \|E_{k_0}\|_F, \|x_{k_0} - x^*\|) < \infty$  и неотрицательная последовательность  $\beta_k$  с  $\sum_{k \geq k_0} \beta_k \leq \Sigma$  такие, что для всех  $k \geq k_0$ :

$$\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + \beta_k, \quad (53)$$

а итерация  $\{x_k\}$   $Q$ -линейно сходится к  $x^*$  с темпом  $\rho_*$ :  $\|x_{k+1} - x^*\| \leq \rho_* \|x_k - x^*\|$ . В частности,  $\|E_k\|_F \leq \sqrt{\|E_{k_0}\|_F^2 + \Sigma}$  равномерно по  $k \geq k_0$ .

### Доказательство.

Без ограничения общности предположим, что safeguard (A3) не срабатывает — иначе  $B_{k+1} = B'_k$ , и (53) сразу следует из (52).

**Шаг 1 (декомпозиция и проектируемое тождество).** SS-коррекция:

$$B_{k+1} = B'_k + \Delta_k^{SS}, \quad \Delta_k^{SS} := \sigma_k^* u_k^* u_k^{*\top}, \quad u_k^* \perp s_k, \quad \|u_k^*\| = 1.$$

Соответственно  $E_{k+1} = E'_k + \Delta_k^{SS}$ . Из  $u_k^* \perp s_k$ :

$$E_{k+1} s_k = E'_k s_k + \sigma_k^* u_k^* (u_k^{*\top} s_k) = E'_k s_k, \quad (54)$$

т.е. SS-коррекция не меняет направленный остаток вдоль  $s_k$ .

По линейности скалярного произведения Фробениуса:

$$\|E_{k+1}\|_F^2 = \|E'_k\|_F^2 + 2\sigma_k^* \langle E'_k, u_k^* u_k^{*\top} \rangle_F + (\sigma_k^*)^2 \|u_k^* u_k^{*\top}\|_F^2.$$

Поскольку  $\langle E'_k, u u^\top \rangle_F = \text{tr}(E_k'^\top u u^\top) = u^\top E'_k u$  (скаляр) и  $\|u u^\top\|_F^2 = \|u\|^4 = 1$ :

$$\|E_{k+1}\|_F^2 = \|E'_k\|_F^2 + 2\sigma_k^* (u_k^{*\top} E'_k u_k^*) + (\sigma_k^*)^2. \quad (55)$$

**Шаг 2 (оценка SS-возмущения через треугольное неравенство).** По Коши–Шварцу и  $\|u_k^*\| = 1$ :  $|u_k^{*\top} E'_k u_k^*| \leq \|E'_k\|_2 \leq \|E'_k\|_F$ . Поэтому из (55):

$$\|E_{k+1}\|_F^2 \leq \|E'_k\|_F^2 + 2|\sigma_k^*| \|E'_k\|_F + (\sigma_k^*)^2. \quad (56)$$

Объединяя с базовым (52) (тождество (54)  $E_{k+1} s_k = E'_k s_k$  удерживается как отдельный

инвариант, используемый ниже при переходе к условию Денниса–Море):

$$\|E_{k+1}\|_F^2 \leq \|E_k\|_F^2 - \frac{\|E_k s_k\|^2}{\|s_k\|^2} + \underbrace{c_{\mathcal{U}} L_H \alpha_k}_{=:\beta_k^{(U)}} + \underbrace{2|\sigma_k^*| \|E'_k\|_F + (\sigma_k^*)^2}_{=:\beta_k^{(SS)}}. \quad (57)$$

Полный композитный  $\beta_k := \beta_k^{(U)} + \beta_k^{(SS)} \geq 0$ .

**Шаг 3 (оценка  $|\sigma_k^*|$  через  $\|R'_k\|_F$ ).** По формуле (47) и Коши–Шварцу:

$$|\sigma_k^*| = \frac{|u_k^{*\top} R'_k S_p^\top u_k^*|}{\|S_p^\top u_k^*\|^2} \leq \frac{\|R'_k\|_2 \|S_p^\top u_k^*\|}{\|S_p^\top u_k^*\|^2} \leq \frac{\|R'_k\|_F}{\|S_p^\top u_k^*\|}.$$

Применяя safeguard (A3)  $\|S_p^\top u_k^*\|^2 \geq \varepsilon_S$ :

$$|\sigma_k^*|^2 \leq \varepsilon_S^{-1} \|R'_k\|_F^2. \quad (58)$$

**Шаг 4 (оценка  $\|R'_k\|_F$  через  $\|E'_k\|_F$  и Lipschitz).** Пусть  $e_i \in \mathbb{R}^{p+1}$  —  $i$ -й канонический базисный вектор; тогда  $i$ -й столбец  $R'_k$  ( $i = 0, 1, \dots, p$ ) имеет вид

$$R'_k e_i = B'_k s_{k-i} - y_{k-i} = E'_k s_{k-i} - q_{k-i}, \quad q_{k-i} := y_{k-i} - J^* s_{k-i}.$$

По интегральной форме теоремы о среднем и (A1):  $y_{k-i} = \left( \int_0^1 \nabla^2 f(x_{k-i} + t s_{k-i}) dt \right) s_{k-i}$ , откуда

$$\|q_{k-i}\| = \left\| \int_0^1 [\nabla^2 f(x_{k-i} + t s_{k-i}) - J^*] dt \cdot s_{k-i} \right\| \leq L_H \bar{\alpha}_{k-i} \|s_{k-i}\|,$$

где  $\bar{\alpha}_{k-i} := \max_{t \in [0,1]} \|x_{k-i} + t s_{k-i} - x^*\| \leq \max(\|x_{k-i} - x^*\|, \|x_{k-i+1} - x^*\|) \leq D_k$ ,  $D_k := \max_{j \in W_k} \|x_j - x^*\|$ ,  $W_k := \{k-p, \dots, k+1\}$ . Поэтому

$$\|R'_k e_i\|^2 \leq 2 \|E'_k\|_2^2 \|s_{k-i}\|^2 + 2 L_H^2 D_k^2 \|s_{k-i}\|^2,$$

и суммируя по  $i$ :

$$\|R'_k\|_F^2 = \sum_{i=0}^p \|R'_k e_i\|^2 \leq 2 \|S_p\|_F^2 (\|E'_k\|_F^2 + L_H^2 D_k^2). \quad (59)$$

**Шаг 5 (явная асимптотика  $\beta_k$  под (A4)).** Подставляя (59) в (58):

$$(\sigma_k^*)^2 \leq 2\varepsilon_S^{-1} \|S_p\|_F^2 (\|E'_k\|_F^2 + L_H^2 D_k^2).$$

Для смешанного члена  $2|\sigma_k^*|\|E'_k\|_F$  применяем  $|\sigma_k^*| \leq \varepsilon_S^{-1/2}\sqrt{2}\|S_p\|_F(\|E'_k\|_F + L_H D_k)$  и АМ–ГМ на смешанный остаток  $L_H D_k\|E'_k\|_F \leq \frac{1}{2}(L_H^2 D_k^2 + \|E'_k\|_F^2)$ :

$$2|\sigma_k^*|\|E'_k\|_F \leq 2\sqrt{2}\varepsilon_S^{-1/2}\|S_p\|_F(\|E'_k\|_F^2 + L_H D_k\|E'_k\|_F) \leq 3\sqrt{2}\varepsilon_S^{-1/2}\|S_p\|_F\|E'_k\|_F^2 + \sqrt{2}\varepsilon_S^{-1/2}L_H^2\|S_p\|_F^2$$

Складывая:

$$\beta_k^{(SS)} \leq C_E(\|S_p\|_F)\|E'_k\|_F^2 + C_D(\|S_p\|_F)D_k^2, \quad (60)$$

с

$$C_E(\xi) := 3\sqrt{2}\varepsilon_S^{-1/2}\xi + 2\varepsilon_S^{-1}\xi^2, \quad C_D(\xi) := L_H^2(\sqrt{2}\varepsilon_S^{-1/2}\xi + 2\varepsilon_S^{-1}\xi^2).$$

**Шаг 6 (суммируемость при Q-линейном темпе  $\rho_*$ ).** Шаги 6 и 7 проводятся совместно: пусть  $\rho_* \in [0, 1)$  — темп, который будет установлен индуктивно в Шаге 7. По индуктивной гипотезе Q-линейности (I.b) Шага 7 при  $j = k_0, \dots, k$ :  $\|x_j - x^*\| \leq \rho_*^{j-k_0}\|x_{k_0} - x^*\|$ , поэтому

$$\|s_j\| \leq \|x_{j+1} - x^*\| + \|x_j - x^*\| \leq (1 + \rho_*)\rho_*^{j-k_0}\|x_{k_0} - x^*\|.$$

Отсюда:

$$\begin{aligned} \alpha_k &\leq \rho_*^{k-k_0}\|x_{k_0} - x^*\|, \\ D_k &= \max_{j \in W_k} \|x_j - x^*\| \leq \rho_*^{k-p-k_0}\|x_{k_0} - x^*\|, \\ \|S_p^{(k)}\|_F^2 &= \sum_{i=0}^p \|s_{k-i}\|^2 \leq (1 + \rho_*)^2\|x_{k_0} - x^*\|^2 \sum_{i=0}^p \rho_*^{2(k-i-k_0)} \leq C_{\rho_*} \rho_*^{2(k-p-k_0)}\|x_{k_0} - x^*\|^2, \end{aligned} \quad (61)$$

где  $C_{\rho_*} := (1 + \rho_*)^2/(1 - \rho_*^2) = (1 + \rho_*)/(1 - \rho_*)$  зависит только от  $\rho_*$  (не от  $p$ ): сумма  $\sum_{i=0}^p \rho_*^{2(p-i)} \leq 1/(1 - \rho_*^2)$  оценивается равномерно по  $p$ . Все три величины убывают геометрически со скоростью  $\rho_*^k, \rho_*^{k-p}, \rho_*^{k-p}$  соответственно.

**Шаг 7 (совместная индукция: ограниченность  $\|E_k\|_F$  и Q-линейность).**

Положим  $M_{k_0} := \|E_{k_0}\|_F$ ,  $M := 2M_{k_0}$  и зафиксируем кандидат

$$\rho_* := 2\|(J^*)^{-1}\|_2 M + \|(J^*)^{-1}\|_2 L_H \delta''. \quad (62)$$

Покажем, что при достаточно малых  $\delta', \delta'' > 0$  одновременно выполняются два инварианта для всех  $k \geq k_0$ :

$$(I.a) \quad \|E_k\|_F \leq M;$$

$$(I.b) \quad \|x_{k+1} - x^*\| \leq \rho_* \|x_k - x^*\| \text{ с } \rho_* < 1.$$

Параметры  $\delta', \delta''$  подчиним двум условиям:

$$\delta' < \frac{1}{4} \|(J^*)^{-1}\|_2^{-1}, \quad 4 \|(J^*)^{-1}\|_2 (\delta' + \frac{1}{4} L_H \delta'') < 1, \quad (63)$$

что обеспечивает  $\rho_* < 1$  (поскольку  $M = 2M_{k_0} < 2\delta'$ ), и ещё одно условие на малость  $\Sigma$  (см. ниже (65)).

*База* ( $k = k_0$ ). (I.a) выполнена по определению  $M$ . Для (I.b): из  $\|E_{k_0}\|_F < \delta' < \frac{1}{2} \|(J^*)^{-1}\|_2^{-1}$  лемма Банаха о возмущении обратимого оператора даёт  $\|B_{k_0}^{-1}\|_2 \leq 2 \|(J^*)^{-1}\|_2$ . Раскладывая  $\nabla f(x_{k_0}) = J^*(x_{k_0} - x^*) + r_{k_0}$  с  $\|r_{k_0}\| \leq \frac{1}{2} L_H \|x_{k_0} - x^*\|^2$  (из (A1) через интегральную форму остатка Тейлора), получаем

$$x_{k_0+1} - x^* = (I - B_{k_0}^{-1} J^*)(x_{k_0} - x^*) - B_{k_0}^{-1} r_{k_0},$$

и  $\|I - B_{k_0}^{-1} J^*\|_2 = \|B_{k_0}^{-1} E_{k_0}\|_2 \leq 2 \|(J^*)^{-1}\|_2 M$ . Отсюда  $\|x_{k_0+1} - x^*\| \leq \rho_* \|x_{k_0} - x^*\|$  при  $\rho_*$  из (62), причём  $\rho_* < 1$  по выбору (63).

*Индуктивный шаг.* Пусть (I.a), (I.b) выполнены для всех  $j = k_0, \dots, k$ . Тогда телескопически  $\|x_j - x^*\| \leq \rho_*^{j-k_0} \|x_{k_0} - x^*\|$ , и Шаги 5–6 с параметром  $\rho_*$  дают (с  $\xi_j := \|S_p^{(j)}\|_F \leq \sqrt{C_{\rho_*}} \rho_*^{j-p-k_0} \|x_{k_0} - x^*\|$ ): из (52)  $\|E'_j\|_F \leq M' := \sqrt{M^2 + c_{\mathcal{U}} L_H \|x_{k_0} - x^*\|}$ , и (60) приводит к оценке

$$\beta_j \leq c_{\mathcal{U}} L_H \alpha_j + (3\sqrt{2} \varepsilon_S^{-1/2} \xi_j + 2\varepsilon_S^{-1} \xi_j^2) (M')^2 + L_H^2 (\sqrt{2} \varepsilon_S^{-1/2} \xi_j + 2\varepsilon_S^{-1} \xi_j^2) D_j^2.$$

Доминирующие слагаемые:  $\xi_j (M')^2 = O(\rho_*^j)$  и  $\xi_j D_j^2 = O(\rho_*^{3j})$  (квадратичные  $\xi_j^2(\cdot)$  ещё быстрее); все — геометрические со знаменателем  $\rho_* < 1$ , суммируются:

$$\Sigma := \sum_{j \geq k_0} \beta_j \leq \frac{c_{\mathcal{U}} L_H \|x_{k_0} - x^*\|}{1 - \rho_*} + A_1(\rho_*, p, \varepsilon_S, L_H, \|x_{k_0} - x^*\|) (M')^2 + A_2(\rho_*, p, \varepsilon_S, L_H, \|x_{k_0} - x^*\|) \quad (64)$$

где  $A_1, A_2 = O(\|x_{k_0} - x^*\|)$  при  $\|x_{k_0} - x^*\| \rightarrow 0$ .

*Замыкание (I.a) на шаге  $k+1$ .* Телескопия (57) от  $k_0$  до  $k$  даёт  $\|E_{k+1}\|_F^2 \leq \|E_{k_0}\|_F^2 + \sum_{j=k_0}^k \beta_j \leq M_{k_0}^2 + \Sigma$ . Для  $\|E_{k+1}\|_F \leq M = 2M_{k_0}$  достаточно

$$\Sigma \leq 3M_{k_0}^2. \quad (65)$$

Из оценки (64) и явных выражений для  $A_1, A_2$  из Шага 6 следует  $\Sigma \leq K \|x_{k_0} - x^*\| (1 + M_{k_0}^2)$  с константой  $K = K(L_H, \|J^*\|_2, \|(J^*)^{-1}\|_2, \varepsilon_S, p, c_{\mathcal{U}}, \rho_*)$ , зависящей только от параметров задачи (не от старта). Подставляя  $M_{k_0} < \delta'$  и  $\|x_{k_0} - x^*\| < \delta''$ , получаем  $\Sigma \leq K \delta'' (1 + \delta'^2)$ ; для выполнения (65) при всех допустимых  $M_{k_0} \leq \delta'$  достаточно,

чтобы  $\delta'', \delta'$  удовлетворяли соотношению

$$K \delta'' (1 + \delta'^2) \leq 3 \delta'^2. \quad (66)$$

Это связывает  $\delta''$  с  $\delta'$ : например, выбор  $\delta' \leq \frac{1}{4} \|(J^*)^{-1}\|_2^{-1}$  из (63) и  $\delta'' \leq 3\delta'^2/(K(1 + \delta'^2))$  обеспечивает (65) вместе с (63) одновременно при  $M_{k_0} < \delta'$ ,  $\|x_{k_0} - x^*\| < \delta''$ . В этом смысле радиус  $\delta''$  масштабируется как  $\delta'^2$ ; такая связь типична для локального анализа квазиньютоновских методов (ср. Деннис–Шнабель [14, Th. 8.2.2]).

*Замыкание (I.b) на шаге  $k + 1$ .* Из (I.a) на шаге  $k + 1$ :  $\|E_{k+1}\|_F \leq M < 2\delta' < \frac{1}{2} \|(J^*)^{-1}\|_2^{-1}$ , поэтому  $\|B_{k+1}^{-1}\|_2 \leq 2 \|(J^*)^{-1}\|_2$ . Тот же аргумент Тейлора с  $x_{k+1}$  вместо  $x_{k_0}$  (используя  $\|x_{k+1} - x^*\| \leq \rho_*^{k+1-k_0} \|x_{k_0} - x^*\| < \delta''$ ) и  $\|I - B_{k+1}^{-1}J^*\|_2 \leq 2 \|(J^*)^{-1}\|_2 M$  дают  $\|x_{k+2} - x^*\| \leq \rho_* \|x_{k+1} - x^*\|$ . Индукция замыкается.

Таким образом, (I.a) обеспечивает (53), а (I.b) — Q-линейную сходимость  $\{x_k\}$  с темпом  $\rho_* \in [0, 1)$  как следствие, не как входное предположение. ■

*Замечание 3.13* (Об условии (A4) как структурной гипотезе локальной близости). Условие (A4) формулируется как требование локальной близости старта ( $\|E_{k_0}\|_F < \delta'$ ,  $\|x_{k_0} - x^*\| < \delta''$ ), а не как предположение о Q-линейной сходимости итерации. Q-линейность с темпом  $\rho_* \in [0, 1)$  — *выходное свойство* Леммы 3.12, устанавливаемое совместной индукцией Шага 7 одновременно с ограниченностью  $\|E_k\|_F$ .

Механизм совместной индукции — стандартный возмущенный аргумент локального анализа квазиньютоновских методов: при малом  $\|E_k\|_F \leq M$  лемма Банаха даёт  $\|B_k^{-1}\|_2 \leq 2 \|(J^*)^{-1}\|_2$ , разложение  $\nabla f$  вокруг  $x^*$  с Lipschitz-остатком (из (A1)) даёт сжатие  $\|x_{k+1} - x^*\| \leq \rho_* \|x_k - x^*\|$  с  $\rho_* = 2 \|(J^*)^{-1}\|_2 M + \|(J^*)^{-1}\|_2 L_H \delta''$  (ср. Бройден–Деннис–Море [7, Th. 3.1] или Деннис–Шнабель [14, Th. 5.4.1]). Композитная BD-оценка, в свою очередь, при  $\rho_*$ -геометрии  $\|s_k\|$  даёт  $\sum \beta_k < \infty$ , сохраняя  $\|E_{k+1}\|_F \leq M$ .

Совокупный результат: SS- $\mathcal{U}$  локально Q-линейна в окрестности  $x^*$  при условии достаточной близости  $\|E_{k_0}\|_F < \delta'$ ,  $\|x_{k_0} - x^*\| < \delta''$ ; темп  $\rho_*$  и радиусы  $\delta', \delta''$  явно выражены в Шаге 7 через  $L_H, \|J^*\|_2, \|(J^*)^{-1}\|_2, \varepsilon_S, c_{\mathcal{U}}, p$ .

*Замечание 3.14* (Замыкание (H5) Теоремы 3.9). Лемма 3.12 закрывает аргумент сохранения (H5) под SS-коррекцией строгой цепочкой:  $(A1)+(A2)+(A3)+(A4) \implies (H5)$  в композитной форме  $\xRightarrow{\text{telescoping}}$  Денниса–Море для  $B_k$   $\xRightarrow{\text{характеризация}}$  Q-сверхлинейность. В совместной формулировке Леммы 3.12 и Теоремы 3.9 условие (H5) перестаёт быть гипотезой — вместо него выступают (A2) [базовое BD] и (A4) [локальная близость старта]; гипотеза (H1) — Lipschitz  $\nabla^2 f$  — сохраняется для применения Шага 4 доказательства Леммы (оценка  $\|q_{k-i}\|$  через  $L_H$ ); гипотезы (H3), (H4) остаются без изменений. Q-линейная сходимость итерации с некоторым  $\rho_* < 1$  — выходное свойство Леммы



(см. Замечание 3.13), устанавливаемое совместной индукцией одновременно с ограниченностью  $\|E_k\|_F$ ; тем самым снимается кажущаяся цикличность “Q-линейность  $\rightarrow$  Q-сверхлинейность” и весь аргумент Теоремы 3.9 держится на одном структурном допущении (A4) о локальной близости старта.

*Замечание 3.15* (Связь с SS-инвариантом теоремы 3.8). Хотя теорема 3.8 п. 3 доказывает *строгое* равенство  $\|R_{k+1}\|_F^2 = \|R'_k\|_F^2 - (\sigma_k^*)^2 \|S_p^\top u_k^*\|^2$  — структурное сокращение накопленной невязки на одном и том же окне  $S_p$ , — в Лемме 3.12 эта монотонность не используется. Шагу 4 достаточно одностороннего верхнего ограничителя (59), который выражается через  $\|E'_k\|_F$  и  $D_k$  без ссылки на SS-механизм; так разделяются два контура: геометрия сокращения невязки (п. 3 теоремы) и передача bounded deterioration (Лемма). Эмпирическая роль монотонности отражена на рис. 5 как прямая верификация того, что MS-коррекция действительно ограничивает  $\|B_k S_p - Y_p\|_F$  в численных режимах.

*Замечание 3.16* (Минимальность гипотез). Гипотеза (A4) о локальной близости старта — *достаточная* для замыкания совместной индукции Шага 7 и извлечения Q-линейного темпа  $\rho_* < 1$ . Альтернативная посылка « $\sum \|s_k\|^2 < \infty$ » (что эмпирически наблюдается в численных экспериментах § 3.6) дала бы тот же вывод суммируемости  $\sum \beta_k < \infty$  без возмущенного аргумента; однако формулировка через  $(\delta', \delta'')$  согласуется со стандартным циклом локального анализа квазиньютоновских методов и явно фиксирует область применимости.

Гипотеза (A1) о Липшице гессиана — *использована* в Шаге 4 (оценка  $\|q_{k-i}\|$ ) и в Шаге 7 (оценка остатка Тейлора  $r_k$ ); ослабление до « $\nabla^2 f$  непрерывен в  $x^*$ » даёт  $\|q_{k-i}\| = o(\|s_{k-i}\|)$  вместо  $O(\|s_{k-i}\| \cdot D_k)$ , что нарушает геометрическое убывание в Шаге 6 и количественную оценку  $\rho_*$  в Шаге 7. Поэтому (A1) в Lipschitz-форме сохраняется как *рабочая*, а не излишняя гипотеза.

*Замечание 3.17* (Роль MS-коррекции: стабилизация без изменения асимптотической скорости). MS-коррекция не влияет на сверхлинейную скорость:  $\Delta_k^{SS}$  действует в  $s_k^\perp$  (так как  $u_k^* \perp s_k$ ), а условие Денниса–Море  $\|(B_k - J^*)s_k\|/\|s_k\| \rightarrow 0$  — только в направлении  $s_k$ . Роль коррекции — стабилизация  $B_k$  (условие (H5) и невырожденность  $B_k$ ), обеспечивающая устойчивую сходимость на практике. Более того, доказательство Th. 3.9 использует от SS- $\mathcal{U}$  только текущее секущее условие  $B_{k+1}s_k = y_k$ , выполняемое и базовым обновлением; поэтому при выполнении (H1)–(H5) тем же аргументом Q-сверхлинейная скорость следует и для базового SR1 (классический результат Конна–Гулда–Тойнта, Халфана–Бёрда–Шнабеля). Узкое место в этом случае — посылка (H2) (сходимость траектории) и условие (H5), ровно те два пункта, которые и предназначена закрывать MS-коррекция.

*Замечание 3.18* (Следствие для дизайна численных экспериментов). Поскольку асимптотическая скорость, заявленная в Th. 3.9, разделяется с базовым обновлением (Замечание 3.17), *отдельная* визуализация скорости в гл. 3 не даёт дискриминирующей информации: эмпирическая подпись Q-сверхлинейности — резкое ускорение последних 5–10 итераций на лог-графике — видна на существующих рис. 3 и 4 для любой сошедшейся траектории (SR1, SS-SR1, PSB, SS-PSB). Дискриминатор SS-конструкции — предпосылка (H2), т. е. *наличие* сходимости, а не её скорость; этот аспект закрыт существующими convergence- и gpastr-фигурами.

### 3.6 Численные результаты

**Постановка статистического эксперимента.** Для общего случая ведущий собственный вектор  $u_k^*$  матрицы  $P_k M'_k P_k$  (см. Опр. 3.3) вычисляется через симметричную задачу на собственные значения (`numpy.linalg.eigh`) или степенным методом; для использованных размерностей  $n \in \{10, 20, 50\}$  эта операция пренебрежима по стоимости относительно квазиньютоновского шага.

Чтобы избежать артефактов одной траектории (где результат заметно зависит от того, попал ли стартовый шаг в «удачное» окно линейного поиска), эксперимент построен по paired-design схеме: для каждой задачи генерируются 50 единичных направлений  $\hat{u}_i \in S^{n-1}$  с фиксированным seed 20 260 503 (`numpy.random.default_rng`), и стартовая точка  $x_0^{(i)} = R_0 \hat{u}_i$  берётся на сфере радиуса  $R_0 = \|x_0^{\text{std}}\|$ , где  $x_0^{\text{std}}$  — стандартная стартовая точка задачи. Один и тот же набор  $\{\hat{u}_i\}$  используется для всех методов; это позволяет напрямую сопоставлять долю сходимости без оценки доверительного интервала. Все методы используют общий backtracking-Armijo ( $c_1 = 10^{-4}$ , откат  $\alpha/2$ , до 40 откатов),  $B_0 = I$ , параметр окна  $p_{\max} = 5$  (фактическое окно растёт как  $p = \min(p_{\max}, k)$  по алгоритму 3), критерий остановки  $\|\nabla f\|_2 \leq 10^{-8}$  или 500 итераций; направление шага  $d_k = -B_k^{-1} \nabla f(x_k)$  через LU-разложение системы. Если  $B_k$  численно сингулярна или даёт направление подъёма  $\langle \nabla f, d_k \rangle \geq 0$  (типично для базового PSB на поздних итерациях ECV), на текущем шаге выполняется fallback  $d_k = -\nabla f(x_k)$ ; коррекция влияет лишь на отдельные итерации и не трансформирует метод в steepest-descent глобально.

Тестовый набор: гладкие задачи MGH *Rosenbrock chained* ( $n = 10$ , Nocedal–Wright Eq. 2.22) и *Extended Rosenbrock* ( $n = 10$ , MGH #21) — контроль на отсутствие деградации; задача с узкой искривлённой долиной *Extended Curved Valley* (блочно по 2 координаты,  $f_{\text{блок}}(x_1, x_2) = \frac{\alpha}{2}(x_2 - \beta x_1^2)^2 + \frac{1}{2}(x_1^2 + x_2^2)$ ,  $\alpha = 100$ ,  $\beta = 1,5$ ,  $x_0^{\text{std}}$  блочно = (1,8; 1,8)) — стресс-тест на стабилизацию, прогоняемый при  $n \in \{10, 20, 50\}$  для оценки масштабируемости.

Каждой паре (SS-X, X) посвящён отдельный график: SS-вариант сравнивается только со своим базовым обновлением (правило выбора сравнений в численных экспери-

ментах настоящей главы). Ниже последовательно разбираются обе пары — SR1/SS-SR1 и PSB/SS-PSB.

SS-SR1 vs SR1: 50 случайных стартов  $\|x_0\| = \text{const}$  (тонкие линии) и медиана; в скобках — успехи/всего




Рисунок 3 — SS-SR1 vs SR1: сходимость  $\|\nabla f(x_k)\|_2$  на пяти тестовых конфигурациях. Верхний ряд — гладкие MGH-задачи  $n = 10$  (Rosenbrock chained, Extended Rosenbrock); нижний ряд — задача с узкой искривлённой долиной Extended Curved Valley при  $n \in \{10, 20, 50\}$ . По 50 случайных стартов на сфере  $\|x_0\| = R_0 = \|x_0^{\text{std}}\|$  (тонкие линии), медиана жирной линией. На гладких задачах SS-SR1 в медиане несколько медленнее SR1 по числу итераций (на Extended Rosenbrock  $\approx 28\%$ , на Rosenbrock chained  $\approx 15\%$  — возмущение траектории под MS-коррекцией); на ECV оба метода сходятся устойчиво (47–50/50).

**Прямая иллюстрация теоремы 3.8, п. 3: динамика накопленной невязки на паре PSB / SS-PSB.** Convergence-кривые рис. 3 и 4 показывают итоговую долю сходимости и медианное число итераций, но оставляют открытым прямой вопрос: действительно ли MS-коррекция *ограничивает* накопленную невязку  $\|B_k S_p - Y_p\|_F$  в смысле теоремы 3.8, п. 3? Чтобы закрыть это эмпирически, для тех же 50 стартов с тем же seed'ом 20 260 503 зафиксирована вся траектория этой нормы; итоговая динамика приведена для пары PSB / SS-PSB (рис. 5; медиана жирной линией, заливка — межквартильный размах  $q_{25}-q_{75}$  по 50 стартам; расходящиеся траектории включены через rad-by-last).

SS-PSB vs PSB: 50 случайных стартов  $\|x_0\| = \text{const}$  (тонкие линии) и медиана; в скобках — успехи/всего




Рисунок 4 — SS-PSB vs PSB: те же пять конфигураций, что на рис. 3. Чистый PSB заметно деградирует на Extended Rosenbrock (21/50) при слабой деградации на Rosenbrock chained (46/50) и практически не сходится на ECV (0–6/50); SS-PSB обеспечивает устойчивую сходимости на всех конфигурациях (48–50/50) и на гладких задачах обходит PSB по медиане числа итераций. Иллюстрация того, что MS-коррекция способна спасать индефинитные базовые обновления с сильной деградацией. Расходящиеся и преждевременно сошедшиеся траектории включены в медиану через `rad-by-last` (заморозка на последнем наблюденном  $\|\nabla f\|$ ).

Пара PSB / SS-PSB выбрана как чистая иллюстрация по двум причинам. Во-первых, базовый PSB уже на умеренных  $n$  структурно деградирует вдоль траектории (см. рис. 4); это даёт MS-коррекции достаточно *материала* для работы и делает разрыв  $\|B_k S_p - Y_p\|_F$  визуально разрешимым. Во-вторых, для пары SR1 / SS-SR1 базовый SR1 на использованных режимах часто и без MS-коррекции удерживает  $\|B_k S_p - Y_p\|_F$  на приемлемом уровне (что отражает ограничение самой теоремы Th. 3.9: MS-коррекция нужна там, где SR1 *реально* деградирует, и не создаёт преимущества там, где уже не деградирует), так что прямая grast-картинка для этой пары читается хуже, чем косвенная сходимостная метрика рис. 3; пара оставлена иллюстрироваться через convergence на рис. 3.

Картина на рис. 5 согласуется со структурным предсказанием. На всех пяти конфигурациях SS-PSB системно держит медиану  $\|B_k S_p - Y_p\|_F$  ниже, чем PSB (с короткими переходными участками вблизи смены доминирующих секущих в окне  $S_p$ ); качественный разрыв особенно ясен на режиме ECV, где PSB теряет устойчивость, а SS-PSB в среднем снижает невязку и достигает уровней  $\sim 10^{-7}$  к концу бюджета итераций. Это прямая эмпирическая поддержка утверждения 3 теоремы 3.8: оценка  $\|R_{k+1}\|_F^2 \leq \|R'_k\|_F^2 - (u_k^{*\top} M'_k u_k^*)^2 / \|S_p^\top u_k^*\|^2$  выполнена по построению на каждом шаге; интегральный эффект — системно меньшая медиана  $\|B_k S_p - Y_p\|_F$  — наблюдается именно там, где базовое обновление действительно теряет устойчивость.

**Изолированная роль гипотезы (H4): эксперименты без Armijo.** Теорема 3.9 формулирует Q-сверхлинейность при условии (H4): после некоторого  $k_0$  глобализация выдаёт полный QN-шаг  $s_k = -B_k^{-1} \nabla f(x_k)$ . В основных экспериментах §3.6 (H4) обеспечивается backtracking-Армихо и отдельно не визуализирована. Чтобы изолировать её роль, повторим paired-дизайн (тот же seed 20 260 503, 50 стартов) с полным шагом  $x_{k+1} = x_k + d_k$  без backtracking, на двух типах задач: выпуклой квадратике, где (H4) выполнено тривиально, и Rosenbrock chained, где (H4) нетривиально.

*Квадратика*  $f(x) = \frac{1}{2} x^\top A x$ ,  $A = Q \operatorname{diag}(\lambda_1, \dots, \lambda_n) Q^\top$ ,  $Q \in O(n)$ ,  $\lambda_i = \kappa^{(i-1)/(n-1)}$  — логарифмически равномерный спектр с  $\lambda_1 = 1, \lambda_n = \kappa$  (так что  $\kappa(A) = \kappa$  при произвольном  $n$ , и устроена непустая малая часть спектра);  $x^* = 0$ ,  $\|x_0\| = R$ . На рис. 6 приведены два режима:  $(n = 20, \kappa = 10^3)$  — оба метода сходятся по медиане (PSB 41/50, SS-PSB 50/50), и  $(n = 50, \kappa = 10^2)$  — PSB *не* сходится ни у одного из 50 стартов за отведённый бюджет итераций, а SS-PSB сходится у 43/50. SR1-семейство из рисунка опущено: по замечанию 3.17 асимптотическая Q-сверхлинейная скорость SS совпадает с базовой, а на квадратике SR1 со skip-rule имеет конечную сходимость за  $\leq n + 1$  шагов [10], так что для SR1-пары MS-добавке нечего улучшать.

Картина одинакова для радиусов  $R \in [0.1, 3]$  (рисунок построен при  $R = 0.3$ ):

SS-PSB vs PSB: накопленная невязка прошлых секущих  $\|B_k S_p - Y_p\|_F$ . 50 стартов; медиана (жирная) и IQR (q25-q75, заливка)




Рисунок 5 — Накопленная невязка прошлых секущих  $\|B_k S_p - Y_p\|_F$  для пары PSB / SS-PSB на тех же пяти конфигурациях, что и рис. 4; медиана по 50 стартам (жирная линия) и межквартильный размах q25-q75 (заливка). Контраст резкий на всех режимах: SS-PSB системно держит медиану ниже, чем PSB. На ECV PSB теряет устойчивость — структурная причина отказа базового обновления, против которой и работает MS-коррекция. Прямая эмпирическая поддержка теоремы 3.8, п. 3.

на локальной выпуклой квадратике поведение определяется парой  $(n, \kappa)$ , не радиусом старта. На режиме  $(n = 20, \kappa = 10^3)$  SS-PSB видимо ускоряет пре-асимптотическую фазу PSB; на более крупной размерности  $(n = 50, \kappa = 10^2)$  — правая панель — PSB уже не достигает сходимости за бюджет итераций, тогда как SS-PSB сходится (и это даже при меньшей  $\kappa$ ). Это эмпирическая поддержка теоремы 3.9 в режиме, где (H4) выполнено тривиально: SS-коррекция *не* меняет асимптотическую скорость (замечание 3.17), но улучшает пре-асимптотический режим за счёт лучшего приближения  $\nabla^2 f(x^*)$  матрицей  $B_k$  на окне прошлых текущих и расширяет диапазон  $(n, \kappa)$ , в котором базовое обновление вообще достигает сходимости без line search.

Локальная сходимость без Armijo:  $f(x) = \frac{1}{2} x^\top A x$ ,  $\|x_0\| = 0.3$ , 50 стартов; медиана и межквартильный коридор




Рисунок 6 — Локальная сходимость без Armijo на выпуклой квадратике  $f(x) = \frac{1}{2} x^\top A x$ ,  $\|x_0\| = 0.3$ , 50 стартов; медиана  $\|\nabla f(x_k)\|$  и межквартильный коридор; расходящиеся траектории включены через rad-by-last (заморозка на последнем конечном значении). Слева  $(n = 20, \kappa = 10^3)$  — режим, где оба обновления сходятся по медиане (PSB 41/50, SS-PSB 50/50): SS-PSB укорачивает пре-асимптотическую фазу PSB в несколько раз (124 vs 300 итераций медианно у сошедшихся стартов). Справа  $(n = 50, \kappa = 10^2)$  — режим, где PSB не сходится ни у одного из 50 стартов за 400 итераций, а SS-PSB сходится у 43/50: расширение области устойчивого поведения. SR1-семейство опущено: на квадратике SR1 имеет конечную сходимость за  $\leq n + 1$  шагов [10], а SS-добавка по rate-invariance (замечание 3.17) её не улучшает.

*Rosenbrock chained*,  $n = 10$ ,  $x^* = \mathbf{1}$ , 50 стартов  $x_0 = x^* + R \cdot u$ ,  $u \in S^{n-1}$ , при разных радиусах  $R$ . На рис. 7 приведена доля сошедшихся стартов против  $R$ . PSB *не* сходится ни на одном из тестированных радиусов; SS-PSB сходится на существенной части стартов уже при умеренно малых  $R$ . SR1 и SS-SR1 показаны для контекста: обе кривые ведут себя практически одинаково (что согласуется с rate-invariance, зам. 3.17) и сходятся лишь в непосредственной окрестности  $R \lesssim 0.03$ , оставаясь существенно ниже SS-PSB во всём диапазоне — основной эффект MS-коррекции в этом эксперименте проявляется именно на паре PSB / SS-PSB. Картина прямо свидетельствует, что (H4) на невыпуклых задачах не дается даром: полный QN-шаг расходится даже из непосред-

ственной окрестности  $x^*$ , и без line search SS-коррекция *не* глобализует, а лишь расширяет локальную область устойчивой сходимости (особенно у PSB-семейства). Глобализация в теореме 3.9 — содержательное предположение, не факультативная инженерная деталь.




Рисунок 7 — Доля сошедшихся стартов (из 50) на Rosenbrock chained,  $n = 10$ ,  $x^* = 1$ , против радиуса  $R = \|x_0 - x^*\|$ , без backtracking-Армихо. PSB не сходится ни на одном из тестируемых радиусов; SS-PSB расширяет область устойчивой сходимости при умеренно малых  $R$ . Прямое визуальное подтверждение нетривиальности (Н4) на невыпуклых задачах.

**Резюме.** На SR1 и PSB SS-коррекция эмпирически подтверждает роль ограничителя накопленной невязки  $\|B_k S_p - Y_p\|_F$  (теорема 3.8, п. 3, и Лемма 3.12): на рис. 5 медиана  $\|B_k S_p - Y_p\|_F$  у SS-PSB системно ниже PSB, а на ECV  $n = 20$  PSB не сходится, тогда как SS-PSB в среднем снижает невязку. Эксперименты без backtracking (§3.6) подтверждают также нетривиальность гипотезы (Н4) Теоремы 3.9: на локально-выпуклой квадратике SS-PSB укорачивает пре-асимптотическую фазу PSB; на Rosenbrock chained полный QN-шаг расходится даже из окрестности  $x^*$ , и MS-коррекция расширяет лишь область устойчивости, не подменяя глобализацию. Дальнейшие направления — формальная глобализация и перенос на негладкий случай — обсуждаются в Заключение.



# Заключение

## Основные результаты работы

В работе развита единая точка зрения на квазиньютоновские обновления с памятью прошлых текущих условий и последовательно применена к задачам нелинейных систем и гладкой оптимизации. Ключевые результаты по главам перечислены ниже.

**Глава 1 (квазиньютоновские обновления).** Выведена общая формула семейства мультисекантных обновлений

$$B_{k+1} = \hat{B}_k + (Y_m - \hat{B}_k S_m) (V_m^\top S_m)^{-1} V_m^\top,$$

охарактеризующая все ранг- $m$  обновления якобиана, которые точно удовлетворяют заданному набору текущих условий. В качестве специализаций получены: классический Бroyден, «плохой» Бroyден, ускорение Андерсона и минимум по Фробениусу при  $m$  текущих условиях. Доказано, что ранг-1 обновление с  $v_k \notin S_p^\perp$  нарушает прошлые текущие условия, что мотивирует конструкцию следующих глав.

**Глава 2 (мультисекантный Бroyден).** Рассматривается мультисекантное обновление Бroyдена [31]

$$B_{k+1} = B_k + (Y_p - B_k S_p) G_p^{-1} S_p^\top, \quad G_p = S_p^\top S_p,$$

$S_p, Y_p$  — окно текущего и  $p$  прошлых текущих пар. Ранг-1 специализация под индуктивным инвариантом  $B_k s_j = y_j$  ( $j < k$ ) совпадает с Projected Broyden Гэя–Шнабеля [18] и используется в §2.2 для limited-memory варианта L-PB через формулу Шермана–Моррисона.

Основной результат главы — **теорема об ограниченной деградации с расширенным проектором** (2.10): точное равенство

$$\|E_{k+1}\|_F^2 = \|E_k\|_F^2 - \|E_k \Pi_k\|_F^2 + \Delta_k$$

с проектором  $\Pi_k$  ранга  $p+1$  на  $\text{col}(S_p)$  ( $y$  классического Бroyдена — ранга 1, на  $\text{span}(s_k)$ )

и явной геометрической константой  $C_{PB} = L(1 + C_s/2)\sqrt{p+1}\kappa_p$ , где  $\kappa_p = \kappa(S_p)$  — обусловленность окна шагов. У Гэя–Шнабеля для ранг-1 специализации оценка bounded deterioration установлена в виде неравенства сверху (Th. 4.2); здесь равенство с явной геометрической константой и переход к мультисекунной форме сделаны впервые. Доказано неравенство  $\|E_k \Pi_k\|_F^2 \geq \|E_k s_k\|^2 / \|s_k\|^2$ : отрицательный член снимает с матрицы ошибки *не меньше* информации, чем у классического Бройдена, и сохраняются  $p+1$  секующих условий  $B_{k+1}s_j = y_j$ ,  $j = k-p, \dots, k$ .

В качестве следствия установлена количественная  $O(\rho_k)$ -**аппроксимация якобиана на подпространстве прошлых шагов**  $\text{col}(S_p)$  (2.12) — структурное преимущество над классическим Бройденом, у которого аппроксимация контролируется лишь вдоль одномерного направления  $s_k$ .

На задаче Discrete BVP ( $n=100$ ) мультисекунный Бройден работает устойчиво там, где классический Бройден неустойчив или сходится медленнее. Limited-memory вариант L-PB при  $m \geq p_{\max} + 1$  устойчиво сходится на Broyden Banded при  $n \in \{10^4, 10^5\}$  за число итераций, не зависящее от  $n$ ; в этом режиме зазор с плотной формой умеренный и монотонно сокращается с ростом  $m$ , что отражает типичную для limited-memory методов картину (ср. L-BFGS).

**Глава 3 (SS-U и SS-SR1).** Воспроизведён классический результат Шнабеля [31] о несовместности точного сохранения  $p$  прошлых секующих условий с требованием симметрии (лемма 3.1): систему одновременно нельзя удовлетворить в общем положении. Предложено разрешение несовместности через конструкцию SS-U: симметричная ранг-1 коррекция  $\sigma_k^* u_k^* (u_k^*)^\top$  в ортогональном дополнении  $s_k^\perp$ , подавляющая накопленные невязки прошлых секующих условий. Установлены:

- точное выполнение текущего секующего условия и симметрия (3.8);
- монотонное убывание невязки в  $s_k^\perp$  по оптимальному направлению  $u_k^*$ ;
- bounded deterioration в композитной форме для SS-U под Lipschitz-непрерывным гессианом и входной Q-линейной сходимостью (Лемма 3.12);
- сверхлинейная сходимость по критерию Dennis–More (3.9);
- эмпирически наблюдаемая устойчивая сходимость на семействе Curved Valley (см. §3.6).

## Связь результатов

Главы работы связаны сквозной идеей: выбор направления обновления  $v_k$ , сохраняющий прошлые секующие условия, расширяет проектор bounded deterioration с ранга 1

до ранга  $p+1$ , что, в свою очередь, последовательно отражается на наблюдаемых и гарантированных свойствах итерационного процесса. В нелинейных системах (глава 2) это даёт усиленную оценку bounded deterioration с явной геометрической константой  $C_{PB} = L(1+C_s/2)\sqrt{p+1}\kappa_p$ , зависящей от обусловленности окна  $\kappa_p$ , а не от размерности  $n$ ; в оптимизации (глава 3) идея переносится через композитное обновление SS- $\mathcal{U}$  с bounded deterioration в форме Леммы 3.12 и условной Q-сверхлинейной сходимостью по Денниса–Море. Расширение проектора с ранга 1 (классический Бroyден) до ранга  $p+1$  (мультисекунный Бroyден) вместе с сохранением  $p+1$  секущих условий — содержательное уточнение классического анализа, дающее на каждой итерации строго не меньше информации об ошибке аппроксимации якобиана.

В литературе закрыты следующие пробелы: количественная форма bounded deterioration для общей мультисекунной формы Шнабеля [31] (у Гэя–Шнабеля [18] — только неравенство сверху для ранг-1 специализации); явная зависимость константы оценки от геометрии окна  $\kappa_p$ , не от  $n$  — основание для применимости в высокой размерности; перенос идеи сохранения прошлых секущих на симметричный случай через коррекцию в  $s_k^\perp$  с bounded deterioration в композитной форме (Лемма 3.12). Полученные количественные оценки ошибки  $\|B_k - J(x_k)\|$  входят константой в оценки скорости сходимости методов более высокого уровня, где аппроксимация якобиана используется как технический блок [15].

## Направления дальнейших исследований

- **Высокая размерность и limited memory.** L-PB-вариант (§2.2), построенный на ранг-1 специализации с Шерманом–Моррисоном, проверен на Broyden Banded при  $n \in \{10^4, 10^5\}$ . Дальнейшее направление — сравнение с L-BFGS и preconditioned Anderson на расширенном тестовом наборе.
- **Обобщение SS-U на не гладкие задачи.** Построить негладкий аналог SS-U (proximal-SS-U) для композитных задач  $\min f(x) + g(x)$  и исследовать его скорость на задачах с разреженной регуляризацией.
- **Практическая валидация на прикладных задачах.** Применить мультисекунный Бroyден к задачам обучения (нелинейные системы, возникающие в физически-информированных нейронных сетях), а также к равновесным моделям из экономики.
- **Глобализация и сравнение стратегий шага.** Формальный анализ глобализации мультисекунного Бroyдена и SS- $\mathcal{U}$  (backtracking-Армихо, условия Вольфа, trust-region-модификации) и систематическое численное сравнение этих стратегий на широком

тестовом наборе Moré–Garbow–Hillstom — естественное продолжение локальной теории, развитой в гл. 2 и гл. 3.

- **Корректная реализация и сравнение с современным Anderson.** Переделать реализацию Anderson-acceleration из [35] с релаксацией и мультисекантной подгонкой в  $L^2$ -норме и провести честное сравнение с мультисекантным Бройденом на всём тестовом наборе Broyden.

## Список использованных источников

- [1] Anderson, D. G. Iterative procedures for nonlinear integral equations [Text] // [Journal of the ACM](#). — 1965. — Vol. 12, no. 4. — P. 547–560.
- [2] Armijo, L. Minimization of functions having Lipschitz continuous first partial derivatives [Text] // [Pacific Journal of Mathematics](#). — 1966. — Vol. 16, no. 1. — P. 1–3.
- [3] Boutet, N. A symmetric grouped and ordered multi-secant quasi-Newton update formula [Text] / Boutet, N., Degroote, J., and Haelterman, R. // [Optimization Methods and Software](#). — 2022. — Vol. 37, no. 6. — P. 1965–1986.
- [4] Boutet, N. Secant update version of quasi-Newton PSB with weighted multisecant equations [Text] / Boutet, N., Haelterman, R., and Degroote, J. // [Computational Optimization and Applications](#). — 2020. — Vol. 75, no. 2. — P. 441–466.
- [5] Boutet, N. Secant Update generalized version of PSB: a new approach [Text] / Boutet, N., Haelterman, R., and Degroote, J. // [Computational Optimization and Applications](#). — 2021. — Vol. 78, no. 3. — P. 953–982.
- [6] Broyden, C. G. A class of methods for solving nonlinear simultaneous equations [Text] // [Mathematics of Computation](#). — 1965. — Vol. 19, no. 92. — P. 577–593.
- [7] Broyden, C. G. On the local and superlinear convergence of quasi-Newton methods [Text] / Broyden, C. G., Dennis, J. E., and Moré, J. J. // [Journal of the Institute of Mathematics and its Applications](#). — 1973. — Vol. 12, no. 3. — P. 223–245.
- [8] Burdakov, O. Multipoint secant and interpolation methods with nonmonotone line search for solving systems of nonlinear equations [Text] / Burdakov, O. and Kamandi, A. // [Applied Mathematics and Computation](#). — 2018. — Vol. 338. — P. 421–431.
- [9] Byrd, R. H. Representations of quasi-Newton matrices and their use in limited memory methods [Text] / Byrd, R. H., Nocedal, J., and Schnabel, R. B. // [Mathematical Programming](#). — 1994. — Vol. 63, no. 1–3. — P. 129–156.

- [10] Conn, A. R. Convergence of quasi-Newton matrices generated by the symmetric rank one update [Text] / Conn, A. R., Gould, N. I. M., and Toint, Ph. L. // **Mathematical Programming**. — 1991. — Vol. 50, no. 1–3. — P. 177–195.
- [11] Davidon, W. C. Variable metric method for minimization [Text] // **SIAM Journal on Optimization**. — 1991. — Vol. 1, no. 1. — P. 1–17. — Originally: AEC Research and Development Report ANL-5990, Argonne National Laboratory, 1959.
- [12] Dennis, J. E. A characterization of superlinear convergence and its application to quasi-Newton methods [Text] / Dennis, J. E. and Moré, J. J. // **Mathematics of Computation**. — 1974. — Vol. 28, no. 126. — P. 549–560.
- [13] Dennis, J. E. Quasi-Newton methods, motivation and theory [Text] / Dennis, J. E. and Moré, J. J. // **SIAM Review**. — 1977. — Vol. 19, no. 1. — P. 46–89.
- [14] Dennis, J. E. **Numerical Methods for Unconstrained Optimization and Nonlinear Equations** [Text] / Dennis, J. E. and Schnabel, R. B. — Philadelphia : SIAM, 1996.
- [15] Exploring Jacobian inexactness in second-order methods for variational inequalities: lower bounds, optimal algorithms and quasi-Newton approximations [Text] / Agafonov, A., Kamzolov, D., Gasnikov, A., Antonakopoulos, K., Cevher, V., and Takáč, M. // arXiv preprint. — 2024. — Vol. arXiv:2405.15990. — Access mode: <https://arxiv.org/abs/2405.15990>.
- [16] Fang, H.-R. Two classes of multisection methods for nonlinear acceleration [Text] / Fang, H.-R. and Saad, Y. // **Numerical Linear Algebra with Applications**. — 2009. — Vol. 16, no. 3. — P. 197–221.
- [17] Gay, D. M. Some convergence properties of Broyden’s method [Text] // **SIAM Journal on Numerical Analysis**. — 1979. — Vol. 16, no. 4. — P. 623–630.
- [18] Gay, D. M. Solving systems of nonlinear equations by Broyden’s method with projected updates [Text] / Gay, D. M. and Schnabel, R. B. // **Nonlinear Programming 3** / ed. by Mangasarian, O. L., Meyer, R. R., Robinson, S. M. — New York : Academic Press, 1978. — P. 245–281.
- [19] Generalization of quasi-Newton methods: application to robust symmetric multisection updates [Text] / Scieur, D., Liu, L., Pumi, T., and Boumal, N. // **Proceedings of the 24th International Conference on Artificial Intelligence and Statistics (AISTATS)** / ed. by Banerjee, A., Fukumizu, K. — [S. l.] : PMLR. — 2021. — Vol. 130 of **Proceedings of Machine Learning Research**. — P. 550–558. — Access mode: <https://proceedings.mlr.press/v130/scieur21a.html>.

- [20] Golub, G. H. Matrix Computations [Text] / Golub, G. H. and Van Loan, C. F. — 4 ed. — Baltimore : Johns Hopkins University Press, 2013. — ISBN: 978-1-4214-0794-4. — Access mode: <https://jhupbooks.press.jhu.edu/title/matrix-computations>.
- [21] Gratton, S. Quasi-Newton updates with weighted secant equations [Text] / Gratton, S., Malmedy, V., and Toint, Ph. L. // [Optimization Methods and Software](#). — 2015. — Vol. 30, no. 4. — P. 748–755.
- [22] Liu, D. C. On the limited memory BFGS method for large scale optimization [Text] / Liu, D. C. and Nocedal, J. // [Mathematical Programming](#). — 1989. — Vol. 45, no. 1–3. — P. 503–528.
- [23] Marquardt, D. W. An algorithm for least-squares estimation of nonlinear parameters [Text] // [Journal of the Society for Industrial and Applied Mathematics](#). — 1963. — Vol. 11, no. 2. — P. 431–441.
- [24] Moré, J. J. Testing unconstrained optimization software [Text] / Moré, J. J., Garbow, B. S., and Hillstom, K. E. // [ACM Transactions on Mathematical Software](#). — 1981. — Vol. 7, no. 1. — P. 17–41.
- [25] Nocedal, J. Updating quasi-Newton matrices with limited storage [Text] // [Mathematics of Computation](#). — 1980. — Vol. 35, no. 151. — P. 773–782.
- [26] Nocedal, J. [Numerical Optimization](#) [Text] / Nocedal, J. and Wright, S. J. — 2 ed. — New York : Springer, 2006.
- [27] On an eigenvector-dependent nonlinear eigenvalue problem [Text] / Cai, Y., Zhang, L.-H., Bai, Z., and Li, R.-C. // [SIAM Journal on Matrix Analysis and Applications](#). — 2018. — Vol. 39, no. 3. — P. 1360–1382.
- [28] Parlett, B. N. [The Symmetric Eigenvalue Problem](#) [Text]. — Philadelphia : SIAM, 1998. — Vol. 20 of Classics in Applied Mathematics.
- [29] Powell, M. J. D. [A new algorithm for unconstrained optimization](#) [Text] // Nonlinear Programming / ed. by Rosen, J. B., Mangasarian, O. L., Ritter, K. — New York : Academic Press, 1970. — P. 31–65.
- [30] Powell, M. J. D. On the convergence of the variable metric algorithm [Text] // [Journal of the Institute of Mathematics and its Applications](#). — 1971. — Vol. 7, no. 1. — P. 21–36.
- [31] Quasi-Newton Methods Using Multiple Secant Equations [Text] : Rep. : CU-CS-247-83 / Department of Computer Science, University of Colorado at Boulder ; executor: Schnabel, R. B. : 1983.

- [32] Schubert, L. K. Modification of a quasi-Newton method for nonlinear equations with a sparse Jacobian [Text] // [Mathematics of Computation](#). — 1970. — Vol. 24, no. 109. — P. 27–30.
- [33] Shanno, D. F. Matrix conditioning and nonlinear optimization [Text] / Shanno, D. F. and Phua, K. H. // [Mathematical Programming](#). — 1978. — Vol. 14, no. 1. — P. 149–160.
- [34] Toth, A. Convergence analysis for Anderson acceleration [Text] / Toth, A. and Kelley, C. T. // [SIAM Journal on Numerical Analysis](#). — 2015. — Vol. 53, no. 2. — P. 805–819.
- [35] Walker, H. F. Anderson acceleration for fixed-point iterations [Text] / Walker, H. F. and Ni, P. // [SIAM Journal on Numerical Analysis](#). — 2011. — Vol. 49, no. 4. — P. 1715–1735.
- [36] Wolfe, P. Convergence conditions for ascent methods [Text] // [SIAM Review](#). — 1969. — Vol. 11, no. 2. — P. 226–235.
- [37] Zoutendijk, G. Nonlinear programming, computational methods [Text] // Integer and Nonlinear Programming / ed. by Abadie, J. — Amsterdam : North-Holland, 1970. — P. 37–86. — Access mode: <https://www.sciencedirect.com/book/9780720420845>.